




估计与检测课程笔记

Notes on Estimation and Detection

作者：StayAtHome@bilibili

时间：2026 年 7 月 22 日

版本：v1.0

讲师：Barry Van Veen 教授

参考资料、版本更迭与声明

参考资料

本笔记主要参考视频课程 [Estimation and Detection Theory](#)。

版本更迭

- v1.0 根据手写笔记和视频字幕内容组合而成，完成于 2026-07-22。

声明

本笔记仅用于学习交流之用。

目录

参考资料、版本更迭与声明	I
第一章 估计理论导论	1
1.1 参数估计问题	1
1.2 估计质量的基本指标	2
1.3 小结	3
1.4 本讲 MATLAB 代码	4
第二章 参数化与非参数化功率谱估计	6
2.1 功率谱及谱估计任务	6
2.2 非参数化谱估计	6
2.3 参数化谱估计	6
2.4 参数法与非参数法的取舍	7
2.5 小结	8
第三章 周期图	9
3.1 由样本自相关到周期图	9
3.2 窗函数与修正周期图	9
3.3 周期图的均值：有限长度偏差	10
3.4 周期图的方差与不一致性	10
3.5 单位与常用归一化	11
3.6 小结	12
3.7 本讲 MATLAB 代码	12
第四章 平均周期图：Welch 方法	14
4.1 从周期图到平均周期图	14
4.2 Welch 方法的构造	14
4.3 性能：方差、偏差与参数权衡	15
4.4 小结	16
4.5 本讲 MATLAB 代码	16
第五章 Welch 方法的 MATLAB 实验	17
5.1 仿真实验对象	17
5.2 pwelch 的参数和归一化	18
5.3 平均、重叠和偏差	18
5.4 小结	21
5.5 本讲 MATLAB 代码	21
第六章 互谱相干性与交叉谱估计	25
6.1 交叉谱与相干性	25
6.2 为什么不能直接代入周期图	25

6.3 Welch 型 MSC 估计	26
6.4 MATLAB 中的 mscohere 仿真	26
6.5 小结	29
6.6 本讲 MATLAB 代码	29
第七章 参数估计准则：最大似然与贝叶斯方法	32
7.1 参数估计问题	32
7.2 最大似然估计	32
7.3 贝叶斯估计	33
7.4 常见贝叶斯估计器	33
7.5 两类准则的取舍	34
7.6 小结	34
第八章 最大似然估计的典型例子	35
8.1 最大似然估计的计算流程	35
8.2 高斯样本模型	35
8.3 线性信号模型	36
8.4 泊松计数模型	37
8.5 小结	37
第九章 检测理论与假设检验入门	38
9.1 检测问题与假设	38
9.2 简单假设与复合假设	38
9.3 判决区域	39
9.4 二元检测的性能指标	39
9.5 阈值、密度重叠与权衡	40
9.6 ROC 曲线	40
9.7 小结	41
第十章 似然比检验	42
10.1 简单假设下的最优检验	42
10.2 已知信号的高斯噪声检测	42
10.3 本讲 MATLAB 代码	44
10.4 小结	46
第十一章 广义似然比检验	47
11.1 从简单假设到复合假设	47
11.2 GLRT 的定义	47
11.3 已知形状信号的 GLRT	48
11.4 本讲 MATLAB 代码	49
11.5 小结	51

第一章 估计理论导论

本讲要点

本讲建立参数估计的基本框架：观测数据的概率分布依赖未知参数，估计量是数据的函数。随后用偏差、协方差与均方误差衡量估计质量，并以三个独立高斯样本的均值和方差估计为例，说明“无偏”与“低方差”的含义。

1.1 参数估计问题

设观测向量为

$$\mathbf{X} = [X_0, X_1, \dots, X_{N-1}]^T,$$

其概率密度或概率质量函数依赖未知参数向量 $\alpha \in \mathbb{R}^p$ ：

$$f_{\mathbf{X}}(\mathbf{x}; \alpha). \quad (1.1)$$

参数估计的任务，是在观测到 $\mathbf{X} = \mathbf{x}$ 后，由某个确定性映射 $g(\cdot)$ 构造

$$\hat{\alpha} = g(\mathbf{X}). \quad (1.2)$$

其中带“帽”的量表示估计值。由于 $\mathbf{X}$ 是随机的，估计量 $\hat{\alpha}$ 本身也是随机向量；因此，评价估计器的核心问题是：它的概率分布在真实参数 α 附近有多集中。

估计器与估计值

估计器是随机数据的函数 $g(\mathbf{X})$ ；将一组具体数据代入后得到的数值称为估计值。同一估计器在重复实验中会给出不同估计值。

例：多普勒雷达测速

这个例子用一个具体的物理测量任务说明“参数估计”在做什么：真实速度 v 不能直接从接收信号中读出，先要从含噪回波里估计多普勒频移 f_d ，再由雷达测速关系换算出速度。

雷达以已知载频 f_0 发射电磁波，运动目标使回波产生多普勒频移 f_d 。从接收数据中估计 f_d ，便可进一步推断目标速度 v 。单站雷达、目标沿径向运动时，常用关系为

$$f_d = \frac{2v}{c} f_0, \quad v = \frac{c}{2f_0} f_d, \quad (1.3)$$

其中 c 为传播速度。课堂采用的离散时间观测模型可写成

$$x[n] = A \cos(2\pi f_d n + \phi) + w[n], \quad n = 0, 1, \dots, N-1, \quad (1.4)$$

其中 A 、 ϕ 以及噪声 $w[n]$ 会增加估计难度。频率估计器具有一般形式

$$\hat{f}_d = g(x[0], x[1], \dots, x[N-1]).$$




图 1.1: 多普勒雷达测速示意: 已知发射频率 f_0 , 从回波估计频移 f_d , 进而估计速度 v 。

1.2 估计质量的基本指标

1.2.1 偏差与无偏性

估计量的偏差定义为

$$\mathbf{b}(\hat{\alpha}) = \mathbb{E}[\hat{\alpha}] - \alpha. \quad (1.5)$$

若对所有允许的 α 都有 $\mathbf{b}(\hat{\alpha}) = \mathbf{0}$, 则称其为无偏估计器。无偏只约束重复实验的平均位置, 并不保证单次误差很小。

1.2.2 协方差矩阵

估计量围绕自身均值的离散程度由协方差矩阵刻画:

$$\mathbf{C}_{\hat{\alpha}} = \mathbb{E}[(\hat{\alpha} - \mathbb{E}[\hat{\alpha}])(\hat{\alpha} - \mathbb{E}[\hat{\alpha}])^T]. \quad (1.6)$$

其第 i 个对角元素是 $\hat{\alpha}_i$ 的方差, 非对角元素反映不同参数估计误差之间的相关性。理想情况下, 协方差矩阵应当“小”, 例如对角元素较小。

1.2.3 均方误差及偏差-方差分解

标量参数 α_i 的均方误差为

$$\text{MSE}(\hat{\alpha}_i) = \mathbb{E}[(\hat{\alpha}_i - \alpha_i)^2] = \text{Var}(\hat{\alpha}_i) + \text{bias}^2(\hat{\alpha}_i). \quad (1.7)$$

因此, 无偏估计器的均方误差等于其方差; 有偏估计器若能显著降低方差, 也可能获得更小的总均方误差。向量形式为

$$\mathbf{M}_{\hat{\alpha}} = \mathbb{E}[(\hat{\alpha} - \alpha)(\hat{\alpha} - \alpha)^T] = \mathbf{C}_{\hat{\alpha}} + \mathbf{b}(\hat{\alpha})\mathbf{b}^T(\hat{\alpha}). \quad (1.8)$$

评价估计器时的两个维度

偏差描述估计分布中心相对真值的系统性偏移; 方差描述估计结果在重复实验间的随机波动。只报告其中一个指标通常不足以说明估计质量。

例: 高斯样本的均值与方差估计

这个例子用三个高斯样本比较三种常见估计量: 样本均值、分母为 n 的方差估计、分母为 $n-1$ 的方差估计。它的作用是把“无偏”“有偏”和“随机波动”从公式落实到可观察的 Monte Carlo 分布上。

设

$$X_1, X_2, X_3 \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2). \quad (1.9)$$

目标是用三个样本估计 μ 和 σ^2 。

样本均值。样本均值估计器为

$$\hat{\mu} = \bar{X} = \frac{1}{3}(X_1 + X_2 + X_3). \quad (1.10)$$

利用线性期望和独立性，

$$\mathbb{E}[\bar{X}] = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{3}. \quad (1.11)$$

所以样本均值无偏，并且增加样本数可使方差按 $1/n$ 衰减。

分母为 n 的方差估计器。对一般样本数 n ，定义

$$\hat{\sigma}_b^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (1.12)$$

由于估计均值消耗了一个自由度，


$$\mathbb{E}[\hat{\sigma}_b^2] = \frac{n-1}{n} \sigma^2. \quad (1.13)$$

当 $n = 3$ 且 $\sigma^2 = 1$ 时，理论均值为 $2/3$ ，因此该估计器向下偏。

分母为 $n - 1$ 的无偏方差估计器。贝塞尔校正给出

$$\hat{\sigma}_u^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \mathbb{E}[\hat{\sigma}_u^2] = \sigma^2. \quad (1.14)$$

对三个样本，分母由 3 改为 2。这消除了均值上的系统偏差，但估计分布仍可能很宽；无偏并不等于低方差。



(a) 样本均值

(b) 分母为 n

(c) 分母为 $n - 1$

图 1.2: 三个估计量的 Monte Carlo 直方图。红线表示真实均值或真实方差；黑虚线表示分母为 n 的方差估计器理论均值 $2/3$ 。

Monte Carlo 现象。取 $\mu = 1$ 、 $\sigma^2 = 1$ 、 $n = 3$ ，重复实验 2000 次。样本均值的经验均值接近 1；分母为 3 的方差估计经验均值接近 $2/3$ ；分母为 2 的方差估计经验均值接近 1。直方图同时表明：小样本下方差估计具有明显随机波动。

1.3 小结

本讲的逻辑链条是

概率模型 $\rightarrow$ 估计器 $\rightarrow$ 估计分布 $\rightarrow$ 偏差、协方差与 MSE。

后续讲次将把这些评价准则用于功率谱估计：既考察估计谱的平均形状，也考察其方差是否随数据长度增加而消失。

1.4 本讲 MATLAB 代码

以下脚本生成样本均值、有偏方差和无偏方差估计器的 Monte Carlo 直方图，并输出理论值与仿真值的比较。

```

1  clear; clc; close all;
2  mu = 1; sigma2 = 1; sigma = sqrt(sigma2); n = 3; numMC = 2000;
3  rng(1);
4
5  X = mu + sigma .* randn(numMC, n);
6  estimatedMean = mean(X, 2);
7  squaredDeviationSum = sum((X - estimatedMean).^2, 2);
8  biasedVariance = squaredDeviationSum ./ n;
9  unbiasedVariance = squaredDeviationSum ./ (n - 1);
10
11 theoreticalMeanOfMean = mu;
12 theoreticalVarOfMean = sigma2 / n;
13 theoreticalMeanBiasedVariance = (n - 1) / n * sigma2;
14 theoreticalMeanUnbiasedVariance = sigma2;
15
16 makeHistogram(estimatedMean, -2:0.1:4, mu, [], 'Sample Mean Estimator', ...
17     'Estimated Mean', [-2, 4], 'fig2.1_sample_mean_estimator.pdf');
18 makeHistogram(biasedVariance, 0:0.1:5, sigma2, theoreticalMeanBiasedVariance, ...
19     'Biased Variance Estimator', 'Estimated Variance', [0, 5], ...
20     'fig2.2_biased_variance_estimator.pdf');
21 makeHistogram(unbiasedVariance, 0:0.1:5, sigma2, [], ...
22     'Unbiased Variance Estimator', 'Estimated Variance', [0, 5], ...
23     'fig2.3_unbiased_variance_estimator.pdf');
24
25 fprintf('\nMonte Carlo trials: %d\n', numMC);
26 fprintf('Sample size per trial: %d\n\n', n);
27 fprintf('Sample mean estimator:\n');
28 fprintf('  Simulated mean      = %.6f\n', mean(estimatedMean));
29 fprintf('  Theoretical mean      = %.6f\n', theoreticalMeanOfMean);
30 fprintf('  Simulated variance     = %.6f\n', var(estimatedMean, 1));
31 fprintf('  Theoretical variance   = %.6f\n\n', theoreticalVarOfMean);
32 fprintf('Biased variance estimator, denominator n:\n');
33 fprintf('  Simulated mean        = %.6f\n', mean(biasedVariance));
34 fprintf('  Theoretical mean       = %.6f\n\n', theoreticalMeanBiasedVariance);
35 fprintf('Unbiased variance estimator, denominator n-1:\n');
36 fprintf('  Simulated mean         = %.6f\n', mean(unbiasedVariance));
37 fprintf('  Theoretical mean       = %.6f\n\n', theoreticalMeanUnbiasedVariance);
38 fprintf('Vector PDF files generated successfully.\n');
39
40 function makeHistogram(data, edges, redLine, blackLine, titleText, xText, limits, fileName)
41     fig = figure();
42     histogram(data, edges, 'FaceColor', [0.10, 0.12, 0.45], ...
43         'EdgeColor', [0.10, 0.12, 0.45]);
44     hold on; xline(redLine, 'r-', 'LineWidth', 1.8);
45     if ~isempty(blackLine), xline(blackLine, 'k--', 'LineWidth', 1.5); end
46     hold off; title(titleText, 'FontSize', 16);
47     xlabel(xText, 'FontSize', 14); ylabel('Number of Cases', 'FontSize', 14);
48     xlim(limits); box on; set(gca, 'FontSize', 12, 'LineWidth', 1);

```



```
49     exportVectorPDF(fig, fileName);
50 end
51
52 function exportVectorPDF(fig, fileName)
53     try
54         exportgraphics(fig, fileName, 'ContentType', 'vector');
55     catch
56         set(fig, 'Renderer', 'painters');
57         print(fig, fileName, '-dpdf', '-painters', '-bestfit');
58     end
59 end
```

第二章 参数化与非参数化功率谱估计

本讲要点

功率谱描述随机时间序列的功率如何随频率分布。谱估计方法分为非参数化方法与参数化方法：前者直接从数据的傅里叶结构出发，模型假设少；后者先假定数据生成模型，再估计模型参数。模型正确时，参数法通常能以更少数据获得更高分辨率；模型错误时则可能产生严重偏差。

2.1 功率谱及谱估计任务

对宽平稳离散时间随机过程 $x[n]$ ，自相关序列为

$$r_{xx}[k] = \mathbb{E}[x[n]x^*[n-k]]. \quad (2.1)$$

功率谱密度是自相关序列的离散时间傅里叶变换：

$$S_{xx}(e^{j\omega}) = \sum_{k=-\infty}^{\infty} r_{xx}[k]e^{-j\omega k}. \quad (2.2)$$

它把总平均功率分解到各个频率上；在适当归一化下，谱在一个基本频率区间上的积分等于信号平均功率。

实际中只拥有有限长度数据 $x[0], \dots, x[L-1]$ ，目标是由这些样本构造 $\hat{S}_{xx}(e^{j\omega})$ 。

2.2 非参数化谱估计

非参数化方法不规定生成数据的有限维模型，通常直接利用 DFT 或样本自相关。其特点是：

- 模型失配风险较低，适用于先验结构不明确的场景；
- 频率分辨率与方差主要由数据长度、窗函数及平均策略决定；
- 典型方法包括周期图、修正周期图以及后续的分段平均方法。

第 3 讲将详细推导周期图。

2.3 参数化谱估计

参数化方法假设数据由一个参数向量 θ 控制的模型产生。一般流程为

$$x[n] \longrightarrow \hat{\theta} \longrightarrow \hat{S}_{xx}(e^{j\omega}; \hat{\theta}). \quad (2.3)$$

也就是说，先估计模型参数，再将参数代入模型的解析谱表达式。

2.3.1 白噪声通过 LTI 系统

设白噪声 $w[n]$ 的方差为 σ_w^2 ，通过频率响应为 $H(e^{j\omega})$ 的稳定 LTI 系统后得到 $x[n]$ 。则

$$S_{xx}(e^{j\omega}) = S_{ww}(e^{j\omega}) |H(e^{j\omega})|^2 = \sigma_w^2 |H(e^{j\omega})|^2. \quad (2.4)$$

因此，只要估计噪声方差和系统参数，即可得到谱估计。

2.3.2 AR、MA 与 ARMA 模型

常见线性随机模型可统一写成

$$A(z)X(z) = B(z)W(z), \quad H(z) = \frac{B(z)}{A(z)}. \quad (2.5)$$

三类模型的区别如下：相应功率谱统一为

表 2.1: 常见参数化随机过程模型

模型	系统结构	典型特征
AR(p)	全极点, $B(z) = 1$	适合描述共振峰或窄带峰值；参数为反馈系数与噪声方差。
MA(q)	全零点, $A(z) = 1$	适合有限记忆的成形过程；参数为前向系数与噪声方差。
ARMA(p, q)	同时含极点和零点	表达能力更强，但参数估计与阶数选择更复杂。

$$S_{xx}(e^{j\omega}) = \sigma_w^2 \frac{|B(e^{j\omega})|^2}{|A(e^{j\omega})|^2}. \quad (2.6)$$

2.3.3 正弦叠加白噪声模型

课堂给出的另一类模型是

$$x[n] = \sum_{i=1}^K A_i e^{j\omega_i n} + w[n], \quad (2.7)$$

其中正弦频率 ω_i 、各分量功率以及背景白噪声功率均未知。在采用随机复幅度并按课堂约定书写时，谱可表示为

$$S_{xx}(\omega) = \sum_{i=1}^K \sigma_i^2 \delta(\omega - \omega_i) + \sigma_w^2. \quad (2.8)$$

若 $x[n]$ 为实信号，每个非零频率谱线通常还伴随位于 $-\omega_i$ 的共轭对称谱线。

2.4 参数法与非参数法的取舍

表 2.2: 两类谱估计方法的比较

维度	非参数化方法	参数化方法
先验假设	少，主要依赖平稳性与有限数据	强，需要指定模型族和阶数
数据效率	通常需要较长数据或平均处理	模型正确时可用较少数据
分辨率	受数据窗长度和窗函数限制	模型正确时可获得高分辨率
鲁棒性	对模型未知更安全	对模型失配敏感
主要风险	方差较大、谱泄漏、分辨率有限	产生错误或误导性的谱峰与谱形

关键判断

参数法的优势来自“额外结构信息”。若结构信息正确，它等价于有效利用先验知识；若结构信息错误，估计器会把数据强行解释成错误模型。选择方法时，应首先判断物理机制是否足以支持所假设的模型。

2.5 小结

非参数化谱估计直接处理有限数据，较少依赖模型；参数化谱估计把问题转化为有限维参数估计。后者并非天然优于前者，其性能依赖模型正确性。下一讲讨论最基本的非参数化估计器——周期图，并用偏差、方差和一致性评价其统计性质。

第三章 周期图

本讲要点

周期图将有限数据的 DFT 幅度平方作为功率谱估计。它随数据长度增加而渐近无偏，但方差一般不会趋于零，因此不是一致估计器。本讲推导其表达式，给出窗函数推广、均值与方差性质，并说明离散角频率和赫兹频率下的常用归一化。

3.1 由样本自相关到周期图

功率谱与自相关互为 DTFT。对长度为 L 的数据，先构造带 $1/L$ 归一化的样本自相关

$$\hat{r}_{xx}^{(b)}[k] = \frac{1}{L} \sum_{n=0}^{L-1-k} x[n]x^*[n-k], \quad (3.1)$$

并约定区间外的样本为零。对 k 作 DTFT:

$$\begin{aligned} \hat{S}_{xx}^{\text{per}}(e^{j\omega}) &= \sum_{k=-\infty}^{\infty} \hat{r}_{xx}^{(b)}[k] e^{-j\omega k} \\ &= \frac{1}{L} \sum_k \sum_n x[n] x^*[n-k] e^{-j\omega k} \\ &= \frac{1}{L} \left(\sum_n x[n] e^{-j\omega n} \right) \left(\sum_\ell x[\ell] e^{-j\omega \ell} \right)^* \\ &= \frac{1}{L} |X_L(e^{j\omega})|^2, \end{aligned} \quad (3.2)$$

其中

$$X_L(e^{j\omega}) = \sum_{n=0}^{L-1} x[n] e^{-j\omega n}. \quad (3.3)$$

式 (3.2) 就是矩形数据窗下的周期图。

若计算 N 点 DFT

$$X[k] = \sum_{n=0}^{L-1} x[n] e^{-j2\pi kn/N}, \quad k = 0, \dots, N-1, \quad (3.4)$$

则在离散频率格点上

$$\hat{S}_{xx}^{\text{per}}[k] = \frac{1}{L} |X[k]|^2. \quad (3.5)$$

允许 $N > L$ ；这相当于在时域补零，使频率曲线采样更密，但不增加由实际观测长度 L 决定的本征分辨率。

3.2 窗函数与修正周期图

先对数据加窗:

$$x_w[n] = w[n]x[n], \quad 0 \leq n \leq L-1, \quad (3.6)$$

再计算 $X_w(e^{j\omega})$ 。定义窗功率归一化因子

$$F = \frac{1}{L} \sum_{n=0}^{L-1} |w[n]|^2. \quad (3.7)$$

修正周期图为

$$\hat{S}_{xx}^{\text{mod}}(e^{j\omega}) = \frac{1}{LF} |X_w(e^{j\omega})|^2 = \frac{|X_w(e^{j\omega})|^2}{\sum_{n=0}^{L-1} |w[n]|^2}. \quad (3.8)$$

矩形窗 $w[n] = 1$ 时 $F = 1$ ，退化为普通周期图；其他窗对应修正周期图。窗函数控制主瓣宽度与旁瓣水平，因此形成分辨率与谱泄漏之间的权衡。

3.3 周期图的均值：有限长度偏差

令

$$W(e^{j\omega}) = \sum_{n=0}^{L-1} w[n] e^{-j\omega n}, \quad C_{ww}(e^{j\omega}) = |W(e^{j\omega})|^2. \quad (3.9)$$

在宽平稳条件下，修正周期图的期望可写为

$$\mathbb{E}[\hat{S}_{xx}^{\text{mod}}(e^{j\omega})] = \frac{1}{2\pi LF} \int_{-\pi}^{\pi} S_{xx}(e^{j\theta}) C_{ww}(e^{j(\omega-\theta)}) d\theta. \quad (3.10)$$

这说明估计谱的平均值是真实谱与谱窗的周期卷积。有限长度下，谱窗会平滑并扭曲真实谱，形成偏差；随着矩形窗长度增加，谱窗主瓣在零频附近越来越集中，于是

$$\mathbb{E}[\hat{S}_{xx}^{\text{per}}(e^{j\omega})] \longrightarrow S_{xx}(e^{j\omega}), \quad L \rightarrow \infty. \quad (3.11)$$

因此周期图是渐近无偏的。

3.4 周期图的方差与不一致性

在常见的大样本与高斯近似条件下，周期图在固定频率处的方差与真实谱平方同阶：

$$\text{Var}[\hat{S}_{xx}^{\text{per}}(e^{j\omega})] \approx S_{xx}^2(e^{j\omega}). \quad (3.12)$$

关键是右端并不随 L 衰减至零。虽然增加数据长度可减小偏差并改善频率分辨率，单次周期图曲线仍会强烈起伏。

一致估计器

若当样本数趋于无穷时，估计器依概率收敛到真值，则称其为一致估计器。常见的充分直观条件是：偏差趋于零且方差趋于零。周期图满足前者，却一般不满足后者，因而不是一致谱估计器。

仿真：数据长度对周期图的影响


这个仿真用一个 MA(1) 随机过程说明周期图的两个典型现象：数据长度 L 增大后频率分辨率会改善，但单次周期图仍然有很强的随机起伏，因此不能只凭“曲线采样更密”判断估计已经稳定。配套脚本生成过程

$$x[n] = 0.5w[n] + 0.5w[n-1], \quad w[n] \sim \mathcal{N}(0, 1), \quad (3.13)$$

其真实功率谱为

$$\begin{aligned} S_{xx}(e^{j\omega}) &= |0.5 + 0.5e^{-j\omega}|^2 \\ &= 0.5(1 + \cos \omega). \end{aligned} \quad (3.14)$$

每个数据长度绘制三次独立试验，红线为真实谱，蓝线为周期图。



(a) $L = 64$

(b) $L = 256$

(c) $L = 1024$

图 3.1: 数据长度对周期图的影响：随着 L 增大，频率采样与分辨率提高，但单次周期图曲线仍不会收敛为平滑真谱。

从三组图可观察到两个不同效应：

1. 随 L 增大，谱窗变窄，偏差与分辨率问题得到改善；
2. 低频处真实谱较大，周期图方差也较大；接近真实谱零点时，波动相应减小。这与式 (3.12) 一致。

3.5 单位与常用归一化

谱估计通常显示为功率密度，即“功率除以频率单位”。归一化的原则是：显示区间内谱曲线的面积等于信号平均功率。设 $X[k]$ 是式 (3.4) 的 DFT。

3.5.1 双边离散角频率谱

若在 $0 \leq \omega < 2\pi$ 上显示，课堂采用

$$\hat{S}_{xx}(\omega) = \frac{1}{2\pi L} \left| \sum_{n=0}^{L-1} x[n] e^{-j\omega n} \right|^2, \quad (3.15)$$

对应 DFT 格点

$$\hat{S}_{xx}\left(\frac{2\pi k}{N}\right) = \frac{1}{2\pi L} |X[k]|^2, \quad k = 0, \dots, N-1. \quad (3.16)$$

单位为功率/(rad/sample)。

3.5.2 单边离散角频率谱

对实信号，双边谱是偶对称的。若只显示 $0 \leq \omega \leq \pi$ ，内部正频率点需要包含负频率一侧的功率，因此可写成

$$\hat{S}_{xx}^{(1)}\left(\frac{2\pi k}{N}\right) = \frac{1}{\pi L} |X[k]|^2, \quad 1 \leq k < \frac{N}{2}. \quad (3.17)$$

DC 点以及偶数 N 时的 Nyquist 点不应加倍，其系数仍为 $1/(2\pi L)$ 。

3.5.3 单边赫兹频率谱

采样频率为 f_s 时，若显示 $0 \leq f \leq f_s/2$ ，内部频点的常用密度归一化为

$$\hat{S}_{xx}^{(1)}\left(\frac{k f_s}{N}\right) = \frac{2}{f_s L} |X[k]|^2, \quad 1 \leq k < \frac{N}{2}, \quad (3.18)$$

单位为功率/Hz；DC 和 Nyquist 点同样不加倍。

软件输出的归一化

MATLAB 等软件可输出功率谱、功率谱密度、单边谱或双边谱，归一化常数随选项变化。比较结果时必须同时核对：DFT 定义、窗功率、单边/双边、频率单位以及 DC/Nyquist 端点处理。

3.6 小结

周期图计算简单，且随 L 增大渐近无偏；然而其方差不随样本数消失，是一个不一致估计器。实际谱估计通常在周期图基础上引入分段、重叠与平均，以牺牲一定分辨率换取显著的方差降低。

3.7 本讲 MATLAB 代码

以下脚本对 $L = 64, 256, 1024$ 分别进行三次随机试验，并使用 1024 点 FFT 绘制周期图与真实功率谱。脚本中的零填充使曲线采样更密，但不改变由 L 决定的实际分辨率。

```

1  clear; clc; close all;
2  rng(1);
3
4  Nfft = 1024; L_list = [64, 256, 1024]; Ntrial = 3;
5  k = 0:Nfft-1; omega = 2*pi*k/Nfft;
6  Sxx_true = 0.5 * (1 + cos(omega));
7  k_plot = 0:Nfft/2; idx_plot = 1:Nfft/2+1;
8
9  for L = L_list
10     fig = figure('Color', 'w');
11     for trial = 1:Ntrial
12         x_all = filter([0.5 0.5], 1, randn(L+1, 1));
13         Sxx_hat = abs(fft(x_all(2:L+1), Nfft)).^2 / L;
14
15         subplot(Ntrial, 1, trial);
16         plot(k_plot, Sxx_hat(idx_plot), 'b', 'LineWidth', 1); hold on;
17         plot(k_plot, Sxx_true(idx_plot), 'r', 'LineWidth', 1.5);
18         grid on; xlim([0 Nfft/2]); ylim([0 max(5, 1.05*max(Sxx_hat(idx_plot)))]);
19         ylabel('$\hat{S}_{xx}[k]$', 'Interpreter', 'latex');
20         if trial == 1, legend('Periodogram', 'True', 'Location', 'northeast'); end
21         if trial == Ntrial, xlabel('k'); end
22     end
23     exportgraphics(fig, sprintf('fig3_periodogram_1%d.pdf', L), 'ContentType', 'vector');

```


24 | `end`

第四章 平均周期图：Welch 方法

本讲要点

本讲从周期图的方差问题出发，引入平均周期图和 Welch 方法。核心思想是把总数据分成若干段，对每段计算加窗周期图，再对这些周期图取平均。平均可降低方差；分段长度、重叠量与窗函数则共同决定偏差、频率分辨率和动态范围。

4.1 从周期图到平均周期图

功率谱密度可看作自相关序列的离散时间傅里叶变换：

$$S_{xx}(e^{j\omega}) = \sum_{k=-\infty}^{\infty} r_{xx}[k]e^{-j\omega k}. \quad (4.1)$$

上一讲的周期图直接由一段长度为 L 的数据构造。若

$$X(e^{j\omega}) = \sum_{n=0}^{L-1} x[n]e^{-j\omega n},$$

则常用的双边角频率归一化为

$$\hat{S}_{xx}^{\text{per}}(e^{j\omega}) = \frac{1}{2\pi L} |X(e^{j\omega})|^2. \quad (4.2)$$

周期图随 $L \rightarrow \infty$ 渐近无偏，但在固定频率处的方差通常与 $S_{xx}^2(e^{j\omega})$ 同阶，不会仅因 L 增大而消失。因此，提高谱估计稳定性的自然做法，是平均多个周期图。

4.2 Welch 方法的构造

设总共有 Q 个样本 $x[m]$ ，把它们分成 K 段，每段长度为 L ，相邻两段的起点相隔 R 个样本。第 r 段加窗数据定义为

$$x_r[n] = x[(r-1)R + n]w[n], \quad n = 0, \dots, L-1, \quad r = 1, \dots, K, \quad (4.3)$$

图 4.1 给出了这一分段方式的直观含义：从同一条观测序列中取出长度相同的局部数据块，起点按步长 R 向右移动。




图 4.1: Welch 方法的分段示意：每段长度为 L ，相邻段起点相隔 R 个样本；当 $R < L$ 时相邻段重叠。

其中 $w[n]$ 是可选窗函数。每一段的加窗周期图为

$$I_r(\omega) = \frac{1}{2\pi \sum_{n=0}^{L-1} w^2[n]} \left| \sum_{n=0}^{L-1} x_r[n] e^{-j\omega n} \right|^2. \quad (4.4)$$

Welch 谱估计器是这些分段周期图的平均：

$$\hat{S}_{xx}^W(e^{j\omega}) = \frac{1}{K} \sum_{r=1}^K I_r(\omega). \quad (4.5)$$

如果各段周期图近似独立，平均 K 项可把方差约降为单段周期图的 $1/K$ ；若段与段高度相关，方差下降会弱于这个理想因子。

4.3 性能：方差、偏差与参数权衡

Welch 方法的方差满足直观的不等式

$$\text{Var}[\hat{S}_{xx}^{\text{per}}(e^{j\omega})] \geq \text{Var}[\hat{S}_{xx}^W(e^{j\omega})] \geq \frac{1}{K} \text{Var}[\hat{S}_{xx}^{\text{per}}(e^{j\omega})]. \quad (4.6)$$

右端等号对应分段周期图彼此独立的理想情形；重叠分段会增加可平均的段数，但也会引入共享样本，使独立性下降。

偏差仍由真实谱与窗函数谱窗的卷积决定。令

$$W(e^{j\omega}) = \sum_{n=0}^{L-1} w[n] e^{-j\omega n}, \quad C_{ww}(e^{j\omega}) = |W(e^{j\omega})|^2, \quad F = \frac{1}{L} \sum_{n=0}^{L-1} w^2[n],$$

则

$$\mathbb{E}[\hat{S}_{xx}^W(e^{j\omega})] = \frac{1}{2\pi L F} \int_{-\pi}^{\pi} S_{xx}(e^{j\theta}) C_{ww}(e^{j(\omega-\theta)}) d\theta. \quad (4.7)$$

因此，段长 L 越大，谱窗主瓣越窄，频率分辨率越高，卷积造成的平滑偏差越小；但当总样本数 Q 固定时，增大 L 往往会减少可平均的段数 K ，从而削弱方差降低。

分段参数必须满足

$$Q \geq (K-1)R + L. \quad (4.8)$$

无重叠时 $R = L$ ，于是 $KL \leq Q$ 。这时各段独立性最好，但 K 与 L 的乘积受总数据量限制：增加 K 有利于降方差，增加 L 有利于降偏差和提高分辨率，二者不能同时任意增大。重叠时 $R < L$ ，可以在相同 Q 下得到更多段，但方差收益依赖重叠程度和窗函数形状。

仿真：矩形窗与 Hamming 窗的谱窗

这个仿真用于观察 $C_{ww}(e^{j\omega}) = |W(e^{j\omega})|^2$ 的形状如何影响 Welch 谱估计的偏差。矩形窗给出较窄主瓣，频率分辨率高，但旁瓣较高，强谱线容易泄漏到邻近频率；Hamming 窗主瓣约更宽，牺牲一定分辨率来显著压低旁瓣，从而提升可分辨强弱谱成分的动态范围。




图 4.2: 两种窗函数的谱窗 C_{ww} : 矩形窗主瓣窄但旁瓣高, Hamming 窗旁瓣低但主瓣更宽。

4.4 小结

Welch 方法用平均降低周期图的方差, 并用窗函数控制由谱窗卷积带来的偏差形态。实际选参时需要同时看三件事: K 决定方差降低的潜力, L 决定分辨率和偏差, R 决定重叠量及分段间相关性。窗函数进一步在主瓣宽度和旁瓣高度之间折中, 也就是在分辨率和动态范围之间折中。

4.5 本讲 MATLAB 代码

以下脚本绘制长度 $L = 32$ 时矩形窗和 Hamming 窗的 C_{ww} 频率响应, 并分别导出两张 PDF 图, 用于比较主瓣宽度与旁瓣高度。

```

1 %% Figure 4: Window frequency responses
2 L = 32; Nfft_window = 16384;
3 n = (0:L-1).'; omega_window = 2*pi*(-Nfft_window/2:Nfft_window/2-1)/Nfft_window;
4 window_data = {ones(L,1), 'fig_4_Cww_rectangular_window.pdf';
5               0.54 - 0.46*cos(2*pi*n/(L-1)), 'fig_4_Cww_hamming_window.pdf'};
6
7 for ii = 1:size(window_data,1)
8     W = fftshift(fft(window_data{ii,1}, Nfft_window));
9     fig = figure('Color','w','Units','inches','Position',[1,1,5.5,4]);
10    plot(omega_window, 10*log10(abs(W).^2 + eps), 'b', 'LineWidth', 1.2);
11    grid on; box on; xlim([-pi,pi]); ylim([-50,30]);
12    xticks([-2,0,2]); yticks(-50:10:30);
13    xlabel('$\omega$ (rads)', 'Interpreter','latex', 'FontSize',12);
14    ylabel('dB', 'Interpreter','none', 'FontSize',12);
15    set(gca, 'FontSize',11, 'LineWidth',0.8);
16    exportgraphics(fig, window_data{ii,2}, 'ContentType','vector', 'BackgroundColor','white');
17 end

```

第五章 Welch 方法的 MATLAB 实验

本讲要点

本讲用 MATLAB 的 `pwelch` 实验观察 Welch 谱估计的实际表现。实验展示三类现象：平均更多分段会降低估计方差；在总样本数固定时，缩短分段会扩大谱窗主瓣并降低分辨率；重叠分段能增加可平均的段数，但强重叠会降低分段之间的独立性。最后通过 500 次独立估计的平均曲线，分离出 Hamming 窗和矩形窗造成的偏差差异。

5.1 仿真实验对象

实验用白噪声通过一个线性时不变系统生成观测数据。若输入白噪声 $w[n]$ 的方差为 1，系统冲激响应为 $h[n]$ ，输出

$$x[n] = (h * w)[n], \quad (5.1)$$

则输出功率谱等于系统频率响应幅度平方：

$$S_{xx}(f) = |H(f)|^2. \quad (5.2)$$

脚本用 `fir2` 设计 $H(f)$ ，采样频率为 $f_s = 100$ Hz，每次观测长度为 $N = 1024$ 。真实谱故意包含较大动态范围、窄凹陷和两个相邻峰值，用来同时考察方差、分辨率和动态范围。

仿真对象：动态范围和分辨率都困难的谱

这个例子不是为了模拟某个具体物理系统，而是构造一个对谱估计器有挑战的目标谱。图中 10 Hz 到 14 Hz 附近有两个相邻高幅度谱峰，中间还有深凹陷；低幅度平台和高幅度区域之间相差约几十 dB。这样的谱能同时暴露两个问题：估计曲线的随机起伏会掩盖弱结构，窗函数旁瓣也会把强谱成分泄漏到弱谱区域。




图 5.1: 实验使用的真实功率谱。红/蓝对比图中的红线均为该真谱。

5.2 pwelch 的参数和归一化

脚本调用 `pwelch` 时, 分段长度为 L , 相邻分段起点间隔为 R , 重叠样本数为 $L - R$ 。固定 $N = 1024$ 时, 实际分段数为

$$K = \left\lfloor \frac{N - L}{R} \right\rfloor + 1. \quad (5.3)$$

无重叠时 $R = L$, 于是 $L = 1024, 256, 64$ 分别对应 $K = 1, 4, 16$ 。固定 $L = 256$ 时, 令 $R = 256, 192, 48$ 分别得到 $K = 4, 5, 17$, 其中后两种存在重叠。

`pwelch` 默认输出功率谱密度。为了与 $|H(f)|^2$ 标度下的功率谱比较, 脚本将单边谱密度乘以 $f_s/2$, 并对 DC 与 Nyquist 端点补偿单边谱的端点处理:



$$\hat{S}_{xx}(f_k) = \frac{f_s}{2} \hat{P}_{xx}^{\text{pwelch}}(f_k), \quad f_k = \frac{k f_s}{N_{\text{fft}}}. \quad (5.4)$$


端点处没有正负频率合并带来的加倍, 因此代码中把归一化后的 DC 点和 Nyquist 点再乘以 2, 使曲线与真实功率谱使用同一标度。

5.3 平均、重叠和偏差

仿真: Welch 参数对谱估计的影响

本例用同一个真实谱比较 Welch 参数的三个影响。第一组无重叠实验只改变 L 和 K : $L = 1024, K = 1$ 等价于单个周期图, 曲线起伏很大; $L = 256, K = 4$ 通过平均四段明显降低方差; $L = 64, K = 16$ 的平坦区域更稳定, 但相邻峰值和尖锐边缘被更宽的谱窗主瓣抹平, 分辨率损失变得明显。


(a) 无重叠, $L = 1024$, $K = 1$ 



(c) 无重叠, $L = 64, K = 16$

图 5.2: 无重叠分段时, 增加 K 降低方差, 但较短 L 会降低频率分辨率。

第二组实验固定 $L = 256$, 只改变 R 。当 $R = 256$ 时无重叠, $K = 4$ 。当 $R = 192$ 时, 相邻段重叠 64 个样本, $K = 5$, 由于 Hamming 窗在边缘较小, 这种轻微重叠不会严重破坏独立性, 但方差改善也有限。当 $R = 48$ 时, 相邻段重叠 208 个样本, 虽然 $K = 17$, 但这些分段高度相关, 方差并不会按 17 个独立估计那样下降。



(a) $R = 256, K = 4$

(b) $R = 192, K = 5$

(c) $R = 48, K = 17$

图 5.3: 固定 $L = 256$ 时, 重叠能增加段数, 但强重叠带来的方差收益受分段相关性限制。

最后一组实验对 500 次独立 Welch 估计先在线性功率域平均, 再转换为 dB。这样随机方差大幅削弱, 曲线主要显示偏差。Hamming 窗旁瓣低, 能保留约 40 dB 的动态范围, 弱谱平台更容易显现; 矩形窗主瓣窄, 局部分辨率较好, 但旁瓣高, 强谱成分会向两侧泄漏, 弱谱区域被抬高。随着 L 从 1024 降到 64, 平均段数增多, 方差性质改善, 但谱窗主瓣变宽, 两个相邻谱峰和尖锐边缘逐渐被平滑。




图 5.4: 500 次估计平均后的偏差比较: Hamming 窗动态范围较好, 矩形窗分辨率较好但旁瓣泄漏更明显; 减小 L 会进一步增加平滑偏差。

5.4 小结

Welch 方法的选参本质上是在固定数据量下分配方差和偏差。较大的 K 来自较短分段或更多重叠, 能降低随机起伏; 较大的 L 让谱窗主瓣更窄, 能保留更好的分辨率和较小的平滑偏差。重叠只有在分段相关性不太强时才有效; 窗函数则决定主瓣宽度和旁瓣高度, 因此同时影响分辨率和动态范围。

5.5 本讲 MATLAB 代码

以下脚本生成本讲全部 13 张 PDF: 真实谱、无重叠 Welch 估计、固定 L 时不同重叠量的估计, 以及 500 次平均后的 Hamming/矩形窗偏差比较。脚本保留原始随机种子、参数和输出文件名, 但删去了冗长注释并合并了重复绘图逻辑。

```

1 clear; clc; close all;
2
3 fs = 100; N = 1024; Nfft = 1024; numTrials = 3; numAverages = 500;
4 filterOrder = 4096; outDir = pwd;
5 Ndesign = 16384; fDesign = linspace(0,fs/2,Ndesign/2+1);
6 fPlot = linspace(0,fs/2,Nfft/2+1);
7 step = @(x,fc,bw) 0.5*(1+tanh((x-fc)/bw));
8 target_dB = -20 + 40*step(fDesign,10,0.035) - 50*step(fDesign,14,0.035) ...
9     + 24*step(fDesign,26,0.035) ...
10     - 85*(step(fDesign,12.05,0.012)-step(fDesign,12.75,0.012)) ...
11     - 20*exp(-((fDesign-12.36)/0.030).^2) + 0.35*sin(2*pi*fDesign/0.24);
12

```

```

13 b = fir2(filterOrder,fDesign/(fs/2),10.^(target_dB/20),32768);
14 truePSD_dB = 20*log10(abs(freqz(b,1,fPlot,fs))+eps);
15
16 fig = figure();
17 plot(fPlot,truePSD_dB,'b','LineWidth',1.0);
18 box on; grid off; title('True Power Spectrum','FontWeight','normal');
19 xlabel('Frequency (Hz)'); ylabel('dB'); xlim([0 50]); ylim([-100 20]);
20 xticks(0:10:50); yticks(-100:20:20); set(gca,'FontSize',11,'LineWidth',0.8);
21 saveFigurePDF(fig,fullfile(outDir,'fig5_eg1.pdf'));
22
23 cases = struct( ...
24     'L',{1024,256,64,256,256,256}, ...
25     'R',{1024,256,64,256,192,48}, ...
26     'K',{1,4,16,4,5,17}, ...
27     'isOverlap',{false,false,false,true,true,true}, ...
28     'file',{ ...
29         'fig5_eg1_noverlap_k1_welch.pdf', ...
30         'fig5_eg1_noverlap_k4_welch.pdf', ...
31         'fig5_eg1_noverlap_k16_welch.pdf', ...
32         'fig5_eg1_overlap_k4_welch.pdf', ...
33         'fig5_eg1_overlap_k5_welch.pdf', ...
34         'fig5_eg1_overlap_k17_welch.pdf'}, ...
35     'seed',{1100,1200,1300,2100,2200,2300});
36
37 for i = 1:numel(cases)
38     c = cases(i);
39     makeWelchFigure(b,fPlot,truePSD_dB,fs,N,Nfft,numTrials,filterOrder, ...
40         c.L,c.R,c.K,c.isOverlap,fullfile(outDir,c.file),c.seed);
41 end
42
43 rng(5000,'twister');
44 xLong = fftfilt(b,randn(N+filterOrder,numAverages));
45 xAverage = xLong(filterOrder+1:filterOrder+N,:);
46 avgCases = struct( ...
47     'L',{1024,256,64,1024,256,64}, ...
48     'K',{1,4,16,1,4,16}, ...
49     'win',{'hamming','hamming','hamming','rectangular','rectangular','rectangular'}, ...
50     'file',{ ...
51         'fig5_eg1_avg500_noverlap_L1024_hamming.pdf', ...
52         'fig5_eg1_avg500_noverlap_L256_hamming.pdf', ...
53         'fig5_eg1_avg500_noverlap_L64_hamming.pdf', ...
54         'fig5_eg1_avg500_noverlap_L1024_rectangular.pdf', ...
55         'fig5_eg1_avg500_noverlap_L256_rectangular.pdf', ...
56         'fig5_eg1_avg500_noverlap_L64_rectangular.pdf'});
57
58 for i = 1:numel(avgCases)
59     c = avgCases(i);
60     makeAverageEstimateFigure(xAverage,fPlot,truePSD_dB,fs,N,Nfft, ...
61         c.L,c.K,c.win,numAverages,fullfile(outDir,c.file));
62 end
63
64 function makeWelchFigure(b,fPlot,truePSD_dB,fs,N,Nfft,numTrials,filterOrder,L,R,K,isOverlap,fileN_
    ↪ ame,seedBase)
65     noverlap = L-R; Kactual = floor((N-L)/R)+1;

```

```

66     if noverlap < 0 || noverlap >= L || Kactual ~= K
67         error('Welch 参数不一致。');
68     end
69
70     win = hamming(L,'periodic');
71     fig = figure(); layout = tiledlayout(3,1,'TileSpacing','compact','Padding','compact');
72     for trial = 1:numTrials
73         rng(seedBase+trial,'twister');
74         xLong = filter(b,1,randn(N+filterOrder,1));
75         x = xLong(filterOrder+1:filterOrder+N);
76         [Pxx,fWelch] = pwelch(x,win,noverlap,Nfft,fs,'onesided');
77         estimate_dB = 10*log10(normalizeOneSidedPSD(Pxx,fs,Nfft)+eps);
78
79         nexttile; plot(fPlot,truePSD_dB,'r','LineWidth',1.3); hold on;
80         plot(fWelch,estimate_dB,'b','LineWidth',0.8); hold off;
81         box on; grid off; xlim([0 50]); ylim([-60 25]);
82         xticks(0:10:50); yticks(-60:20:20); ylabel('dB');
83         set(gca,'FontSize',11,'LineWidth',0.8);
84         if trial == 1
85             legend('true',ternary(Kactual==1,'periodogram','Welch'),'Location','northeast');
86         end
87         if trial < numTrials, set(gca,'XTickLabel',[]); else, xlabel('Frequency (Hz)'); end
88     end
89
90     if isOverlap
91         titleText = sprintf('Hamming Window, L=%d, R=%d, Overlap=%d, K=%d',L,R,L-R,Kactual);
92     else
93         titleText = sprintf('Hamming Window, No Overlap: L=%d, K=%d',L,Kactual);
94     end
95     title(layout,titleText,'FontWeight','normal');
96     saveFigurePDF(fig,fileName);
97 end
98
99 function makeAverageEstimateFigure(xAverage,fPlot,truePSD_dB,fs,N,Nfft,L,K>windowType,numAverages
↳ ,fileName)
100     Kactual = floor((N-L)/L)+1;
101     if Kactual ~= K, error('无重叠参数不一致。'); end
102
103     switch lower(windowType)
104         case 'hamming'
105             win = hamming(L,'periodic'); label = 'Hamming';
106         case 'rectangular'
107             win = ones(L,1); label = 'Rectangular';
108         otherwise
109             error('不支持的窗类型。');
110     end
111
112     [PxxAll,fWelch] = pwelch(xAverage,win,0,Nfft,fs,'onesided');
113     meanPxx_dB = 10*log10(mean(normalizeOneSidedPSD(PxxAll,fs,Nfft),2)+eps);
114     fig = figure();
115     plot(fPlot,truePSD_dB,'r','LineWidth',1.4); hold on;
116     plot(fWelch,meanPxx_dB,'b','LineWidth',1.0); hold off;
117     box on; grid off; xlim([0 50]); ylim([-60 25]);
118     xticks(0:10:50); yticks(-60:20:20); xlabel('Frequency (Hz)'); ylabel('dB');

```

```

119     set(gca,'FontSize',11,'LineWidth',0.8);
120     title(sprintf('Average of %d Estimates, No Overlap, %s Window: L=%d, K=%d', ...
121         numAverages,label,L,Kactual),'FontWeight','normal');
122     legend('true','average estimate','Location','northeast');
123     saveFigurePDF(fig,fileName);
124 end
125
126 function Pnormalized = normalizeOneSidedPSD(Pxx,fs,Nfft)
127     Pnormalized = Pxx*(fs/2);
128     Pnormalized(1,:) = 2*Pnormalized(1,:);
129     if rem(Nfft,2) == 0, Pnormalized(end,:) = 2*Pnormalized(end,:); end
130 end
131
132 function out = ternary(cond,a,b)
133     if cond, out = a; else, out = b; end
134 end
135
136 function saveFigurePDF(figHandle,fileName)
137     drawnow;
138     try
139         exportgraphics(figHandle,fileName,'ContentType','vector','BackgroundColor','white');
140     catch
141         set(figHandle,'PaperPositionMode','auto');
142         print(figHandle,fileName,'-dpdf','-painters','-bestfit');
143     end
144 end

```

第六章 互谱相干性与交叉谱估计

本讲要点

本讲把前面功率谱估计的思想推广到两个随机序列之间的频域关系。交叉谱由互相关序列的 DTFT 定义，相干度用交叉谱除以两个自谱的平方根来归一化；实际更常用的是幅值平方相干性（magnitude-squared coherence, MSC），它只保留相关强度而去掉相位。直接把单段周期图代入 MSC 会导致恒等为 1 的退化结果，因此必须先对自谱和交叉谱做平均，再形成比值。MATLAB 中的 `mscohere` 正是按 Welch 平均思想实现这一估计。

6.1 交叉谱与相干性

对两个零均值宽平稳离散时间随机过程 $x[n]$ 和 $y[n]$ ，互相关序列取为

$$r_{xy}[k] = \mathbb{E}\{x[n]y[n-k]\}. \quad (6.1)$$

它的 DTFT 给出交叉谱

$$S_{xy}(\omega) = \sum_{k=-\infty}^{\infty} r_{xy}[k]e^{-j\omega k}. \quad (6.2)$$

与功率谱不同， $S_{xy}(\omega)$ 一般是复数，幅度反映两个序列在该频率附近共享的能量关系，相位则反映频率分量之间的相对延迟或相位差。

相干度把交叉谱按两个自谱归一化：

$$\text{Coh}_{xy}(\omega) = \frac{S_{xy}(\omega)}{S_{xx}^{1/2}(\omega)S_{yy}^{1/2}(\omega)}. \quad (6.3)$$

它类似频域中的相关系数。为了只观察关联强度，常使用幅值平方相干性

$$C_{xy}(\omega) = |\text{Coh}_{xy}(\omega)|^2 = \frac{|S_{xy}(\omega)|^2}{S_{xx}(\omega)S_{yy}(\omega)}, \quad 0 \leq C_{xy}(\omega) \leq 1. \quad (6.4)$$

若 $C_{xy}(\omega) = 1$ ，说明 $x[n]$ 和 $y[n]$ 在该频率处可由一个线性时不变关系完全联系起来；若 $C_{xy}(\omega) = 0$ ，则说明它们在该频率处没有线性相关的共同成分。

6.2 为什么不能直接代入周期图

交叉谱估计可以仿照周期图。取长度为 L 的两段数据，其 DTFT 分别为 $X(e^{j\omega})$ 和 $Y(e^{j\omega})$ ，单段交叉周期图为

$$\hat{S}_{xy}^{\text{per}}(\omega) = \frac{1}{L} X(e^{j\omega}) Y^*(e^{j\omega}). \quad (6.5)$$

相应的自周期图为

$$I_{xx}(\omega) = \frac{1}{L} |X(e^{j\omega})|^2, \quad I_{yy}(\omega) = \frac{1}{L} |Y(e^{j\omega})|^2. \quad (6.6)$$

如果把这三个单段估计直接代入 [equation \(6.4\)](#)，则

$$\hat{C}_{xy}^{\text{per}}(\omega) = \frac{|\frac{1}{L} X(e^{j\omega}) Y^*(e^{j\omega})|^2}{\frac{1}{L} |X(e^{j\omega})|^2 \frac{1}{L} |Y(e^{j\omega})|^2} = 1. \quad (6.7)$$

所有与 X 、 Y 和 L 有关的项完全抵消，因此单段周期图不能给出有意义的 MSC。它不仅方差很大，而且在相干性估计中会直接退化为“任何频率都完全相干”的错误结论。

6.3 Welch 型 MSC 估计

解决办法不是先形成每段的 MSC 再平均，而是先分别平均自谱和交叉谱，再取比值。将 $x[n]$ 、 $y[n]$ 分成 K 个长度为 L 的片段，相邻片段起点相隔 R ，重叠样本数为 $L - R$ ，总长度 Q 需满足

$$(K - 1)R + L \leq Q. \quad (6.8)$$

第 k 段的 DTFT 记为 $X_k(e^{j\omega})$ 、 $Y_k(e^{j\omega})$ 。每段先形成

$$I_{xx}^{(k)}(\omega) = \frac{1}{L}|X_k(e^{j\omega})|^2, \quad I_{yy}^{(k)}(\omega) = \frac{1}{L}|Y_k(e^{j\omega})|^2, \quad I_{xy}^{(k)}(\omega) = \frac{1}{L}X_k(e^{j\omega})Y_k^*(e^{j\omega}). \quad (6.9)$$

Welch 型 MSC 估计量为

$$\hat{C}_{xy}(\omega) = \frac{\left| \frac{1}{K} \sum_{k=1}^K I_{xy}^{(k)}(\omega) \right|^2}{\left(\frac{1}{K} \sum_{k=1}^K I_{xx}^{(k)}(\omega) \right) \left(\frac{1}{K} \sum_{k=1}^K I_{yy}^{(k)}(\omega) \right)}. \quad (6.10)$$

这里平均的作用与 Welch 功率谱估计相同：增加有效平均段数可以降低随机起伏；但较短的 L 会降低频率分辨率，强重叠也会使片段间相关性升高，从而削弱方差收益。

6.4 MATLAB 中的 mscohere 仿真

例：mscohere 的相干性估计

本例构造一个可以精确写出真 MSC 的系统，用来观察 mscohere 的方差、偏差和重叠效应。令 $x[n]$ 为方差 $\sigma_x^2 = 1$ 的白噪声，经过三点滑动平均系统

$$h[n] = \frac{1}{3}(\delta[n] + \delta[n-1] + \delta[n-2]) \quad (6.11)$$

得到滤波分量，再在输出端叠加与 $x[n]$ 独立的白噪声 $v[n]$ ，其方差为 $\sigma_v^2 = 0.1$ ：

$$y[n] = (h * x)[n] + v[n]. \quad (6.12)$$


于是

$$S_{xx}(\omega) = 1, \quad S_{yy}(\omega) = |H(e^{j\omega})|^2 + 0.1, \quad S_{xy}(\omega) = H(e^{j\omega}), \quad (6.13)$$


真幅值平方相干性为

$$C_{xy}(\omega) = \frac{|H(e^{j\omega})|^2}{|H(e^{j\omega})|^2 + 0.1}. \quad (6.14)$$

当 $|H|$ 接近 1 时，MSC 约为 1/1.1；当系统响应较小，例如 $|H| \approx 1/3$ 时，MSC 约为 $(1/9)/(1/9+0.1)$ ，也就是接近 0.5；当系统零点使 $|H| = 0$ 时，MSC 为 0。



(a) 三点滑动平均系统的幅频响应



(b) 由式 (6.14) 得到的真 MSC

图 6.1: 仿真系统及其真幅值平方相干性。系统响应越弱，输出中由独立噪声占据的比例越高，相干性越低。

脚本设置 $Q = 2048$ 、采样频率 $f_s = 100$ Hz，使用 Hamming 窗和 `mscohere`。第一组参数为 $L = 256, R = 256, K = 8$ ，没有重叠。三次独立运行的蓝色估计曲线都围绕红色真值起伏，但在真 MSC 较低的频率附近起伏尤其明显，因为估计量被限制在 0 到 1 之间，随机正偏差不能被负值对称抵消。




图 6.2: 无重叠时三次独立 `mscohere` 估计: $L = 256, R = 256, K = 8$ 。

第二组把分段长度缩短到 $L = 64$ ，仍无重叠，因而 $K = 32$ 。更多片段平均显著降低了随机起伏，但较短分段会带来更宽的谱窗主瓣。由于本例的真相干函数本身较平滑，分辨率损失没有像窄峰谱估计那样突出。




图 6.3: 无重叠且短分段时三次独立估计: $L = 64, R = 64, K = 32$ 。

第三组恢复 $L = 256$, 但令 $R = 48$, 相邻片段重叠 208 个样本, 得到 $K = 38$ 。重叠增加了可平均的片段数, 但这些片段共享大量数据, 并不等价于 38 个独立估计; 图中仍可看到方差降低, 收益却受片段相关性限制。





图 6.4: 强重叠时三次独立估计: $L = 256, R = 48, K = 38$ 。

为了分离平均意义下的偏差, 脚本对每组参数做 500 次独立实验, 先平均 mscohere 输出, 再与真 MSC 比较。三幅均值图说明: 在真相干性较大的区域, 平均曲线通常接近真值; 在真相干性接近

0 的区域, 由于估计值非负, 平均后仍可能被抬高; 若真值接近 1, 则估计值不能超过 1, 平均值会倾向于略低于真值。



(a) $K = 8, L = 256, R = 256$

(b) $K = 32, L = 64, R = 64$

(c) $K = 38, L = 256, R = 48$

图 6.5: 500 次独立实验的平均 MSC。平均降低方差后, 低相干区域的非负约束偏差和高相干区域的上界约束更容易被看出。

6.5 小结

交叉谱把两个序列的互相关搬到频域, 相干性再把交叉谱按两个自谱归一化, 使不同频率处的线性关联强度落在可比较的尺度上。MSC 的估计不能直接使用单段周期图, 因为代入后会恒等于 1; 必须先对自谱和交叉谱进行 Welch 型平均, 再形成比值。MATLAB 的 `mscohere` 实验显示, 增加有效平均段数可以降低方差, 但估计值被限制在 $[0, 1]$ 内, 因此在低相干和高相干区域会出现不同方向的平均偏差; 分段长度和重叠量仍然需要在方差、分辨率和片段相关性之间折中。

6.6 本讲 MATLAB 代码

以下脚本生成本讲使用的 8 张 PDF: 系统幅频响应、真幅值平方相干性、三组参数下的三次独立 `mscohere` 估计, 以及对应的 500 次 Monte Carlo 平均曲线。脚本保留原始随机种子、参数和输出文件名, 并把重复绘图逻辑合并成局部函数。

```
1 clear; close all; clc;
2 rng(6, 'twister');
3
4 Fs = 100;
5 sigma_x2 = 1;
6 sigma_v2 = 0.1;
7 h = [1 1 1] / 3;
8 outDir = pwd;
9
10 [Hsys, fH] = freqz(h, 1, 4096, Fs);
11 plotOne(fH, abs(Hsys), 'Gain', 'System Frequency Response', ...
12     fullfile(outDir, 'fig6_01_system_frequency_response.pdf'));
13
14 nFreq = 4096;
15 [Htrue, fTrue] = freqz(h, 1, nFreq, Fs);
16 trueCoherence = sigma_x2 * abs(Htrue).^2 ./ ...
17     (sigma_x2 * abs(Htrue).^2 + sigma_v2);
18 plotOne(fTrue, trueCoherence, 'Magnitude-Squared Coherence', ...
19     'True Coherence', fullfile(outDir, 'fig6_02_true_coherence.pdf'));
```

```

20
21 Q = 2048;
22 nfftWelch = 2048;
23 Nmean = 500;
24 configs = [8 256 256; 32 64 64; 38 256 48];
25 figureNumber = 3;
26
27 for configIndex = 1:size(configs, 1)
28     K = configs(configIndex, 1);
29     L = configs(configIndex, 2);
30     R = configs(configIndex, 3);
31     noverlap = L - R;
32     if floor((Q - L) / R) + 1 ~= K
33         error('Inconsistent Welch parameters.');
```

34 end

35

36 window = hamming(L, 'periodic');

37 [figRuns, fWelch, CxyTrue] = runFigure(K, L, R, Q, Fs, ...

38 sigma_x2, sigma_v2, h, window, noverlap, nfftWelch);

39 exportPDF(figRuns, fullfile(outDir, sprintf(...

40 'fig6_%02d_K%02d_L%03d_R%03d_three_runs.pdf', ...

41 figureNumber, K, L, R)));

42 figureNumber = figureNumber + 1;

43

44 CxySum = zeros(size(fWelch));

45 for meanIndex = 1:Nmean

46 [x, y] = makeSignals(Q, sigma_x2, sigma_v2, h);

47 CxySum = CxySum + mscohere(x, y, window, noverlap, nfftWelch, Fs);

48 end

49

50 figMean = figure();

51 plot(fWelch, CxyTrue, 'r-', 'LineWidth', 1.5); hold on;

52 plot(fWelch, CxySum / Nmean, 'b-', 'LineWidth', 1.4); hold off;

53 styleAxes('Magnitude-Squared Coherence', sprintf(...

54 'Mean mscohere: K=%d, L=%d, R=%d, N=%d', K, L, R, Nmean));

55 legend('True', 'Mean mscohere', 'Location', 'best');

56 exportPDF(figMean, fullfile(outDir, sprintf(...

57 'fig6_%02d_K%02d_L%03d_R%03d_mean.pdf', ...

58 figureNumber, K, L, R)));

59 figureNumber = figureNumber + 1;

60 end

61

62 fprintf('\nAll done: generated 8 PDF files.\nOutput directory:\n%s\n\n', outDir);

63

64 function [figRuns, fWelch, CxyTrue] = runFigure(K, L, R, Q, Fs, ...

65 sigma_x2, sigma_v2, h, window, noverlap, nfftWelch)

66 figRuns = figure();

67 fWelch = [];

68 CxyTrue = [];

69 for runIndex = 1:3

70 [x, y] = makeSignals(Q, sigma_x2, sigma_v2, h);

71 [CxyRun, fWelch] = mscohere(x, y, window, noverlap, nfftWelch, Fs);

72 Hgrid = freqz(h, 1, 2*pi*fWelch/Fs);

73 CxyTrue = sigma_x2 * abs(Hgrid).^2 ./ ...

```

74         (sigma_x2 * abs(Hgrid).^2 + sigma_v2);
75
76         subplot(3, 1, runIndex);
77         plot(fWelch, CxyTrue, 'r-', 'LineWidth', 1.2); hold on;
78         plot(fWelch, CxyRun, 'b-', 'LineWidth', 1.0); hold off;
79         styleAxes('Coherence', sprintf('Run %d: K=%d, L=%d, R=%d', ...
80             runIndex, K, L, R));
81         if runIndex == 1
82             legend('True', sprintf('mscohere K=%d', K), 'Location', 'best');
83         end
84     end
85 end
86
87 function [x, y] = makeSignals(Q, sigma_x2, sigma_v2, h)
88     x = sqrt(sigma_x2) * randn(Q, 1);
89     v = sqrt(sigma_v2) * randn(Q, 1);
90     y = filter(h, 1, x) + v;
91 end
92
93 function plotOne(f, y, ylab, ttl, filePath)
94     fig = figure();
95     plot(f, y, 'b-', 'LineWidth', 1.6);
96     styleAxes(ylab, ttl);
97     exportPDF(fig, filePath);
98 end
99
100 function styleAxes(ylab, ttl)
101     xlim([0 50]);
102     ylim([0 1]);
103     xlabel('Frequency (Hz)');
104     ylabel(ylab);
105     title(ttl);
106     grid on;
107     box on;
108 end
109
110 function exportPDF(figHandle, filePath)
111     set(figHandle, 'PaperPositionMode', 'auto');
112     try
113         exportgraphics(figHandle, filePath, 'ContentType', 'vector');
114     catch
115         print(figHandle, filePath, '-dpdf', '-painters', '-bestfit');
116     end
117 end

```

第七章 参数估计准则：最大似然与贝叶斯方法

本讲要点

本讲从一般参数估计问题出发,讨论两类常用准则。最大似然估计(maximum likelihood estimation, MLE)把未知参数看作确定但未知的量,选择使已观测数据最可能出现的参数值;贝叶斯估计(Bayesian estimation)把未知参数看作随机变量,先用先验密度描述已有信息,再由观测数据形成后验密度。两者的差别不只是公式不同,而是对“未知参数”的建模态度不同:MLE依赖观测模型 $f(\mathbf{x}; \alpha)$, Bayesian 方法还需要先验 $f_\alpha(\alpha)$ 和代价函数。

7.1 参数估计问题

设观测向量 $\mathbf{x}$ 的概率模型依赖未知参数 α 。若把这种依赖写成

$$\mathbf{x} \sim f_{\mathbf{X}}(\mathbf{x}; \alpha), \quad (7.1)$$

则参数估计的任务是构造一个由观测数据决定的函数

$$\hat{\alpha} = g(\mathbf{x}), \quad (7.2)$$

用它作为 α 的估计值。问题的核心不是“能不能写出一个函数”,而是怎样选择 $g(\cdot)$ 。不同准则对“好估计量”的定义不同,因此会给出不同的估计器。

本讲关注两个在信号处理中最常见的准则。最大似然方法认为 α 是一个固定常数,只是其数值未知;贝叶斯方法则认为 α 本身是随机变量,需要先指定它的先验概率密度。前者通常导向一个优化问题,后者先导出后验分布,再根据代价函数选取后验分布上的某个代表值。

7.2 最大似然估计

给定一次具体观测 $\mathbf{x}_0$ 后,密度 $f_{\mathbf{X}}(\mathbf{x}_0; \alpha)$ 可以看成 α 的函数。最大似然估计选择使该函数最大的参数值:

$$\hat{\alpha}_{\text{ML}} = \arg \max_{\alpha} f_{\mathbf{X}}(\mathbf{x}_0; \alpha). \quad (7.3)$$

这里的 $f_{\mathbf{X}}(\mathbf{x}_0; \alpha)$ 称为似然函数。它不是 α 的概率密度,因为在 MLE 框架中 α 并非随机变量;它只是说明:如果真实参数取某个 α ,那么观测到 $\mathbf{x}_0$ 附近数据的可能性有多大。

对连续观测,精确取到单点 $\mathbf{x}_0$ 的概率为零。似然的直观意义来自一个很小邻域:以标量观测为例,

$$\Pr\{x_0 - \Delta/2 \leq X \leq x_0 + \Delta/2; \alpha\} = \int_{x_0 - \Delta/2}^{x_0 + \Delta/2} f_X(x; \alpha) dx \approx f_X(x_0; \alpha) \Delta. \quad (7.4)$$

当 Δ 足够小时,比较不同 α 下观测落在 x_0 附近的概率,等价于比较 $f_X(x_0; \alpha)$ 。因此 MLE 选择的就是让已观测数据最“容易出现”的参数。




图 7.1: 固定观测 $\mathbf{x}_0$ 后, 似然函数是参数 α 的函数; MLE 取其最大点。

MLE 之所以常用, 首先是因为形式直接: 只要给定数据模型 $f_{\mathbf{X}}(\mathbf{x}; \alpha)$, 观测后就转化为解析或数值优化问题。其次, 在相当一般的正则条件下, 当测量次数趋于无穷时, MLE 具有良好的渐近性质: 它渐近无偏, 并且能够达到任何无偏估计量可能达到的最小渐近方差。需要注意的是, 这些性质是大样本性质; 样本数有限时, MLE 不一定无偏, 也不一定总是最理想的估计器。

7.3 贝叶斯估计

贝叶斯方法把未知参数 α 视为随机变量。除了观测模型 $f_{\mathbf{X}|\alpha}(\mathbf{x}|\alpha)$, 还需要指定先验密度 $f_{\alpha}(\alpha)$ 。观测到 $\mathbf{x}_0$ 后, Bayes 公式给出后验密度:

$$f_{\alpha|\mathbf{X}}(\alpha|\mathbf{x}_0) = \frac{f_{\mathbf{X}|\alpha}(\mathbf{x}_0|\alpha)f_{\alpha}(\alpha)}{f_{\mathbf{X}}(\mathbf{x}_0)}, \quad (7.5)$$

其中分母

$$f_{\mathbf{X}}(\mathbf{x}_0) = \int f_{\mathbf{X}|\alpha}(\mathbf{x}_0|\alpha)f_{\alpha}(\alpha) d\alpha \quad (7.6)$$

只负责归一化, 使后验密度在所有 α 上积分为 1。实际寻找最优点时, 若只比较不同 α 的相对大小, 常可把分母看成与 α 无关的常数。

有了后验密度后, 还需要说明估计误差的代价。设非负代价函数为 $C(\hat{\alpha} - \alpha)$, 贝叶斯估计选择使后验平均代价最小的估计值:

$$\hat{\alpha}_B = \arg \min_{\hat{\alpha}} \mathbb{E}\{C(\hat{\alpha} - \alpha) | \mathbf{x}_0\}. \quad (7.7)$$

这一定义强调: Bayesian 方法不是单一估计器, 而是一套框架。观测数据先把先验更新为后验, 随后代价函数决定从后验分布中取均值、中位数还是最大点。

7.4 常见贝叶斯估计器

若代价函数为平方误差

$$C(\hat{\alpha} - \alpha) = |\hat{\alpha} - \alpha|^2, \quad (7.8)$$

则使后验均方误差最小的估计值是后验均值:

$$\hat{\alpha}_{\text{MMSE}} = \mathbb{E}\{\alpha | \mathbf{x}_0\} = \int \alpha f_{\alpha|\mathbf{X}}(\alpha|\mathbf{x}_0) d\alpha. \quad (7.9)$$

这就是最小均方误差 (minimum mean-squared error, MMSE) 估计器。它适合误差越大惩罚越重的情形。

若代价函数为绝对误差

$$C(\hat{\alpha} - \alpha) = |\hat{\alpha} - \alpha|, \quad (7.10)$$

则 Bayes 估计为后验中位数, 即满足左右后验概率各不超过一半的点。若代价函数只关心是否估错, 例

如估对时代价为 0，估错时代价为 1，则最优估计为后验密度的最大点：

$$\hat{\alpha}_{\text{MAP}} = \arg \max_{\alpha} f_{\alpha|X}(\alpha|\mathbf{x}_0), \quad (7.11)$$

称为最大后验（maximum a posteriori, MAP）估计。MAP 与 MLE 形式相近，但 MAP 最大化的是后验密度，因而包含先验；当先验在参数范围内近似均匀时，MAP 才会退化为 MLE。

7.5 两类准则的取舍

MLE 的优势在于简单直接：一旦写出数据模型，就只需最大化似然函数。它在大样本下还具有良好渐近性质，因此在信号处理中非常常见。它的限制也同样清楚：MLE 不使用参数先验，也不直接表达不同误差大小的代价差异；有限样本下，其渐近优势未必已经体现。

Bayesian 方法的优势在于能够纳入先验信息，并能通过代价函数定义真正意义上的最优估计。例如若物理知识告诉我们参数必须为正，或很可能落在某个范围内，这些信息都可以写入先验。它还能根据平方误差、绝对误差或判决错误等不同目标给出不同估计器。其挑战是后验密度可能难以求出，且错误先验会把估计结果推向错误方向。

7.6 小结

最大似然和贝叶斯估计给出了两种不同的参数估计准则。MLE 把参数看成确定未知量，选择使观测数据最可能出现的参数；Bayesian 方法把参数看成随机量，先由先验和观测模型得到后验，再由代价函数决定估计值。平方误差对应后验均值，绝对误差对应后验中位数，0-1 型错误代价对应 MAP。实际使用时，若缺少可靠先验且希望得到直接的优化问题，MLE 往往自然；若有可信先验或明确的误差代价，Bayesian 框架更能表达问题本身。

第八章 最大似然估计的典型例子

本讲要点

本讲通过三个模型说明最大似然估计的使用方式。最大似然估计的第一步是写出观测数据在未知参数下的概率密度或概率质量函数，第二步才是把它看成参数的函数并最大化。高斯均值与方差估计给出样本均值和以 N 为分母的样本方差；高斯噪声中的线性信号模型导出加权最小二乘估计；泊松计数模型则说明计数率的最大似然估计就是平均计数。

8.1 最大似然估计的计算流程

设观测数据为 $\mathbf{x}$ ，未知参数为 α 。最大似然估计选择使观测数据最可能出现的参数值：

$$\hat{\alpha}_{\text{ML}} = \arg \max_{\alpha} f_{\mathbf{X}}(\mathbf{x}; \alpha). \quad (8.1)$$

这里 $f_{\mathbf{X}}(\mathbf{x}; \alpha)$ 是把观测 $\mathbf{x}$ 固定之后得到的似然函数。实际计算时通常先确定数据模型，再取对数似然

$$\ell(\alpha) = \ln f_{\mathbf{X}}(\mathbf{x}; \alpha), \quad (8.2)$$

因为对数函数单调递增，最大化 $\ell(\alpha)$ 与最大化原似然等价。对数还会把乘积变成求和，使微分和代数整理更直接。

8.2 高斯样本模型

例：高斯样本的均值与方差

观测 N 个独立高斯样本

$$x[n] \sim \mathcal{N}(\mu, \sigma^2), \quad n = 0, 1, \dots, N-1,$$

希望由数据估计均值 μ 和方差 σ^2 。由于样本独立，联合概率密度为

$$f_{\mathbf{X}}(\mathbf{x}; \mu, \sigma^2) = \frac{1}{(2\pi)^{N/2} (\sigma^2)^{N/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - \mu)^2 \right\}. \quad (8.3)$$

取对数并去掉与优化无关的常数项，可写成

$$\ell(\mu, \sigma^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - \mu)^2. \quad (8.4)$$

分别对 μ 和 σ^2 求导并令其为零：

$$\begin{aligned} \frac{\partial \ell}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - \mu) = 0, \\ \frac{\partial \ell}{\partial \sigma^2} &= -\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{n=0}^{N-1} (x[n] - \mu)^2 = 0. \end{aligned} \quad (8.5)$$

于是最大似然估计为

$$\begin{aligned}\hat{\mu}_{\text{ML}} &= \frac{1}{N} \sum_{n=0}^{N-1} x[n], \\ \hat{\sigma}_{\text{ML}}^2 &= \frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \hat{\mu}_{\text{ML}})^2.\end{aligned}\tag{8.6}$$

需要注意的是, $\hat{\sigma}_{\text{ML}}^2$ 使用分母 N , 它是方差的最大似然估计, 但有限样本下有偏; 统计中常见的无偏样本方差使用分母 $N-1$ 。MLE 的优势更多体现在大样本的渐近性质上。

8.3 线性信号模型

例：高斯噪声中的线性信号模型

设每次观测都是已知基函数的线性组合加高斯噪声：

$$\mathbf{x}_k = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}), \quad k = 1, 2, \dots, K.\tag{8.7}$$

其中 $\mathbf{H}$ 由已知基函数组成, $\boldsymbol{\theta}$ 是待估计系数。若把 K 次独立观测取平均, 记

$$\bar{\mathbf{x}} = \frac{1}{K} \sum_{k=1}^K \mathbf{x}_k,$$

则与 $\boldsymbol{\theta}$ 有关的对数似然等价于最小化二次型

$$J(\boldsymbol{\theta}) = \sum_{k=1}^K (\mathbf{x}_k - \mathbf{H}\boldsymbol{\theta})^\top \mathbf{R}^{-1} (\mathbf{x}_k - \mathbf{H}\boldsymbol{\theta}).\tag{8.8}$$

展开并配方后, 依赖 $\boldsymbol{\theta}$ 的部分可写为

$$\begin{aligned}J(\boldsymbol{\theta}) &= K\boldsymbol{\theta}^\top \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}\boldsymbol{\theta} - 2K\boldsymbol{\theta}^\top \mathbf{H}^\top \mathbf{R}^{-1} \bar{\mathbf{x}} + C \\ &= K(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{ML}})^\top \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{ML}}) + C',\end{aligned}\tag{8.9}$$

其中 C, C' 与 $\boldsymbol{\theta}$ 无关。因此只要 $\mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$ 可逆, 最小点为

$$\hat{\boldsymbol{\theta}}_{\text{ML}} = (\mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} \bar{\mathbf{x}}.\tag{8.10}$$

这就是加权最小二乘估计。若只有一次观测, 把 $\bar{\mathbf{x}}$ 换成 $\mathbf{x}$ 即可; 若噪声为白噪声 $\mathbf{R} = \sigma^2 \mathbf{I}$, 权矩阵只差一个常数, 估计退化为普通最小二乘:

$$\hat{\boldsymbol{\theta}}_{\text{ML}} = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{x}.\tag{8.11}$$

例如正弦信号

$$s[n] = A \cos(\omega_0 n) + B \sin(\omega_0 n)$$

可以把 $\cos(\omega_0 n)$ 和 $\sin(\omega_0 n)$ 看成两列基函数, 把 A, B 看成待估计系数。此时 $\mathbf{H}$ 是 $N \times 2$ 矩阵, $\boldsymbol{\theta} = [A \ B]^\top$ 。

8.4 泊松计数模型

例：盖革计数器的计数率估计

放射源在固定时间窗内发出的粒子数常用泊松分布建模。设独立观测计数为 $x_1, x_2, \dots, x_N$ ，且

$$x_i \sim \text{Poisson}(\lambda), \quad \Pr\{x_i = m\} = e^{-\lambda} \frac{\lambda^m}{m!}, \quad m = 0, 1, 2, \dots$$

联合概率质量函数为

$$p(\mathbf{x}; \lambda) = \prod_{i=1}^N e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = \frac{\lambda^{\sum_{i=1}^N x_i} e^{-N\lambda}}{\prod_{i=1}^N x_i!}. \quad (8.12)$$

取对数似然，

$$\ell(\lambda) = \left(\sum_{i=1}^N x_i \right) \ln \lambda - N\lambda - \sum_{i=1}^N \ln(x_i!). \quad (8.13)$$

对 λ 求导并令其为零：

$$\frac{d\ell}{d\lambda} = \frac{\sum_{i=1}^N x_i}{\lambda} - N = 0, \quad \hat{\lambda}_{\text{ML}} = \frac{1}{N} \sum_{i=1}^N x_i. \quad (8.14)$$

这个结果非常直观：泊松分布的参数 λ 是平均计数率，因此用重复测量的平均计数来估计它。若所有观测计数都为零，则最大点落在边界 $\lambda = 0$ 。

8.5 小结

三个例子展示了同一条主线：先写出 $f(\mathbf{x}; \alpha)$ ，再把观测数据固定并最大化参数函数。简单模型往往能给出闭式解，例如样本均值、样本方差、加权最小二乘和平均计数；更复杂的模型可能无法解析求解，需要数值优化。MLE 的形式简洁，但估计结果完全由所选概率模型决定，因此建模假设本身和优化步骤一样重要。

第九章 检测理论与假设检验入门

本讲要点

本讲从检测理论的基本语言开始，把“由观测数据作决定”写成假设检验问题。二元检测只有两个假设，常见例子是信号不存在与信号存在；多元检测则对应多个可能信号或类别。为了评价一个检测规则，需要定义判决区域、检测概率、虚警概率、漏检概率和特异性。对于阈值检验，改变阈值会同时改变 P_{FA} 和 P_D ，接收机工作特性曲线（receiver operating characteristic, ROC）正是用来描述这种权衡。

9.1 检测问题与假设

检测理论研究的是根据观测数据决定某个事件、目标或信号是否存在的问题。设观测向量为 $\mathbf{x}$ ，检测器把 $\mathbf{x}$ 映射为一个离散决定。最简单的情形是二元检测：

$$\begin{aligned} H_0 : & \text{信号不存在，观测只含噪声，} \\ H_1 : & \text{信号存在，观测为信号加噪声。} \end{aligned} \quad (9.1)$$

在离散时间信号模型中，可写成

$$\begin{aligned} H_0 : & x[n] = w[n], \\ H_1 : & x[n] = s[n] + w[n]. \end{aligned} \quad (9.2)$$

这里 $w[n]$ 是噪声， $s[n]$ 是待检测信号。雷达中的目标检测、通信中的同步检测、医学测试中的疾病筛查，都可以放进类似的二元假设检验框架。

多元检测有两个以上的假设。通信分类中，发送端可能从 M 个候选波形里选择一个发送，接收端根据观测数据判断哪一个波形最可能出现：

$$H_i : x[n] = s_i[n] + w[n], \quad i = 1, 2, \dots, M. \quad (9.3)$$

此时检测问题也可以看作分类问题：每个假设对应一个类别，每次观测必须被划入其中之一。

9.2 简单假设与复合假设

假设还可以按概率模型是否完全给定来分类。若在 H_i 下观测数据的概率密度函数完全已知，则称 H_i 为简单假设（simple hypothesis）。例如

$$H_i : \mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_i, \mathbf{R}), \quad \boldsymbol{\mu}_i, \mathbf{R} \text{ 已知}, \quad (9.4)$$

因为均值向量和协方差矩阵都已知， $f_{\mathbf{X}|H_i}(\mathbf{x}|H_i)$ 已完全确定。

若在某个假设下只知道模型形式，而模型中仍含未知参数，则称为复合假设。例如

$$H_1 : \mathbf{x} \sim \mathcal{N}(A\mathbf{s}, \sigma^2 \mathbf{I}), \quad A, \sigma^2 \text{ 未知}, \quad (9.5)$$

虽然可以确定观测服从高斯分布，且均值方向与 $\mathbf{s}$ 有关，但幅度 A 和噪声方差 σ^2 未知，因此概率密度函数没有被完全指定。复合假设检验通常需要额外处理这些未知参数，例如估计、边缘化或构造对参数不敏感的检验统计量。

9.3 判决区域

二元检测器可以等价地描述为对观测空间的划分。设

$$\mathcal{R}_0 = \{\mathbf{x} : \text{判定 } H_0\}, \quad \mathcal{R}_1 = \{\mathbf{x} : \text{判定 } H_1\}. \quad (9.6)$$

如果 $\mathbf{x} \in \mathcal{R}_0$, 检测器输出 H_0 ; 如果 $\mathbf{x} \in \mathcal{R}_1$, 检测器输出 H_1 。对于二维观测 $\mathbf{x} = [x_1 \ x_2]^T$, 判决区域可以画成平面上的两个区域, 分界线就是检测器的判决边界。




图 9.1: 二元检测可看成把观测空间划分为 $\mathcal{R}_0$ 与 $\mathcal{R}_1$ 。

实际检测器常先把高维数据压缩成一个标量检验统计量 $T(\mathbf{x})$, 再用阈值 η 划分判决区域:

$$T(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta. \quad (9.7)$$

若采用式 (9.7) 的方向, 则 $T(\mathbf{x}) \geq \eta$ 时判定 H_1 , 否则判定 H_0 。阈值越大, 判定 H_1 越保守; 阈值越小, 判定 H_1 越积极。

9.4 二元检测的性能指标

二元检测中, 真实假设与检测器决定各有两种可能, 因此共有四种结果。最重要的两个概率是检测概率和虚警概率:

$$\begin{aligned} P_D &= \Pr\{\text{判定 } H_1 \mid H_1 \text{ 为真}\}, \\ P_{FA} &= \Pr\{\text{判定 } H_1 \mid H_0 \text{ 为真}\}. \end{aligned} \quad (9.8)$$

P_D 描述信号真的存在时被正确发现的概率, 在医学测试中也称灵敏度 (sensitivity)。 P_{FA} 描述信号不存在时误判为存在的概率, 在统计学中对应第一类错误。

另外两个概率可由前两个得到。漏检概率为

$$P_M = \Pr\{\text{判定 } H_0 \mid H_1 \text{ 为真}\} = 1 - P_D, \quad (9.9)$$

它对应第二类错误; 当 H_0 为真且判定 H_0 时, 决定正确, 其概率为

$$\Pr\{\text{判定 } H_0 \mid H_0 \text{ 为真}\} = 1 - P_{FA}, \quad (9.10)$$

在医学测试中称为特异性 (specificity)。

若检测器由判决区域 $\mathcal{R}_0, \mathcal{R}_1$ 描述, 则虚警概率和检测概率可写为区域积分:

$$\begin{aligned} P_{FA} &= \int_{\mathbf{x} \in \mathcal{R}_1} f_{X|H_0}(\mathbf{x}|H_0) d\mathbf{x}, \\ P_D &= \int_{\mathbf{x} \in \mathcal{R}_1} f_{X|H_1}(\mathbf{x}|H_1) d\mathbf{x}. \end{aligned} \quad (9.11)$$

两者都在同一个判决区域 $\mathcal{R}_1$ 上积分，但使用的条件密度不同：虚警概率使用 H_0 下的数据分布，检测概率使用 H_1 下的数据分布。

9.5 阈值、密度重叠与权衡

对阈值检验，令 $f_{T|H_0}(t|H_0)$ 和 $f_{T|H_1}(t|H_1)$ 分别表示统计量 $T(\mathbf{x})$ 在两个假设下的密度。若 $T(\mathbf{x}) \geq \eta$ 判定 H_1 ，则

$$\begin{aligned} P_{\text{FA}}(\eta) &= \int_{\eta}^{\infty} f_{T|H_0}(t|H_0) dt, \\ P_{\text{D}}(\eta) &= \int_{\eta}^{\infty} f_{T|H_1}(t|H_1) dt. \end{aligned} \quad (9.12)$$

这两个积分对应阈值右侧的尾概率。把阈值向右移动，会减少 H_0 密度右尾的面积，从而降低虚警概率；同时也会减少 H_1 密度右尾的面积，从而降低检测概率。因而 P_{FA} 和 P_{D} 通常不能独立调节。




图 9.2: 阈值检验中，虚警概率和检测概率分别是两个条件密度在阈值右侧的尾面积。

若两个条件密度有明显重叠，就不可能通过某个阈值同时达到 $P_{\text{FA}} = 0$ 和 $P_{\text{D}} = 1$ 。完美检测要求所有 H_0 样本的统计量都落在阈值左侧，所有 H_1 样本的统计量都落在阈值右侧；密度重叠意味着这两个要求无法同时满足。

9.6 ROC 曲线

接收机工作特性曲线 (receiver operating characteristic, ROC) 以 P_{FA} 为横轴、 P_{D} 为纵轴，描述阈值变化时一组点

$$(P_{\text{FA}}(\eta), P_{\text{D}}(\eta)) \quad (9.13)$$

形成的轨迹。对于式 (9.7) 的检验， $\eta \rightarrow -\infty$ 时检测器总是判定 H_1 ，因此 $(P_{\text{FA}}, P_{\text{D}}) = (1, 1)$ ； $\eta \rightarrow +\infty$ 时检测器总是判定 H_0 ，因此 $(P_{\text{FA}}, P_{\text{D}}) = (0, 0)$ 。




图 9.3: ROC 曲线描述 P_{FA} 与 P_D 的权衡；左上角越接近理想检测。

ROC 图中的左上角对应低虚警、高检测，是最理想的工作区域。对完全不利用数据的随机判决，性能位于从 $(0, 0)$ 到 $(1, 1)$ 的机会线附近。一个有用的检测器应当让 ROC 曲线高于机会线；在同一虚警概率下，检测概率越高，测试越好。




图 9.4: 若 T_2 的 ROC 曲线整体位于 T_1 上方，则 T_2 在相同虚警概率下能取得更高检测概率。

9.7 小结

检测理论把观测数据到离散决定的映射写成假设检验问题。二元检测的核心对象是判决区域或阈值检验；核心性能指标是 P_D 、 P_{FA} 、漏检概率和特异性。阈值变化会在检测概率和虚警概率之间形成权衡，ROC 曲线把这种权衡画成一条曲线，并提供了比较不同检测器的统一方式。下一步建立具体检测策略时，关键就在于怎样选择统计量 $T(\mathbf{x})$ 和阈值 η 。

第十章 似然比检验

本讲要点

本讲讨论二元简单假设下怎样选择检验统计量。若 H_0 与 H_1 下观测向量 $\mathbf{x}$ 的概率密度函数完全已知，Neyman–Pearson 引理给出固定虚警概率下检测概率最大的检验：似然比检验（likelihood ratio test, LRT）。在已知信号形状的高斯噪声检测中，似然比检验化为匹配滤波统计量 $\mathbf{s}^T \mathbf{x}$ ，其 ROC 曲线只由信噪比控制。

10.1 简单假设下的最优检验

二元检测仍写成对统计量 $T(\mathbf{x})$ 的阈值检验：

$$T(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta. \quad (10.1)$$

上一讲已经看到，阈值 η 决定虚警概率 P_{FA} 与检测概率 P_{D} 的折中。现在的问题不是怎样移动阈值，而是怎样选择统计量 $T(\mathbf{x})$ ，使 ROC 曲线在固定 P_{FA} 时尽可能高。

当两个假设都是简单假设时，条件密度 $f_{\mathbf{X}|H_0}(\mathbf{x}|H_0)$ 与 $f_{\mathbf{X}|H_1}(\mathbf{x}|H_1)$ 已完全给定。Neyman–Pearson 引理说明，在所有满足同一虚警概率约束的检验中，使检测概率 P_{D} 最大的统计量是似然比

$$L(\mathbf{x}) = \frac{f_{\mathbf{X}|H_1}(\mathbf{x}|H_1)}{f_{\mathbf{X}|H_0}(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \eta. \quad (10.2)$$

式中分子衡量当前观测在 H_1 下出现的可能性，分母衡量同一观测在 H_0 下出现的可能性。若 $L(\mathbf{x})$ 很大，说明这组数据更支持 H_1 ；若 $L(\mathbf{x})$ 很小，则更支持 H_0 。

阈值 η 通常由目标虚警概率决定。设 $L(\mathbf{x})$ 在 H_0 下的密度为 $f_{L|H_0}(\ell|H_0)$ ，则

$$P_{\text{FA}} = \Pr\{L(\mathbf{x}) > \eta \mid H_0\} = \int_{\eta}^{\infty} f_{L|H_0}(\ell|H_0) d\ell. \quad (10.3)$$

给定一个允许的虚警概率后，可由式 (10.3) 反求 η 。在这个阈值下，似然比检验达到该虚警概率对应的最大检测概率。

10.2 已知信号的高斯噪声检测

例：已知信号形状的似然比检验

设观测向量 $\mathbf{x} = [x[0], x[1], \dots, x[N-1]]^T$ ，噪声为零均值白高斯噪声。需要在“只有噪声”和“已知信号加噪声”之间作决定：

$$\begin{aligned} H_0 : \mathbf{x} &= \mathbf{w}, & \mathbf{x} &\sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), \\ H_1 : \mathbf{x} &= \mathbf{s} + \mathbf{w}, & \mathbf{x} &\sim \mathcal{N}(\mathbf{s}, \sigma^2 \mathbf{I}). \end{aligned} \quad (10.4)$$

这里 $\mathbf{s}$ 与 σ^2 已知，因此两个假设都是简单假设。两个条件密度为

$$\begin{aligned} f_{X|H_0}(\mathbf{x}|H_0) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2}\mathbf{x}^\top\mathbf{x}\right\}, \\ f_{X|H_1}(\mathbf{x}|H_1) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2}(\mathbf{x}-\mathbf{s})^\top(\mathbf{x}-\mathbf{s})\right\}. \end{aligned} \quad (10.5)$$

代入似然比后，公共归一化因子相消；取对数并整理得

$$\begin{aligned} \ln L(\mathbf{x}) &= -\frac{1}{2\sigma^2}(\mathbf{x}-\mathbf{s})^\top(\mathbf{x}-\mathbf{s}) + \frac{1}{2\sigma^2}\mathbf{x}^\top\mathbf{x} \\ &= \frac{1}{\sigma^2}\mathbf{s}^\top\mathbf{x} - \frac{1}{2\sigma^2}\mathbf{s}^\top\mathbf{s}. \end{aligned} \quad (10.6)$$

后一项不依赖观测数据，因此检验可等价写成

$$T(\mathbf{x}) = \mathbf{s}^\top\mathbf{x} = \sum_{n=0}^{N-1} s[n]x[n] \underset{H_0}{\overset{H_1}{\geq}} \gamma. \quad (10.7)$$

这个内积把观测投影到已知信号 $\mathbf{s}$ 的方向上；在信号处理中，它等价于匹配滤波器在特定时刻的输出。

统计量 $Z = \mathbf{s}^\top\mathbf{x}$ 仍为高斯随机变量。在 H_0 下，

$$Z | H_0 \sim \mathcal{N}(0, \sigma^2 \mathbf{s}^\top \mathbf{s}), \quad (10.8)$$

在 H_1 下，

$$Z | H_1 \sim \mathcal{N}(\mathbf{s}^\top \mathbf{s}, \sigma^2 \mathbf{s}^\top \mathbf{s}). \quad (10.9)$$

若记 $Q(a) = \int_a^\infty (2\pi)^{-1/2} \exp(-u^2/2) du$ ，则

$$\begin{aligned} P_{\text{FA}} &= Q\left(\frac{\gamma}{\sigma\sqrt{\mathbf{s}^\top \mathbf{s}}}\right), \\ P_{\text{D}} &= Q\left(\frac{\gamma - \mathbf{s}^\top \mathbf{s}}{\sigma\sqrt{\mathbf{s}^\top \mathbf{s}}}\right). \end{aligned} \quad (10.10)$$

消去阈值后，ROC 可写成

$$P_{\text{D}} = Q\left(Q^{-1}(P_{\text{FA}}) - \sqrt{\frac{\mathbf{s}^\top \mathbf{s}}{\sigma^2}}\right). \quad (10.11)$$

因此该例的性能由信号能量相对噪声方差的比值控制。信噪比越大，两个高斯分布的均值分离越明显，同一虚警概率下的检测概率越高。




图 10.1: 已知信号高斯检测的理论 ROC 曲线。SNR 从 0.1 增大到 10 时, 曲线逐渐靠近左上角。

10.3 本讲 MATLAB 代码

lec_10_ROC_snr.m 计算式 (10.11) 给出的理论 ROC 曲线。程序用 `erfc` 和 `erfcinv` 实现 Q 函数及其反函数, 分别绘制 $\text{SNR} = 0.1, 1, 3, 10$ 的曲线, 并导出 `ROC_curve.pdf`。

```

1  clear;
2  clc;
3  close all;
4
5  snrList = [0.1, 1, 3, 10];
6  PfaInner = linspace(1e-6, 1 - 1e-6, 2000);
7  Qfun = @(x) 0.5 .* erfc(x ./ sqrt(2));
8  QinvFun = @(p) sqrt(2) .* erfcinv(2 .* p);
9  curveColors = [
10     0.00, 0.00, 0.00
11     0.28, 0.27, 0.52
12     0.48, 0.66, 0.33
13     0.75, 0.25, 0.25
14 ];
15
16 fig = figure();
17 ax = axes(fig);
18 hold(ax, 'on');
19
20 for k = 1:numel(snrList)
21     snrValue = snrList(k);
22     PdInner = Qfun(QinvFun(PfaInner) - sqrt(snrValue));
23     Pfa = [0, PfaInner, 1];
24     Pd = [0, PdInner, 1];
25     plot(ax, Pfa, Pd, ...

```



```

26         'Color', curveColors(k, :), ...
27         'LineWidth', 1.5);
28     end
29
30     xlim(ax, [0, 1]);
31     ylim(ax, [0, 1]);
32     xticks(ax, 0:0.2:1);
33     yticks(ax, 0:0.2:1);
34     xlabel(ax, 'Prob False Alarm', ...
35         'FontSize', 17, ...
36         'FontWeight', 'normal');
37     ylabel(ax, 'Prob Detection', ...
38         'FontSize', 17, ...
39         'FontWeight', 'normal');
40     title(ax, 'Receiver Operating Characteristic', ...
41         'FontSize', 18, ...
42         'FontWeight', 'normal');
43     legend(ax, ...
44         {'SNR = 0.1', 'SNR = 1', 'SNR = 3', 'SNR = 10'}, ...
45         'Location', 'southeast', ...
46         'FontSize', 14, ...
47         'Box', 'on');
48     set(ax, ...
49         'FontSize', 14, ...
50         'LineWidth', 1, ...
51         'Box', 'on', ...
52         'Layer', 'top');
53
54     grid(ax, 'off');
55     hold(ax, 'off');
56
57     pdfName = 'ROC_curve.pdf';
58
59     if exist('exportgraphics', 'file') == 2
60         exportgraphics(fig, pdfName, ...
61             'ContentType', 'vector', ...
62             'BackgroundColor', 'white');
63     else
64         set(fig, ...
65             'PaperUnits', 'inches', ...
66             'PaperPosition', [0, 0, 8.6, 6.5], ...
67             'PaperSize', [8.6, 6.5], ...
68             'PaperPositionMode', 'manual');
69         print(fig, pdfName, '-dpdf', '-painters');
70     end
71
72     fprintf('PDF 文件已导出: %s\n', fullfile(pwd, pdfName));

```

10.4 小结

似然比检验把“当前观测更像哪个假设”写成两个条件密度的比值。对于二元简单假设，NP引理保证LRT在给定 P_{FA} 时达到最大的 P_{D} 。在已知信号加白高斯噪声的例子中，LRT化为匹配滤波统计量 $\mathbf{s}^T \mathbf{x}$ ，其ROC只依赖信号能量与噪声方差之比。若假设中含未知参数，简单假设的最优性条件不再直接成立，这就引出下一讲的广义似然比检验。

第十一章 广义似然比检验

本讲要点

本讲把似然比检验推广到复合假设。复合假设下， H_0 或 H_1 的概率密度函数含有未知参数，通常无法直接应用简单假设下的最优 LRT。广义似然比检验（generalized likelihood ratio test, GLRT）用各假设下的最大似然估计替代未知参数，再形成似然比。核心例子是已知信号形状、未知幅度和未知噪声功率的高斯检测，最终统计量可解释为“与信号方向对齐的能量”相对于“未对齐能量”的比值，并具有 CFAR 性质。

11.1 从简单假设到复合假设

二元假设检验仍以

$$T(\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} \eta \quad (11.1)$$

为基本形式。若 H_0 与 H_1 都是简单假设，则最优统计量是似然比，它在任意给定虚警概率下给出最大可能检测概率。这个结论依赖一个强条件：两个假设下的数据密度都必须完全已知。

复合假设中，密度函数只给出模型族，而其中参数未知。例如 $f_{\mathbf{X}|H_0}(\mathbf{x}; \boldsymbol{\alpha}_0)$ 和 $f_{\mathbf{X}|H_1}(\mathbf{x}; \boldsymbol{\alpha}_1)$ 中的 $\boldsymbol{\alpha}_0, \boldsymbol{\alpha}_1$ 没有预先给定。此时一般不存在像 Neyman–Pearson 引理那样普遍适用的最优检验。GLRT 的思想是先在每个假设内部选择最能解释当前观测的参数，再比较这两个“最佳解释”的似然大小。

11.2 GLRT 的定义

设

$$\begin{aligned} H_0 &: f_{\mathbf{X}|H_0}(\mathbf{x}; \boldsymbol{\alpha}_0), & \boldsymbol{\alpha}_0 \text{ 未知}, \\ H_1 &: f_{\mathbf{X}|H_1}(\mathbf{x}; \boldsymbol{\alpha}_1), & \boldsymbol{\alpha}_1 \text{ 未知}. \end{aligned} \quad (11.2)$$

在第 i 个假设下，未知参数用最大似然估计

$$\hat{\boldsymbol{\alpha}}_i = \arg \max_{\boldsymbol{\alpha}_i} f_{\mathbf{X}|H_i}(\mathbf{x}; \boldsymbol{\alpha}_i), \quad i = 0, 1 \quad (11.3)$$

替代。广义似然比检验定义为

$$L_G(\mathbf{x}) = \frac{f_{\mathbf{X}|H_1}(\mathbf{x}; \hat{\boldsymbol{\alpha}}_1)}{f_{\mathbf{X}|H_0}(\mathbf{x}; \hat{\boldsymbol{\alpha}}_0)} = \frac{\max_{\boldsymbol{\alpha}_1} f_{\mathbf{X}|H_1}(\mathbf{x}; \boldsymbol{\alpha}_1)}{\max_{\boldsymbol{\alpha}_0} f_{\mathbf{X}|H_0}(\mathbf{x}; \boldsymbol{\alpha}_0)} \underset{H_0}{\overset{H_1}{\geq}} \eta. \quad (11.4)$$

GLRT 不保证在所有复合假设问题中都是最优的；它的优点是构造明确，且把参数估计和假设比较合并同一套似然框架中。

11.3 已知形状信号的 GLRT

例：已知信号形状、未知幅度和未知噪声功率

设 $\mathbf{x} \in \mathbb{R}^N$ ，已知信号形状为 $\mathbf{s}$ ，但信号幅度 A 和噪声方差 σ^2 未知。检测模型为

$$\begin{aligned} H_0: \mathbf{x} &= \mathbf{w}, & \mathbf{x} &\sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), & \sigma^2 \text{ 未知}, \\ H_1: \mathbf{x} &= A\mathbf{s} + \mathbf{w}, & \mathbf{x} &\sim \mathcal{N}(A\mathbf{s}, \sigma^2 \mathbf{I}), & A, \sigma^2 \text{ 未知}. \end{aligned} \quad (11.5)$$

在不失一般性的条件下取 $\mathbf{s}^\top \mathbf{s} = 1$ ，因为 $\mathbf{s}$ 的尺度可以吸收到未知幅度 A 中。

两个假设下的高斯密度为

$$\begin{aligned} f_{\mathbf{X}|H_0}(\mathbf{x}; \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} \mathbf{x}^\top \mathbf{x}\right\}, \\ f_{\mathbf{X}|H_1}(\mathbf{x}; A, \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left\{-\frac{1}{2\sigma^2} (\mathbf{x} - A\mathbf{s})^\top (\mathbf{x} - A\mathbf{s})\right\}. \end{aligned} \quad (11.6)$$

分别在两个假设下最大化似然，得到

$$\begin{aligned} H_0: \quad \hat{\sigma}_0^2 &= \frac{1}{N} \mathbf{x}^\top \mathbf{x}, \\ H_1: \quad \hat{A} &= \frac{\mathbf{s}^\top \mathbf{x}}{\mathbf{s}^\top \mathbf{s}}, \quad \hat{\sigma}_1^2 = \frac{1}{N} (\mathbf{x} - \hat{A}\mathbf{s})^\top (\mathbf{x} - \hat{A}\mathbf{s}). \end{aligned} \quad (11.7)$$

这里 $\hat{A}$ 是把观测投影到信号形状方向上的最小二乘幅度估计， $\hat{\sigma}_1^2$ 是扣除该信号分量后的平均残差能量。

把 MLE 代入 GLRT，指数项中的二次型在两个最大似然方差处分别等于 $N\hat{\sigma}_1^2$ 和 $N\hat{\sigma}_0^2$ ，因此指数因子相消，得到

$$\begin{aligned} L_G(\mathbf{x}) &= \frac{f_{\mathbf{X}|H_1}(\mathbf{x}; \hat{A}, \hat{\sigma}_1^2)}{f_{\mathbf{X}|H_0}(\mathbf{x}; \hat{\sigma}_0^2)} \\ &= \left(\frac{\hat{\sigma}_0^2}{\hat{\sigma}_1^2} \right)^{N/2} \underset{H_0}{\overset{H_1}{\geq}} \eta. \end{aligned} \quad (11.8)$$

因为 $u \mapsto u^{N/2}$ 单调递增，检验可等价写成方差比

$$L'(\mathbf{x}) = \frac{\hat{\sigma}_0^2}{\hat{\sigma}_1^2} = \frac{\mathbf{x}^\top \mathbf{x}}{(\mathbf{x} - \hat{A}\mathbf{s})^\top (\mathbf{x} - \hat{A}\mathbf{s})} \underset{H_0}{\overset{H_1}{\geq}} \eta'. \quad (11.9)$$

再利用 $\mathbf{s}^\top \mathbf{s} = 1$ 和 $\hat{A} = \mathbf{s}^\top \mathbf{x}$ ，可以把统计量改写为

$$L''(\mathbf{x}) = \frac{(\mathbf{x}^\top \mathbf{s})^2}{\mathbf{x}^\top \mathbf{x} - (\mathbf{x}^\top \mathbf{s})^2} \underset{H_0}{\overset{H_1}{\geq}} \eta''. \quad (11.10)$$

分子是观测在 $\mathbf{s}$ 方向上的能量，分母是总能量扣除该方向投影后的剩余能量。内积

$$\mathbf{x}^\top \mathbf{s} = \sum_{n=0}^{N-1} x[n]s[n] \quad (11.11)$$

就是匹配滤波器输出的核心量。若信号存在， $\mathbf{x}$ 与 $\mathbf{s}$ 对齐的能量倾向于增大，式 (11.10) 也随之增大；若只有噪声，该方向并不会比其它方向获得系统性优势。

为了写出门限和性能，常把式 (11.10) 乘以常数 $N-1$ ，定义等价统计量

$$T_G(\mathbf{x}) = (N-1)L''(\mathbf{x}) = \frac{(\mathbf{x}^\top \mathbf{s})^2}{[\mathbf{x}^\top \mathbf{x} - (\mathbf{x}^\top \mathbf{s})^2]/(N-1)}. \quad (11.12)$$

在 H_0 下, 分子对应一个自由度为 1 的中心 χ^2 变量, 分母对应自由度为 $N - 1$ 的独立中心 χ^2 变量除以 $N - 1$, 因此

$$T_G(\mathbf{x}) | H_0 \sim F_{1,N-1}. \quad (11.13)$$

在 H_1 下, 沿 $\mathbf{s}$ 方向的分量均值为 A , 分子变为非中心 χ^2 变量, 因此

$$T_G(\mathbf{x}) | H_1 \sim F_{1,N-1}\left(\frac{A^2}{\sigma^2}\right). \quad (11.14)$$

非中心参数 A^2/σ^2 就是该归一化模型下的 SNR。

由式 (11.13) 可知, 门限只需根据 N 和目标 P_{FA} 由中心 F 分布确定, 不依赖未知的 σ^2 或 A 。因此该检验具有恒虚警率 (constant false alarm rate, CFAR) 性质。检测概率则由 N 和 $\text{SNR} = A^2/\sigma^2$ 决定; SNR 越大, H_1 下的非中心 F 分布越向右偏移, 同一门限下更容易判定 H_1 。




图 11.1: $N = 20$ 时 GLRT 的 ROC 曲线。低 SNR 曲线接近机会线, SNR 增大后 ROC 明显上移。

11.4 本讲 MATLAB 代码

lec_11_ROC_snr.m 以 $N = 20$ 为例, 先用 H_0 下的中心 $F_{1,N-1}$ 分布由 P_{FA} 反求门限, 再用 H_1 下非中心 F 分布计算 P_D 。程序绘制 $\text{SNR} = 0.1, 1, 3, 10$ 的 ROC 曲线, 并导出 ROC_N20.pdf。

```

1 clear;
2 clc;
3 close all;
4
5 N = 20;
6 snrList = [0.1, 1, 3, 10];
7 PfaInner = linspace(1e-6, 1-1e-6, 2000);
8 curveColors = [
9     0.00, 0.00, 0.00

```

```

10     0.30, 0.30, 0.60
11     0.50, 0.70, 0.35
12     0.90, 0.20, 0.20
13 ];
14
15 fig = figure();
16 ax = axes(fig);
17 hold(ax, 'on');
18
19 threshold = finv(1-PfaInner, 1, N-1);
20
21 for k = 1:length(snrList)
22     lambda = snrList(k);
23     PdInner = 1 - ncfcdf(threshold, 1, N-1, lambda);
24     Pfa = [0, PfaInner, 1];
25     Pd = [0, PdInner, 1];
26     plot(Pfa, Pd, ...
27         'Color', curveColors(k,:), ...
28         'LineWidth', 1.5);
29 end
30
31 xlim([0, 1]);
32 ylim([0, 1]);
33 xticks(0:0.2:1);
34 yticks(0:0.2:1);
35 xlabel('Prob False Alarm', 'FontSize', 15);
36 ylabel('Prob Detection', 'FontSize', 15);
37 title('Receiver Operating Characteristic', ...
38     'FontSize', 15, ...
39     'FontWeight', 'normal');
40 legend( ...
41     {'SNR = 0.1', 'SNR = 1', 'SNR = 3', 'SNR = 10'}, ...
42     'Location', 'southeast', ...
43     'FontSize', 12);
44 set(gca, ...
45     'FontSize', 12, ...
46     'LineWidth', 1, ...
47     'Box', 'on');
48
49 grid off;
50 hold off;
51
52 exportgraphics(fig, 'ROC_N20.pdf', ...
53     'ContentType', 'vector', ...
54     'BackgroundColor', 'white');
55
56 fprintf('已导出: %s\n', fullfile(pwd, 'ROC_N20.pdf'));

```

11.5 小结

GLRT 处理的是含未知参数的复合假设：在每个假设下先求最大似然估计，再比较两个最大化后的似然。已知信号形状、未知幅度与未知噪声功率的例子中，GLRT 最终化为投影能量与残差能量的比值：它本质上仍依赖匹配滤波内积 $\mathbf{x}^T \mathbf{s}$ ，但同时用剩余能量估计噪声水平。归一化后的统计量服从中心或非中心 F 分布，使门限只依赖样本长度 N 和目标虚警概率，从而得到 CFAR 检验。