




信息论、模式识别和神经网络课程讲义

Notes on Information Theory, Pattern Recognition and Neural Networks

作者：StayAtHome@bilibili

组织：University of Cambridge

时间：August 7, 2026

版本：v1.0

整理：课程字幕与公开讲义材料

参考资料、版本更迭与声明

参考资料

本讲义主要参考 David J. C. MacKay 的 公开视频课程、课程 slides 与黑板板书 snapshots，以及教材 *Information Theory, Inference, and Learning Algorithms*。

版本更迭

- v1.0 根据课程 slides、黑板板书 snapshot 和视频字幕内容组合而成，更新于 2026-08-07（由于主观或客观原因，该笔记仅记录至第十二讲-蒙特卡罗方法）。

声明

本讲义由公开课程材料与字幕整理而成，仅用于学习交流。课程内容版权归原作者与相应发布方所有；整理过程中可能仍有疏漏，后续将结合人工校对继续修订。

目录

第一章 简介	1
1.1 信息论导论	1
第二章 熵与数据压缩	7
2.1 数据压缩与信息量	7
2.2 源编码定理	10
2.3 符号编码	13
2.4 符号编码与算术编码	16
第三章 噪声信道编码	20
3.1 噪声信道中的推断与信息度量	20
3.2 噪声信道容量	25
3.3 噪声信道编码定理	29
第四章 贝叶斯推断	32
4.1 参数推断	32
4.2 参数与模型推断	37
第五章 近似概率分布	42
5.1 聚类作为推断问题	42
5.2 蒙特卡洛方法	46
第六章 用神经网络进行数据建模	51

第一章 简介

1.1 信息论导论

基本问题：如何在不完美信道上实现可靠通信

设源消息为 s ，译码结果为 $\hat{s}$ 。可靠通信的理想目标是 $\hat{s} = s$ ；在有噪声信道中，更实际的说法是让错误概率 $\mathbb{P}(\hat{s} \neq s)$ 足够小。系统框图可以如图 1.1 所示。




图 1.1: 通信系统框图。

本讲从 Shannon 的通信问题进入信息论：怎样在有噪声的物理信道上可靠地传递消息。声音经过空气到达人耳，光学信号经由眼睛进入大脑，DNA 在复制中传递遗传信息，探测器和地球天线通过电磁波通信，电话机之间通过铜线进行通信，硬盘把今天写入的数据传给未来的读出装置；这些例子表面上相差很远，但都包含同一个抽象问题：

$$\text{接收信号} \simeq \text{发射信号} + \text{噪声}. \quad (1.1)$$

降低错误率有两条思路。第一条是改善物理信道本身，例如使用更可靠的器件、更强的信号、更好的绝缘或更低的热噪声。第二条是系统解法：接受原始信道并不完美，在传输前加入冗余，在传输后用译码算法恢复消息。信息论关心后者的极限：在给定信道上，最好的纠错性能能做到什么程度；编码理论则关心怎样构造实际可用的编码器和译码器。

二元对称信道

本讲使用的最小模型是二元对称信道 (binary symmetric channel, BSC)。每次使用信道时，输入和输出都属于 $\{0, 1\}$ ；输入比特以概率 f 被翻转，以概率 $1 - f$ 保持不变。转移矩阵为

$$Q = \begin{bmatrix} 1-f & f \\ f & 1-f \end{bmatrix}. \quad (1.2)$$

可靠性的数量级

例题 1.1 硬盘作为 BSC 问题：若硬盘写入可视为翻转概率 $f = 0.1$ 的 BSC，写入 $N = 10,000$ 个比特时典型会有多少错误？商业硬盘需要怎样的有效误码率数量级？

答案：错误比特数 X 服从二项分布，其均值、方差和标准差为

$$X \sim \text{Binomial}(N, f), \quad \mathbb{E}[X] = 1000, \quad \text{Var}(X) = 900, \quad \text{sd}(X) = 30. \quad (1.3)$$

因此典型错误数约为 1000 ± 30 。




图 1.2: 二元对称信道。

如果目标是可销售的 1GB 硬盘，要求会严得多。连续五年每天写入约 1GB，总写入量约为 $5 \times 365 \times 8 \times 10^9 \approx 1.46 \times 10^{13}$ bits。若希望整个使用期内至少一次不可恢复错误的概率很小，则每比特有效误码率必须压到大约 10^{-15} ，甚至 10^{-18} 的量级。直接把 $f = 0.1$ 的物理信道交给用户是不可能的，冗余编码因而成为必要。

说明：这个例子把“物理信道有噪声”变成数量级问题。未经编码的 10% 翻转率和实际存储可靠性之间差了十几个数量级，可靠通信必须依赖系统级编码。

二元对称信道上的纠错码

纠错码的基本想法是在消息中加入接收端已知的冗余。最简单的冗余是奇偶校验：例如令校验位

$$p = s_1 \oplus s_2 \oplus \cdots \oplus s_k, \quad (1.4)$$

使数据位和校验位中的 1 的总数为偶数。单个翻转会破坏奇偶约束，因此可以被检测；但一个奇偶位通常不能指出哪一位出错，也不能检测所有偶数个翻转。

重复码

三重重复码 R_3 把 0 编成 000，把 1 编成 111，码率为 $R = 1/3$ 。

例题 1.2 三重重复码译码 问题：源序列 $s = 01101$ 经过三重重复码和给定噪声后，应怎样译码？

答案：编码后 $t = 000\ 111\ 111\ 000\ 111$ 。若噪声为 $n = 000\ 100\ 000\ 101\ 000$ ，接收端得到 $r = t \oplus n = 000\ 011\ 111\ 101\ 111$ 。译码器把 r 按三个比特分组，并对每组作多数表决。

接收三元组	译码	接收三元组	译码
000	0	111	1
001	0	110	1
010	0	101	1
100	0	011	1

解码器是推断（inference），是逆概率（inverse probability）。译码的最优目标是在给定接收向量

$\mathbf{r}$ 后选择后验概率最大的源消息。乘法规则和求和规则给出 Bayes 公式：

$$\mathbb{P}(\mathbf{s} | \mathbf{r}) = \frac{\mathbb{P}(\mathbf{r} | \mathbf{s})\mathbb{P}(\mathbf{s})}{\sum_{\mathbf{s}'} \mathbb{P}(\mathbf{r} | \mathbf{s}')\mathbb{P}(\mathbf{s}')} \quad (1.5)$$

分子中的 $\mathbb{P}(\mathbf{r} | \mathbf{s})$ 是源消息给定后的接收似然， $\mathbb{P}(\mathbf{s})$ 是先验概率。若先验均匀， $\mathbb{P}(s=0) = \mathbb{P}(s=1) = 1/2$ ；接收到 $\mathbf{r} = 001$ 时，源比特为 0 只需一次翻转，源比特为 1 需要两次翻转，即 $\mathbb{P}(001 | s=0) = (1-f)^2 f$ ，而 $\mathbb{P}(001 | s=1) = f^2(1-f)$ 。归一化后得到 $\mathbb{P}(s=0 | 001) = 1-f$ ， $\mathbb{P}(s=1 | 001) = f$ 。当 $f < 1/2$ 时，应选择 $s=0$ ，这正是多数表决。

每个三比特块中若没有错误或只有一个错误，多数表决能恢复源比特；若有两个或三个翻转，多数表决会给出错误结果。因此 R_3 能纠正每个分组内的任意单比特错误，但不能纠正两个错误。

说明：多数表决是一个后验最大化规则。接收三元组越接近 000，源比特为 0 的似然越大；越接近 111，源比特为 1 的似然越大。

重复码的性能：前向概率（Forward Probability）

R_3 译错当且仅当三个传输比特中至少两个被翻转。其比特错误率为

$$\begin{aligned} p_b &= \binom{3}{2} f^2(1-f) + \binom{3}{3} f^3 \\ &= 3f^2(1-f) + f^3 \\ &= 3f^2 - 2f^3. \end{aligned} \quad (1.6)$$

当 f 很小时，主导项为 $p_b \simeq 3f^2$ 。

例题 1.3 三重重复码的误码率 问题：BSC 翻转概率为 $f = 0.1$ 时，三重重复码 R_3 的译错概率是多少？

答案：代入式 (1.6) 得 $p_b = 3(0.1)^2 - 2(0.1)^3 = 0.028$ 。相比未编码时的 0.1 明显下降，但码率也从 1 降到 $1/3$ 。

说明：重复码用码率换可靠性。它能降低错误率，却很快消耗大量信道使用次数。

一般地，奇数重重复码 R_{2m+1} 的码率为 $1/(2m+1)$ ，误码率为

$$p_b(R_{2m+1}) = \sum_{k=m+1}^{2m+1} \binom{2m+1}{k} f^k (1-f)^{2m+1-k}. \quad (1.7)$$

当 $f = 0.1$ 时，若想单靠重复把误码率压到约 10^{-15} ，需要大约 61 次重复，码率只有约 $1/61$ 。重复码能把错误率压低，但代价是码率迅速趋近于零。

(7,4) 汉明码

(7,4) Hamming 码把四个源比特编码成七个传输比特，码率为 $R = 4/7$ 。它使用三个重叠的奇偶校验，使每个传输位置都有唯一的校验参与模式。采用系统型写法时，前四位直接保存源比特，即 $(t_1, t_2, t_3, t_4) = (s_1, s_2, s_3, s_4)$ ；后三位由

$$\begin{aligned} t_5 &= s_1 \oplus s_2 \oplus s_3, \\ t_6 &= s_2 \oplus s_3 \oplus s_4, \\ t_7 &= s_1 \oplus s_3 \oplus s_4 \end{aligned} \quad (1.8)$$

给出。写成矩阵形式为


$$t = sG, \quad G = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 0 & 1 & 1 \end{bmatrix}, \quad (1.9)$$

所有运算均在模 2 下进行。


例题 1.4 Hamming 码编码 问题：系统型 (7, 4) Hamming 码如何把四个源比特编码成七个传输比特？

答案：按式 (1.8) 计算三个校验位。例如 $1000 \mapsto 1000101$, $1110 \mapsto 1110100$ 。

说明：前四位保留原始消息，后三位记录三个重叠奇偶约束。重叠结构使不同传输位置拥有不同的综合模式。



(a) (7, 4) Hamming 码的编码韦恩图



(b) (7, 4) Hamming 码的译码韦恩图

图 1.3: (7, 4) Hamming 码的编码和译码韦恩图。

综合译码

定义校验矩阵

$$H = \begin{bmatrix} 1 & 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 1 \end{bmatrix}. \quad (1.10)$$

合法码字满足 $Ht^T = 0$ 。对接收向量 r ，定义综合 (syndrome) 为

$$z = Hr^T. \quad (1.11)$$

由于 $r = t \oplus n$ 且 $Ht^T = 0$ ，综合只反映噪声破坏了哪些奇偶约束。

综合 z	译码动作	综合 z	译码动作
000	不翻转	100	翻转 r_5
001	翻转 r_7	101	翻转 r_1
010	翻转 r_6	110	翻转 r_2
011	翻转 r_4	111	翻转 r_3

例题 1.5 Hamming 码译码 问题：发送码字 $t = 1000101$ ，若第二位被翻转，接收端如何用综合定位错误？

答案：接收端得到 $r = 1100101$ ，计算综合 $z = Hr^T = 110$ 。查表可知最可能的错误位是 r_2 ；将该位翻回后恢复 t ，再读取前四位得到 $\hat{s} = 1000$ 。

说明：三个二元校验结果共有 $2^3 = 8$ 种综合：全零综合表示“最可能没有错误”，其余七种非零综合分别对应七个单比特错误位置。因此 (7, 4) Hamming 码能纠正任意单比特错误。




图 1.4: 汉明码译码实例。同时存在于红圈之内，以及不在绿圈之内的则为错误比特。

汉明码的误码率

当一个七比特块中出现两个或更多翻转时，本讲采用的综合译码器会产生块错误。块错误概率为

$$\begin{aligned}
 p_B &= \mathbb{P}(\text{七位中至少两位翻转}) \\
 &= 1 - (1 - f)^7 - 7f(1 - f)^6 \\
 &= 21f^2 + O(f^3).
 \end{aligned} \tag{1.12}$$

平均比特误码率的低阶展开为 $p_b = 9f^2 + O(f^3)$ ；对这里的系统型编码和综合译码器，完整枚举得到 $p_b = 9f^2 - 26f^3 + 30f^4 - 12f^5$ 。在 $f = 0.1$ 时， $p_b = 0.06688 \approx 6.7\%$ ，而码率为 $4/7 \approx 0.571$ 。与 R_3 相比，Hamming 码在这个噪声水平下比特误码率更高，但用显著更高的码率传输信息；评价编码方案时必须同时看码率和目标可靠性。

噪声信道编码定理

重复码给人的直觉是：若希望错误概率趋近于零，似乎必须让码率也趋近于零。Shannon 的结论推翻了这这个直觉。若编码器把 K 个源比特映射为长度 N 的码字，码率为 $R = K/N$ bits per channel use。




图 1.5: 比特翻转概率 $f = 0.1$ 的 BSC 上, 不同编码方式的误码率随码率变化的示意图。

定理 1.1 (噪声信道编码定理, 课堂表述)

对给定信道, 存在一个容量 C 。对任意 $R < C$ 和任意 $\varepsilon > 0$, 只要允许使用足够长的分组, 就存在在编码器和译码器, 使译码错误概率小于 ε 。反之, 若 $R > C$, 则不可能把错误概率任意压低。♡

对翻转概率为 f 的 BSC, 容量为

$$C_{\text{BSC}}(f) = 1 - H_2(f), \quad H_2(f) = f \log_2 \frac{1}{f} + (1 - f) \log_2 \frac{1}{1 - f}. \quad (1.13)$$

等价地, $H_2(f) = -f \log_2 f - (1 - f) \log_2 (1 - f)$ 。当 $f = 0.1$ 时, $C(0.1) \approx 0.531$, 所以码率 $R = 1/2$ 理论上低于容量。Shannon 定理意味着: 存在码率约为 $1/2$ 的编码方案, 能够把错误概率压到 10^{-15} 、 10^{-18} 或更低, 而不需要像重复码那样使用约六十份物理副本。

例题 1.6 十二球称重谜题 问题: 有 12 个外观相同的球, 其中恰好一个重量异常, 但不知道更重还是更轻。每次无砝码天平称重只有左重、平衡、右重三种结果。这个问题有多少种初始可能状态?

答案: 共有 $12 \times 2 = 24$ 种“异常球位置 $\times$ 偏重或偏轻”假设。一次称重至多给出三种结果。

说明: 这个谜题引向下一讲的核心: 一次观测能区分多少种可能性, 怎样用尽量少的符号、问题或实验结果唯一标识未知状态。

结论 第一讲把可靠通信表述为概率推断问题。BSC 提供了最小模型, 使翻转概率、Hamming 距离和似然之间的关系可以明确写出。重复码展示了冗余如何降低错误率, 也暴露了码率趋零的低效; (7,4) Hamming 码通过重叠奇偶校验定位单比特错误; Shannon 定理则给出更深的边界: 只要码率低于容量, 可靠性不必以码率趋零为代价。

第二章 熵与数据压缩

2.1 数据压缩与信息量

简介

第一讲讨论的是怎样在不可靠信道上可靠通信：编码器在消息中加入冗余，噪声信道改变一部分符号，译码器再用推断恢复原消息。对二元对称信道，重复码和 (7, 4) Hamming 码展示了“加冗余”这件事可以怎样做；Shannon 噪声信道编码定理进一步说明，只要码率低于信道容量，可靠通信原则上可以做到几乎无误。

第二讲把视角转到系统的另一端。真实数据源本身通常已经带有冗余：英文文本中元音、辅音和单词结构高度依赖上下文；即使擦掉相当一部分字母，人仍然可以凭语言结构把句子读出来。这说明数据由某种概率结构生成。若先把源中的冗余去掉，再对压缩后的近似“理想源”做信道编码，通信系统就更合理：




图 2.1: 通信系统框图。

弯曲硬币

例题 2.1 弯曲硬币源 问题：一枚弯曲硬币满足 $\mathbb{P}(1) = 0.1$ 、 $\mathbb{P}(0) = 0.9$ 。长度为 $N = 1000$ 的抛掷序列为什么具有可压缩性？

答案：这类序列大约含有 100 个 1 和 900 个 0。多数位置为 0 是源本身的概率结构，真实序列不需要被当成 1000 个独立、等价的公平比特来描述。

说明：这个例子引出压缩的核心：源的冗余来自非均匀概率和可预测结构，压缩要利用这些结构。

更一般地，有随机变量（ensemble） $X = \{x, \mathcal{A}_X, \mathbb{P}_x\}$ ，其中字母表 $\mathcal{A}_X = \{a_1, \dots, a_I\}$ 表示可能的输出集合；概率分布为 $\mathbb{P}(X = a_i) = p_i$ ，其中 $\sum_i p_i = 1$ 且 $p_i > 0$ 。

压缩问题可以问成三个层次：一次结果 $x = a_i$ 带来多少信息；一长串独立样本大约包含多少信息；最好的无损压缩长度应当接近什么数值。Shannon 信息量和熵正是为了回答这些问题而引入的。

Shannon 信息量与熵

单个结果的信息量取决于它发生前有多不确定。若结果 $x = a_i$ 的概率为 p_i ，Shannon 信息量定义为

$$h(x = a_i) = \log_2 \frac{1}{\mathbb{P}(X = a_i)} = \log_2 \frac{1}{p_i} \quad \text{bits.} \quad (2.1)$$

概率越小，结果越意外，信息量越大；概率为 1 的必然事件不提供信息；概率为 1/2 的二元选择提供 1 bit 信息。

例题 2.2 弯曲硬币的一次结果信息量 问题：对 $\mathbb{P}(0) = 0.9$ 、 $\mathbb{P}(1) = 0.1$ 的弯曲硬币，看到 0 和看到 1 分别提供多少信息？

答案：反面 0 带来的信息量是 $\log_2(1/0.9) \simeq 0.15$ bits；正面 1 带来的信息量是 $\log_2(1/0.1) \simeq 3.32$ bits。

说明：少见结果更意外，所以单次信息量更大；熵则会把这些单次信息量按发生概率平均。




图 2.2: Shannon 信息量随概率的变化曲线。

结论 $h(x)$ 就是我们在压缩文件时应力求达到的文件长度。

$h(x)$ 的一个关键性质是可加性。若 X 与 Y 独立，则 $\forall x, y$ 有 $\mathbb{P}(x, y) = \mathbb{P}(x)\mathbb{P}(y)$ ，于是

$$h(x, y) = \log_2 \frac{1}{\mathbb{P}(x, y)} = \log_2 \frac{1}{\mathbb{P}(x)\mathbb{P}(y)} = \log_2 \frac{1}{\mathbb{P}(x)} + \log_2 \frac{1}{\mathbb{P}(y)} = h(x) + h(y). \quad (2.2)$$

这正符合“告诉你两件彼此独立的事情，信息量应当相加”的直觉。

熵

单个结果的信息量是随机的；数据源整体的典型信息量由平均值给出。随机变量 X 的熵定义为

$$H(X) = \sum_{x \in \mathcal{A}_X} \mathbb{P}(x) \log_2 \frac{1}{\mathbb{P}(x)} = \sum_{i=1}^I p_i \log_2 \frac{1}{p_i} \quad \text{bits}. \quad (2.3)$$

熵是一次抽样的平均 Shannon 信息量，也可以理解为理想压缩时每个符号平均需要保留的不确定性。

熵如何指导提问

例题 2.3 第一次称重应怎样设计 问题：有 12 个外观相同的球，其中恰好一个异常，但不知道它偏重还是偏轻。第一次称重若采用 m 个球对 m 个球，应怎样选择 m 才能平均获得最多相关信息？

答案：可能状态共有 24 个，即“哪一个球异常”和“偏重或偏轻”的组合。每次称重只有三种结果：左重、平衡、右重。一次好的称重应当尽量把这些可能状态分成概率接近的几组，因为这样无论结果如何，剩下的不确定性都比较少。

假设第一次称重采用 m 个球对 m 个球，另有 $12 - 2m$ 个球留在桌上。在先验均匀时，平衡当且

仅当异常球在桌上，因此

$$\mathbb{P}(\text{平衡}) = \frac{12-2m}{12}, \quad \mathbb{P}(\text{左重}) = \mathbb{P}(\text{右重}) = \frac{m}{12}. \quad (2.4)$$

这个三结果分布的熵衡量第一次称重平均能给出多少相关信息。

第一次称重	结果分布	熵
6 对 6	(1/2, 1/2, 0)	1 bit
5 对 5	(5/12, 5/12, 1/6)	$\simeq 1.48$ bits
4 对 4	(1/3, 1/3, 1/3)	$\log_2 3 \simeq 1.58$ bits
3 对 3	(1/4, 1/4, 1/2)	1.5 bits
2 对 2	(1/6, 1/6, 2/3)	$\simeq 1.25$ bits
1 对 1	(1/12, 1/12, 5/6)	$\simeq 0.82$ bits

在这些选择中，4 对 4 使三种结果**等概率**，因此第一次称重的信息量达到 $\log_2 3$ bits。它是把 24 个候选状态分成三个同样大小的集合：左重、平衡、右重各留下 8 种可能。

若第一次称重后得到某个具体结果，问题会变成一个新的推断任务。例如 4 对 4 后若左盘上升、右盘下降，则左盘上的球只可能偏轻，右盘上的球只可能偏重，桌上的四个球已知正常。下一次称重应继续让可能结果尽量均匀地分裂剩余状态。一个典型目标是把 8 种可能分成尽量接近的三份。

说明：称重例子说明熵可以指导提问和实验设计：好的观测应把仍可能的状态尽量均匀地分开，同时必须与目标相关。

注 最大熵原则必须用于“与目标相关”的信息。打开一台显示随机噪声的电视也许产生很多不可预测的比特，但这些比特与哪个球异常无关，因此不能帮助解决称重问题。此外，逐步选择当前熵最大的实验是一条有用启发式，但一般不保证全局最优；它真正可靠的地方，是把“好问题”转化为可计算的目标函数。

压缩长度的预告

例题 2.4 弯曲硬币彩票 问题：若弯曲硬币连续抛掷 $N = 1000$ 次，把每个具体序列看成一张彩票。为了以高概率覆盖实际结果，是否需要购买全部 2^{1000} 张票？

答案：不需要。所有 2^N 张票在形式上都可以买，但概率并不相等：全零串比含有大量正面的串更可能，典型中奖串大约含有 100 个 1。如果只要求以 99% 的概率覆盖实际结果，应购买那些总概率质量足够大、数量又尽可能少的典型序列。

说明：这个例子预告源编码定理。高概率序列只占输出空间中的一小部分，压缩长度由这部分集合的大小决定。

结论 第二讲把信息论从“给信道添加冗余”推进到“从源中去除冗余”。Shannon 信息量把结果的意外程度变成 bit 数，并且对独立结果可加；熵 $H(X)$ 是平均信息量，给出理想压缩长度的基本尺度。称重问题说明，熵也可以用来设计实验或问题：好的观测应尽量均匀地划分仍然可能的状态，同时必须提供与目标相关的信息。

2.2 源编码定理

信息量定义的检验

第二讲给出了 Shannon 信息量

$$h(x) = \log_2 \frac{1}{\mathbb{P}(x)} \quad (2.5)$$

以及熵 $H(X) = \sum_x \mathbb{P}(x) \log_2(1/\mathbb{P}(x))$ 。第三讲检验这个定义是否真能解释“知道一件事”所获得的信息，并把它推进到压缩长度的定理。

二分提问与固定长度编码

例题 2.5 六个二元问题确定一个数 问题：令 X 在 $\{0, 1, \dots, 63\}$ 上均匀分布。若每次只能问一个是或否的问题，最少需要多少次才能确定 X ？课堂结果 42 对应怎样的二进制回答串？

答案：需要六次。反复二分：先问 X 是否不小于 32，再在剩下的一半中继续二分。六个回答本身就是 X 的二进制名字。记第 i 次回答为 C_i ，则每次二分都使 $\mathbb{P}(C_i = 0) = \mathbb{P}(C_i = 1) = 1/2$ ，所以每个回答提供 1 bit 信息。课堂结果 42 对应的编码可写作 $c(42) = 101010$ 。总信息量为 6 bits，正好等于 $\log_2 64$ 。

这个例子给出一个直接的编码解释：若一个结果来自大小为 S 的均匀集合，则用等长二进制名字描述它需要

$$L = \lceil \log_2 S \rceil \quad (2.6)$$

个 bits。这里的上取整只是因为真实码字长度必须是整数；信息量的核心尺度仍然是 $\log_2 S$ 。

说明：这个例子给出固定长度编码解释：均匀 S 选 1 的结果，需要约 $\log_2 S$ bits 来命名。

潜艇游戏中的零碎信息

例题 2.6 潜艇游戏中的零碎信息 问题：潜艇均匀藏在 8×8 网格中的一个格子里。如果每次只朝一个格子开火，许多次未命中加上最后一次命中，总信息量是多少？

答案：第一次未命中的概率是 $63/64$ ，这次未命中只提供 $\log_2(64/63) \simeq 0.023$ bits；第二次若又未命中，提供的是 $\log_2(63/62)$ bits。若在还剩 k 个可能格子时终于命中，则命中本身的信息量是 $\log_2 k$ bits。把此前所有未命中的信息量加起来，会得到一个望远镜式的求和：

若在还剩 k 个可能格子时终于命中，则命中本身的信息量是 $\log_2 k$ bits。把此前所有未命中的信息量加起来，会得到一个望远镜式的求和：

$$\begin{aligned} h_{\text{tot}} &= \log_2 \frac{64}{63} + \log_2 \frac{63}{62} + \cdots + \log_2 \frac{k+1}{k} + \log_2 k \\ &= \log_2 64 = 6 \text{ bits.} \end{aligned} \quad (2.7)$$

例如若还剩 20 个位置时命中，最后一下贡献 $\log_2 20 \simeq 4.32$ bits；此前那些未命中贡献的正是其余部分。无论问题问得优雅还是笨拙，只要最终确定同一个均匀的 64 选 1 结果，总信息量就应为 6 bits。这正是 $h(x) = \log_2(1/\mathbb{P}(x))$ 的强一致性。

说明：这个例子说明信息量可以由很多个很小的观测贡献累计而成；提问方式笨拙时，每一步信

息少，但总账仍对。

弯曲硬币彩票与典型集

现在回到弯曲硬币源。设每次抛掷得到 1 的概率为 $f = 0.1$ ，得到 0 的概率为 0.9，并连续抛掷 $N = 1000$ 次。一个完整输出 $x = x_1x_2 \cdots x_N$ 可以看作一张长度为 1000 的彩票；真正开出的号码就是实际产生的那串 bits。

最可能单串与高概率集合

例题 2.7 弯曲硬币彩票的单张选择 问题：对 $N = 1000$ 、 $f = 0.1$ 的弯曲硬币彩票，若只能买一张票应买哪张？这张票是否代表典型结果？

答案：若只能买一张票，最好的选择是全零串，因为任何含有 1 的串都比它多乘了因子 $0.1/0.9$ 。但实际序列中 1 的个数 R 大约在 100 附近波动；全零串虽然是单张票中概率最大的一张，但它只代表极小的一块概率质量。

说明：这个例子区分“单个结果概率最大”和“典型结果”。压缩要覆盖高概率集合，不能只盯住概率最大的单个字符串。

如果目标改成“用尽量少的彩票获得 99% 的中奖概率”，策略就要购买一整个高概率集合。含有 r 个 1 的具体序列概率为

$$\mathbb{P}(x) = f^r(1-f)^{N-r}, \quad (2.8)$$

这样的序列共有 $\binom{N}{r}$ 个。因为 $f < 1/2$ ，在 r 较小时，单张票的概率随 r 增大而下降；因此要覆盖大概率质量，应从 $r = 0$ 开始，把含有较少 1 的所有序列依次收入集合。

二项分布给出覆盖范围

例题 2.8 弯曲硬币彩票的 99% 覆盖 问题：若想以约 99% 概率覆盖 $N = 1000$ 、 $f = 0.1$ 的弯曲硬币输出，需要买多少张数量级的票？

答案：随机变量 R 服从二项分布。对 $N = 1000$ 、 $f = 0.1$ ，

$$R \sim \text{Binomial}(1000, 0.1), \quad \mathbb{E}[R] = 100, \quad \text{Var}(R) = 90, \quad \text{sd}(R) \simeq 9.5. \quad (2.9)$$

因此，若只覆盖到 $r = 120$ ，大约是均值右侧两个标准差；若要把总概率推到约 99%，课堂估算把上限推进到约 $r_{\max} = 123$ 。

所需彩票数为

$$M = \sum_{r=0}^{r_{\max}} \binom{1000}{r}, \quad r_{\max} \simeq 123. \quad (2.10)$$

这个和式的后端项占主导，课堂数量级估计为 $M \approx 2^{530}$ 。这个数字极大，但比全部 2^{1000} 张票小得多；它正是在说，弯曲硬币源的输出空间虽然形式上有 2^{1000} 个点，真正需要覆盖的高概率区域却远远稀疏。

组合数的指数阶由二元熵控制。对 $r = qN$ ，有近似

$$\log_2 \binom{N}{r} \simeq NH_2(q), \quad H_2(q) = q \log_2 \frac{1}{q} + (1-q) \log_2 \frac{1}{1-q}. \quad (2.11)$$

若只看 $q = 0.1$ 附近的典型峰值, $NH_2(0.1) \simeq 469$ bits; 为获得 99% 覆盖, 还要把右尾多收入一些, 于是有限长度下出现了约 530 bits 的课堂估算。随着 N 变大, 这种为了提高覆盖概率而多付出的边缘代价相对于 N 会变小, 主导项仍是 $NH_2(f)$ 。

说明: 压缩关心总概率质量足够大的集合。集合大小的对数就是给集合中每个候选序列命名所需的 bit 数。

从典型集到源编码定理

票袋压缩器

例题 2.9 票袋压缩器 问题: 若已经选出一个覆盖约 99% 概率、大小为 M 的高概率彩票集合, 怎样把长度 1000 的序列压缩成较短名字?

答案: 把这个集合想成一个巨大的袋子。袋中每张票正面写着一个长度为 1000 的原始序列, 背面重新贴上一个较短的二进制名字。只要袋中共有 M 张票, 就可以用 $\lceil \log_2 M \rceil$ bits 给它们逐一命名。对课堂上的 99% 例子, 这个长度约为 530 bits。

于是得到一个概念上的压缩器: 源产生长度为 1000 的序列后, 若该序列在袋中, 压缩器输出它背面的短名字; 解压器看到短名字后, 查表恢复原来的长序列。这个方案以约 99% 的概率工作, 把 1000 bits 压到约 530 bits。若愿意接受更小的失败概率, 可以把袋子向右尾再扩大一些; 所需额外长度随 N 的增长只属于较低阶修正。

说明: 这个压缩器只是存在性证明, 不是实用程序。它说明高概率输出集中在大小约为 $2^{NH(X)}$ 的典型集里。

注 这个构造证明“存在一种短描述”, 还没有给出实用压缩程序。袋子本身大到无法存储, 查表也不可行; 实际压缩算法需要更聪明地利用源的结构。尽管如此, 它已经抓住源编码定理的核心: 高概率结果集中在一个大小约为 $2^{NH(X)}$ 的典型集里。

定理表述

定理 2.1 (源编码定理, 课堂表述)

设 X 是一个离散无记忆源, 熵为 $H(X)$ 。对足够长的独立输出序列 $X_1, \dots, X_N$, 几乎全部概率质量都集中在一个典型集内; 该典型集的大小在指数阶上约为 $2^{NH(X)}$ 。因此, N 个源符号可以用大约 $NH(X)$ bits 表示, 并且失败概率可以做得任意小。



在弯曲硬币例子中, 单次熵为 $H_2(0.1) \simeq 0.469$ bits。因此, 对很长的序列, 理想压缩长度的主导项是 $0.469N$ bits, 远小于原始的 N bits。第三讲最后留下的实践问题也是同一个思想的算法化版本: 当 $N = 10,000$ 且 $f = 0.01$ 时, 怎样设计一个压缩器和解压器, 或者至少估计某种方法的压缩效果。

结论 第三讲完成了从“信息量定义”到“压缩极限”的连接。二分提问和潜艇游戏说明, Shannon 信息量能正确累计获得的信息; 弯曲硬币彩票说明, 最可能的单个结果不等于最值得整体覆盖的高概率集合; 典型集计数则给出源编码定理: 独立源的长度 N 输出, 在高概率意义下只需要约 $NH(X)$ bits 来描述。

2.3 符号编码

从源编码定理到符号码

第三讲用典型集说明了源编码定理：若离散无记忆源 X 连续产生 N 个独立符号，则典型输出数约为 $2^{NH(X)}$ ，因而整段序列原则上可压缩到约 $NH(X)$ bits。第四讲转向一个更具体、也更可实现的问题：给每个源符号分配一个二进制码字，再把这些码字顺次拼接。

设源的字母表为 $\mathcal{A}_X = \{a_1, \dots, a_I\}$ ，分布为 $p_i = \mathbb{P}(X = a_i)$ 。一个二元符号码 (symbol code) 是映射 $C: \mathcal{A}_X \rightarrow \{0, 1\}^*$ ，其中 $C(a_i) = c_i$ 是一个有限二进制串，长度记为 ℓ_i 。若源输出 $x_1 x_2 \cdots x_N$ ，编码器输出

$$C(x_1)C(x_2) \cdots C(x_N). \quad (2.12)$$

这种逐符号编码比第三讲的“典型集大查表”更有希望实际使用，因为编码器只需要一张符号表，无需保存所有可能长串。

符号码的平均代价由期望码长衡量：

$$L(C, X) = \sum_{i=1}^I p_i \ell_i. \quad (2.13)$$

这里 $L(C, X)$ 是每输出一个源符号平均需要的 bits 数。对于英文文本，空格和常见字母应分配较短码字，少见字母则可以使用较长码字；图中的字母频率表和二进制码表正是在展示这种压缩思想。

可译码性与前缀码

符号码不能只追求短。若把两个不同符号都编码成同一个码字，单个符号已经无法恢复；即使单个码字不同，拼接后的长串也可能出现歧义。一个码称为唯一可译码 (uniquely decodable)，是指任意两个不同的源符号串编码后都不会得到同一个二进制串。换句话说，若 $\mathbf{x} \neq \mathbf{y}$ ，则必须有 $C(\mathbf{x}) \neq C(\mathbf{y})$ 。

例题 2.10 四符号码的取舍 问题：令 $\mathcal{A}_X = \{a, b, c, d\}$ ，概率为 $(1/2, 1/4, 1/8, 1/8)$ 。哪些码可以唯一译码？哪些码真正利用了概率不均匀性？

答案：该源的熵为

$$H(X) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = \frac{7}{4} \text{ bits}. \quad (2.14)$$

同一分布下，不同码的平均长度和可译码性差别很大：

码	(a, b, c, d) 的码字	性质	$L(C, X)$
C_1	(1000, 0100, 0010, 0001)	固定长度，容易译码	4
C_2	(1, 01, 001, 0001)	前缀码	15/8
C_3	(0, 1, 0, 1)	不唯一可译码	1
C_6	(1, 01, 001, 000)	前缀码且达到熵	7/4

C_3 的平均长度看起来最小，但它把 a 与 c 、 b 与 d 混在一起，实际丢失了信息。 C_1 绝不会歧义，却完全没有利用概率不均匀性。真正有价值的是像 C_2 、 C_6 这样的变长码：高概率符号短，低概率符号长，同时拼接后仍能恢复原符号串。

说明：平均长度小本身不够，码必须可译。这个例子把“短”和“可恢复”两个要求分开了。

最方便的一类唯一可译码是前缀码（prefix code）：任意一个码字都不是另一个码字的前缀。前缀码可以从左到右即时译码；读入 bits 后，一旦到达某个码字就立即输出对应符号并重新开始。二叉树图像特别直观：从根出发，左、右边分别代表 0、1，每个码字是一片叶子；前缀条件等价于“没有叶子位于另一片叶子的祖先位置”。

注 前缀码只是“容易译码”的充分条件。唯一可译码还包含一些非前缀码，它们需要等待后续 bits 才能完成译码。课程后半段主要使用前缀码，因为它们可以用二叉树描述，且足以达到最优平均长度。

Kraft 不等式

码字长度不能任意指定。若一个二元码是唯一可译码的，码长 $\ell_1, \dots, \ell_I$ 必须满足 Kraft 不等式

$$\sum_i 2^{-\ell_i} \leq 1. \quad (2.15)$$

对前缀码，这个条件可以直接从二叉树看出：长度为 ℓ_i 的码字占据深度 ℓ_i 处一整块大小为 $2^{-\ell_i}$ 的叶子区域；不同码字对应的区域互不重叠，所以总占用量不能超过 1。

例题 2.11 Kraft 不等式中的完备码 问题：长度集合 $(1, 2, 3, 3)$ 能否构成前缀码？它是否完备？

答案：因为 $2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = 1$ ，它满足 Kraft 不等式且等号成立，因此可以构成完备前缀码。

说明：完备码没有留下可再利用的二叉树空间。若 Kraft 和式严格小于 1，树中仍有未使用的叶子空间，码长结构并未把二元串空间填满。

Kraft 不等式在本讲中扮演两种角色。第一，它给出可译码性的硬约束：平均长度再短，也必须通过这个约束。第二，它也是构造工具：只要一组整数码长满足 Kraft 不等式，就存在一个具有这些长度的前缀码。因此，在讨论最优符号码时，可以先研究码长，再把码长实现为二叉树上的叶子。

熵界与最优符号码

若暂时忽略“码长必须为整数”，最自然的选择是令码长等于每个符号的 Shannon 信息量：

$$\ell_i^* = \log_2 \frac{1}{p_i}. \quad (2.16)$$

这样平均长度恰好为熵 $H(X)$ 。

例题 2.12 理想码长刚好为整数 问题：对概率 $(1/2, 1/4, 1/8, 1/8)$ ，逐符号码能否达到熵下界？

答案：可以。各符号的信息量正好是 $(1, 2, 3, 3)$ ，因此前面表中的 C_6 可以达到 $L = H(X) = 7/4$ 。

说明：一般情况下， $\ell_i^* = \log_2(1/p_i)$ 未必是整数，真实码只能接近这个理想值。这个四符号源是整齐的特例。

下界来自 Kraft 不等式和 Gibbs 不等式。记 $Z = \sum_i 2^{-\ell_i} \leq 1$ ，并令 $q_i = 2^{-\ell_i}/Z$ ，则 q_i 是一个概率分布。由 $\ell_i = \log_2(1/q_i) - \log_2 Z$ 得

$$\begin{aligned} L(C, X) &= \sum_i p_i \log_2 \frac{1}{q_i} - \log_2 Z \\ &= H(X) + \sum_i p_i \log_2 \frac{p_i}{q_i} - \log_2 Z \geq H(X). \end{aligned} \quad (2.17)$$

其中用到的 Gibbs 不等式为

$$\sum_i p_i \log \frac{p_i}{q_i} \geq 0, \quad \text{等号当且仅当 } q_i = p_i. \quad (2.18)$$

因此，任何唯一可译码的符号码都不能把平均长度压到熵以下。若能达到等号，需要同时满足 $Z = 1$ 且 $q_i = p_i$ ，也就是码是完备的，并且码长正好等于 $\log_2(1/p_i)$ 。

上界则来自取整。选择 $\ell_i = \lceil \log_2(1/p_i) \rceil$ ，就有 $2^{-\ell_i} \leq p_i$ ，从而 $\sum_i 2^{-\ell_i} \leq 1$ ；Kraft 不等式保证存在相应的前缀码。同时 $\ell_i < \log_2(1/p_i) + 1$ ，所以

$$H(X) \leq L(C, X) < H(X) + 1. \quad (2.19)$$

这就是本讲中符号码版本的源编码结论：逐符号编码不一定精确达到熵，但最优平均长度至多比熵多不到 1 bit。Huffman 算法进一步给出实际构造最优前缀码的方法：反复合并概率最小的两个符号，自底向上生成二叉树；其最优性在后续章节中证明。

结论 第四讲把源编码定理落到符号层面的可构造问题上。符号码把每个源符号映射为二进制串，平均长度为 $L(C, X) = \sum_i p_i \ell_i$ ；可靠压缩首先要求唯一可译码，前缀码则提供了易译码的二叉树结构。Kraft 不等式给出可译码码长的约束，Gibbs 不等式给出熵下界；结合取整构造可得最优符号码满足 $H(X) \leq L(C, X) < H(X) + 1$ ，而 Huffman 编码提供达到最优前缀码的算法。

2.4 符号编码与算术编码

最优符号码的构造

前一讲已经把符号编码问题化成了一个清楚的优化问题。若源字母表为 $\mathcal{A}_X = \{a_1, \dots, a_I\}$ ，概率为 p_i ，前缀码的码长为 ℓ_i ，则平均码长是 $L = \sum_i p_i \ell_i$ 。Kraft 不等式限制了可实现的码长集合，Gibbs 不等式给出熵下界，因此最优前缀码的平均长度满足 $H(X) \leq L < H(X) + 1$ 。接下来的任务是实际构造达到最优的前缀树。

Huffman 算法正是这个构造。它从概率最小的两个符号开始，把它们合并成一个新的“临时符号”，其概率等于二者概率之和；然后在缩小后的字母表上重复同样的操作，直到只剩一个根节点。最后把每一次合并反向展开，并在二叉树的两条分支上标 0 和 1，叶节点到根的路径就给出各符号的码字。这个算法的直觉很简单：低概率符号应该出现在树的深处，而最深处的两个叶子可以看成一对兄弟。若把这一对兄弟压缩成一个“合成符号”，剩下的问题又是同一个最优编码问题，只是字母表少了一个元素。于是 Huffman 算法以递归方式把局部的兄弟关系拼成整棵最优树。**注** Huffman 码是最优的前缀符号码，但“最优符号码”仍然是逐符号编码。它已经在前缀码这一类里做到了最好，却还没有完全解决实际压缩中的两个问题：整数码长造成的舍入损失，以及真实数据中强烈的上下文依赖。

逐符号编码的瓶颈

例题 2.13 弯曲硬币上的整数码长损失 问题：一枚弯曲硬币满足 $P(a) = 0.99$ 、 $P(b) = 0.01$ 。逐符号二元前缀码能否接近单次熵？

答案：单次熵只有约 0.08 bits，但任何二元前缀符号码若要区分 a 和 b ，至少要给每个结果分配一个 bit。最自然的码是 $a \mapsto 0$ 、 $b \mapsto 1$ ，平均长度 $L = 1$ bit，远高于熵。

说明：损失来自整数码长。逐符号编码每次都要输出完整码字，无法让大量高概率的 a 平均只消耗 0.08 bits 左右。

例题 2.14 十一个符号的极端分布 问题：若有 11 个符号，其中 c 的概率为 0.990，其余十个符号各为 0.001，最优符号码与熵之间会有多大差距？

答案：一个最优符号码仍会让高概率的 c 占用一个 bit；该例的平均长度约为 1.034 bits，而熵约为 0.114 bits，二者相差将近一个数量级。

说明：问题出在“每次必须输出一个完整码字”的模型本身太粗。Huffman 算法仍然是在这个模型内最优，但模型限制会带来不可忽略的舍入损失。

一个临时补救办法是把连续出现的高概率符号合成更大的块，例如用游程长度（run length）描述“很多个 a 之后才出现一个 b ”。这能说明问题所在，但块的定义依赖源的结构，而且真实文本、图像或程序文件不会总是表现为简单游程。更好的办法是对整段序列编码，使小概率事件和长串高概率事件在同一个概率模型里自然结算。

例题 2.15 英文标题中的上下文预测 问题：为什么固定字母频率表不足以压缩英文标题？

答案：英语标题里下一个字符的分布通常不是固定的：在看到若干前缀之后，某些字母会突然变得非常可能，另一些字母几乎不可能。标题中的词在逐字母展开时，前缀越长，候选词越少；看到 ‘MINERS REFUSE TO WORK AFTER’ 这样的上下文后，后续字母由英文、语义和常见标题模式共同限制，已经

不同于字母表上的均匀抽样。

说明：上下文模型可以把预测分布变尖。压缩器若只使用固定字母频率表，就会浪费这种结构；算术编码则能自然接受逐步变化的概率分布。

这引出三个逐步增强的压缩任务。第一是已知弯曲硬币：字母表为 $\{a, b\}$ ，且 $P(a) = 0.99$ 、 $P(b) = 0.01$ 已知，编码器只需利用这个固定分布。第二是未知弯曲硬币：仍然只有两个结果，但 $P(a)$ 和 $P(b)$ 需要随着数据到来从已经观察到的前缀中估计；如果开头出现了大量 a ，模型就应把后续 a 的预测概率调高。第三是一般的 **oracle 任务**：在每个时刻 t ，有一个预测器给出当前条件分布 $P(X_t | X_1, \dots, X_{t-1})$ 。这三个任务把“概率模型”从固定表逐渐推广到自适应、上下文相关的预测器。

因此，真实压缩更合理的目标是：对整段数据 $\mathbf{x} = (x_1, \dots, x_N)$ 编码，让码长接近整段序列的信息量 $h(\mathbf{x})$ ，避免让每个源符号单独四舍五入一次。这里 $h(\mathbf{x}) = \log_2(1/P(\mathbf{x}))$ 。由链式法则，

$$P(x_1, \dots, x_N) = P(x_1)P(x_2 | x_1) \cdots P(x_N | x_1, \dots, x_{N-1}). \quad (2.20)$$

只要编码器和解码器共享同一个预测模型，它们就可以逐步使用这些条件概率来压缩整段消息。

例题 2.16 identical twins 同步模型 问题：算术编码中，编码端和解码端为什么必须像 identical twins 一样保持同步？

答案：二者使用同一套预测程序，看到同样的已解码前缀，就必须得到同样的下一步分布。编码端根据真实下一个符号选择子区间并输出必要的 bits；解码端只根据这些 bits 和自己重建出的前缀，重复同样的区间划分。

说明：若模型中有随机性或自适应更新，随机种子和更新规则也必须同步，否则解码端会在某一步切错区间。算术编码传输的是区间选择，概率模型本身必须在两端共同生成。

算术编码的区间表示

例题 2.17 二进制前缀对应区间 问题：二进制串 01 和 100 在算术编码的区间观点下分别表示什么？

答案：两个前缀对应的区间为

二进制前缀	对应区间
01	$[0.25, 0.5)$
100	$[0.5, 0.625)$

码字越长，区间越短。

说明：发送一个二进制前缀，就是把真实数限制在一个更小的二进制区间里。算术编码利用这一点，用一个短前缀指向整段消息对应的概率区间。

这也解释了为什么可以把一个完整文件视为一个实数。一个 8×10^6 bits 左右的文件对应 $[0, 1)$ 中极细的二进制区间；若改用十进制小数描述，大约需要几百万位小数才能同等精确。算术编码实际利用的是“二进制前缀等价于区间”这个观点，把整段消息的概率质量压进一个足够小的区间；实现时无需保存无限精度实数。

反过来，编码一个源序列时，可以先让源模型在 $[0, 1)$ 上不断切分区间。设当前区间为 $[l, u)$ ，宽度 $w = u - l$ 。对字母表按某个固定顺序排列，令 $F_i = \sum_{j < i} p_j$ 为符号 a_i 之前的累积概率，则读到 a_i 后

新区间为

$$[l', u') = [l + wF_i, l + w(F_i + p_i)). \quad (2.21)$$

若概率会随上下文改变，只需把这里的 p_i 和 F_i 换成当前上下文下的条件分布。编码器逐符号缩小区间，解码器用同一个模型和收到的二进制前缀逐步判断实数落在哪个子区间中，因此二者不需要传输整张查表。

经过 N 个符号后，最终区间的宽度等于序列概率。对无记忆源，这是 $\prod_{t=1}^N P(x_t)$ ；对一般的上下文模型，由链式法则仍为

$$|I(x_1, \dots, x_N)| = P(x_1, \dots, x_N). \quad (2.22)$$

只要找到一个二进制区间完全落在最终区间内，就可以用对应的二进制前缀表示整段序列。所需长度满足

$$\ell(x_1, \dots, x_N) \leq \log_2 \frac{1}{P(x_1, \dots, x_N)} + 2. \quad (2.23)$$

这条界之后，有三点尤其值得单独记住。

 **笔记** 第一，算术编码的额外长度是按整段消息计的常数级开销。对很长的序列来说，平均到每个符号上的冗余可以趋近于零；这正是它能绕开逐符号码整数长度瓶颈的根本原因。

 **笔记** 第二，算术编码不需要枚举所有可能的字符串。若字母表大小为 I ，长度为 N ，块编码思路会很快遇到 I^N 个候选块；算术编码只需要沿着真实发生的路径逐步计算条件概率向量。换句话说，工作量主要是得到 $P(X_t | X_1, \dots, X_{t-1})$ 这些逐时刻的预测分布，再做区间缩放和 bit 输出。

 **笔记** 第三，源字母表和传输字母表可以分离。源端可以是三元字母表 $\{A, B, C\}$ ，可以是弯曲硬币的 $\{a, b\}$ ，也可以是英文字符和空格；传输端通常取二进制 bits，但同一个区间思想也可以改写成三进制或其他进制的前缀表示。因此算术编码给出了一种把任意概率模型转换为传输前缀的通用框架。

模型与编码器的分离

算术编码的一个重要优点，是把“怎样预测数据”和“怎样把概率变成 bits”分开了。编码器本身只需要在每一步知道当前字母表中各符号的条件概率；至于这些概率来自弯曲硬币、英文字符模型、上下文树，还是更复杂的自适应模型，并不改变区间缩放的基本机制。实际实现中，为长序列保存一个无限精度实数当然不现实，但可以在区间已经确定某些前缀 bit 时立刻输出这些 bit，并对区间重新缩放。

例题 2.18 弯曲硬币的算术编码 问题：对 $P(a) = 0.99$ 、 $P(b) = 0.01$ 的弯曲硬币，算术编码如何绕开逐符号码的整数长度损失？

答案：逐符号码必须让高概率的 a 每次仍占一个 bit；算术编码则会让连续的许多 a 只是在 $[0, 1)$ 中反复选择一个很大的子区间，区间宽度缓慢缩小，直到偶尔出现的 b 才显著消耗长度。

说明：算术编码按整段消息结算长度，平均码长接近真实熵，绕开逐符号整数长度的限制。

Dasher 也使用了同一思想。普通压缩是把文本变成尽量短的 bit 串；Dasher 把方向、速度等连续手势解释为在概率空间里选择文本。越可能的字符占据越大的区域，越不可能的字符占据越小的区域。用户通过很短的动作进入高概率区域，本质上就是用一个概率模型和区间细分来高效书写。

同一思想也出现在实际无损压缩格式中。JBIG、PPM、DjVu 等方法的核心差别主要在概率模型：

它们如何从上下文预测下一个符号。算术编码则承担共同的后端任务：把这些预测概率转化为接近信息量下界的 bits。这样看，压缩问题被拆成了两个相对独立的部分：模型越会预测， $P(x_1, \dots, x_N)$ 越大，所需 bits 越少；算术编码越接近理想区间长度，模型给出的概率优势就越少被整数码长浪费。

结论 第五讲完成了从最优符号码到算术编码的过渡。Huffman 算法给出了最优前缀符号码的构造，但逐符号编码仍会为整数码长和固定分布付出代价；当源的熵远小于 1 bit 或预测分布强烈依赖上下文时，这个代价尤其明显。弯曲硬币、未知弯曲硬币和 oracle 三个任务说明，实际压缩器真正需要一套与解码端同步的预测模型。算术编码把整段序列映射为 $[0, 1)$ 中长度为 $P(x_1, \dots, x_N)$ 的区间，并用一个二进制前缀指明该区间，因此码长接近 $\log_2(1/P(x_1, \dots, x_N))$ ，额外开销只属于整段消息。

第三章 噪声信道编码

3.1 噪声信道中的推断与信息度量

从压缩到信道

令 $\mathcal{A}_X = \{a, b, c, d\}$ ，分布为 $(1/2, 1/4, 1/8, 1/8)$ ，码字为 $C = \{0, 10, 110, 111\}$ 。若按源概率产生符号并拼接码字，那么随机抽取一个输出 bit 时，不能简单按“某几个码字含有多少个 1”平均，而应按 bit 在长码流中的出现频率加权。设码字 c_i 中 1 的个数为 n_i ，码长为 ℓ_i ，则

例题 3.1 压缩后 bit 流的偏置 问题：对分布 $(1/2, 1/4, 1/8, 1/8)$ 和前缀码 $C = \{0, 10, 110, 111\}$ ，从拼接后的长码流中随机抽一个 bit，它等于 1 的概率是多少？

答案：设码字 c_i 中 1 的个数为 n_i ，码长为 ℓ_i ，应按长码流中的 bit 位置加权：

$$p_1 = \frac{\sum_i p_i n_i}{\sum_i p_i \ell_i} = \frac{\frac{1}{4} + \frac{1}{8} \cdot 2 + \frac{1}{8} \cdot 3}{\frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3} = \frac{1}{2}. \quad (3.1)$$

说明：随机抽 bit 时不能按码字个数平均，因为长码字贡献更多 bit。这里得到 $p_1 = 1/2$ ，说明理想码长与信息量匹配时，压缩输出会失去明显的单 bit 偏置。

前几讲的压缩问题有一个重要收尾：理想码长应当匹配信息量。若符号 a_i 的概率为 p_i ，理想码长是 $\ell_i^* = \log_2(1/p_i)$ ；实际的最优符号码由于码长必须为整数，只能保证平均码长 L 满足 $H(X) \leq L < H(X) + 1$ 。这个“不超过每个源符号一 bit”的界已经很好，但它也暴露了逐符号编码的边界：当源的熵很小，或者预测分布强烈依赖上下文时，逐符号的整数舍入仍会浪费结构。

一个检验压缩是否已经到位的办法，是观察压缩后的 bit 流是否还带有可预测性。若某种无损压缩把源序列变成二进制流，而从中随机抽取一个 bit 得到 1 的概率明显不是 1/2，或者相邻 bits 仍有相关性，那么这些 bits 本身还像一个可压缩的源。换言之，足够好的压缩输出应当接近公平硬币产生的 bit 流；否则可以继续对这个输出流做压缩。

算术编码进一步把“压缩”和“从随机 bits 生成样本”放在同一幅图中。若一段均匀随机 bits 被看成 $[0, 1)$ 中的随机实数，把它投进某个源模型对应的算术编码区间划分，就会落入某个源序列的区间；该区间的长度正是该序列概率，所以被抽中的概率也正是源模型概率。对于弯曲硬币，若 $P(a) = 0.01$ 、 $P(b) = 0.99$ ，用均匀随机数 $u \in (0, 1)$ 与阈值比较即可生成一次样本；算术编码只是把这种逆变换采样推广到长序列和上下文模型。实际计算机里的均匀数只有有限精度，例如常见实现可看成 $m/2^{32}$ ，所以不会给出数学上无限精确的随机实数，但这种精度通常已经远超过一次二元决策所需。

注 Dasher 的文字输入也利用了同一种区间思想。压缩时，文本被映射成尽量短的 bit 串；书写时，人的连续手势可以看成在概率空间里选择文本。更可能的字符占据更大的区域，因此较短的动作就能进入高概率文本区域。

推断：先写联合分布

进入噪声信道之前，先要把概率推断的基本动作说清楚。三张卡片问题和三扇门问题都提醒我们：推断需要把观测如何产生也写成概率，只看剩下几个口头候选项会丢掉关键信息。

例题 3.2 三张卡片 问题：三张卡分别为两面白、两面棕、一白一棕。随机选一张并随机朝上放置；若看到朝上的一面是白色，另一面也是白色的概率是多少？

答案：概率为 $2/3$ 。直观计数法按“面”来数：三张卡共有三个白面，其中两个来自两面白卡，一个来自混色卡。已经看到白面时，落在两面白卡的概率为 $2/3$ 。

用联合分布写得更稳妥。记 F 为朝上的颜色， B 为背面的颜色，颜色取 W 和 C ，其中 W 表示白色， C 表示棕色。随机选卡并随机翻面后，非零联合概率为

$$P(F=W, B=W) = \frac{1}{3}, \quad P(F=C, B=C) = \frac{1}{3}, \quad P(F=W, B=C) = P(F=C, B=W) = \frac{1}{6}. \quad (3.2)$$

于是

$$P(B=W | F=W) = \frac{P(F=W, B=W)}{P(F=W)} = \frac{1/3}{1/3 + 1/6} = \frac{2}{3}. \quad (3.3)$$

说明：这个例子的重点是条件化对象。把变量、联合概率和观测事件写出来，推断就是重新归一化。

例题 3.3 三扇门 问题：奖品等概率藏在三扇门之一。参赛者先选门一；主持人知道奖品位置，并承诺打开另一扇没有奖品的门。若主持人随后打开门三，应坚持门一还是换到门二？

答案：应换到门二，获胜概率为 $2/3$ ；坚持门一的获胜概率为 $1/3$ 。记 C 为奖品所在的门， H 为主持人打开的门。若 $C=1$ ，主持人可在门二和门三之间任选一扇空门；按对称规则取 $P(H=3 | C=1) = 1/2$ 。若 $C=2$ ，主持人必须打开门三；若 $C=3$ ，主持人不能打开门三。因此

$$\begin{aligned} P(C=1, H=3) &= \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{6}, \\ P(C=2, H=3) &= \frac{1}{3} \cdot 1 = \frac{1}{3}, \\ P(C=3, H=3) &= \frac{1}{3} \cdot 0 = 0, \\ P(C=2 | H=3) &= \frac{P(C=2, H=3)}{P(H=3)} = \frac{1/3}{1/6 + 1/3} = \frac{2}{3}. \end{aligned} \quad (3.4)$$

说明：这里的观测不只是“门三被打开”，还包括主持人知道奖品位置并保证打开空门这一规则。规则变了， $P(H | C)$ 就会变，后验也会变。

 **笔记** 三扇门问题的答案依赖主持人的规则。如果主持人并不知道奖品位置，或者没有保证打开空门，那么 $P(H | C)$ 会改变，后验概率也会随之改变。推断中的“证据”既包括看见了哪一扇门被打开，也包括这件事是在什么规则下产生的。

信道与联合分布

噪声信道 (noisy channel) 有输入 X 和输出 Y 。信道本身给出一组条件概率 $P(y | x)$ ：若输入为 x ，输出各个 y 的概率是多少。要从输出反推输入，或者要衡量输出告诉了我们多少关于输入的信息，还必须给输入加上先验分布 $P(x)$ ，从而得到联合分布

$$P(x, y) = P(x)P(y | x). \quad (3.5)$$

有了联合分布，就可以用统一的概率语言计算后验 $P(x | y)$ 、各种熵以及互信息。

二元对称信道 (binary symmetric channel, BSC) 是最基本的例子。输入和输出都取 $\{0, 1\}$ ；以概率

$1 - f$ 正确传输，以概率 f 翻转。因此信道矩阵可写为

$$Q = \begin{bmatrix} 1-f & f \\ f & 1-f \end{bmatrix}, \quad (3.6)$$

其中行对应输入，列对应输出。若 $f = 0.1$ ，发送 0 时有 0.9 概率收到 0，发送 1 时有 0.9 概率收到 1。但信道矩阵并不告诉我们发送 0 和 1 的频率；这个频率属于输入分布 P_X ，必须额外指定。

联合熵、条件熵与互信息

为理解信道上的信息度量，可以先从一个普通联合分布出发。令 X, Y 都取值于 $\{1, 2, 3, 4\}$ ，联合概率表为

	$x = 1$	$x = 2$	$x = 3$	$x = 4$	$P_Y(y)$
$y = 1$	1/8	1/16	1/32	1/32	1/4
$y = 2$	1/16	1/8	1/32	1/32	1/4
$y = 3$	1/16	1/16	1/16	1/16	1/4
$y = 4$	1/4	0	0	0	1/4
$P_X(x)$	1/2	1/4	1/8	1/8	1

边缘概率由行和列求和得到。这里 $P_X = (1/2, 1/4, 1/8, 1/8)$ ，所以 $H(X) = 7/4$ bits；而 Y 是四个等概率结果，所以 $H(Y) = 2$ bits。

联合熵把 (X, Y) 当成一个随机对象：

$$H(X, Y) = \sum_{x,y} P(x, y) \log_2 \frac{1}{P(x, y)}. \quad (3.7)$$

对上表计算得到 $H(X, Y) = 27/8$ bits。若 X 和 Y 独立，则 $H(X, Y) = H(X) + H(Y)$ ；但这里 $H(X) + H(Y) = 15/4$ 大于 $27/8$ ，差出的部分正是在表达二者的依赖。

条件概率由联合分布归一化得到：

$$P(x | y) = \frac{P(x, y)}{P(y)}. \quad (3.8)$$

在上表中，每个 y 的概率都是 $1/4$ ，因此条件化相当于把对应行乘以 4。例如 $P(X | Y = 1) = (1/2, 1/4, 1/8, 1/8)$ ，其熵为 $7/4$ bits； $P(X | Y = 3)$ 是四点均匀分布，熵为 2 bits；而 $P(X | Y = 4)$ 是确定分布，熵为 0 bits。某个具体观测值 $Y = y$ 可能让 X 的不确定性变大、变小或不变，但平均起来，观测不会增加不确定性。

平均意义下的条件熵定义为

$$H(X | Y) = \sum_y P(y) H(X | Y = y) = \sum_{x,y} P(x, y) \log_2 \frac{1}{P(x | y)}. \quad (3.9)$$

对这个例子， $H(X | Y) = 11/8$ bits；同理 $H(Y | X) = 13/8$ bits。条件熵满足 $H(X | Y) \leq H(X)$ ，等号当且仅当 X 与 Y 独立。这个不等式说的是平均效果：单个观测值可能让条件分布更分散，但把所有可能观测按其概率平均后，额外信息不会使不确定性增加。

这些量之间有一个链式关系：

$$H(X, Y) = H(Y) + H(X | Y) = H(X) + H(Y | X). \quad (3.10)$$

把 $H(X)$ 、 $H(Y)$ 和 $H(X, Y)$ 画成长度条时, $H(X)$ 与 $H(Y)$ 的重叠部分就是二者共有的信息。这个重叠定义为互信息 (mutual information):

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X). \quad (3.11)$$

在当前例子中, $I(X; Y) = 7/4 - 11/8 = 3/8$ bits, 也等于 $2 - 13/8$ 。互信息为零意味着二者独立; 互信息越大, 说明观察一个变量平均能消除另一个变量越多的不确定性。




图 3.1: 几个信息度量之间的关系。

BSC 的互信息

把互信息用于信道时, X 是输入, Y 是输出。信道 Q 给出 $P(y | x)$, 输入分布 P_X 给出 $P(x)$, 二者合成 $P(x, y)$ 。此时 $I(X; Y)$ 衡量输出平均传达了关于输入的信息。对 BSC, 若翻转概率为 f , 则给定输入后输出的不确定性总是二元熵 $H_2(f)$, 所以

$$H(Y | X) = H_2(f), \quad H_2(p) = p \log_2 \frac{1}{p} + (1 - p) \log_2 \frac{1}{1 - p}. \quad (3.12)$$

若再指定 $P_X = (p_0, p_1)$, 输出为 1 的概率是 $P(Y = 1) = p_0 f + p_1(1 - f)$, 于是 $H(Y) = H_2(P(Y = 1))$, 互信息为

$$I(X; Y) = H_2(p_0 f + p_1(1 - f)) - H_2(f). \quad (3.13)$$

例题 3.4 非均匀输入下的 BSC 互信息 问题: 对翻转概率 $f = 0.1$ 的 BSC, 若输入分布为 $P_X = (0.9, 0.1)$, 一次信道使用平均传递多少信息?

答案: 此时 $P(Y = 1) = 0.9 \cdot 0.1 + 0.1 \cdot 0.9 = 0.18$, 所以

$$I(X; Y) = H_2(0.18) - H_2(0.1) \simeq 0.68 - 0.47 = 0.21 \text{ bits}. \quad (3.14)$$

说明: 这个数小于 1 bit, 有两个原因: 信道会翻转, 输入本身也偏向 0。后续讨论容量时, 要研究同一信道在不同输入分布下能达到的最大互信息。

结论 本节把信息论从无噪声压缩推进到噪声信道。压缩复盘说明, 好的压缩输出应接近无偏、无相关的随机 bit 流; 算术编码还可以反向理解为按模型生成随机样本。三张卡片和三扇门提醒我们, 推断必须把变量、先验、观测以及观测产生的规则一并写进联合分布。进入信道后, 核心对象从单个随机变量变成输入 X 与输出 Y 的联合分布。信道只给出 $P(y | x)$, 必须配合输入分布 $P(x)$ 才能推断和计算信息量。联合熵、条件熵和互信息给出了统一语言, 其中 $I(X; Y)$ 衡量输出平均提供了多少关于输入

的信息，并为下一步讨论噪声信道容量做准备。

3.2 噪声信道容量

从推断到信道度量

噪声信道问题延续上一节的推断语言。一般的推断题可以先写成“假设”和“数据”的联合概率，再对已经观察到的数据归一化。若 h 表示假设、 d 表示数据，则

$$P(h | d) = \frac{P(d | h)P(h)}{\sum_{h'} P(d | h')P(h')}. \quad (3.15)$$

分子是某个假设解释数据的权重，分母是所有解释的总权重。三扇门问题中，主持人打开哪扇门就是数据，主持人的规则给出似然 $P(d | h)$ ；只要把这个似然写出来，换门概率 $2/3$ 便不再是一个需要记忆的谜题答案。

信道只是把同样的结构换了名字。输入 X 扮演假设，输出 Y 扮演数据；信道 Q 给出条件概率 $P(y | x)$ 。但只有 Q 还不够，因为要形成联合分布还必须选择输入分布 P_X ：

$$P(x, y) = P_X(x)Q(y | x). \quad (3.16)$$

有了这个联合分布，既可以做后验推断 $P(x | y)$ ，也可以计算 $H(X)$ 、 $H(Y)$ 、条件熵和互信息。

几个基本信道模型会反复出现。二元对称信道 (binary symmetric channel, BSC)、二元擦除信道 (binary erasure channel, BEC)、Z 信道和嘈杂打字机 (noisy typewriter)。它们的共同点是都由条件分布 $Q_{ji} = P(y = b_j | x = a_i)$ 描述，但最佳使用方式可能完全不同。




图 3.2: 四种信道：二元对称信道、二元擦除信道、Z 信道、嘈杂打字机。

BSC 中的后验与互信息

例题 3.5 BSC 中的后验与互信息 问题：固定一个 BSC：翻转概率 $f = 0.1$ ，输入分布 $P_X(0) = 0.9$ 、 $P_X(1) = 0.1$ 。若观察到 $Y = 1$ 或 $Y = 0$ ，输入为 1 的后验概率是多少？该输入分布下互信息是多少？

答案：若观察到输出 $Y = 1$ ，输入可能本来就是 1 且没有翻转，也可能本来是 0 且发生翻转。Bayes 公式给出

$$P(X = 1 | Y = 1) = \frac{0.1 \cdot 0.9}{0.1 \cdot 0.9 + 0.9 \cdot 0.1} = \frac{1}{2}. \quad (3.17)$$

这个结果有点反直觉：虽然先验里 1 很少，但看到 1 之后，两种解释的权重刚好相等。若观察到 $Y = 0$ ，则

$$P(X = 1 | Y = 0) = \frac{0.1 \cdot 0.1}{0.1 \cdot 0.1 + 0.9 \cdot 0.9} = \frac{1}{82}. \quad (3.18)$$

这里输出 0 与先验中常见的输入 0 相一致，因此 $X = 1$ 的后验概率被压得更小。两个输出概率也在计算中自然出现： $P(Y = 1) = 0.18$ ， $P(Y = 0) = 0.82$ ，二者相加为 1。

这个例子接着引出信道中的平均信息传递。互信息可以写成

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X). \quad (3.19)$$

第一种写法强调输出让输入的不确定性平均减少了多少；第二种写法常常更易计算，因为给定输入后，BSC 的输出不确定性总是二元熵 $H_2(f) = f \log \frac{1}{f} + (1 - f) \log \frac{1}{1-f}$ 。

对当前参数，输出为 1 的概率是 0.18，因此

$$I(X; Y) = H_2(0.18) - H_2(0.1) \simeq 0.68 - 0.47 = 0.21 \text{ bits}. \quad (3.20)$$

若改用 $H(X) - H(X | Y)$ 也会得到同一个结果，但需要分别计算 $Y = 1$ 和 $Y = 0$ 下的后验熵，再按 0.18 与 0.82 加权。等价性本身重要，实际计算时可以选择更短的路线。

说明：这个例子把“后验推断”和“平均信息量”放在一起。单个输出值给出具体后验，互信息则把所有输出可能性按概率平均。

信道容量

到目前为止，互信息依赖两个对象：信道 Q 和我们选择的输入分布 P_X 。但在通信问题中，发送端通常可以控制输入分布；于是自然的问题变成：这条信道在最会使用它时最多能传多少信息？信道容量（channel capacity）定义为

$$C = \max_{P_X} I(X; Y), \quad (3.21)$$

达到最大值的 P_X^* 称为最佳输入分布（optimal input distribution）。这个定义把“信道本身的能力”和“某次输入选择的好坏”分开。

例题 3.6 BSC 的容量 问题：翻转概率为 f 的 BSC，在最佳输入分布下每次使用最多能传多少信息？当 $f = 0.1$ 时容量是多少？

答案：令 $p_1 = P_X(1)$ ，则 $P_X = (1 - p_1, p_1)$ 。输出为 1 的概率为

$$P(Y = 1) = p_1(1 - f) + (1 - p_1)f = f + p_1(1 - 2f). \quad (3.22)$$

于是任意输入分布下的互信息为

$$\begin{aligned} I(X; Y) &= H(Y) - H(Y|X) \\ &= H_2(p_1(1 - f) + (1 - p_1)f) - H_2(f) \\ &= H_2(f + p_1(1 - 2f)) - H_2(f). \end{aligned} \quad (3.23)$$

第二项与 p_1 无关；第一项最大为 1 bit，并在输出均匀时达到最大。对称性也给出同样结论：最佳输入分布是 $P_X^* = (1/2, 1/2)$ 。

因此翻转概率为 f 的 BSC 容量为

$$C_{\text{BSC}}(f) = 1 - H_2(f). \quad (3.24)$$

当 $f = 0.1$ 时， $H_2(0.1) \simeq 0.47$ ，所以容量约为 0.53 bits per channel use。

说明：这里的优化变量是输入分布。容量表示发送端最会使用这条信道时能达到的互信息最大值。




图 3.3: 互信息与输入概率的关系。最大化互信息的概率为 0.5，对应互信息约为 0.53 bits.

定理 3.1 (Shannon 噪声信道编码定理的方向)

若通信速率低于信道容量 C ，则可以通过合适的编码与解码使错误概率任意小。



这个定理是后续证明的目标。它的含义并不显然：即使一个 BSC 会翻转 10% 的 bits，只要跨许多次信道使用进行编码，仍可在低于容量的速率上实现几乎无错的通信。

容量例子

例题 3.7 确定的四输入信道 问题：若 a, b, c, d 四个输入分别可靠地产生四个不同输出，信道容量是多少？

答案：取均匀输入时，输出也均匀， $H(Y) = \log_2 4 = 2$ bits；又因为给定输入后输出确定， $H(Y | X) = 0$ 。因此容量为 2 bits per channel use。

说明：每次使用信道可以可靠地区分四种输入，等价于传输两位二进制信息。

例题 3.8 三元混淆信道 问题：三元混淆信道输入为 a, b, c ，输出为 M, N 。均匀输入下互信息是多少？最佳输入分布和容量是多少？

答案：信道矩阵可写为

$$Q = \begin{bmatrix} 1 & 1/2 & 0 \\ 0 & 1/2 & 1 \end{bmatrix}, \quad (3.25)$$

其中列对应输入 a, b, c ，行对应输出 M, N 。这个信道等价于三张卡片问题： a 总给出 M ， c 总给出 N ，而 b 随机给出 M 或 N 。




图 3.4: 三元混淆信道。中间输入 b 会把输出混到 M 或 N ，而 a 与 c 分别给出确定输出。

若先取均匀输入 $P_X = (1/3, 1/3, 1/3)$ ，看到 $Y = M$ 后，后验为 $P(X = a | Y = M) = 2/3$ 、 $P(X = b | Y = M) = 1/3$ 、 $P(X = c | Y = M) = 0$ 。互信息可以从输入侧或输出侧计算：

$$I(X; Y) = \log_2 3 - H\left(\frac{1}{3}\right) = 1 - \frac{1}{3} = \frac{2}{3} \text{ bits.} \quad (3.26)$$

左边的写法来自 $H(X) - H(X | Y)$ ：均匀三输入给出 $H(X) = \log_2 3$ ，而给定任一输出后的不确定性是二元分布 $(2/3, 1/3)$ 的熵。右边的写法来自 $H(Y) - H(Y | X)$ ：输出 M, N 等概率， $H(Y) = 1$ ；只有输入 b 时输出仍有 1 bit 不确定性，因此 $H(Y | X) = 1/3$ 。

但是均匀输入并非最佳。输入 b 只会把输出随机化，并不能帮助接收端可靠区分更多消息；若只使用 a 和 c ，并令二者各以概率 $1/2$ 出现，输出便可靠地区分两种输入，得到 1 bit per channel use。因此该信道容量为 1 bit，最佳输入分布可以取 $P_X^* = (1/2, 0, 1/2)$ 。这个例子说明，容量最大化允许某些输入符号完全不用。

说明：这个例子的重点是最佳输入分布可能舍弃某些输入符号。均匀使用所有输入并不一定最优。

嘈杂打字机则留作下一步讨论。它的输入是字母键，输出可能是自身或相邻键，例如按 G 时可能得到 F, G, H ，每种概率为 $1/3$ 。由于结构具有循环对称性，最佳输入分布和容量可以从对称性与可区分输入集合两方面分析；这将把容量定义进一步连接到实际构造码字的问题。

结论 本节把信道中的互信息推进为信道容量。给定信道 Q 后，先选择输入分布 P_X 才能得到联合分布并进行推断；互信息 $I(X; Y)$ 衡量输出平均提供了多少关于输入的信息。容量 $C(Q) = \max_{P_X} I(X; Y)$ 则把输入分布也纳入优化，描述信道在最佳使用方式下的最大信息传递能力。对 BSC，最佳输入分布是均匀分布，容量为 $1 - H_2(f)$ ；对三元混淆信道，最佳做法是不用会制造歧义的中输入，从而达到 1 bit。Shannon 噪声信道编码定理将说明，容量既是信息度量，也对应可靠通信可以逼近的速率上限。

3.3 噪声信道编码定理

容量为什么是可达速率

上一节把信道容量定义为互信息在输入分布上的最大值：

$$C = \max_{P_X} I(X; Y) = \max_{P_X} \{H(Y) - H(Y|X)\}. \quad (3.27)$$

这一节说明容量对应可靠通信可以逼近的速率。若发送端与接收端把同一个噪声信道连续使用许多次，并在这些使用之间做联合编码和联合解码，那么即使单次输出有噪声，整体的块错误概率也可以被压到任意小。

例题 3.9 嘈杂打字机的容量 问题：设有 27 个输入字母，每个字母被敲下后，输出可能是它本身或相邻的两个字母，三种结果等概率出现。这个信道每次使用的容量是多少？

答案：给定输入后，输出的不确定性为 $\log_2 3$ bits。若取均匀输入分布，由循环对称性可知输出也是 27 个字母上的均匀分布，于是

$$C_{\text{typewriter}} = \log_2 27 - \log_2 3 = \log_2 9 \text{ bits/use}. \quad (3.28)$$

这也可以从可区分输入集合来理解：只使用每隔三个字母取一个的 9 个输入，例如 $b, e, h, \dots, z$ ，则这些输入对应的输出集合互不重叠，接收端可以零错误地区分是哪一个输入被使用。每次使用信道可选择 9 种可靠消息，正好是 $\log_2 9$ bits。

说明：这个例子说明容量可以通过可区分输入集合直接达到。后面的编码定理把这种“输出集合互不重叠”的图像推广到长块信道。

若把 N 次独立使用合成一个扩展信道，那么输入、输出都是长度为 N 的序列。给定某个输入序列后，典型输出集合的规模约为 $2^{NH(Y|X)}$ ；而整个典型输出空间的规模约为 $2^{NH(Y)}$ 。因此可以容纳的、几乎互不混淆的输入块数量约为

$$\frac{2^{NH(Y)}}{2^{NH(Y|X)}} = 2^{NI(X;Y)}. \quad (3.29)$$

若再对输入分布优化，就得到每 N 次信道使用大约 NC bits 的可靠信息。这个计数解释了为什么容量会出现在编码定理中：噪声把每个输入膨胀成一个典型输出云，而可靠通信需要把不同输入的输出云尽量分开。

定理表述

对二元对称信道 (binary symmetric channel, BSC)，每个 bit 以概率 f 翻转、以概率 $1 - f$ 保持不变。它的容量为

$$C_{\text{BSC}}(f) = 1 - H_2(f), \quad H_2(f) = f \log_2 \frac{1}{f} + (1 - f) \log_2 \frac{1}{1 - f}. \quad (3.30)$$

下面的证明集中在 BSC 的可达方向：只要速率严格低于 $1 - H_2(f)$ ，就存在足够长的码，使块错误概率任意小。

定理 3.2 (二元对称信道的噪声信道编码定理)

设 BSC 的翻转概率为 f ，容量为 $C = 1 - H_2(f)$ 。对任意 $\epsilon > 0$ 与任意速率 $R < C$ ，存在足够大的块长 N ，以及长度为 N 、速率至少为 R 的编码和对应解码器，使块错误概率小于 ϵ 。



这里的速率是 $R = K/N$ ，其中 K 是一次传输中用户真正选择的信息 bits 数， N 是信道使用次数。块错误概率指整个长度为 N 的码字解码错误的概率。定理的强处正在这里：它允许每个符号仍然有固定噪声，只要求把很多次使用绑在一起处理。

线性码与校验子解码

例题 3.10 Hamming 码与校验子解码 问题：为什么 (7, 4) Hamming 码的译码可以看成“从校验子推断噪声”？

答案：一个线性分组码可以由奇偶校验矩阵 H 定义，合法传输向量 $\mathbf{t} \in \mathbb{F}_2^N$ 满足

$$H\mathbf{t} = \mathbf{0} \pmod{2}. \quad (3.31)$$

在 (7, 4) Hamming 码中， $N = 7$ 、 $K = 4$ ，共有 $M = N - K = 3$ 个校验约束。矩阵的每一行对应一个奇偶约束；若写成带单位矩阵的形式，前 K 个 bit 可由用户指定，后 M 个 bit 由约束决定。

通过 BSC 后，接收向量可以写成

$$\mathbf{r} = \mathbf{t} + \mathbf{n} \pmod{2}, \quad (3.32)$$

其中 $\mathbf{n}$ 是噪声向量，1 表示对应位置被翻转。接收端计算校验子 (syndrome)：

$$\mathbf{z} = H\mathbf{r} = H(\mathbf{t} + \mathbf{n}) = H\mathbf{n} \pmod{2}. \quad (3.33)$$

由于合法码字满足 $H\mathbf{t} = \mathbf{0}$ ，校验子完全由噪声向量决定，和实际发送的消息无关。解码的任务因此变成：从 $\mathbf{z}$ 推断最可能的噪声 $\hat{\mathbf{n}}$ ，再用 $\hat{\mathbf{t}} = \mathbf{r} - \hat{\mathbf{n}}$ 恢复码字；在二元域里减法与加法相同。

Hamming 码的单比特纠错正是这个机制的特例。若只翻转第 j 位，则 $\mathbf{n}$ 是第 j 个单位向量，校验子就是 H 的第 j 列；只要各列不同，接收端就能从校验子读出哪一位翻转。一般线性码的校验子解码也是同一件事，只是可能的噪声向量扩展到整个典型噪声集合。

说明：这个例子为编码定理证明铺路。Hamming 码区分的是七个单比特噪声；长块随机码要区分的是大约 $2^{NH_2(f)}$ 个典型噪声向量。

典型噪声集合

对长度为 N 的 BSC，噪声向量 $\mathbf{n}$ 由独立 Bernoulli(f) bits 组成。大多数概率质量集中在那些大约含有 Nf 个 1 的向量上；这些向量构成典型集合，记为 $\mathcal{T}_f^{(N)}$ 。从弯曲硬币彩票的角度看，典型噪声向量就是那些最值得买的票。对足够大的 N ，实际噪声落在典型集合外的概率可以小于任意给定的数。

典型集合的规模在指数阶上为

$$\left| \mathcal{T}_f^{(N)} \right| \simeq 2^{NH_2(f)}. \quad (3.34)$$

这给出校验约束数量的第一层要求。矩阵 H 有 M 行时，校验子是 M bits，共有 2^M 种可能值。若希望不同的典型噪声向量尽量落到不同校验子上，至少需要 2^M 的量级超过 $2^{NH_2(f)}$ ，也就是 M/N 要大于 $H_2(f)$ 。

若这个条件成立，码率就是

$$R = \frac{K}{N} = 1 - \frac{M}{N} < 1 - H_2(f) = C_{\text{BSC}}(f). \quad (3.35)$$

这已经把证明的形状暴露出来：为了纠正典型噪声，需要用约 $NH_2(f)$ 个校验 bits 描述噪声；剩下的

约 $N(1 - H_2(f))$ 个自由度可以承载信息。

随机校验矩阵的平均错误概率

接下来从所有 $M \times N$ 的二元矩阵中随机选择 H ，每个元素独立地以概率 $1/2$ 取 0 或 1。证明策略是计算这些随机码的平均块错误概率；若平均值可以任意小，那么至少存在一个具体矩阵也具有足够小的错误概率。

固定某个 H 后，解码失败有两类原因。第一类是实际噪声 $\mathbf{n}$ 不在典型集合中；其概率记为 P_1 ，通过增大 N 可以使它任意小。第二类是 $\mathbf{n}$ 在典型集合中，但还有另一个典型噪声 $\tilde{\mathbf{n}} \neq \mathbf{n}$ 与它有相同校验子：

$$H\tilde{\mathbf{n}} = H\mathbf{n} \iff H(\tilde{\mathbf{n}} - \mathbf{n}) = \mathbf{0}. \quad (3.36)$$

这种碰撞会让接收端无法唯一确定噪声向量。

关键概率很简单。对任意固定的非零向量 $\mathbf{x} \in \mathbb{F}_2^N$ ，随机矩阵 H 的一行与 $\mathbf{x}$ 的模二内积为 0 或 1 的概率各为 $1/2$ ； M 行相互独立，因此

$$\mathbb{P}_H(H\mathbf{x} = \mathbf{0}) = 2^{-M}. \quad (3.37)$$

在碰撞问题中， $\mathbf{x} = \tilde{\mathbf{n}} - \mathbf{n}$ ，只要两个噪声向量不同， $\mathbf{x}$ 就非零。

用联合边界（union bound）把所有可能的错误碰撞加起来，可得随机矩阵平均意义下的第二类错误概率满足

$$\mathbb{E}_H[P_{\Pi}(H)] \leq \left| \mathcal{T}_f^{(N)} \right| 2^{-M} \simeq 2^{NH_2(f) - M}. \quad (3.38)$$

这里的上界会故意高估真实错误概率：若同时出现多个碰撞，实际仍只是一次解码失败，但联合边界会把它们分别计入。这个粗糙性是可接受的，因为当 $M > NH_2(f)$ 且留有固定余量时，右端随 N 增大指数下降。

综合两类错误，

$$\mathbb{E}_H[P_{\text{block}}(H)] \leq P_1 + 2^{NH_2(f) - M}. \quad (3.39)$$

先取足够大的 N 使典型集外概率 P_1 很小，再取 $M/N > H_2(f)$ 使碰撞项很小，就得到平均块错误概率小于任意 ϵ 。于是至少有一个线性码达到同样的要求。把 $R = 1 - M/N$ 代回，条件正是 $R < 1 - H_2(f)$ 。

注 这个证明是非构造性的。它说明好码存在，甚至说明随机选出的许多校验矩阵平均表现很好；但它没有给出高效寻找最佳矩阵或高效 syndrome 解码的算法。实际编码理论还要继续研究如何把存在性证明变成可计算、可实现的编码和解码方法。

结论 本节把信道容量从互信息的最大值提升为可靠通信速率的边界。嘈杂打字机说明，容量可以通过选择互不混淆的输入集合直接达到；一般信道的扩展使用则把这种图像变成典型输出云之间的打包问题。对 BSC，证明的核心是把噪声看成长度为 N 的典型向量：约有 $2^{NH_2(f)}$ 种需要区分，因此用 $M > NH_2(f)$ 个校验子 bits 足以在随机线性码中以高概率区分它们。剩余自由度给出速率 $R = 1 - M/N$ ，于是所有 $R < 1 - H_2(f)$ 的速率都可在足够大块长下实现任意小的块错误概率。

第四章 贝叶斯推断

4.1 参数推断

擦除信道与反馈

在进入参数推断之前，先补一个和信道容量有关的小结。二元擦除信道（binary erasure channel, BEC）把输入 $X \in \{0, 1\}$ 变成输出 $Y \in \{0, 1, ?\}$ ：以概率 $1 - f$ 正确输出原 bit，以概率 f 输出擦除符号？。

例题 4.1 BEC 的容量与反馈 问题：BEC 的擦除概率为 f 。它的容量是多少？如果接收端把擦除位置反馈给发送端并要求重发，长期速率能否超过这个容量？

答案：若输入分布为 $P_X(0) = p_0$ ，则用 $I(X; Y) = H(X) - H(X | Y)$ 计算最直接。看到 $Y = 0$ 或 $Y = 1$ 时，输入已经确定；只有看到 $Y = ?$ 时，输入仍按先验分布不确定。因此

$$I(X; Y) = H_2(p_0) - f H_2(p_0) = (1 - f) H_2(p_0). \quad (4.1)$$

最大值在 $p_0 = 1/2$ 处取得，容量为

$$C_{\text{BEC}} = 1 - f \text{ bits/use}. \quad (4.2)$$

这个结果也有很朴素的通信解释：平均有比例 $1 - f$ 的符号没有被擦除，它们每个可靠传递 1 bit；被擦除的部分则没有传递关于输入的 bit。

说明：反馈可以让策略变得简单：一旦知道某个 bit 被擦除，就重发同一个 bit。长期来看，比例 f 的信道使用会花在补发擦除项上，所以速率仍是 $1 - f$ bits per channel use。反馈改变实现方式，不改变 BEC 的容量边界。

从信道推断到参数推断

参数推断关注某个产生数据的未知量。科学实验、宇宙学测量、垃圾邮件识别、图像和语音识别都可以放进这个框架：有一组观测数据 D ，也有一组隐藏的假设或参数 θ ，我们希望从 D 反推 θ 的可信程度。关键是写下这些参数如何预测实际观测到的数据。

本讲用高斯分布作为最熟悉的例子。设假设 H 规定数据独立来自一个正态分布，参数为均值 μ 和标准差 σ 。单个观测 x_n 的概率密度为

$$p(x_n | \mu, \sigma, H) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x_n - \mu)^2}{2\sigma^2}\right]. \quad (4.3)$$

这里要区分两个空间： μ, σ 所在的是参数空间，数据点 x_n 所在的是数据空间。参数空间中的一个点代表一整条对数据空间的预测密度曲线。

若观测到 $D = \{x_n\}_{n=1}^N$ ，在独立性假设下似然函数为

$$p(D | \mu, \sigma, H) = \prod_{n=1}^N p(x_n | \mu, \sigma, H). \quad (4.4)$$

似然函数是把已经发生的数据固定住后，考察不同参数对这些数据给出的预测密度。那些没有发生的数据点在似然中不直接出现。因而判断一个参数是否好，要看它对实际观测到的 N 个点给了多大的密

度。

贝叶斯更新与最大似然

Bayes 公式把似然与先验合在一起，得到参数的后验分布：

$$p(\mu, \sigma | D, H) = \frac{p(D | \mu, \sigma, H) p(\mu, \sigma | H)}{p(D | H)}. \quad (4.5)$$

其中分母给出了这组数据在模型 H 下的总概率：

$$p(D | H) = \iint p(D | \mu, \sigma, H) p(\mu, \sigma | H) d\mu d\sigma \quad (4.6)$$

只是使后验归一化的常数；若只想在同一模型 H 下比较不同的 μ, σ ，它可以暂时忽略。但这个常数本身并不无聊，后面做模型比较时它会成为证据。

最大似然估计（maximum likelihood estimate, MLE）是在不考虑先验形状时最大化 $p(D | \mu, \sigma, H)$ 的参数。对高斯模型，均值的最大似然估计是样本平均：

$$\mu_{\text{ML}} = \bar{x} = \frac{1}{N} \sum_{n=1}^N x_n. \quad (4.7)$$

若同时把 μ 和 σ 都作为待优化参数，标准差的最大似然估计为

$$\sigma_N = \left[\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2 \right]^{1/2}. \quad (4.8)$$

这里的下标 N 强调分母是 N 。这对应计算器上的一种标准差按钮：它回答的是“哪一个 σ 与哪个 μ 一起使这组数据的联合密度最大”。

例题 4.2 一个样本点与五个样本点的高斯似然 问题：图 4.1 中，同一个高斯模型在只有一个样本点和有五个样本点时，似然函数在 (μ, σ) 平面上有什么变化？这对最大似然估计有什么提醒？

答案：只有一个样本点时，许多不同的 (μ, σ) 都能给出相当大的密度，曲面在参数空间里拉得很开；把样本数增加到五个以后，联合似然变成多个密度值的乘积，支持区域明显收缩，最大似然点也更容易被看出来。

说明：最大似然点只是后验或似然曲面上的一个点。图中的等高线说明，五个数据点共同给出的似然通常在 (μ, σ) 平面上形成一个峰，但峰附近仍有一片具有相当支持度的参数区域。样本少时，报告完整后验比分别报出两个最大似然数更能反映不确定性。

边际化与自由度

例题 4.3 已知噪声水平时推断均值 问题：若高斯噪声水平 σ 已知，只需要从数据 D 中推断均值 μ ，后验如何写？样本数增加会怎样改变 μ 的不确定性？

答案：Bayes 公式给出

$$p(\mu | D, \sigma, H) = \frac{p(D | \mu, \sigma, H) p(\mu | H)}{p(D | \sigma, H)}. \quad (4.9)$$

若 $p(\mu | H)$ 在似然峰附近足够平坦，后验的峰仍在样本平均 $\bar{x}$ 附近。已知 σ 时， N 个独立观测会把 μ 的不确定性压窄到大约 $\sigma/\sqrt{N}$ 的尺度。

说明：这里的 $\bar{x}$ 不是单纯的公式记忆，它表示所有样本共同支持的均值位置。样本越多，关于均




图 4.1: 高斯模型中样本数对似然函数形状的影响。参数为均值 μ 和标准差 σ ; 随着观测点增多, 似然从宽而平的区域收缩成更集中的峰。

值的后验越集中。

例题 4.4 未知均值时推断噪声水平 问题：若只想知道噪声水平 σ ，而均值 μ 也是未知量，应直接把 μ 固定为 $\bar{x}$ 吗？

答案：概率规则要求把不关心的参数积分掉：

$$p(\sigma | D, H) = \int p(\mu, \sigma | D, H) d\mu = \frac{p(D | \sigma, H) p(\sigma | H)}{p(D | H)}. \quad (4.10)$$

其中边际似然为

$$p(D | \sigma, H) = \int p(D | \mu, \sigma, H) p(\mu | H) d\mu. \quad (4.11)$$

若对 μ 采用很宽的近似均匀先验，这个积分把均值的不确定性纳入了 σ 的推断。它回答的是“在不知道均值到底是多少的情况下，数据支持怎样的噪声水平”。

这也解释了为什么另一个常见标准差使用 $N - 1$ 作分母。令 $S = \sum_{n=1}^N (x_n - \bar{x})^2$ 。在对 μ 边际化后，作为 σ 的函数，主要形状近似为 $\sigma^{-(N-1)} \exp[-S/(2\sigma^2)]$ ，其峰值出现在

$$\sigma_{N-1} = \left[\frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2 \right]^{1/2}. \quad (4.12)$$

若均值已知， N 个样本各自给出一个关于噪声大小的独立偏差 $x_n - \mu$ ；推断 σ 时可以使用 N 个独立偏差信息。均值未知时，数据先要确定中心位置，偏差改为围绕 $\bar{x}$ 计算，并满足 $\sum_n (x_n - \bar{x}) = 0$ 这一条约束；因此关于离散程度的独立信息剩下 $N - 1$ 个自由度。自由度语言给出直观解释，真正决定 σ_{N-1} 的仍是把 μ 积分掉的概率计算。

证据与模型比较

公式 (4.6) 中的 $p(D | H)$ 对参数推断只是归一化常数，但对模型比较是核心量。它也称为边际似然 (marginal likelihood) 或证据 (evidence)。若有两个不同理论 H_1, H_2 ，Bayes 公式在模型层面写成

$$p(H | D) = \frac{p(D | H) p(H)}{p(D)}. \quad (4.13)$$

这里 $p(D | H)$ 衡量整个模型 H 在综合其参数先验之后，对实际数据 D 的预测能力。它在模型比较中扮演的角色，正如普通似然在参数比较中扮演的角色。不要把证据和模型先验混在一起： $p(H)$ 表达看见数据前对模型本身的相信程度， $p(D | H)$ 表达模型在看见数据前会给当前数据集多少概率质量。

证据衡量模型在自己承诺的参数范围内，平均来说把多少预测质量放到了实际发生的数据上。过于灵活的模型可能在最大似然点上表现很好，但若大部分参数区域都预测得很差，证据并不一定高。这个思想将在下一讲继续展开，用于比较参数数目和结构都不同的模型。

例题 4.5 带观测窗口的指数衰变 问题：设粒子由源发出，并在位置 x 处衰变；裸模型给出尺度为 λ 的指数密度。实验只能在窗口 $[x_{\min}, x_{\max}]$ 内记录事件。若观测到 N 个位置 $x_1, \dots, x_N$ ，推断 λ 时单点似然应怎样写？

答案：应使用窗口条件化后的单点密度

$$p(x_n | \lambda, H, \text{obs}) = \frac{\lambda^{-1} \exp(-x_n/\lambda)}{\exp(-x_{\min}/\lambda) - \exp(-x_{\max}/\lambda)}, \quad x_{\min} \leq x_n \leq x_{\max}. \quad (4.14)$$

说明：分母来自“衰变落在可观测窗口内”这一条件。写似然时不仅要写物理分布，还要写清楚实验选择机制；否则 λ 的后验会把探测窗口造成的偏差误认为衰变长度本身的性质。

结论 本节从 BEC 的反馈旁注转入参数推断。BEC 的容量为 $1 - f$ ，反馈能让重传策略更简单，却不提高可实现速率。参数推断部分的核心是把“假设如何生成数据”写成概率模型：在高斯例子中， (μ, σ) 的每个取值对应一个数据空间中的预测密度，观测数据给出似然 $p(D | \mu, \sigma, H)$ ，再由 Bayes 公式得到后验。最大似然给出一个代表性参数点，但边际化能回答只关心某个参数时应相信什么；把不关心的 μ 积分掉后， σ_{N-1} 的形式自然出现。最后，归一化常数 $p(D | H)$ 在模型比较中成为证据，衡量整个模型对实际数据的预测能力；指数衰变练习则把同一原则用于带观测窗口的连续参数模型。

4.2 参数与模型推断

指数衰变问题与传统拟合

本讲承接上一讲最后的指数衰变练习。事件位置 x 由尺度参数 λ 控制，但实验只能观察窗口 $[a, b]$ 内的事件，例如 $a = 1$ cm、 $b = 20$ cm。观测数据为 $D = \{x_n\}_{n=1}^N$ ，目标是从这些位置推断衰变长度 λ 。

例题 4.6 指数衰变参数的推断题 问题：给定窗口 $[a, b]$ 内观测到的位置 $D = \{x_n\}_{n=1}^N$ ，如何从数据推断指数衰变长度 λ ？能否先把数据分箱、画直线或匹配样本均值来得到唯一答案？


答案：分箱、直线化、经验 CDF 和均值匹配都能产生估计，但它们会引入额外选择。分箱法需要选箱宽 Δx 、箱边界、距离函数以及零计数处理方式；数据点很少时，这些选择会明显改变结果。

物理实验中常见的另一个做法，是把指数关系变成直线。若模型密度在窗口内正比于 $\exp(-x/\lambda)$ ，第 b 个小箱的期望计数近似为 $N\Delta x \exp(-x_b/\lambda)/Z(\lambda)$ 。取对数后得到一条关于 x_b 的直线：


$$\log \mathbb{E}[f_b | \lambda] \simeq \log \frac{N\Delta x}{Z(\lambda)} - \frac{x_b}{\lambda}. \quad (4.15)$$

斜率给出 $-1/\lambda$ 。这个方法看起来熟悉，但它仍然依赖分箱；若某些箱计数为零， $\log f_b$ 直接失效。即使图上能看出一条漂亮的直线，也很难说明该直线拟合方式是这个推断问题唯一合理的答案。


还可以使用经验累积分布函数，或用样本平均 $\bar{x} = N^{-1} \sum_n x_n$ 与模型预测均值匹配。均值方法摆脱了分箱，但会丢掉数据中除平均值以外的信息；在有限窗口中，模型均值 $\mu(a, b, \lambda) = \mathbb{E}[x | a \leq x \leq b, \lambda]$ 随 λ 增大最终趋向窗口中点附近，因此某些数据均值可能无法反推出唯一的 λ 。这些方法都可能有用，问题在于每一种都引入了额外选择。




(a) 三个观测点各自给出的似然



(b) 三个观测点的联合似然



(c) 全部观测点各自给出的似然



(d) 全部观测点的联合似然

图 4.2: 截断指数模型中, 不同数据点对 λ 的似然贡献及其乘积。单个观测只能排除部分尺度范围; 多个观测的似然相乘后, 支持区域集中到更窄的区间。

说明: 这个例子想说明参数推断应先写出数据在给定参数下的概率模型。人工拟合规则可以作为摘要或近似, 但不能替代似然函数。

直接写出似然

Bayes 方法把上述选择压缩为一个核心动作: 写出数据在给定参数下的概率。采用未归一化形式 $\exp(-x/\lambda)$ 时, 窗口内的归一化常数为

$$Z(\lambda) = \int_a^b \exp(-x/\lambda) dx = \lambda [\exp(-a/\lambda) - \exp(-b/\lambda)]. \quad (4.16)$$

因此一参数模型 H_1 下的单点密度为

$$p(x_n | \lambda, H_1) = \frac{\exp(-x_n/\lambda)}{Z(\lambda)}, \quad a \leq x_n \leq b. \quad (4.17)$$

这个式子已经包含实验窗口的影响。若忽略 $Z(\lambda)$ 对 λ 的依赖, 就会把“只能看见窗口内事件”误当成数据本身的性质。

例题 4.7 一个指数模型的似然 问题: 在一个指数成分模型 H_1 下, 窗口 $[a, b]$ 内的 N 个独立观测给出怎样的 λ 似然?

答案: 单点密度已经由式 (4.17) 给出。在独立观测假设下, 整组数据的似然为

$$p(D | \lambda, H_1) = \prod_{n=1}^N \frac{\exp(-x_n/\lambda)}{Z(\lambda)} = \frac{\exp\left[-\sum_{n=1}^N x_n/\lambda\right]}{Z(\lambda)^N}. \quad (4.18)$$

这就是推断 λ 所需的全部数据相关信息。似然可以直接画成 λ 或 $\log \lambda$ 的函数; 单个数据点也能排除某些 λ 值, 多个数据点的似然相乘后通常形成更尖的峰。数据越多, 峰宽常按 $1/\sqrt{N}$ 的量级缩小。

说明: 式 (4.18) 保留了每个观测位置, 也保留了窗口归一化常数 $Z(\lambda)$ 对参数的依赖, 因此比先分箱或只取样本均值更贴近原问题。

Bayes 公式给出后验

$$p(\lambda | D, H_1) = \frac{p(D | \lambda, H_1)p(\lambda | H_1)}{p(D | H_1)}. \quad (4.19)$$

如果只想在 H_1 内比较不同的 λ , 分母可暂时看作归一化常数; 若后面要比较模型, 分母 $p(D | H_1)$ 就

是证据，必须保留下来。

先验、点估计与完整后验

λ 是正的长度尺度。若事先只知道它落在若干数量级范围内，一种常见先验是在 $\log \lambda$ 上近似均匀；这等价于在该范围内取 $p(\lambda) \propto 1/\lambda$ 。这种先验表达的是：1, 10, 100 这样的尺度相隔同样一个数量级，先验上应得到相近重视。实际问题中先验范围仍要由物理背景决定，并且模型比较的数值会对这个选择有一定依赖。

若考试题只要求给出一个数，最大似然估计 $\lambda_{\text{ML}} = \arg \max_{\lambda} p(D | \lambda, H_1)$ 是一个自然摘要。但题目问“ λ 是什么”时，更完整的回答是后验分布。后验能表达估计的不确定性，也能处理不规则情况：少量数据可能给出很宽的尾部，多组数据可能让似然峰变得很尖，某些数据甚至可能让似然具有多个局部峰。

这一点也解释了为什么本讲反复回到似然函数。分箱、直线化和矩估计都先把数据压缩成某个摘要；似然函数直接问每个备选 λ 对实际发生的数据给了多大概率密度。若数据足以精确确定 λ ，似然峰会自己变尖；若数据不足，后验会保留这种不确定性。

从一个指数到两个指数

例题 4.8 一个指数还是两个指数 问题：数据是否真的来自一个指数分布？若可能来自两个指数成分的混合，应如何比较 H_1 与 H_2 ？

答案：引入两个模型： H_1 表示一个指数成分，参数为 λ ； H_2 表示两个指数成分，参数为 λ_1, λ_2 。为了把重点放在模型比较上，混合权重先固定为 $\pi_1 = \pi_2 = 1/2$ 。

在 H_2 下，单点密度可写为

$$p(x_n | \lambda_1, \lambda_2, H_2) = \frac{1}{2} \frac{\exp(-x_n/\lambda_1)}{Z(\lambda_1)} + \frac{1}{2} \frac{\exp(-x_n/\lambda_2)}{Z(\lambda_2)}, \quad a \leq x_n \leq b. \quad (4.20)$$

参数后验为

$$p(\lambda_1, \lambda_2 | D, H_2) = \frac{p(D | \lambda_1, \lambda_2, H_2) p(\lambda_1, \lambda_2 | H_2)}{p(D | H_2)}. \quad (4.21)$$

若只关心 λ_1, λ_2 的取值，分母仍可充当归一化常数；若比较 H_1 与 H_2 ， $p(D | H_2)$ 与 $p(D | H_1)$ 正是需要比较的两个证据。

模型层面的 Bayes 公式写成

$$\frac{p(H_2 | D)}{p(H_1 | D)} = \frac{p(D | H_2) p(H_2)}{p(D | H_1) p(H_1)}. \quad (4.22)$$

其中第一项是证据比。若两个模型先验相同，证据比就直接给出后验 odds。最大似然会偏爱参数更多的模型，因为额外参数几乎总能提高最佳点处的拟合；证据比较会把整个参数空间中的预测质量平均进去，因此更复杂的模型需要在足够大的参数区域内预测得好，才能真正胜出。

说明：这个例子把参数推断推进到模型推断。问题不再只是寻找最佳的 λ ，还要比较整个模型在看见数据前会给当前数据集多少概率质量。

隐含标签与证据比

两个指数混合还可以用隐含标签来理解。设每个数据点有一个未观测标签 $k_n \in \{1, 2\}$ ，表示它来自第一个或第二个指数成分；整组标签记为 $K = (k_1, \dots, k_N)$ 。令

$$g(x | \lambda) = \frac{\exp(-x/\lambda)}{Z(\lambda)}, \quad a \leq x \leq b, \quad (4.23)$$

并取混合权重 $\pi_1 = \pi_2 = 1/2$ 。如果标签 K 已知，完整数据似然分解为

$$p(D, K | \lambda_1, \lambda_2, H_2) = \prod_{n=1}^N \pi_{k_n} g(x_n | \lambda_{k_n}) = 2^{-N} \prod_{n:k_n=1} g(x_n | \lambda_1) \prod_{n:k_n=2} g(x_n | \lambda_2). \quad (4.24)$$

这个式子说明，若标签已知，分到成分 1 的点只约束 λ_1 ，分到成分 2 的点只约束 λ_2 。真实数据中标签被擦掉了，所以观测数据似然要对所有 2^N 种标签分配求和：

$$\begin{aligned} p(D | \lambda_1, \lambda_2, H_2) &= \sum_{K \in \{1,2\}^N} p(D, K | \lambda_1, \lambda_2, H_2) \\ &= \prod_{n=1}^N \left[\frac{1}{2} g(x_n | \lambda_1) + \frac{1}{2} g(x_n | \lambda_2) \right]. \end{aligned} \quad (4.25)$$

最后一行正好回到式 (4.20) 的逐点混合密度：每个观测点都可以来自任一成分，独立观测使这些逐点混合项相乘。

这就是“煎饼堆”的含义：每一层对应一种标签分配，每一层都有一张以 (λ_1, λ_2) 为坐标的似然曲面。把所有层相加，可以得到 λ_1, λ_2 的边际后验；沿着 λ_1, λ_2 积分，可以得到标签的后验概率。具体地，若参数先验为 $p(\lambda_1, \lambda_2 | H_2)$ ，则

$$p(\lambda_1, \lambda_2 | D, H_2) = \frac{[\sum_K p(D, K | \lambda_1, \lambda_2, H_2)] p(\lambda_1, \lambda_2 | H_2)}{p(D | H_2)}. \quad (4.26)$$

标签本身的后验则通过积分消去两个尺度参数：

$$p(K | D, H_2) = \frac{\iint p(D, K | \lambda_1, \lambda_2, H_2) p(\lambda_1, \lambda_2 | H_2) d\lambda_1 d\lambda_2}{p(D | H_2)}. \quad (4.27)$$

对全部参数积分、对全部标签求和，就得到 H_2 的证据：

$$\begin{aligned} p(D | H_2) &= \iint p(D | \lambda_1, \lambda_2, H_2) p(\lambda_1, \lambda_2 | H_2) d\lambda_1 d\lambda_2 \\ &= \sum_K \iint p(D, K | \lambda_1, \lambda_2, H_2) p(\lambda_1, \lambda_2 | H_2) d\lambda_1 d\lambda_2. \end{aligned} \quad (4.28)$$

这个归一化常数把每一种标签解释和每一组参数取值都纳入平均，因而是模型比较中真正进入证据比的量。

标签模型具有交换对称性：把所有标签 1 与 2 互换，同时交换 λ_1 与 λ_2 ，模型对数据的预测不变。因此当数据支持两个指数成分时， (λ_1, λ_2) 的后验常出现两个对称峰，一个对应“小 λ_1 、大 λ_2 ”，另一个对应相反标记。若数据实际上更像单个指数， H_2 仍可能找到略高的最大似然点，但两个长度尺度会彼此接近，证据未必支持复杂模型。

例题 4.9 证据比的两个数值结果 问题：两指数模型参数更多，最大似然通常更高。数值证据是否总会支持两指数模型？

答案：某个八点数据集给出 $p(D | H_1) \approx 5.4 \times 10^{-7}$ ， $p(D | H_2) \approx 1.4 \times 10^{-5}$ ，证据比约为 26 : 1。若模型先验相同，后验约为 96% 支持 H_2 、4% 支持 H_1 。另一个真正由单个指数生成的数据集给出相反结论：相对 H_1 ， H_2 的证据比约为 0.27，等先验下约为 78% 支持 H_1 、22% 支持 H_2 。

说明：证据比较考察整个参数空间中的平均预测质量。同样拥有更高最大似然的复杂模型，仍会受到参数空间体积的检验。

结论 本节把上一讲的参数推断推进到模型推断。指数衰变例子说明，分箱、直线化、CDF 距离和矩估计都能产生一个 λ 的估计，但会引入许多额外选择；直接写出窗口条件化密度和似然函数，能更稳定地处理少量数据和有限窗口。一个指数模型给出 $p(\lambda \mid D, H_1)$ ，两个指数模型给出 $p(\lambda_1, \lambda_2 \mid D, H_2)$ ，两者的归一化常数成为模型证据。隐含标签视角把两指数混合理解为对所有颜色分配的求和；证据比则说明，贝叶斯模型比较考察整个模型对数据的预测能力，因而不会自动奖励参数更多的模型。

第五章 近似概率分布

5.1 聚类作为推断问题

从二元高斯信道到软判决

本讲从一个很小的推断练习进入聚类。设信道输入 X 只有两个可能取值，先验概率为 π_1 与 π_2 ；信道输出为实数 Y 。当 $X = i$ 时，输出围绕均值 m_i 作高斯扰动，且两种输入共享同一个噪声标准差 σ ：

$$p(y | X = i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(y - m_i)^2}{2\sigma^2}\right], \quad i \in \{1, 2\}. \quad (5.1)$$

观察到 y 以后，推断问题是计算 $X = 1$ 的后验概率。Bayes 公式给出

$$p(X = 1 | y) = \frac{\pi_1 p(y | X = 1)}{\pi_1 p(y | X = 1) + \pi_2 p(y | X = 2)}. \quad (5.2)$$

把分子分母同除以 $\pi_1 p(y | X = 1)$ ，可得一个 sigmoid 形式：

$$p(X = 1 | y) = \frac{1}{1 + \exp[-a(y)]}, \quad a(y) = \log \frac{\pi_1}{\pi_2} + \frac{(y - m_2)^2 - (y - m_1)^2}{2\sigma^2}. \quad (5.3)$$

式 (5.3) 中的高斯归一化因子相消，只留下两个平方距离的差和先验 odds。利用 $u^2 - v^2 = (u - v)(u + v)$ ， $a(y)$ 是 y 的线性函数：

$$a(y) = \log \frac{\pi_1}{\pi_2} + \frac{2y(m_1 - m_2) + m_2^2 - m_1^2}{2\sigma^2}. \quad (5.4)$$

若 $\pi_1 = \pi_2$ ，后验为 1/2 的分界点在两个均值的中点；若先验倾向某一类，sigmoid 曲线整体平移。这个小练习已经包含本讲后面所有聚类算法的核心：距离给出似然，先验权重移动判决边界，后验概率可以是硬的 0/1 判决，也可以是软的概率责任。

例题 5.1 二元高斯信道的后验概率 问题：信道输入 $X \in \{1, 2\}$ ，先验为 π_1, π_2 ；给定 $X = i$ 时，输出 Y 服从均值为 m_i 、方差为 σ^2 的高斯分布。观测到 $Y = y$ 后， $X = 1$ 的后验概率是多少？分界点受什么影响？

答案：后验由式 (5.2) 给出，也可以写成式 (5.3) 的 sigmoid 形式。两类高斯的公共归一化常数会相消，判决只依赖先验 odds 和两个平方距离的差。等先验时， $p(X = 1 | y) = 1/2$ 的点在 m_1 与 m_2 的中点；先验偏向某一类时，分界点向另一类方向移动。

说明：这个例子说明，高斯模型下的分类并不必直接给出一个类别标签；更自然的输出是后验概率。后面的软 K 均值把同一思想用于多个中心和多个数据点。

K 均值：硬分配与中心更新

聚类问题中，数据点 x_n 通常是多维实向量，例如语音的时频图特征，或自动分拣设备测得的反射率、电导率、质量等属性。目标是在没有人工标签的情况下，发现数据中反复出现的结构。K 均值 (K-means) 先指定中心数 K ，再用一组中心 $m_1, \dots, m_K$ 表示这些结构。

算法从随机初始化中心开始。给定当前中心后，定义数据点 x_n 到中心 m_k 的平方距离

$$d_k(x_n) = \frac{1}{2} \|x_n - m_k\|^2. \quad (5.5)$$

硬分配步骤把 x_n 交给最近的中心。用责任 r_{nk} 记这个分配：

$$r_{nk} = \begin{cases} 1, & k = \arg \min_j d_j(x_n), \\ 0, & \text{其他情况.} \end{cases} \quad (5.6)$$

这里的 r_{nk} 没有引入新的模型，只是把“最近中心”写成便于更新的符号。分配完成后，每个中心移动到自己负责的数据点的平均位置：

$$m_k \leftarrow \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}}. \quad (5.7)$$

反复执行“分配”和“更新”，直到分配与中心都不再明显变化，就得到一个稳定状态。

这个算法简洁，也确实常能给出有用聚类。不过它的答案依赖随机初始化；同一组数据、同一个 K ，多次运行可能收敛到不同稳定状态。指定更大的 K 也会强迫算法给出更多中心，即使数据本身没有相应数量的自然簇。另一个局限来自距离度量：平方欧氏距离偏好近似圆形的簇。若数据呈长条形、弯曲形或各方向尺度不同，硬 K 均值容易把人眼看来属于同一结构的点切开。

例题 5.2 硬 K 均值的分配和更新 问题：已知数据 $x_1, \dots, x_N$ 和当前中心 $m_1, \dots, m_K$ ， K 均值如何完成一次迭代？它为什么会受初始化影响？

答案：一次迭代先用式 (5.5) 计算平方距离，再用式 (5.6) 把每个点分配给最近中心，最后用式 (5.7) 把每个中心改为其负责点的均值。由于分配边界由当前中心决定，不同初始化会进入不同的分配序列，因此可能停在不同局部稳定状态。

说明： K 均值给出的“簇”是算法和度量共同决定的结果。它会稳定下来，但稳定状态本身未必是人类想要的解释，也未必是全局最优解释。

概率解释：球形高斯混合的局部最大化

硬 K 均值可以被看作一个高斯混合模型的近似最大后验过程。设数据来自 K 个高斯成分，每个成分的先验权重相等，且所有成分具有相同、各向同性的方差 $\sigma^2 I$ ：

$$p(x_n | k, m_k, \sigma) = (2\pi\sigma^2)^{-D/2} \exp\left[-\frac{\|x_n - m_k\|^2}{2\sigma^2}\right], \quad p(k) = \frac{1}{K}. \quad (5.8)$$

在给定中心和方差时，最可能的类别标签就是使 $\|x_n - m_k\|^2$ 最小的 k 。这正是硬分配步骤。给定标签时，使似然最大的中心是被分到该类的数据均值，这正是中心更新步骤。

因此，硬 K 均值背后隐含着三类假设：簇可以由高斯成分表示；这些高斯具有相同球形方差；各个成分的先验权重相等。算法的缺陷也从这里变得可解释。若真实结构不是球形，或者不同簇的尺度、权重差异很大，硬分配和简单均值更新就会给出偏离直觉的结果。即使这些假设基本成立，硬分配也会因为把边界附近的数据点完全交给一侧，使中心位置出现系统偏移。

例题 5.3 K 均值在概率上做了什么 问题： K 均值为什么会自然使用平方距离和样本均值？它对应怎样的概率假设？

答案：若假设每个簇是同方差、同权重的球形高斯，式 (5.8) 的指数项正比于负平方距离。给定中心时，最大后验标签选择最近中心；给定标签时，最大似然中心是该类样本均值。硬 K 均值就是在这些变量之间交替取局部最优。

说明：这个解释让算法的可改造性变得清楚：改变生成模型的假设，就应同步改变分配规则和参数更新规则。

软 K 均值：用责任替代硬标签

硬分配把每个点的责任强行设为 0 或 1。软 K 均值 (soft K-means) 保留中心初始化和中心更新的框架，但把分配改成概率责任。给定刚性参数 $\beta > 0$ ，定义

$$r_{nk} = \frac{\exp[-\beta d_k(x_n)]}{\sum_{j=1}^K \exp[-\beta d_j(x_n)]}. \quad (5.9)$$

这相当于对距离作 **softmax**：距离越小，责任越大，但每个中心一般都会得到一部分责任。若 β 很大，责任趋近于 0/1，算法接近硬 K 均值；若 β 较小，责任分布更平缓，一个点会同时影响多个中心。

中心更新沿用加权均值：

$$m_k \leftarrow \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}}. \quad (5.10)$$

当 $d_k(x_n) = \frac{1}{2} \|x_n - m_k\|^2$ 时， β 可解释为 $1/\sigma^2$ 。因此软分配与本讲开头的二元高斯信道后验是同一个形式：各中心给出高斯似然，归一化后得到类别后验。实际演示中，若从较大的 σ 开始再逐渐减小 σ ，多个中心可能先聚在一起，再随着尺度变小而分裂成多个簇。这类似退火思想：先看粗尺度结构，再逐步允许更细的分辨率。

软 K 均值缓解了硬边界带来的偏移，尤其在两个高斯簇相互重叠时更合理；但它引入了尺度参数 β 或 σ 。若这个尺度选得不合适，算法仍可能给出不理想结果。因此，软化标签只是向概率建模迈进一步，还没有自动解决模型选择、尺度选择和形状选择。

例题 5.4 软责任和温度参数 问题：软 K 均值怎样把硬分配改成软分配？参数 β 有什么含义？

答案：软责任由式 (5.9) 给出，它对所有中心的负距离指数作归一化。 β 越大，最近中心的责任越接近 1； β 越小，责任越平均。若距离定义为式 (5.5)，则 $\beta = 1/\sigma^2$ ，其中 σ 是球形高斯的标准差。

说明：软 K 均值把聚类从“把点染成某一种颜色”改成“每个中心对每个点承担多少责任”。这正是后验概率语言在聚类中的用法。

可变尺度、权重与 EM 视角

若数据簇在不同方向上宽度不同，球形高斯的假设太强。一个自然扩展是让第 k 个成分在第 i 个维度有自己的标准差 σ_{ki} ，并允许混合权重 π_k 随数据更新。对应的轴对齐高斯成分为

$$p(x_n | k) = \prod_{i=1}^D \frac{1}{\sqrt{2\pi\sigma_{ki}^2}} \exp\left[-\frac{(x_{ni} - m_{ki})^2}{2\sigma_{ki}^2}\right]. \quad (5.11)$$

责任变成

$$r_{nk} = \frac{\pi_k p(x_n | k)}{\sum_{j=1}^K \pi_j p(x_n | j)}. \quad (5.12)$$

参数更新也相应变为加权估计：

$$m_{ki} \leftarrow \frac{\sum_n r_{nk} x_{ni}}{\sum_n r_{nk}}, \quad \sigma_{ki}^2 \leftarrow \frac{\sum_n r_{nk} (x_{ni} - m_{ki})^2}{\sum_n r_{nk}}, \quad \pi_k \leftarrow \frac{1}{N} \sum_n r_{nk}. \quad (5.13)$$

这已经是用 **EM** 思想拟合高斯混合模型的一种形式：先用当前参数计算隐含标签的后验责任，再用这些责任更新均值、方差和权重。它比 K 均值更有概率解释，也能处理轴向拉伸的簇。

不过这个扩展也暴露了概率模型的一个经典问题。若某个中心几乎只负责一个数据点，最大似然更新可能让该成分的方差趋向 0，从而把这个点解释得过分完美，导致似然出现奇异行为。实际算法需

要正则化、先验、最小方差约束或模型证据来控制这种退化。另一个问题是 K 仍由使用者指定；指定七个成分，算法就会寻找七个高斯成分的解释，即使这不是最自然的解释。

例题 5.5 可变方差和混合权重 问题：如果数据簇是长条形或不同簇大小不同，怎样改造软 K 均值？

答案：可以把球形高斯扩展为式 (5.11) 的轴对齐高斯，并引入混合权重 π_k 。责任由式 (5.12) 计算，均值、方差和权重按式 (5.13) 更新。这样每个簇可以有自己的尺度和权重。

说明：改变模型假设后，更新公式也必须一起改变。继续沿用旧的均值更新和旧的距离公式，会使算法和概率解释脱节。

聚类算法的边界

本讲的最后一个重点是：聚类算法给出的结果始终带有模型解释。硬 K 均值解释为同权重、同方差的球形高斯；软 K 均值解释为带软后验责任的球形高斯混合；可变尺度版本解释为轴对齐高斯混合。若数据呈环形、弯曲流形或重尾结构，高斯混合仍可能给出一个可计算的答案，但这个答案未必符合人想要的结构描述。

从概率角度看，算法背后真正应该有一个目标函数。对 K 均值和软 K 均值而言，为什么交替“分配、更新”会稳定下来、它到底优化了什么，需要在变分方法中讲清楚。本讲先把这个目标函数称为变分自由能。后续的变分解释会把“隐含标签”“责任”“参数更新”和“模型证据”放到同一个框架中。

这个观点也指出了通往更一般聚类方法的方向。若认为数据有重尾簇，可以用 t 分布替换高斯；若认为数据位于低维流形附近，就需要能表达低维解释的生成模型。更稳妥的做法是先写清楚数据如何生成、隐含变量是什么、参数如何影响似然，再由相应的概率目标导出更新规则。

结论 本讲把聚类看作隐含变量推断问题。二元高斯信道给出 sigmoid 后验，说明距离、先验和软责任之间的关系；硬 K 均值用平方距离作硬分配，并把中心更新为负责点的均值；其概率解释是同权重、同方差的球形高斯混合的局部最大化。软 K 均值把 0/1 标签换成由指数距离归一化得到的责任，参数 β 对应高斯噪声尺度。进一步允许每个簇有自己的方差和权重后，算法进入高斯混合与 EM 的形式，但也出现方差塌缩和 K 选择等问题。聚类结果因此总是某个概率假设下的解释；变分自由能将为这些交替更新提供统一目标。

5.2 蒙特卡洛方法

复杂后验与两个蒙特卡洛问题

聚类问题把我们带到一种典型局面：模型很容易写下，完整的后验分布却很难直接计算。以高斯混合为例，未知量包括各个成分的均值 $\mu_1, \dots, \mu_K$ 、尺度 $\sigma_1, \dots, \sigma_K$ 、混合权重 $\pi_1, \dots, \pi_K$ ，以及每个数据点的隐含类别 $C_1, \dots, C_N$ 。数据 $x_1, \dots, x_N$ 已经观测到，目标是在所有未知量的联合空间上进行推断。

把这些未知量合写成状态 z ，Bayes 公式给出

$$p(z | x_{1:N}) = \frac{p(x_{1:N} | z)p(z)}{\int p(x_{1:N} | z)p(z) dz}. \quad (5.14)$$

如果 z 中含有离散标签，分母还要对所有标签组合求和。通常我们能计算分子，也就是未归一化概率；困难集中在分母。蒙特卡洛方法常把目标分布写成

$$p(z) = \frac{p^*(z)}{Z}, \quad Z = \int p^*(z) dz, \quad (5.15)$$

其中 $p^*(z)$ 可逐点计算， Z 是未知归一化常数。在统计物理语言中，也常写 $p^*(z) = \exp[-E(z)]$ ，把概率计算转化为能量函数计算。

蒙特卡洛方法首先关心两个问题。第一个问题是从目标分布 p 中得到有代表性的随机样本。第二个问题是估计某个函数在 p 下的期望。若已经得到样本 $z^{(1)}, \dots, z^{(R)} \sim p$ ，则

$$\mathbb{E}_p[f(Z)] \simeq \frac{1}{R} \sum_{r=1}^R f(z^{(r)}). \quad (5.16)$$

这条公式把复杂积分变成随机平均。它并不要求枚举所有状态，也不要求找到最可能状态；它要求样本能代表目标分布中真正占据概率质量的区域。最可能状态有时只是一个尖点，真正的典型状态可能数量巨大。

例题 5.6 手稿归属中的期望 问题：有一批古手稿字符，每个字符由某位书写者产生，但书写者身份未知。怎样回答“两个字符是否来自同一位书写者”这类问题？

答案：设 C_i 和 C_j 是两个字符的隐含书写者标签，定义指示函数 $f(C) = \mathbf{1}\{C_i = C_j\}$ 。后验概率 $p(C_i = C_j | \text{data})$ 就是 $\mathbb{E}[f(C) | \text{data}]$ 。若能从标签后验中抽样，便可用样本平均估计这个概率。

说明：这个例子说明，蒙特卡洛推断常常服务于具体查询。我们并不需要把整张后验表列出来，只要抽样能覆盖后验中的重要解释，就能估计问题对应的函数期望。

物理例子：纳米磁体

纳米磁体提供了另一类更直观的复杂分布。设系统有 N 个微小磁矩，每个自旋 s_i 只能取 -1 或 $+1$ ，整体状态为 $s = (s_1, \dots, s_N)$ 。若相邻或相互作用的自旋倾向于同向排列，可以用耦合矩阵 J 定义能量，例如

$$E(s; J) = - \sum_{i < j} J_{ij} s_i s_j. \quad (5.17)$$

温度由参数 β 控制时，系统状态服从 Boltzmann 分布

$$p(s | J, \beta) = \frac{\exp[-\beta E(s; J)]}{Z(J, \beta)}. \quad (5.18)$$

即使 $N = 1000$ ，状态数也已经达到 2^{1000} 。逐个状态求和完全不可行，但给定一个状态 s 后，计算能量和未归一化概率通常很容易。

在这类问题中，感兴趣的量包括平均能量 $\mathbb{E}[E(S)]$ 、能量方差、平均磁化强度 $\mathbb{E}[\sum_i S_i]$ 、磁化强度方差、熵和热容等。许多量都可以写成目标分布下的期望，因此适合由样本平均估计。归一化常数的对数 $\log Z$ 更难，它对应自由能，不能直接由普通样本平均给出；后面会看到一些专门估计归一化常数的方法。

例题 5.7 自旋系统的规模障碍 问题：一个 $N = 1000$ 的二值自旋系统为什么需要蒙特卡洛方法？

答案：系统共有 2^{1000} 个状态。虽然单个状态的能量 $E(s; J)$ 和权重 $\exp[-\beta E(s; J)]$ 可以快速算出，归一化常数和期望量需要对天文数量的状态求和。通过从高概率区域抽取代表性状态，可以估计平均能量、磁化强度等物理量。

说明：蒙特卡洛方法的价值正在于这种差异：局部计算容易，全局求和困难。抽样把全局求和替换为对典型状态的随机平均。

重要性采样

重要性采样从一个容易抽样的分布 $q(z)$ 出发，再用权重修正它和目标分布的差异。设目标分布为 $p(z) = p^*(z)/Z_p$ ，而样本 $z^{(r)}$ 来自 q 。若直接平均 $\phi(z^{(r)})$ ，得到的是 q 下的期望；要估计 p 下的期望，需要引入权重

$$w(z) = \frac{p^*(z)}{q(z)}. \quad (5.19)$$

当 Z_p 未知时，常用自归一化重要性采样估计

$$\hat{\Phi}_{\text{IS}} = \frac{\sum_{r=1}^R w(z^{(r)}) \phi(z^{(r)})}{\sum_{r=1}^R w(z^{(r)})}, \quad z^{(r)} \sim q. \quad (5.20)$$

这个公式的来源很简单：

$$\begin{aligned} \mathbb{E}_q \left[\frac{p^*(Z)}{q(Z)} \phi(Z) \right] &= \int q(z) \frac{p^*(z)}{q(z)} \phi(z) dz = Z_p \mathbb{E}_p[\phi(Z)], \\ \mathbb{E}_q \left[\frac{p^*(Z)}{q(Z)} \right] &= \int p^*(z) dz = Z_p. \end{aligned} \quad (5.21)$$

把两个 Monte Carlo 平均相除，未知的 Z_p 被消去。

重要性采样的成败取决于 q 是否覆盖目标分布的重要区域。若 q 太窄，或中心位置偏离目标分布，样本可能长期见不到真正高概率的区域，估计值看起来稳定，却已经偏离真实答案。偶尔出现的一个巨大权重会突然改写平均值。观察最大权重、有效样本数和权重方差很有帮助，但这些诊断只能发现一部分问题。

例题 5.8 重要性采样的陷阱 问题：为什么一个看起来收敛平稳的重要性采样估计仍可能严重错误？

答案：若提议分布 q 没有覆盖目标分布 p 的主要质量区域，样本只会反复探索错误位置。由于缺失区域没有被访问，估计曲线可能显得很平滑。等到极少数样本落入目标分布的重要区域时，权重 $p^*(z)/q(z)$ 会非常大，估计值可能突然跳变。

说明：重要性采样的核心在于让 q 在目标分布重要的地方有足够概率质量，容易抽样只是基本要求。覆盖不足比方差大更危险，因为它可能在有限样本中完全不可见。

拒绝采样

拒绝采样用一个包住目标未归一化密度的上界来产生精确样本。设 $q(z)$ 容易抽样，且存在常数 c 使

$$cq(z) \geq p^*(z) \quad \text{对所有 } z \text{ 成立.} \quad (5.22)$$

一次拒绝采样包含三步：先抽取 $z \sim q$ ；再抽取 $u \sim \text{Uniform}(0, cq(z))$ ；若 $u \leq p^*(z)$ ，接受 z ，否则丢弃这次候选。

几何上，可以把 (z, u) 看作在曲线 $cq(z)$ 下方均匀撒点。被接受的点恰好落在 $p^*(z)$ 下方，把这些点投影回 z 轴，就得到来自目标分布的样本。因此，只要包络条件全局成立，接受样本的分布就是 p 。

拒绝采样的限制也很直接。首先，常数 c 必须真正包住目标密度；只检查已经抽到的点并不能证明包络成立。其次，若 $cq(z)$ 比 $p^*(z)$ 高很多，接受率会非常低。维度升高后，找到一个既容易抽样又紧贴目标的包络往往很难。

例题 5.9 包络与接受率 问题：拒绝采样什么时候可靠，什么时候低效？

答案：可靠性来自全局包络 $cq(z) \geq p^*(z)$ 。只要这个条件成立，所有接受样本都服从目标分布。效率由接受率决定；包络越松，落在目标曲线下方的比例越小，需要丢弃的候选越多。

说明：拒绝采样给出了很干净的抽样原理，但它把难点转移到包络设计上。低维、形状简单的分布适合它；高维复杂后验通常需要更灵活的方法。

Metropolis 方法

Metropolis 方法把独立抽样改成沿着状态空间移动的随机过程。给定当前状态 z_t ，先从局部提议分布 $q(z' | z_t)$ 产生候选 z' ，再决定是否接受。一般的 Metropolis-Hastings 接受比为

$$a(z_t, z') = \frac{p^*(z')q(z_t | z')}{p^*(z_t)q(z' | z_t)}. \quad (5.23)$$

以概率 $\min\{1, a(z_t, z')\}$ 接受候选；若接受则 $z_{t+1} = z'$ ，若拒绝则 $z_{t+1} = z_t$ 。当提议分布对称，即 $q(z' | z_t) = q(z_t | z')$ 时，接受比化简为

$$a(z_t, z') = \frac{p^*(z')}{p^*(z_t)}. \quad (5.24)$$

这正是 Metropolis 方法最常见的形式。

这个接受规则有两层直觉。若候选状态的未归一化概率更大，则总是接受；若候选状态概率更小，仍可能按比例接受。前者让链条偏向高概率区域，后者避免它只做贪心爬山。长时间运行后，在合适的连通性和稳定性条件下，链条访问状态的频率会接近目标分布。

Metropolis 方法的样本不是相互独立的。链条每一步只做局部移动，因此连续样本高度相关；提议步长太小会移动缓慢，步长太大会频繁拒绝。如何判断链条已经充分探索目标分布，也是实际应用中的主要困难。下一讲会介绍减轻随机游走问题和调参敏感性的改进方法。

例题 5.10 从局部移动得到全局样本 问题：Metropolis 方法为什么能只用 $p^*(z)$ ，不需要知道归一化常数 Z ？

答案：接受比只含目标密度的比值。因为 $p(z) = p^*(z)/Z$ ，两个状态的概率比中 Z 会相消。对称提议下，接受概率只需要比较 $p^*(z')$ 与 $p^*(z_t)$ 。

说明：这使 Metropolis 方法特别适合贝叶斯后验和物理系统。许多问题都能计算未归一化概率，却无法计算完整归一化常数。

Gibbs 采样与聚类

Gibbs 采样是一类特殊的 Markov chain Monte Carlo 方法。若联合分布 $p(z_1, \dots, z_D)$ 很复杂，但每个变量在其他变量给定时的条件分布容易抽样，就可以逐个更新变量。二维情形可写为

$$z_1^{(t+1)} \sim p(z_1 | z_2^{(t)}), \quad z_2^{(t+1)} \sim p(z_2 | z_1^{(t+1)}). \quad (5.25)$$

高维时，可以按坐标或按变量组循环更新。每一步都从精确条件分布中抽样，整体链条的平稳分布就是目标联合分布。

Gibbs 采样特别适合含有隐含标签的模型。以高斯均值和尺度的后验为例，若尺度给定，均值的条件分布通常是高斯；若均值给定，精度或方差的条件分布通常属于 gamma 或 inverse-gamma 族。交替抽取这些条件分布，就能在均值和尺度的联合后验上移动。

在高斯混合聚类中，Gibbs 采样可以交替更新标签和参数。给定标签后，每个簇内的数据决定该簇的均值与尺度条件分布；给定参数后，每个数据点属于第 k 个簇的概率为

$$p(C_n = k | x_n, \theta) = \frac{\pi_k p(x_n | \theta_k)}{\sum_{j=1}^K \pi_j p(x_n | \theta_j)}. \quad (5.26)$$

这和软 K 均值中的责任形式相同，但 Gibbs 采样下一步会按这些概率真正抽取一个标签。软 K 均值保留概率责任并做确定性更新；Gibbs 采样产生标签、均值和尺度的随机样本，从而表示完整后验中的不确定性。

这种随机表示还能用于预测。对每个后验样本，都可以得到一条可能的数据生成分布；把许多样本对应的预测分布平均起来，就得到考虑参数不确定性和标签不确定性的预测。若模型具有标签交换对称性，链条还应有机会在对称解释之间切换；否则样本只代表后验中的一部分模式。

例题 5.11 聚类中的 Gibbs 更新 问题：高斯混合聚类中怎样用 Gibbs 采样处理未知标签？

答案：先在给定标签时抽取每个簇的参数，例如均值和尺度；再在给定参数时，用式 (5.26) 计算每个数据点属于各簇的条件概率，并按这个 categorical 分布抽取新标签。反复交替后，样本序列表示标签和参数的联合后验。

说明：这个过程把聚类从单一答案扩展为后验样本集合。边界附近的数据点可以在不同样本中归入不同簇，预测时也会自然反映这种不确定性。

归一化常数与下一步

本讲的几个方法处理了不同层面的困难。重要性采样可以直接估计期望，但依赖提议分布对目标分布的覆盖。拒绝采样能给出精确样本，但需要全局包络和足够高的接受率。Metropolis 方法只需要未归一化概率的比值，适合复杂后验；代价是样本相关、随机游走缓慢、收敛诊断困难。Gibbs 采样利用条件分布结构，在层次模型和隐含变量模型中尤其自然。

这些方法大多解决抽样和期望估计问题，对归一化常数 Z 的估计并不直接。模型比较却常常需要证据，也就是对参数和隐含变量积分或求和后的概率。若要比不同簇数、不同模型结构或不同物理参数，归一化常数会重新成为核心对象。后续的高级蒙特卡洛方法会继续处理随机游走、步长选择、收

敛判断和归一化常数估计这些问题。

结论 蒙特卡洛方法面对的是可逐点计算、难以全局归一化的概率分布。若能获得目标分布的代表性样本，期望可以由样本平均估计。重要性采样用权重修正提议分布，拒绝采样用包络产生精确样本，Metropolis 方法通过局部随机移动构造以目标分布为平稳分布的链条，Gibbs 采样则利用条件分布逐块更新变量。聚类、手稿归属和自旋系统展示了同一思想：用随机样本表达复杂后验中的典型解释，再由这些解释回答具体的概率问题。

第六章 用神经网络进行数据建模