

随机过程课程讲义

授课教师：_____

2026 年 8 月 10 日

目录

第1章 基本概念	1
1.1 定义	1
1.1.1 为什么引入随机或随机过程	1
1.1.2 随机变量	2
1.1.3 域/代数的概念	4
1.1.4 概率测度	6
1.1.5 基于概率空间定义随机变量的作用: 抽象与观测	7
1.1.6 随机向量与随机过程的过渡	11
1.1.7 随机过程	14
1.1.8 复随机过程	17
1.1.9 随机过程的分类	18
1.1.10 一阶分布	18
1.1.11 分布、密度与二阶性质	21
1.1.12 一阶与二阶性质的工程含义	23
1.1.13 交叉相关与交叉协方差	24
1.1.14 随机过程的一般性质	25
1.1.15 相关 α -依赖、白过程与严格白过程	26
1.1.16 独立增量与不相关增量	28
1.1.17 正态过程与存在定理	29
1.1.18 随机过程的 Riemann 积分	30
1.1.19 点过程、更新过程与计数过程	33
1.1.20 Poisson 过程的定义性性质	33
1.1.21 Poisson 电报信号	36
1.1.22 Poisson 过程的运算性质	39

1.1.23	Poisson 点的随机筛选	41
1.1.24	Poisson 点的条件分布	42
1.1.25	平稳性族	43
1.1.26	其他形式的平稳性	44
1.1.27	随机同相/正交载波的平稳性	45
1.1.28	弱平稳的两个常用充分条件	48
1.1.29	圆对称与独立性推出高斯	50
1.1.30	相关时间	52
1.2	随机输入系统	52
1.2.1	随机输入系统的基本模型	52
1.2.2	确定性系统与随机系统	53
1.2.3	无记忆系统	54
1.2.4	无记忆系统与平稳性	55
1.2.5	硬限幅器与反正弦律	57
1.2.6	Bussgang 定理	59
1.2.7	线性系统与卷积表示	61
1.2.8	时不变系统	63
1.2.9	卷积表示的限制	64
1.2.10	Dirac delta 函数	64
1.2.11	时变线性系统与模拟调制器	65
1.2.12	线性系统中矩函数的传播	66
1.2.13	微分器	68
1.2.14	随机激励下的微分方程	69
1.2.15	高阶矩的推广	69
1.3	功率谱	71
1.3.1	功率谱与互功率谱	71
1.3.2	协方差谱	73
1.3.3	具有指定功率谱的过程	73
1.3.4	多普勒效应	74

目录	iii
1.3.5 宽平稳输入通过线性系统	76
1.3.6 传递函数与扩展傅里叶变换	77
1.3.7 Hilbert 变换与解析信号	78
1.3.8 累积谱与累积协方差谱	80
1.3.9 非负频谱与非负定性	81
1.3.10 Pólya 充分判据与必要排除	82
1.3.11 互功率谱的频带上界	84
1.3.12 均方意义下的相等与周期性	84
1.3.13 均方连续性	86
1.3.14 均方可微性	87
1.3.15 均方可积性	88
1.4 离散时间过程	90
1.4.1 离散时间过程与离散功率谱	90
1.4.2 取样后的谱周期延拓与混叠	91
1.4.3 离散时间卷积与二阶矩传播	91
1.4.4 Schur 引理与 Toeplitz 非负定性	92
1.4.5 Paley–Wiener 判据	94
1.4.6 有限谐波和的宽平稳性	94
1.4.7 离散时间系统中的功率谱传播	95
第2章 随机游走及其他应用	97
2.3 调制	97
2.4 循环平稳过程	97
2.5 带限过程与采样理论	97
2.6 噪声中的确定性信号	97
附录 10A: 泊松求和公式	97
第3章 谱表示	98
3.1 因子分解与新息	98
3.2 有限阶系统与状态变量	98

目录	iv
3.3 傅里叶级数与 Karhunen–Loève 展开	98
3.4 随机过程的谱表示	98
第4章 谱估计	99
4.1 遍历性	99
4.2 谱估计	99
第5章 均方估计	100
5.1 引言	100
5.2 预测（部分）	100
5.3 格型滤波器与 Levinson 算法	100
课程说明	101

第1章 基本概念

1.1 定义

1.1.1 为什么引入随机或随机过程

Random 一词在字典中的意思是：没有方法或有意识决定而发生；在统计中，表示每个项目受到相等机会支配。Stochastic 则指具有随机概率分布或随机模式，可以统计分析，但未必能够精确预测。Process 是为了达到某个目的而采取的一系列动作或步骤。

引入随机过程的理由，是为了方便分析系统。以通信系统为例，可以考虑两类模型：deterministic model 与 random/stochastic model。确定性模型对系统随时间变化的精确行为没有不确定性；随机或随机模型则对系统随时间变化的精确行为不确定，但对统计行为是确定的。典型的随机模型包括信道噪声、干扰，以及语音等信息源。

这里要先区分 random 与 stochastic 的语感。random 在一般用法里常带有 uniform 的意思，例如说从十个人中 randomly pick one，通常隐含每个人被选到的机会都是 $1/10$ 。因此如果没有特别说明，random 往往会让人联想到 equal chance。stochastic 更接近本课程真正要用的概念：具体值不一定能精确预测，但可以用概率分布、相关结构或统计模式来分析。

Process 这个词也很重要。它强调带有时间或索引推进的系统行为，而一次孤立的随机试验只给出单个结果。通信系统在今天、明天、很长时间内都要运作；噪声、干扰和数据源都随时间变化。后面要谈的 stationary、ergodic、time shift 等概念，都与时间索引有关。因此随机过程的重点在于：对象随时间展开，具体轨迹不确定，统计规律仍可分析。

deterministic model 与 stochastic model 的差别，可以从“什么确定、什么不确定”来理解。若系统完全知道要传送的序列、噪声的具体形状和

每个时刻的行为，那就是确定性模型；这种模型可以针对某个特定序列设计，却缺乏泛用性。随机模型承认具体时刻传的是 0 还是 1、噪声值是多少并不知道，但要求概率特性是确定的。若连统计特性都不知道，就接近 blind system，通常要牺牲复杂度、效能或传输速率。

1.1.2 随机变量

定义 1.1.1 (随机变量). 设 $(S, \mathcal{F}, P)$ 为概率空间，其中 $\mathcal{F}$ 是 σ -域， P 是定义在 $\mathcal{F}$ 中事件上的概率测度。定义在该概率空间上的随机变量，是实值函数 $x: S \rightarrow \mathbb{R}$ ，并且对每个 $a \in \mathbb{R}$ 都满足

$$\{\zeta \in S : x(\zeta) \leq a\} \in \mathcal{F}. \quad (1.1)$$

S 中的元素称为样本结果 (sample outcome)。 $\mathcal{F}$ 中的元素称为事件 (event)。事件是 S 的子集；换句话说， $\mathcal{F}$ 是由 S 的若干子集组成的非空集合族。概率测度 P 定义在 $\mathcal{F}$ 的事件上，因此所有包含在 $\mathcal{F}$ 中的事件都必须能够被赋予概率。

“随机变量”这个名称本身容易造成误解。给定样本结果 ζ 后， $x(\zeta)$ 的值由映射规则完全决定；随机性来自样本结果本身的不确定，函数 x 作为映射规则是确定的。因此随机变量本质上是一个 deterministic function mapping：它把样本空间中的每个 outcome 映射到实数轴上的一个数。

为什么一定要映射到实数？样本空间可以很抽象，例如硬币的正面和反面、图形符号、某些状态或事件本身都未必能加减乘除，也未必有大小顺序。实数系统有完整的运算和排序结构，映射到 $\mathbb{R}$ 后，才可以讨论大小比较、分布函数、期望和后续随机过程中的相关量。

式 (1.1) 的条件是整页定义中最关键的一句。因为 $x(\zeta)$ 是实数，所以可以讨论 $x(\zeta) \leq a$ ；把所有满足这个不等式的样本结果收集起来，会得到 S 的一个子集。这个子集必须属于 $\mathcal{F}$ ，也就是必须是一个事件。只要属于 $\mathcal{F}$ ，就表示它有概率。若这个条件不成立，随机变量的累积分布函数就无法良好定义 (well-defined)。

此外, $\mathcal{F}$ 不能是空集合。最小的事件空间至少包含 $\emptyset$ 与 S : 前者表示不可能事件, 概率为 0; 后者表示必然事件, 概率为 1。实际应用中当然不会只关心这两个平凡事件, 但这说明事件空间必须至少有可被概率测度处理的基本对象。

例 1.1.2 (随机变量的事件域). 设 $S = \{\square, \triangle, \diamond\}$, 并令 $\mathcal{F} = \{\emptyset, \{\square, \triangle\}, \{\diamond\}, S\}$ 。一个合法的概率测度必须对下列所有事件定义概率:

$$P(\emptyset) = 0, \quad P(\{\square, \triangle\}) = 0.7, \quad P(\{\diamond\}) = 0.3, \quad P(S) = 1. \quad (1.2)$$

在这个模型中, 不需要、也不应该给出 $P(\{\square\})$ 与 $P(\{\triangle\})$ 。

这个例子说明, 概率测度的定义域是事件域 $\mathcal{F}$ 。当前模型只把 S 的一部分子集列为事件, 并关心 “ $\square$ 或 $\triangle$ 出现” 以及 “ $\diamond$ 出现”, 所以 $\{\square, \triangle\}$ 与 $\{\diamond\}$ 在 $\mathcal{F}$ 中; 单独的 $\{\square\}$ 、 $\{\triangle\}$ 不在 $\mathcal{F}$ 中, 因此在这个概率模型中它们没有被列为可量概率的事件。

这体现的是概率模型的选择。一个事件若不在事件域中, 就表示当前模型没有把它当作可测事件来处理。以后看到 $A \in \mathcal{F}$, 应立即理解为: A 是关心的事件, 并且 $P(A)$ 有意义。

随机变量定义中的可测性 随机变量仍定义为概率空间 $(S, \mathcal{F}, P)$ 上的实值函数 $x: S \rightarrow \mathbb{R}$, 并满足对每个 $a \in \mathbb{R}$,

$$\{\zeta \in S : x(\zeta) \leq a\} \in \mathcal{F}. \quad (1.3)$$

事件空间 $\mathcal{F}$ 必须是 σ -域, 原因在后面的域与 σ -域中说明。这里先强调可测性条件: $\{\zeta \in S : x(\zeta) \leq a\}$ 对每个实数 a 都必须是事件。

若上述集合未被列为事件, 就不能对它取概率, 于是累积分布函数

$$\Pr[x \leq a] = P(\{\zeta \in S : x(\zeta) \leq a\}) \quad (1.4)$$

便无法良好定义。随机变量的定义之所以写得这样严格, 是为了保证后续所有关于分布、期望和随机过程统计量的讨论都有概率意义。

因此，从 S 到 $\mathbb{R}$ 的函数要成为随机变量，还必须把实数轴上的半无限区间 $(-\infty, a]$ 的原像变成 $\mathcal{F}$ 中的事件。这就是概率论中“可测”的直观含义：通过这个函数所提出的“ x 是否不超过 a ”的问题，必须是当前概率模型能够回答且能够赋概率的问题。

1.1.3 域/代数的概念

定义 1.1.3 (域或代数). 设 $\mathcal{F}$ 是样本空间 S 的非空子集族。若 $\mathcal{F}$ 满足以下性质，则称 $\mathcal{F}$ 为 S 上的域 (field) 或代数 (algebra)：

1. $\emptyset \in \mathcal{F}$ 且 $S \in \mathcal{F}$;
2. 若 $A \in \mathcal{F}$, 则 $A^c \in \mathcal{F}$;
3. 若 $A \in \mathcal{F}$ 且 $B \in \mathcal{F}$, 则 $A \cup B \in \mathcal{F}$ 。

第一条表示，事件域必须包含空集合与整个样本空间。其直观解释是： $\mathcal{F}$ 应该提供一种机制，判断结果是否落在不可能事件 $\emptyset$ 或必然事件 S 中。这两个事件的概率分别是 0 与 1，必须可量。

第二条是补集封闭。若有机判断 outcome 是否落在 A 中，就等价于有机判断 outcome 是否落在 A^c 中。第三条是有限并封闭。若能够判断 outcome 是否落在 A 中，也能够判断是否落在 B 中，就能够判断 outcome 是否落在 $A \cup B$ 中。

这些性质是公理式的规则。公理在这里承担规定作用：它说明什么样的集合族可以作为事件空间。公理越少越好；能由现有公理推出的性质，不必再列为新公理。例如如果 $A, B \in \mathcal{F}$ ，则由 De Morgan 公式

$$A \cap B = (A^c \cup B^c)^c \quad (1.5)$$

可知 $A \cap B \in \mathcal{F}$ 。有限交封闭可以由补集封闭与有限并封闭推出，因此不需要作为第四条公理单独加入；但在实际推导中，记住事件域对有限并、有限交和补集都封闭很有用。

σ -域/代数 只使用 field 在处理“极限”时可能出现的问题。令 $S = \mathbb{R}$ ，并令 $\mathcal{F}$ 为所有端点为有理数的开区间、半开区间、闭区间以及 $\mathbb{R}$ 本身组成的集合族。对每个 $k = 1, 2, \dots$ ，令

$$A_k = [0, [\pi]_k), \quad [\pi]_k \triangleq \frac{\lfloor \pi 10^k \rfloor}{10^k}. \quad (1.6)$$

这里 $[\pi]_k$ 表示把 π 截到小数点后 k 位所得的有理数。因此每个 A_k 的两个端点都是有理数，属于上述集合族。问题是：无限并

$$\bigcup_{k=1}^{\infty} A_k = [0, \pi) \quad (1.7)$$

是否仍属于 $\mathcal{F}$ ？答案是否定的，因为右端点 π 是无理数。

这个例子说明，有限操作下看似完整的 field，在极限或无限并操作下可能不封闭。工程上经常会遇到这种极限问题：系统长时间运行，设备反复使用，样本数量趋于很大，随机过程的长期行为、收敛事件和时间平均都会把分析推向极限。若事件域在极限下漏掉集合，就会造成“想讨论的事件没有概率”的问题。

定义 1.1.4 (σ -域或 σ -代数). 设 $\mathcal{F}$ 是样本空间 S 的非空子集族。若 $\mathcal{F}$ 满足以下性质，则称 $\mathcal{F}$ 为 S 上的 σ -域 (σ -field) 或 σ -代数 (σ -algebra):

1. $\emptyset \in \mathcal{F}$ 且 $S \in \mathcal{F}$;
2. 若 $A \in \mathcal{F}$ ，则 $A^c \in \mathcal{F}$;
3. 若 $A_i \in \mathcal{F}$ ， $i = 1, 2, 3, \dots$ ，则

$$\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}. \quad (1.8)$$

σ -域相对于 field 的关键差别，是把有限并封闭扩展为可数并封闭。这样一来，只要一系列事件都可量，它们的可数并也仍然是可量事件。对随机过程而言，这个扩展足以支撑后续关于长期行为、极限和统计结构的讨论。因此在随机变量定义中，事件空间 $\mathcal{F}$ 被要求是 σ -域，而不仅仅是 field。

1.1.4 概率测度

定义 1.1.5 (概率测度). 设 $(S, \mathcal{F})$ 为可测空间。若定义在 $\mathcal{F}$ 上的集合函数 P 满足:

1. 对任意 $A \in \mathcal{F}$, 有 $0 \leq P(A) \leq 1$;
2. $P(\emptyset) = 0$ 且 $P(S) = 1$;
3. 若 $A_1, A_2, \dots$ 是 $\mathcal{F}$ 中两两不交的集合序列, 则

$$P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} P(A_k), \quad (1.9)$$

则称 P 为 $(S, \mathcal{F})$ 上的概率测度 (probability measure)。

概率测度首先是一个 set function, 也就是把事件集合映射到 $[0, 1]$ 中实数的函数。它的输入对象是集合; 只有当集合属于事件域 $\mathcal{F}$ 时, $P(A)$ 才有定义。因此概率空间的三个要素 $(S, \mathcal{F}, P)$ 是一组整体: S 给出所有可能的样本结果, $\mathcal{F}$ 指定哪些子集可量, P 再对这些可量事件赋概率。

前两条公理符合日常概率语言。 $P(S) = 1$ 表示样本空间涵盖了当前模型承认的全部可能性, 必然事件的概率为 1; $P(\emptyset) = 0$ 表示不可能事件的概率为 0。从工程应用的角度, 概率通常以 0 到 1 的数值表达, 1 对应百分之百发生, 0 对应不会发生。

第三条可数可加性是概率测度中最重要的结构。若 $A_1, A_2, \dots$ 两两不交, 则并集中的每个样本结果只属于其中一个事件, 整体概率便等于各事件概率之和。这个等号支撑后续大量 union bound、概率不等式和事件分解的推导。对于宏观工程模型, 式 (1.9) 是基本成立的概率语言; 若改用不同公理, 例如只保留次可加性, 许多定理的陈述和证明都会随之改变。

CDF 的充分性 给定一个实值随机变量 x 的累积分布函数 (cumulative distribution function, CDF) $F(\cdot)$ 时, 可以构造出良好定义的概率空间 $(S, \mathcal{F}, P)$ 。更一般地, 若函数 $G(x)$ 满足

1. $\lim_{x \rightarrow -\infty} G(x) = 0$ 且 $\lim_{x \rightarrow \infty} G(x) = 1$;
2. G 右连续;
3. G 单调不减;

则 G 是某个随机变量的合法 CDF。换言之，检查这三条性质，就足以确认一个函数可以作为某个实值随机变量的分布函数。

这三条性质与随机变量定义中的事件 $\{\zeta \in S : x(\zeta) \leq a\}$ 直接对应。当 $a \rightarrow -\infty$ 时，该事件趋向空集合，概率趋向 0；当 $a \rightarrow \infty$ 时，该事件趋向整个样本空间，概率趋向 1。因为 CDF 采用“小于等于”的形式，跳跃点应从右侧连续；随着阈值 a 增大，被纳入的样本结果只会增加，概率不会下降。

因此，在只讨论单个实值随机变量时，从工程角度给出 CDF 已经足够。大学概率课程中定义高斯随机变量时，通常只给出密度函数或分布函数，而不显式写出背后的 $(S, \mathcal{F}, P)$ ，原因就在这里。CDF 像是把所有事件 $\{x \leq a\}$ 的概率沿实轴扫描一遍，从而完整描述这个随机变量的概率行为。

这一结论也解释了为什么还要保留概率空间这一抽象语言。对单个随机变量，CDF 往往足够；对随机过程，仅靠单个 CDF 不能描述不同时间、不同指标之间的联合关系。随机过程需要共同的样本空间、事件域和概率测度来支撑多维乃至无限维的联合分布。

1.1.5 基于概率空间定义随机变量的作用：抽象与观测

概率空间 $(S, \mathcal{F}, P)$ 的第一个作用，是把真实发生但可能不可直接操作的随机结果抽象出来。这里的 non-observable 不只表示肉眼看不见，还包括“看见了但无法在数学上操作”的情形。例如硬币的正反面、动物种类、图形符号或原子的旋转方向，都可以作为样本结果；它们本身没有自然的加减乘除，也没有统一的大小顺序。

为了推断抽象样本结果 ζ 真实发生了什么，需要进行实验并得到可观察、可操作的实数值 x 。随机变量 x 正是从 $\zeta \in S$ 到实数的确定性映射。

由于 ζ 相对于概率测度 P 具有随机性, 观察值 x 出现的概率由原空间中的原像集合决定:

$$\Pr[x = x_0] = P(\{\zeta \in S : x(\zeta) = x_0\}). \quad (1.10)$$

概率真正发生在原来的样本空间中; 实数值 x_0 是观测和操作端得到的表示。

有些书把这种映射写成

$$x : (S, \mathcal{F}, P) \rightarrow (x(S), \mathcal{B}, Q), \quad (1.11)$$

并称 $(x(S), \mathcal{B}, Q)$ 为 observation probability space。这里的 observation 带有“可操作”的意味: 经过随机变量映射后, 样本空间变成实数集合 $x(S)$, 事件域变成实数集合上的可量子集族 $\mathcal{B}$, 概率测度 Q 由原来的 P 推过去。若 $A \in \mathcal{F}$, 则

$$x(A) = \{x(\zeta) : \zeta \in A\}, \quad Q(x(A)) = P(A). \quad (1.12)$$

因此 observation probability space 可以理解为“样本空间经过实数化之后的概率空间”。

例 1.1.6 (原子旋转方向的观测). 考虑一个原子可能逆时针旋转或顺时针旋转。原始的真实概率空间为

$$S = \{\text{counterclockwise}, \text{clockwise}\}, \quad (1.13)$$

$$\mathcal{F} = \{\emptyset, \{\text{counterclockwise}\}, \{\text{clockwise}\}, S\}, \quad (1.14)$$

并且

$$\begin{aligned} P(\emptyset) &= 0, \\ P(\{\text{counterclockwise}\}) &= 0.4, \\ P(\{\text{clockwise}\}) &= 0.6, \\ P(S) &= 1. \end{aligned} \quad (1.15)$$

这里的 counterclockwise 与 clockwise 是概念性的样本结果，它们本身无法排序，也不能参与代数运算。

若通过某种测量设备判断原子的旋转方向，并暂时假设没有观测噪声，那么测量过程给出一个从 S 到实数的 one-to-one deterministic mapping:

$$x(\text{counterclockwise}) = 1, \quad x(\text{clockwise}) = -1. \quad (1.16)$$

这个映射本身是确定的：逆时针对应 1，顺时针对应 -1 。随机性来自原子实际处于哪个旋转状态，而来自映射规则。用电流、电压或仪器读数表示旋转方向时，本质上也是把抽象状态映射为实数值。

抽象样本空间与数学结构 概率空间的第二个作用，是处理抽象样本空间缺少数学操作结构的问题。设样本空间由六个图形结果组成，为了书写方便记作

$$S = \{\zeta_1, \zeta_2, \zeta_3, \zeta_4, \zeta_5, \zeta_6\}, \quad (1.17)$$

其中 $\mathcal{F}$ 是 S 的某个 σ -域， P 是定义在 $\mathcal{F}$ 上的概率测度。定义随机变量 x 为

$$x(\zeta_1) = 1, \quad x(\zeta_2) = 2, \quad x(\zeta_3) = 3, \quad x(\zeta_4) = 4, \quad x(\zeta_5) = 5, \quad x(\zeta_6) = 6. \quad (1.18)$$

六个图形样本结果不能自然排序，也不能讨论 $\zeta_1 + \zeta_2$ 或 $\zeta_3 - \zeta_4$ ；映射到 $1, 2, \dots, 6$ 后，才可以按实数大小构造 CDF。

为了使 x 的 CDF 良好定义，所有形如 $\{\zeta \in S : x(\zeta) \leq a\}$ 的集合都必

须属于 $\mathcal{F}$ 。在这个例子中:

$$\begin{aligned}
 a < 1 : \{\zeta : x(\zeta) \leq a\} &= \emptyset, \\
 1 \leq a < 2 : \{\zeta : x(\zeta) \leq a\} &= \{\zeta_1\}, \\
 2 \leq a < 3 : \{\zeta : x(\zeta) \leq a\} &= \{\zeta_1, \zeta_2\}, \\
 3 \leq a < 4 : \{\zeta : x(\zeta) \leq a\} &= \{\zeta_1, \zeta_2, \zeta_3\}, \\
 4 \leq a < 5 : \{\zeta : x(\zeta) \leq a\} &= \{\zeta_1, \zeta_2, \zeta_3, \zeta_4\}, \\
 5 \leq a < 6 : \{\zeta : x(\zeta) \leq a\} &= \{\zeta_1, \zeta_2, \zeta_3, \zeta_4, \zeta_5\}, \\
 a \geq 6 : \{\zeta : x(\zeta) \leq a\} &= S.
 \end{aligned} \tag{1.19}$$

例如 $a = 3.5$ 时, 原像集合就是前三个样本结果, 因为只有 1, 2, 3 不超过 3.5。这些集合必须是事件, 才能对 CDF 中的概率取值。

定义 1.1.7 (随机变量生成的 σ -域). 给定随机变量 $x : S \rightarrow \mathbb{R}$, 包含所有集合

$$\{\zeta \in S : x(\zeta) \leq a\}, \quad a \in \mathbb{R}, \tag{1.20}$$

并且满足 σ -域公理的最小 σ -域, 称为由随机变量 x 生成的 σ -域, 记为 $\sigma(x)$ 。

这里“最小”表示刚好足以让 x 成为良好定义随机变量的事件域。构造时要把式 (1.19) 中出现的集合放入事件域, 并按照 σ -域公理补上补集、可数并以及由此得到的交集。在一一映射 (1.18) 中, 每个单点集合都可以由 CDF 事件和集合运算分离出来, 因此 $\sigma(x)$ 等于 S 的幂集。由于 S 有六个元素, 幂集共有 $2^6 = 64$ 个子集。

非一一映射生成的 σ -域 再定义另一个随机变量 y :

$$y(\zeta_1) = y(\zeta_2) = y(\zeta_3) = 1, \quad y(\zeta_4) = y(\zeta_5) = y(\zeta_6) = 2. \tag{1.21}$$

这种映射没有反函数。若观测值为 1, 只能知道真实结果属于 $\{\zeta_1, \zeta_2, \zeta_3\}$; 若观测值为 2, 只能知道真实结果属于 $\{\zeta_4, \zeta_5, \zeta_6\}$ 。工程测量中常会出现这种情形: 多个真实现象在仪器读数上不可分辨。

检查 CDF 所需事件可得

$$\begin{aligned} a < 1 : \{\zeta : y(\zeta) \leq a\} &= \emptyset, \\ 1 \leq a < 2 : \{\zeta : y(\zeta) \leq a\} &= \{\zeta_1, \zeta_2, \zeta_3\}, \\ a \geq 2 : \{\zeta : y(\zeta) \leq a\} &= S. \end{aligned} \quad (1.22)$$

为了满足补集封闭, $\{\zeta_4, \zeta_5, \zeta_6\}$ 也必须加入。于是由 y 生成的最小 σ -域为

$$\sigma(y) = \{\emptyset, \{\zeta_1, \zeta_2, \zeta_3\}, \{\zeta_4, \zeta_5, \zeta_6\}, S\}. \quad (1.23)$$

与 $\sigma(x)$ 相比, $\sigma(y)$ 小得多, 因为 y 只能区分两类样本结果。这个例子说明, 随机变量的映射精细程度决定了它在原样本空间中能分辨哪些事件。

1.1.6 随机向量与随机过程的过渡

定义 1.1.8 (随机向量). 设 $(S, \mathcal{F}, P)$ 为概率空间。 k 维随机向量是映射

$$\mathbf{x} : S \rightarrow \mathbb{R}^k, \quad (1.24)$$

并且对任意 $\mathbf{a} = (a_1, \dots, a_k) \in \mathbb{R}^k$, 集合

$$\{\zeta \in S : \mathbf{x}(\zeta) \leq \mathbf{a}\} \in \mathcal{F}. \quad (1.25)$$

这里向量不等号按分量定义:

$$\mathbf{x} \leq \mathbf{a} \iff x_1 \leq a_1, x_2 \leq a_2, \dots, x_k \leq a_k. \quad (1.26)$$

向量比较采用逐分量比较。例如 $(3, 4) \leq (5, 6)$, 因为两维都小于等于对应分量; 而 $(0, 1)$ 与 $(1, 0)$ 之间无法给出全序意义下的大小关系, 因为第一维较小、第二维较大。高维实数空间在这种定义下会出现不可比较的点, 但这已经足够定义工程中常用的概率事件和积分区域。

例如事件 $\{x(1) < 0 \text{ or } x(2) < 1\}$ 可以写成两个一维事件的并。令 $A = \{x(1) < 0\}$ 、 $B = \{x(2) < 1\}$, 则

$$\Pr[x(1) < 0 \text{ or } x(2) < 1] = P(A) + P(B) - P(A \cap B). \quad (1.27)$$

交集 $A \cap B$ 对应平面中同时满足第一维小于 0、第二维小于 1 的区域。即使某些向量点彼此不可比较，只要关心的区域能由这些分量条件清楚描述，概率就是良好定义的。

随机向量也可以从随机变量族的角度定义。若

$$\mathbf{x}(\zeta) = (x(1, \zeta), x(2, \zeta), \dots, x(k, \zeta)), \quad (1.28)$$

则每一维 $x(i, \cdot)$ 本身都是定义在同一个概率空间上的随机变量。因此随机向量等价于有限个随机变量的集合，每个分量都定义在同一个概率空间上。文献中也常写成 indexed family:

$$\{x(i), i \in I\}, \quad (1.29)$$

其中 I 是有限指标集。这个写法更容易推广到随机过程，因为随机过程可以看作指标集不再有限时的一族随机变量。

共同概率空间与联合分布 随机向量要求所有分量定义在 same 或 common probability space 上，关键原因是联合分布。若只分别给出 $x(i)$ 和 $x(j)$ 的边缘行为，就无法自动知道二者的依赖、相关或独立关系。把它们放在同一个 $(S, \mathcal{F}, P)$ 上后，任意两个分量的联合事件都能回到同一个样本空间中表达：

$$\begin{aligned} \Pr[x(i) \leq a_i, x(j) \leq a_j] &= P(\{\zeta \in S : x(i, \zeta) \leq a_i, x(j, \zeta) \leq a_j\}) \\ &= P(A_i \cap A_j), \end{aligned} \quad (1.30)$$

其中

$$A_i = \{\zeta \in S : x(i, \zeta) \leq a_i\}, \quad A_j = \{\zeta \in S : x(j, \zeta) \leq a_j\}. \quad (1.31)$$

因为 $x(i)$ 和 $x(j)$ 都定义在同一个概率空间上，所以 $A_i, A_j \in \mathcal{F}$ 。由 σ -域的补集封闭性， $A_i^c, A_j^c \in \mathcal{F}$ ；由可数并封闭性， $A_i^c \cup A_j^c \in \mathcal{F}$ ；再取补集得到

$$A_i \cap A_j = (A_i^c \cup A_j^c)^c \in \mathcal{F}. \quad (1.32)$$

因此 $P(A_i \cap A_j)$ 可量, 联合分布良好定义。同理, 三个、四个以及更多分量的联合事件也可由同一个事件域中的交集表示。这样一来, 只要分量映射定义清楚, 概率空间会自动承担联合分布的定义工作。

例 1.1.9 (二维随机向量的离散构造). 仍令

$$S = \{\zeta_1, \zeta_2, \zeta_3, \zeta_4, \zeta_5, \zeta_6\}, \quad (1.33)$$

$\mathcal{F}$ 为 S 的某个 σ -域, P 为定义在 $\mathcal{F}$ 上的概率测度。定义二维随机向量 $\{x(i), i \in \{1, 2\}\}$, 其中

$$\begin{aligned} x(1, \zeta_1) &= 1, & x(1, \zeta_2) &= 2, & x(1, \zeta_3) &= 1, \\ x(1, \zeta_4) &= 2, & x(1, \zeta_5) &= 1, & x(1, \zeta_6) &= 2, \\ x(2, \zeta_1) &= 1, & x(2, \zeta_2) &= 1, & x(2, \zeta_3) &= 1, \\ x(2, \zeta_4) &= 2, & x(2, \zeta_5) &= 2, & x(2, \zeta_6) &= 2. \end{aligned} \quad (1.34)$$

这可以理解为两个观测机制对同一组真实样本结果进行测量: 第一个机制得到第一维, 第二个机制得到第二维。两个机制各自的映射可以不同, 但它们面对的是同一个样本空间。

为了让 $x(1)$ 的 CDF 良好定义, $\mathcal{F}$ 至少要包含

$$\begin{aligned} a_1 &< 1 : \emptyset, \\ 1 \leq a_1 &< 2 : \{\zeta_1, \zeta_3, \zeta_5\}, \\ a_1 &\geq 2 : S. \end{aligned} \quad (1.35)$$

为了让 $x(2)$ 的 CDF 良好定义, $\mathcal{F}$ 至少还要包含

$$\begin{aligned} a_2 &< 1 : \emptyset, \\ 1 \leq a_2 &< 2 : \{\zeta_1, \zeta_2, \zeta_3\}, \\ a_2 &\geq 2 : S. \end{aligned} \quad (1.36)$$

因此 $\mathcal{F}$ 必须是包含上述六类集合的 σ -域。这样 $x(1)$ 与 $x(2)$ 各自的 CDF 都可以定义。

由共同空间得到联合事件 由于 $x(1)$ 和 $x(2)$ 定义在同一个概率空间 $(S, \mathcal{F}, P)$ 上, 且 $\mathcal{F}$ 包含式 (1.35) 与式 (1.36) 所需的集合, 任意

$$\Pr[x(1) \leq a_1, x(2) \leq a_2] \quad (1.37)$$

都可以良好定义。其本质是把两个观测条件同时拉回到同一个样本空间, 再在 $\mathcal{F}$ 中取交集并用 P 赋概率。

这个例子说明了共同概率空间的真正作用。若有多个人或多台设备观测同一个随机现象, 每个观测机制都可以是自己的 deterministic mapping; 只要这些映射定义在同一个 $(S, \mathcal{F}, P)$ 上, 任意两两、三三乃至更多观测之间的联合分布就已经被概率空间统一规定。这个思想正是从随机向量推广到随机过程的关键: 随机过程可以看成由同一个概率空间支撑的一族随机变量, 指标集从有限集合扩展到时间或更一般的无限指标集。

1.1.7 随机过程

定义 1.1.10 (随机过程). 随机过程 (random process) 是一族带指标的随机变量

$$\{x(t), t \in I\}, \quad (1.38)$$

其中每个 $x(t)$ 都定义在同一个概率空间 $(S, \mathcal{F}, P)$ 上。等价地, 对每个 $t \in I$, 都有一个映射

$$x(t, \cdot) : S \rightarrow \mathbb{R}. \quad (1.39)$$

随机向量是有限个随机变量的集合; 随机过程把这个指标集合推广到可能无限的情形。指标 t 通常表示时间, 也可以表示其他有序或无序的索引。关键要求仍然是 same probability space: 所有 $x(t)$ 都必须活在同一个 $(S, \mathcal{F}, P)$ 中。只要这一点成立, 任意有限个时间点的联合事件都能写回同一个样本空间。

取任意 $t_1, \dots, t_k \in I$ 和实数 $x_1, \dots, x_k$, 有

$$\begin{aligned} & [x(t_1) \leq x_1, x(t_2) \leq x_2, \dots, x(t_k) \leq x_k] \\ &= \{\zeta \in S : x(t_1, \zeta) \leq x_1, x(t_2, \zeta) \leq x_2, \dots, x(t_k, \zeta) \leq x_k\} \\ &= \bigcap_{i=1}^k \{\zeta \in S : x(t_i, \zeta) \leq x_i\}. \end{aligned} \quad (1.40)$$

每个集合 $\{\zeta : x(t_i, \zeta) \leq x_i\}$ 都属于 $\mathcal{F}$; σ -域对有限交封闭, 因此式 (1.40) 也是事件, 可以由 P 赋概率。这样, 有限维联合分布不需要逐一列出。

有限维联合分布与概率空间的第三个作用 基于 $(S, \mathcal{F}, P)$ 定义随机过程的第三个作用, 是让所有有限维, 甚至可数无限维的联合分布在同一个框架下良好定义。若没有共同概率空间, 两个时间点之间、三个时间点之间、更多时间点之间的依赖关系都要另外列出; 当指标集很大时, 这种列举很快不可操作。

这个结论的逆向说法并不成立。即使给出所有有限维联合分布, 也不能保证随机过程的全部统计性质都被唯一决定。原因是有些性质涉及不可数无限多个时间点, 例如 $\min_{t \in [0,1)} x(t)$ 。这些性质超出有限个采样点的联合分布所能完全捕捉的范围。

从工程角度看, 有限维联合分布通常已经足够。实际系统常关心有限个采样时刻、有限长度封包、均值函数、自相关函数等对象; 这些都属于有限维或低阶统计描述。但从严格数学角度看, 概率空间保留了更多信息, 也使某些极限型事件和路径型性质有明确概率意义。

一个有限维分布无法区分的例子 设 $S = [0, 1)$, $\zeta \in S$, $P(A) = \int_A d\alpha$, 也就是 $[0, 1)$ 上的 Lebesgue 测度。定义两个随机过程 $\{x(t), t \in [0, 1)\}$ 与 $\{y(t), t \in [0, 1)\}$:

$$x(t, \zeta) = \begin{cases} 1, & \zeta \neq t, \\ 0, & \zeta = t, \end{cases} \quad y(t, \zeta) = 1. \quad (1.41)$$

对固定的 ζ 来看, $x(t, \zeta)$ 是一条几乎处处为 1、只在 $t = \zeta$ 处掉到 0 的确定性波形; $y(t, \zeta)$ 则恒等于 1。

考察整个时间区间上的最小值:

$$\begin{aligned} \Pr \left[\min_{t \in [0,1]} x(t) < 1 \right] &= P \left(\left\{ \zeta \in S : \min_{t \in [0,1]} x(t, \zeta) < 1 \right\} \right) \\ &= P(S) = 1, \end{aligned} \quad (1.42)$$

因为对每个 ζ , 取 $t = \zeta$ 时都有 $x(\zeta, \zeta) = 0$ 。而

$$\begin{aligned} \Pr \left[\min_{t \in [0,1]} y(t) < 1 \right] &= P \left(\left\{ \zeta \in S : \min_{t \in [0,1]} y(t, \zeta) < 1 \right\} \right) \\ &= P(\emptyset) = 0. \end{aligned} \quad (1.43)$$

因此这两个随机过程具有不同的统计性质。

有限维联合分布相同的原因 尽管式 (1.42) 与式 (1.43) 不同, $x(t)$ 与 $y(t)$ 在任意有限采样点上具有完全相同的联合分布。记这些采样点为

$$t_1, \dots, t_k.$$

对 $x(t)$, 有

$$\{\zeta \in S : x(t_i, \zeta) \leq x_i\} = \begin{cases} S, & x_i \geq 1, \\ \{t_i\}, & x_i < 1. \end{cases} \quad (1.44)$$

若所有 $x_i \geq 1$, 交集为 S , 概率为 1; 若至少一个 $x_i < 1$, 交集只剩有限个单点的交集或空集合, 其 Lebesgue 测度为 0。因此

$$\Pr[x(t_1) \leq x_1, \dots, x(t_k) \leq x_k] = \begin{cases} 1, & \min_{1 \leq i \leq k} x_i \geq 1, \\ 0, & \text{otherwise.} \end{cases} \quad (1.45)$$

对恒等于 1 的 $y(t)$, 同样得到式 (1.45)。

这个例子的要点在于, 有限多个时间点看不见 $x(t, \zeta)$ 在 $t = \zeta$ 处的单点下跳, 因为单点在 Lebesgue 测度下概率为 0; 但对不可数个时间同时取最小值时, 每条样本路径都会在自己的 ζ 处下跳。由此可见, 所有有限维联合分布仍可能遗漏路径层面的性质。

1.1.8 复随机过程

定义 1.1.11 (复随机过程). 复随机过程 (complex random process) 由定义在同一个概率空间上的两个实随机过程指定。通常写为

$$z(t) = x(t) + jy(t), \quad (1.46)$$

其中 $x(t)$ 与 $y(t)$ 分别是实部和虚部对应的实随机过程。

复数域上没有自然的大小顺序，因此不能直接仿照实随机变量写出

$$\{\zeta \in S : z(\zeta) \leq z_0\} \in \mathcal{F}, \quad z_0 \in \mathbb{C}, \quad (1.47)$$

因为 $z(\zeta) \leq z_0$ 在复数域中没有定义。处理复随机变量、复随机向量和复随机过程时，应把它们理解为两个实对象组成的二维实对象，并且实部、虚部必须定义在同一个概率空间上。这样既保留复数运算的便利，也避免在定义中使用不存在的复数排序。

在概率空间下计算均值 考虑随机变量 y ，其样本空间为

$$S = \{\zeta_1, \zeta_2, \zeta_3, \zeta_4, \zeta_5, \zeta_6\}, \quad (1.48)$$

事件域与概率测度为

$$\mathcal{F} = \{\emptyset, \{\zeta_1, \zeta_2, \zeta_3\}, \{\zeta_4, \zeta_5, \zeta_6\}, S\}, \quad P = \{0, 1/2, 1/2, 1\}, \quad (1.49)$$

并定义

$$y(\zeta_1) = y(\zeta_2) = y(\zeta_3) = 1, \quad y(\zeta_4) = y(\zeta_5) = y(\zeta_6) = 2. \quad (1.50)$$

均值定义为

$$E[y] = \int_S y(\zeta) dP(\zeta). \quad (1.51)$$

若把六个单点逐项列出，会遇到 $P(\{\zeta_1\})$ 、 $P(\{\zeta_2\})$ 等单点概率未给定的问题。这里并不需要知道这些单点概率，因为 y 在 $\{\zeta_1, \zeta_2, \zeta_3\}$ 上同为 1，在 $\{\zeta_4, \zeta_5, \zeta_6\}$ 上同为 2。这两个集合正是 $\mathcal{F}$ 中的可量事件，于是

$$E[y] = 1 \cdot P(\{\zeta_1, \zeta_2, \zeta_3\}) + 2 \cdot P(\{\zeta_4, \zeta_5, \zeta_6\}) = \frac{3}{2}. \quad (1.52)$$

这个例子说明，只要随机变量在概率空间上良好定义，均值、二阶矩、三阶矩等实数端统计量都可以通过可量事件来计算。

实随机过程定义的最后说明 对固定 ζ ， $x(t, \zeta)$ 是 t 的确定性函数；对固定 t 和 ζ ， $x(t, \zeta)$ 是一个实数。随机性出现在省略 ζ 后的记号 $x(t)$ 中：不知道实际发生的是哪个样本结果 ζ ，便只能用概率描述 $x(t)$ 的取值。

因此，一条样本路径本身是确定波形。若真实样本结果为 ζ_1 ，沿时间量测得到的是 $x(t, \zeta_1)$ ；若真实样本结果为 ζ_2 ，得到的是另一条确定波形 $x(t, \zeta_2)$ 。随机过程这个记号把这些可能样本路径连同它们在概率空间中的发生概率一起组织起来。

1.1.9 随机过程的分类

随机过程可按指标集 I 分类。若 $I = \mathbb{R}$ 或实数区间，则称为连续时间随机过程 (continuous-time random process)；若 I 是整数集或可数时间索引，则称为离散时间随机过程 (discrete-time random process)。这里的 continuous/discrete 描述的是时间索引。

随机过程也可按每个时刻可能取到的状态数分类。定义

$$x(t, S) \triangleq \{x \in \mathbb{R} : x(t, \zeta) = x \text{ for some } \zeta \in S\}. \quad (1.53)$$

若 $x(t, S)$ 是可数集合，则称 $x(t)$ 为离散状态随机过程；若 $x(t, S)$ 不可数，则称为连续状态随机过程。例如观测值只可能为 ± 1 、 ± 3 时是离散状态；观测值可能落在连续实数范围内时是连续状态。

1.1.10 一阶分布

定义 1.1.12 (一阶分布函数). 随机过程 $x(t)$ 的一阶分布函数 (first-order distribution function) 定义为

$$F(x; t) \triangleq \Pr[x(t) \leq x]. \quad (1.54)$$

一阶表示只看单一时间点。对固定 t , $x(t)$ 是一个随机变量, 因此式 (1.54) 就是该随机变量的 CDF。前面提到的 Billingsley 定理说明: 若 $F(\cdot)$ 单调不减、右连续, 并满足左端极限为 0、右端极限为 1, 则存在某个概率空间和某个随机变量, 使它的 CDF 等于 $F(\cdot)$ 。

这个定理把单个随机变量的定义从显式概率空间中解放出来: 只给 CDF, 也能定义一个随机变量。需要记住的是, 该定理证明的是存在性, 不保证唯一性。不同概率空间可以给出同样的一阶分布, 却在更细的路径性质或高阶性质上不同。

工程定义与严格定义 随机变量和随机向量可以通过列出分布或联合分布来定义; 随机过程在严格数学意义上无法只靠所有有限采样点的联合分布完全确定。前面的反例已经说明, $\min_{t \in [0,1]} x(t)$ 这类不可数维性质, 可能无法由有限维联合分布唯一决定。

工程上常采用更务实的做法。若关心的统计性质, 例如均值函数、自相关函数、有限个时刻的联合分布, 都已经给出并且彼此一致, 那么这个随机过程在工程用途上就可以视为良好定义。许多常见过程, 例如 Poisson process, 常常先通过其可观察的统计性质来定义, 而不显式写出继承的概率空间。

一阶密度

定义 1.1.13 (一阶密度函数). 若 $F(x;t)$ 对 x 可微, 且 $x(t)$ 具有密度, 则随机过程 $x(t)$ 的一阶密度函数定义为

$$f(x;t) \triangleq \frac{\partial F(x;t)}{\partial x}. \quad (1.55)$$

这里有两个条件: $F(x;t)$ 对 x 可微, 并且 $x(t)$ 确实具有密度。CDF 总是存在, 因为它只需要概率空间中事件 $\{x(t) \leq x\}$ 的概率; 密度则要求更强。直观上, 概率密度描述概率在不同实数值附近的疏密程度, 密度对区域积分后应返回概率。

定义 1.1.14 (概率密度函数). 随机变量 x 及其分布具有密度 f , 是指 f 为非负函数, 并且对每个合适的集合 $A \subset \mathbb{R}$,

$$\Pr[x \in A] = \int_A f(x) dx. \quad (1.56)$$

这里 A 通常取 Borel 集。

Borel 集与 Lebesgue 测度 Borel 集是由开区间、闭区间、半开区间经过可数次集合运算, 主要是并、交和补, 构造出来的实数集合。概率密度的积分通常只要求对 Borel 集成立, 因为 Lebesgue 测度正是定义在这类集合上。工程应用中遇到的可积分区域基本都落在这个范围内。

定义 1.1.15 (Lebesgue 测度). 设 A 为 Borel 集。若 A 可以写为两两不交区间 I_i 的可数并

$$A = \bigcup_{i=1}^{\infty} I_i, \quad (1.57)$$

则 Lebesgue 测度 λ 满足

$$\lambda(A) = \sum_{i=1}^{\infty} \lambda(I_i), \quad (1.58)$$

其中 $\lambda(I)$ 等于区间右端点减左端点。

区间长度的定义很直观: 例如 $(2, 3)$ 、 $[2, 3]$ 、 $[2, 3)$ 的测度都为 1。更复杂的 Borel 集可拆为可数个互不相交的区间片段, 再由可数可加性求测度。因此, 一个可管理的典型概率空间是

$$(S = [0, 1), \mathcal{B}, P = \text{Lebesgue measure}), \quad (1.59)$$

其中 $\mathcal{B}$ 是 $[0, 1)$ 上包含所有开、闭、半开区间并对 σ -域运算封闭的 Borel σ -域。

关于 pdf 的几点说明 随机变量总有 CDF。若随机变量具有密度 f ，则

$$f(x) = \frac{\partial F(x)}{\partial x}. \quad (1.60)$$

这个方向成立；反过来，仅仅写出某个 $\partial F(x)/\partial x$ ，还不足以保证它就是概率密度。密度的核心要求是对每个 Borel 集 A 都满足

$$\Pr[x \in A] = \int_A f(x) dx. \quad (1.61)$$

若积分不能返回对应概率，函数就不能称为概率密度。后面出现 power spectral density 时也应保持同样直觉：密度的积分必须回到它所描述的总量。

1.1.11 分布、密度与二阶性质

定义 1.1.16 (二阶分布函数). 随机过程 $x(t)$ 的二阶分布函数定义为

$$F(x_1, x_2; t_1, t_2) \triangleq \Pr[x(t_1) \leq x_1, x(t_2) \leq x_2]. \quad (1.62)$$

定义 1.1.17 (二阶密度函数). 若 $F(x_1, x_2; t_1, t_2)$ 对 x_1, x_2 可微，且 $x(t)$ 在 t_1, t_2 处具有二阶密度，则

$$f(x_1, x_2; t_1, t_2) \triangleq \frac{\partial^2 F(x_1, x_2; t_1, t_2)}{\partial x_1 \partial x_2}. \quad (1.63)$$

二阶表示同时看两个时间点的关系，例如早上十点和十一点的随机量如何共同变化。若两个映射定义在同一个概率空间上，二阶联合事件自然可量；若没有显式概率空间，就必须额外给出二阶联合分布，并保证它与一阶分布一致。

一致性条件 (consistency condition) 要求边缘化后回到低阶分布。对 $t_2 \neq t_1$,

$$F(x_1; t_1) = F(x_1, \infty; t_1, t_2), \quad f(x_1; t_1) = \int_{-\infty}^{\infty} f(x_1, x_2; t_1, t_2) dx_2. \quad (1.64)$$

若随机过程定义在同一个概率空间上，这类一致性会自动保持；若通过显式列出各阶分布来定义，就必须逐条检查，避免高阶和低阶分布互相矛盾。 n 阶分布和密度可以类似定义，并同样需要保持一致性。

一阶与二阶性质 随机过程的均值函数定义为

$$\eta_x(t) \triangleq E[x(t)] = \int_{-\infty}^{\infty} x f(x; t) dx, \quad (1.65)$$

其中积分形式要求一阶密度存在。均值是趋势性统计量，未必等于任何实际样本路径在该时刻的取值。

自相关函数 (autocorrelation function) 定义为

$$R_{xx}(t_1, t_2) \triangleq E[x(t_1)x^*(t_2)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 x_2^* f(x_1, x_2; t_1, t_2) dx_1 dx_2. \quad (1.66)$$

其中 $*$ 表示复共轭。自相关描述同一个随机过程在两个时间点之间的平均乘积关系，工程上常用它衡量一个时间点对另一个时间点的残余影响或能量关联。

自相关函数满足非负定性。对任意有限组时间 t_i 和复数系数 a_i ,

$$\sum_i \sum_j a_i a_j^* R_{xx}(t_i, t_j) \geq 0. \quad (1.67)$$

证明来自平方模的非负性:

$$0 \leq E \left[\left| \sum_i a_i x(t_i) \right|^2 \right] = \sum_i \sum_j a_i a_j^* E[x(t_i)x^*(t_j)]. \quad (1.68)$$

有些书称这种性质为 positive definite; 严格区分时, 式 (1.67) 更准确地说是 non-negative definite。若要求等号只在系数向量为零时成立, 才是严格正定。反向结论也成立: 任意非负定函数都可以作为某个随机过程的自相关函数。

平均功率、自协方差、方差与相关系数 随机过程在时刻 t 的平均功率为

$$E[x(t)x^*(t)] = E[|x(t)|^2] = R_{xx}(t, t) \geq 0. \quad (1.69)$$

自相关在两个时间相同处给出平均平方幅度, 因此自然非负。

自协方差函数定义为

$$\begin{aligned} C_{xx}(t_1, t_2) &\triangleq E[(x(t_1) - \eta_x(t_1))(x(t_2) - \eta_x(t_2))^*] \\ &= R_{xx}(t_1, t_2) - \eta_x(t_1)\eta_x^*(t_2). \end{aligned} \quad (1.70)$$

它把均值项扣掉后，描述随机波动部分在两个时间点之间的关联。方差是自协方差在同一时间点的取值：

$$E[|x(t) - \eta_x(t)|^2] = C_{xx}(t, t). \quad (1.71)$$

相关系数定义为

$$r_{xx}(t_1, t_2) \triangleq \frac{C_{xx}(t_1, t_2)}{\sqrt{C_{xx}(t_1, t_1)C_{xx}(t_2, t_2)}} \in [-1, 1]. \quad (1.72)$$

自协方差函数和相关系数函数也具有非负定性质。后续讨论平稳性、功率谱和系统响应时，这些一阶、二阶统计量会成为最常用的描述工具。

1.1.12 一阶与二阶性质的工程含义

随机过程进入工程应用后，最常用的是一阶与二阶统计量。二阶量常被解释为能量或功率相关的量；一阶量也不能忽略，因为非零均值对应 DC 分量，维持一个固定准位同样需要能量。平均功率定义为

$$E[x(t)x^*(t)] = E[|x(t)|^2] = R_{xx}(t, t) \geq 0. \quad (1.73)$$

它表示时刻 t 的平均平方幅度，在通信系统中可直接对应到信号或噪声的功率。

自协方差函数把均值扣掉后再看波动之间的关系：

$$C_{xx}(t_1, t_2) \triangleq E[(x(t_1) - \eta_x(t_1))(x(t_2) - \eta_x(t_2))^*] = R_{xx}(t_1, t_2) - \eta_x(t_1)\eta_x^*(t_2). \quad (1.74)$$

方差是同一时刻的自协方差，

$$E[|x(t) - \eta_x(t)|^2] = C_{xx}(t, t), \quad (1.75)$$

描述样本值围绕均值的变异程度。相关系数再把这种变异关系正规化:

$$r_{xx}(t_1, t_2) \triangleq \frac{C_{xx}(t_1, t_2)}{\sqrt{C_{xx}(t_1, t_1)C_{xx}(t_2, t_2)}} \in [-1, 1]. \quad (1.76)$$

正规化的目的, 是把“相关量有多大”转成“相对于各自能量尺度有多强”。例如绝对相关功率较小的两组数据, 若各自总变异也很小, 相关系数仍可能很高。

自协方差函数与相关系数函数也具有非负定性质。不同教材对 positive definite 与 non-negative definite 的用词可能略有差异; 严格说, 若只要求二次型非负, 应称为 non-negative definite。若要求非零系数向量时二次型严格大于零, 才是严格正定。

1.1.13 交叉相关与交叉协方差

定义 1.1.18 (交叉相关函数). 两个定义在同一个概率空间上的随机过程 $x(t)$ 与 $y(t)$ 的交叉相关函数 (cross-correlation) 定义为

$$R_{xy}(t_1, t_2) \triangleq E[x(t_1)y^*(t_2)]. \quad (1.77)$$

交叉相关描述两个不同随机过程之间的平均乘积关系。在通信系统中, 常把 $x(t)$ 看成输入、 $y(t)$ 看成输出; $R_{xy}(t_1, t_2)$ 便反映输入某个时刻的能量结构对输出另一个时刻的影响。讨论 x 与 y 的关系时, 二者必须定义在同一个概率空间上, 否则联合期望没有共同的概率基础。

定义 1.1.19 (交叉协方差函数). 两个随机过程 $x(t)$ 与 $y(t)$ 的交叉协方差函数 (cross-covariance) 定义为

$$\begin{aligned} C_{xy}(t_1, t_2) &\triangleq E[(x(t_1) - \eta_x(t_1))(y(t_2) - \eta_y(t_2))^*] \\ &= R_{xy}(t_1, t_2) - \eta_x(t_1)\eta_y^*(t_2). \end{aligned} \quad (1.78)$$

交叉协方差把两个过程的均值部分扣除, 只保留随机波动之间的关系。若只关心两个信号的变化部分是否相互牵动, C_{xy} 比 R_{xy} 更贴近这个目的; 若 DC 分量本身也是能量或干扰的一部分, 则 R_{xy} 保留了这部分信息。

1.1.14 随机过程的一般性质

定义 1.1.20 (独立随机过程). 两个随机过程 $x(t)$ 与 $y(t)$ 称为独立 (independent), 若 $x(t)$ 的任意有限维样本与 $y(t)$ 的任意有限维样本相互独立。

这里的“有限维样本”很重要。若从 $x(t)$ 中取 $t_1, t_2, \dots, t_m$, 从 $y(t)$ 中取 $s_1, s_2, \dots, s_n$, 则要求两个随机向量

$$(x(t_1), \dots, x(t_m)) \quad \text{与} \quad (y(s_1), \dots, y(s_n)) \quad (1.79)$$

独立。连续时间随机过程有不可数多个时间点, 工程定义通常只要求有限维样本层面的独立性。这与前面有限维联合分布的限制一致。例如

$$\min_{t \in [0,1)} x(t) \quad \text{与} \quad \min_{t \in [0,1)} y(t)$$

的独立性, 未必能由有限维样本定义直接判断。

定义 1.1.21 (正交与不相关). 两个随机过程 $x(t)$ 与 $y(t)$ 称为正交 (orthogonal), 若

$$R_{xy}(t_1, t_2) = 0, \quad \forall t_1, t_2 \in I. \quad (1.80)$$

它们称为不相关 (uncorrelated), 若

$$C_{xy}(t_1, t_2) = 0, \quad \forall t_1, t_2 \in I. \quad (1.81)$$

正交使用交叉相关函数, 因此连均值带来的 DC 能量也一并纳入。若两个信号之间连 DC 影响都要求消失, 应使用正交。若只关心波动部分的线性关系, 则使用不相关; 此时均值被扣掉, 固定准位本身不会被算作变化之间的关联。

定义 1.1.22 (a -依赖). 随机过程 $x(t)$ 称为 a -依赖 (a -dependent), 若对任意 t_0 , 两个过程

$$\{x(t), t < t_0\} \quad \text{与} \quad \{x(t), t > t_0 + a\} \quad (1.82)$$

相互独立。

a -依赖表示相隔超过 a 的两段过程独立。它把复杂的长期依赖简化成有限记忆范围：例如 a 取两小时，就表示间隔超过两小时后的样本段可视为独立。研究中若完整描述依赖结构过于困难， a -依赖常能提供可操作的近似模型。

1.1.15 相关 a -依赖、白过程与严格白过程

定义 1.1.23 (相关 a -依赖). 随机过程称为相关 a -依赖 (correlation a -dependent), 若

$$C_{xx}(t_1, t_2) = 0, \quad |t_1 - t_2| > a. \quad (1.83)$$

相关 a -依赖把 a -依赖中的独立性放松为二阶层面的不相关。它只控制自协方差在时间距离超过 a 后消失，适合只需要二阶统计的分析。

定义 1.1.24 (严格白过程与白过程). 随机过程 $x(t)$ 称为严格白 (strictly white), 若对任意 $t_1 \neq t_2$, $x(t_1)$ 与 $x(t_2)$ 独立。随机过程 $x(t)$ 称为白 (white), 若对任意 $t_1 \neq t_2$, $x(t_1)$ 与 $x(t_2)$ 不相关。

严格白要求不同时间样本相互独立，因此不仅二阶关系消失，高阶联合关系也受到限制。白过程只要求不同时间样本不相关，也就是二阶层面的白。二者在功率谱密度上可能无法区分，因为功率谱通常只由一阶和二阶量决定；若分析涉及更高阶概率性质，严格白和白的差异才会显现。

按照白过程的定义， $t_1 \neq t_2$ 时自协方差为零。写成滞后量 $\tau = t_2 - t_1$, 可表示为

$$C_{xx}(t, t + \tau) = q(t)\delta(\tau). \quad (1.84)$$

这里 $q(t)$ 允许随时间变化，因此这个定义可以容纳 time-varying white process。 $\tau = 0$ 处的强度没有被“不同时间不相关”限制，便由 $q(t)$ 描述。

Proakis 教材中的白噪声定义 在 Proakis 的 *Digital Communications* 中，白噪声常通过自相关函数或平坦功率谱密度定义。例如令

$$\phi_{xx}(\tau) = \frac{1}{2}N_0\delta(\tau), \quad (1.85)$$

这样的过程被称为 white noise。由于自相关函数是冲激，傅里叶变换为常数，因而可解释为在整个频率范围内具有平坦功率谱密度。

这种定义很适合数字通信中常见的平稳白噪声模型。它直接抓住“白色”的频域直觉：所有频率成分的功率密度相同。相应地，若功率谱密度定义为自相关函数的傅里叶变换，则非零均值会在 $f = 0$ 处产生额外冲激；于是严格要求所有频率都为同一个常数时，通常隐含零均值。

平稳情形下功率谱密度与均值 对宽平稳过程，常有

$$R_{xx}(\tau) = C_{xx}(\tau) + \mu_x^2. \quad (1.86)$$

若功率谱密度定义为自相关函数 $R_{xx}(\tau)$ 的傅里叶变换，则常数项 μ_x^2 会变成频域原点的冲激 $\mu_x^2 \delta(f)$ 。因此非零均值的白过程在 $f \neq 0$ 时可呈现常数谱，但在原点会出现无限高的冲激。

从“功率”这个名称出发，把功率谱密度定义为自相关函数的傅里叶变换有清楚的物理意义，因为对频率积分能回到总平均功率。这个定义把 DC 能量也算入功率。若希望谱在所有频率处完全平坦，白过程就需要零均值；若允许原点冲激，则可保留非零均值。

Gray–Davisson 教材中的白过程定义 Gray 与 Davisson 的 *Random Processes: A Mathematical Approach for Engineers* 采用另一套定义：过程若其 power spectral density 对所有频率为常数，则称为 white。该书中的 power spectral density 定义为自协方差函数的傅里叶变换，而自协方差已经扣除了均值。

这样做的结果是，非零均值不会进入功率谱密度的积分；因此该定义下的 power spectral density 积分不等于非零均值过程的总平均功率。它的优点是可以容纳非零均值白过程。该书随后说明，白过程通常还会假设为零均值；一旦零均值成立，自相关与自协方差相同，两种谱定义便合在一起。

本课程采用的白过程观点 本课程所用教材把白过程定义为不同时间样本不相关:

$$x(t_1) \text{ and } x(t_2) \text{ are uncorrelated, } t_1 \neq t_2. \quad (1.87)$$

这个定义较宽, 不预先要求平稳, 也不直接要求频谱处处为常数。若过程进一步是宽平稳, 且功率谱密度定义为自相关函数的傅里叶变换, 那么白过程的功率谱在零点以外为常数; 非零均值带来的原点冲激可单独看待。

这种写法是间接定义, 因为它从时间域的不相关性出发, 而非直接从“所有频率成分相同”的白色直觉出发。它的好处是能与严格白过程的定义平行: 白过程用 uncorrelated, 严格白过程用 independent, 二者只差一个条件强度。需要记住的是, 仅凭功率谱密度无法区分白过程和严格白过程, 因为功率谱只反映二阶信息。

1.1.16 独立增量与不相关增量

增量性质描述的是随机过程在两个互不重叠时间区间上的变化量之间有什么关系。设 $t_1 < t_2 < t_3 < t_4$, 区间 $[t_1, t_2]$ 上的变化量为 $x(t_2) - x(t_1)$, 区间 $[t_3, t_4]$ 上的变化量为 $x(t_4) - x(t_3)$ 。直观地说, 一个区间内发生了多少变化, 若不影响另一个分离区间内的变化, 就得到增量之间的独立或不相关。

定义 1.1.25 (独立增量). 随机过程 $x(t)$ 称为具有独立增量 (independent increment), 若对任意 $t_1 < t_2 < t_3 < t_4$,

$$x(t_2) - x(t_1) \text{ 与 } x(t_4) - x(t_3) \quad (1.88)$$

相互独立。

布朗运动是理解独立增量的典型例子: 一小段时间内由分子碰撞造成的位移, 与隔开一段时间之后另一小段时间内的位移, 可以建模为彼此独立。Poisson 过程也将采用同类思想来描述点到达; 在通信和网络中, 早期电话到达数、封包到达数常用这类模型近似。若两个时间区间互不重叠,

前一区间来了几通电话，不会改变后一区间的到达机制，这就是独立增量在工程模型中的含义。

定义 1.1.26 (不相关增量). 随机过程 $x(t)$ 称为具有不相关增量 (uncorrelated increment)，若对任意 $t_1 < t_2 < t_3 < t_4$,

$$x(t_2) - x(t_1) \quad \text{与} \quad x(t_4) - x(t_3) \quad (1.89)$$

不相关。

不相关增量只约束一阶、二阶统计量，假设强度低于独立增量。若应用中只讨论均值、相关函数、能量或功率等二阶性质，使用不相关增量通常已经足够；若还要控制高阶联合分布，则需要独立增量。这个区别与前面白过程和严格白过程的区别相同：uncorrelated 是二阶层面的条件，independent 是完整联合分布层面的条件。

1.1.17 正态过程与存在定理

定义 1.1.27 (正态过程). 随机过程 $x(t)$ 称为正态过程 (normal process)，若 $x(t)$ 的任意有限维样本都是联合正态的。也就是说，对任意有限个时间点 $t_1, \dots, t_n$ ，随机向量

$$(x(t_1), \dots, x(t_n)) \quad (1.90)$$

服从 n 维联合正态分布。

这里的关键词仍然是有限维。连续时间过程包含不可数多个时间点，直接处理无限维联合分布会很困难；本课程定义正态过程时，只要求任意有限维样本联合正态。若给定三维样本，其联合密度就是多元高斯密度，形式中包含协方差矩阵的行列式与二次型：

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}. \quad (1.91)$$

因此，正态过程的全部有限维统计结构可由均值向量和协方差矩阵决定。

定理 1.1.28 (正态过程的存在定理). 给定任意函数 $\eta(t)$ 和任意正定, 即非负定函数 $C(t_1, t_2)$, 存在一个正态过程 $x(t)$, 使得

$$E[x(t)] = \eta(t), \quad C_{xx}(t_1, t_2) = C(t_1, t_2). \quad (1.92)$$

这个定理说明, 均值函数和非负定自协方差函数确实可以被某个正态过程实现。证明思想用有限维样本的特征函数来构造分布。对任意有限个 t_i , 可令其特征函数为

$$\phi(\omega_1, \dots, \omega_n) = \exp \left\{ j \sum_i \eta(t_i) \omega_i - \frac{1}{2} \sum_{i,k} C(t_i, t_k) \omega_i \omega_k \right\}. \quad (1.93)$$

特征函数与分布一一对应, 这种写法正是多元正态分布的特征函数形式。式中只出现有限个指标 i, k , 也与正态过程的有限维定义完全配合。

正态过程在工程和物理中非常常见。许多由大量小效应叠加形成的热运动、噪声模型, 或由中心极限定理近似得到的分布, 都自然导向正态模型。normal 这个词在这里可理解为常见、基准、标准的意思; 对本课程而言, 重要的是掌握“任意有限维样本联合正态”这一可操作定义。

1.1.18 随机过程的 Riemann 积分

设随机过程 $x(t)$ 在区间 $[a, b]$ 上积分得到随机变量

$$s = \int_a^b x(t) dt. \quad (1.94)$$

若把上式解释为 Riemann 积分, 则可以写出一阶矩

$$E[s] = \int_a^b E[x(t)] dt = \int_a^b \eta_x(t) dt \quad (1.95)$$

和二阶矩

$$E[s^2] = \int_a^b \int_a^b E[x(t_1)x(t_2)] dt_1 dt_2 = \int_a^b \int_a^b R_{xx}(t_1, t_2) dt_1 dt_2. \quad (1.96)$$

严格地说, s 的定义是先对每条样本路径做积分, 再对得到的随机变量取期望。式 (1.95) 和式 (1.96) 在计算时把期望与积分交换了顺序。工程课程中常常直接这样做, 但从严谨数学角度看, 任何交换次序都需要条件。课件强调 Riemann integral, 就是把讨论限制在较规则的函数类里, 避开很多病态可测函数带来的问题。

Riemann 积分: 阶梯函数与上下逼近 Riemann 积分的基本想法是用阶梯函数 (step function) 从下方和上方逼近目标函数。设 $s(x)$ 是定义在 $[a, b]$ 上的阶梯函数, 即存在分割

$$a = x_0 < x_1 < \cdots < x_n = b, \quad (1.97)$$

使得 $s(x)$ 在每个区间 (x_i, x_{i+1}) 上为常数。若函数 $f(x)$ Riemann 可积, 则从下方逼近的最大面积与从上方覆盖的最小面积相等:

$$\int_a^b f(x) dx \triangleq \sup_{\{s(x): s(x) \leq f(x)\}} \int_a^b s(x) dx = \inf_{\{s(x): s(x) \geq f(x)\}} \int_a^b s(x) dx. \quad (1.98)$$

几何上, 下方阶梯函数像一组高度不超过曲线的长方形, 上方阶梯函数像一组覆盖曲线的长方形。分割越来越细时, 若两边逼近同一个面积, 这个公共值就是 Riemann 积分。阶梯函数的底边必须是连续区间, 因此它天然适合通常工程中遇到的平滑曲线、分段连续曲线和有限跳变曲线。

一个经典的不可 Riemann 积分例子是 Dirichlet 函数:

$$f(x) = \begin{cases} 0, & x \text{ 为无理数,} \\ 1, & x \text{ 为有理数.} \end{cases} \quad (1.99)$$

在任意小区间内, 有理数和无理数都处处稠密。所有低于 f 的阶梯函数高度只能取 0, 所以下积分为 0; 所有高于 f 的阶梯函数高度至少为 1, 所以上积分为 $b - a$:

$$\sup_{\{s(x): s(x) \leq f(x)\}} \int_a^b s(x) dx = 0, \quad \inf_{\{s(x): s(x) \geq f(x)\}} \int_a^b s(x) dx = b - a. \quad (1.100)$$

上下极限无法合在一起, 因此该函数无法作 Riemann 积分。

Lebesgue 积分 Lebesgue 积分把基本逼近单位从阶梯函数换成简单函数 (simple function)。设 $U_1, \dots, U_m$ 是定义域 X 的有限个互不相交分割, 且

$$\bigcup_{i=1}^m U_i = X. \quad (1.101)$$

集合 U_i 的指标函数定义为

$$\mathbf{1}(x; U_i) = \begin{cases} 1, & x \in U_i, \\ 0, & x \notin U_i. \end{cases} \quad (1.102)$$

若

$$t(x) = \sum_{i=1}^m a_i \mathbf{1}(x; U_i), \quad (1.103)$$

则 $t(x)$ 是简单函数, 并且

$$\int_X t(x) dx = \sum_{i=1}^m a_i \lambda(U_i), \quad (1.104)$$

其中 $\lambda(\cdot)$ 为 Lebesgue 测度。

简单函数可看成阶梯函数的扩展。阶梯函数要求每块底边是连续区间; 简单函数只要求每个 U_i 是可测集合, 不要求它在数轴上连成一段。换句话说, 只要一批点映射到同一个函数值, 就可以把它们放在同一块 U_i 中, 用测度 $\lambda(U_i)$ 来计算这块区域的“底边大小”。

若 $f(x)$ Lebesgue 可积, 则可用简单函数从下方和上方逼近:

$$\int_a^b f(x) dx = \sup_{\{t(x): t(x) \leq f(x)\}} \int_a^b t(x) dx = \inf_{\{t(x): t(x) \geq f(x)\}} \int_a^b t(x) dx. \quad (1.105)$$

前面的 Dirichlet 函数在 Lebesgue 意义下可以积分。因为有理数集合可数, 每个单点的 Lebesgue 测度为 0, 可数个单点的测度仍为 0; 函数在有理数上取 1 的部分不贡献面积, 在无理数上取 0, 因此 Lebesgue 积分为 0。

这一段与随机过程积分的关系在于: 当我们写

$$E \left[\int x(t) dt \right] = \int E[x(t)] dt \quad (1.106)$$

时, 实际使用了积分与期望的交换。Riemann 框架下讨论的对象较规则, 工程上通常已经够用; Lebesgue 框架处理的函数类更大, 也更接近严格概率论中随机变量和随机过程的可测性语言。

1.1.19 点过程、更新过程与计数过程

定义 1.1.29 (点过程). 点过程 (point process) 是在时间轴上的一组随机点 t_i 。这些随机点表示某些事件发生的时刻, 例如电话到达、封包到达、灯泡损坏或粒子探测事件。

定义 1.1.30 (更新过程). 更新过程 (renewal process) 由点过程相邻点之间的更新间隔组成:

$$z_n = t_n - t_{n-1}. \quad (1.107)$$

灯泡寿命是更新过程的直观例子。第 $(i-1)$ 个灯泡坏掉后立刻换上第 i 个灯泡, z_i 就是第 i 个新灯泡的寿命。每次更换都像系统重新开始, 因此相邻失效时刻之间的间隔构成 renewal intervals。

定义 1.1.31 (计数过程). 计数过程 (counting process) $x(t)$ 统计区间 $[0, t)$ 内随机点出现的个数。

若点表示电话、封包或故障, 那么 $x(t)$ 就是到时间 t 为止累计发生的电话数、封包数或故障数。它通常是一条右连续、单调不减的阶梯形样本路径: 每来一个点, 过程值向上跳一格。

1.1.20 Poisson 过程的定义性性质

Poisson 过程是一个通过可观察性质来定义随机过程的例子。这里不显式写出继承的概率空间, 定义时直接规定区间内点的个数分布和互不重叠区间之间的独立性。设 $n[t_1, t_2)$ 表示区间 $[t_1, t_2)$ 内 Poisson 点出现的个数, 假设

$$\nu(t_1, t_2) \triangleq \int_{t_1}^{t_2} \lambda(t) dt. \quad (1.108)$$

第一条性质为

$$\Pr\{n[t_1, t_2] = k\} = e^{-\nu(t_1, t_2)} \frac{[\nu(t_1, t_2)]^k}{k!}. \quad (1.109)$$

第二条性质为：若 $[t_1, t_2]$ 与 $[t_3, t_4]$ 互不重叠，则 $n[t_1, t_2]$ 与 $n[t_3, t_4]$ 独立。

这两个性质都不可省略。第一条说明每个区间中的到达数服从 Poisson 随机变量；第二条说明互不重叠区间的到达数独立，也就是独立增量。实际推导时，常先利用第二条把时间区间拆成互不重叠部分，再利用第一条代入 Poisson 随机变量的矩。若只检查每个区间内的边缘分布，仍不足以保证整个计数过程具有 Poisson 过程的结构。

令

$$x(t) \triangleq n[0, t], \quad (1.110)$$

则 $x(t)$ 是从 0 开始累计点数的计数过程。若 $\lambda(t)$ 随时间变化，它描述的是非齐次 Poisson 过程；若 $\lambda(t) = \lambda$ 为常数，则得到齐次 Poisson 过程。早期电话话务量和封包流量常用 Poisson 模型描述，因为不同用户的到达行为可近似为彼此独立；现代网络流量常出现同步突发到达，便可能偏离这个模型。

命题 1.1.32 (Poisson 计数过程的均值与自相关). 设 $x(t) = n[0, t]$ 为 Poisson 计数过程。它的均值函数为

$$\mu_x(t) = \int_0^t \lambda(u) du. \quad (1.111)$$

自相关函数满足

$$R_{xx}(t_1, t_2) = \int_0^{\min\{t_1, t_2\}} \lambda(u) du + \int_0^{t_1} \int_0^{t_2} \lambda(u) \lambda(v) du dv. \quad (1.112)$$

若 $\lambda(t) = \lambda$ 为常数，则

$$R_{xx}(t_1, t_2) = \lambda \min\{t_1, t_2\} + \lambda^2 t_1 t_2. \quad (1.113)$$

证明. 先计算均值函数。由式 (1.109)，Poisson 随机变量的均值等于其参数，因此

$$\mu_x(t) = E[x(t)] = E[n[0, t]] = \int_0^t \lambda(u) du. \quad (1.114)$$

下面计算自相关函数。先设 $t_1 \leq t_2$ 。根据定义,

$$\begin{aligned} R_{xx}(t_1, t_2) &= E[x(t_1)x^*(t_2)] \\ &= E[n[0, t_1)n[0, t_2]]. \end{aligned} \quad (1.115)$$

为了使用互不重叠区间独立性, 将 $[0, t_2)$ 拆成 $[0, t_1)$ 与 $[t_1, t_2)$:

$$n[0, t_2] = n[0, t_1] + n[t_1, t_2]. \quad (1.116)$$

于是

$$\begin{aligned} R_{xx}(t_1, t_2) &= E\{n[0, t_1][n[0, t_1] + n[t_1, t_2]]\} \\ &= E[n^2[0, t_1]] + E[n[0, t_1)n[t_1, t_2]]. \end{aligned} \quad (1.117)$$

由于 $[0, t_1)$ 与 $[t_1, t_2)$ 互不重叠, 第二项可用独立性拆成两个均值的乘积:

$$E[n[0, t_1)n[t_1, t_2]] = E[n[0, t_1]]E[n[t_1, t_2]]. \quad (1.118)$$

记

$$\Lambda_1 = \int_0^{t_1} \lambda(u) du, \quad \Lambda_{12} = \int_{t_1}^{t_2} \lambda(u) du. \quad (1.119)$$

Poisson 随机变量满足 $E[N] = \Lambda$ 、 $\text{var}(N) = \Lambda$, 因此

$$E[N^2] = \text{var}(N) + (E[N])^2 = \Lambda + \Lambda^2. \quad (1.120)$$

代回可得

$$\begin{aligned} R_{xx}(t_1, t_2) &= (\Lambda_1 + \Lambda_1^2) + \Lambda_1 \Lambda_{12} \\ &= \int_0^{t_1} \lambda(u) du + \left(\int_0^{t_1} \lambda(u) du \right) \left(\int_0^{t_2} \lambda(u) du \right) \\ &= \int_0^{t_1} \lambda(u) du + \int_0^{t_1} \int_0^{t_2} \lambda(u)\lambda(v) du dv. \end{aligned} \quad (1.121)$$

同理, 当 $t_1 > t_2$ 时, 第一项中的上限换成 t_2 , 第二项保持为两个累计均值的乘积:

$$R_{xx}(t_1, t_2) = \int_0^{t_2} \lambda(u) du + \int_0^{t_1} \int_0^{t_2} \lambda(u)\lambda(v) du dv. \quad (1.122)$$

Poisson 自相关的最终形式与操作意义 合并 $t_1 \leq t_2$ 与 $t_1 > t_2$ 两种情况, 得到

$$R_{xx}(t_1, t_2) = \int_0^{\min\{t_1, t_2\}} \lambda(u) du + \int_0^{t_1} \int_0^{t_2} \lambda(u) \lambda(v) du dv. \quad (1.123)$$

若 $\lambda(t)$ 是常数 λ , 则

$$R_{xx}(t_1, t_2) = \lambda \min\{t_1, t_2\} + \lambda^2 t_1 t_2. \quad (1.124)$$

自相关函数的操作意义是量化一个数据点与过去或未来数据点之间的关联。对 Poisson 计数过程来说, $x(t)$ 是累计量; 若 $t_2 > t_1$, 那么 $x(t_2) = n[0, t_2)$ 中天然包含 $n[0, t_1)$ 的全部点。因此当前累计数和遥远未来累计数之间的关系不会因为时间拉远而自然消失, 早期累计部分会一直保留在后来的累计值中。

自协方差把均值项扣掉。由

$$\mu_x(t) = \lambda t \quad (1.125)$$

和式 (1.124) 可得

$$\begin{aligned} C_{xx}(t_1, t_2) &= R_{xx}(t_1, t_2) - \mu_x(t_1)\mu_x(t_2) \\ &= [\lambda \min\{t_1, t_2\} + \lambda^2 t_1 t_2] - (\lambda t_1)(\lambda t_2) \\ &= \lambda \min\{t_1, t_2\}. \end{aligned} \quad (1.126)$$

若固定 t_1 并令 $t_2 > t_1$ 越来越大, $C_{xx}(t_1, t_2) = \lambda t_1$ 保持常数。这个现象来自累计过程的结构: 未来累计量始终含有早期累计量。若观察某个数据过程时发现远距离时间点仍保持强相关, 常要检查变量本身是否包含累积成分; 若自相关还随时间尺度快速增长, 则均值或 DC 分量也可能在其中贡献了主要能量。 $\square$

1.1.21 Poisson 电报信号

Poisson 过程的例题不只用于练习计算, 还用来观察统计量与原始过程结构之间的关系。若一个模型的自相关函数不会随时间间隔衰减, 通常

意味着过程里有累积成分；若自相关随间隔衰减，则更接近通信信号中常见的“距离越远，关系越弱”的直观。

在齐次 Poisson 情形 $\lambda(t) = \lambda$ 下，令 $n[0, t)$ 表示 $[0, t)$ 内的 Poisson 到达数。半随机电报信号 (semirandom telegraph signal) 定义为

$$u(t) = \begin{cases} 1, & n[0, t) \text{ 为偶数,} \\ -1, & n[0, t) \text{ 为奇数.} \end{cases} \quad (1.127)$$

每出现一个 Poisson 点， $u(t)$ 的符号翻转一次；样本路径便是在 $+1$ 与 -1 之间跳变的阶梯波形。因为 $n[0, 0) = 0$ ，所以 $u(0) = 1$ 是确定的，这也是 later 称它为 semirandom 的原因：起点被固定，后续跳变由随机点控制。

均值函数可由偶数点数与奇数点数的概率差得到：

$$\begin{aligned} E[u(t)] &= \Pr\{n[0, t) = 0, 2, 4, \dots\} - \Pr\{n[0, t) = 1, 3, 5, \dots\} \\ &= e^{-\lambda t} \left[1 + \frac{(\lambda t)^2}{2!} + \frac{(\lambda t)^4}{4!} + \dots \right] - e^{-\lambda t} \left[\lambda t + \frac{(\lambda t)^3}{3!} + \frac{(\lambda t)^5}{5!} + \dots \right] \\ &= e^{-\lambda t} \cosh(\lambda t) - e^{-\lambda t} \sinh(\lambda t) = e^{-2\lambda t}. \end{aligned} \quad (1.128)$$

这里 $\cosh$ 收集所有偶次幂正项， $\sinh$ 收集所有奇次幂正项。由于起点固定为 $+1$ ， $E[u(t)]$ 在 $t = 0$ 等于 1，随后指数衰减并趋近于 0；时间离固定起点越远，起点造成的偏置越弱。

半随机电报信号的自相关 计算自相关函数时，关键仍然是 Poisson 过程的第二个定义性性质：非重叠区间上的到达数独立。设 $t_1 \leq t_2$ 。因为 $u(t)$ 只取 ± 1 ，所以乘积的期望可分成四种奇偶组合：

$$\begin{aligned} E[u(t_1)u^*(t_2)] &= \Pr\{n[0, t_1) \text{ 偶}, n[0, t_2) \text{ 偶}\} \\ &\quad + \Pr\{n[0, t_1) \text{ 奇}, n[0, t_2) \text{ 奇}\} \\ &\quad - \Pr\{n[0, t_1) \text{ 偶}, n[0, t_2) \text{ 奇}\} \\ &\quad - \Pr\{n[0, t_1) \text{ 奇}, n[0, t_2) \text{ 偶}\}. \end{aligned} \quad (1.129)$$

为了让独立增量可用, 把 $[0, t_2)$ 拆成 $[0, t_1)$ 与 $[t_1, t_2)$ 。例如 $n[0, t_1)$ 与 $n[0, t_2)$ 同为偶数时, 差值 $n[t_1, t_2) = n[0, t_2) - n[0, t_1)$ 也为偶数; 同为奇数时差值仍为偶数。一偶一奇时, 差值为奇数。因此式 (1.129) 化为

$$\begin{aligned}
 E[u(t_1)u^*(t_2)] &= \Pr\{n[0, t_1) \text{ 偶}\} \Pr\{n[t_1, t_2) \text{ 偶}\} \\
 &\quad + \Pr\{n[0, t_1) \text{ 奇}\} \Pr\{n[t_1, t_2) \text{ 偶}\} \\
 &\quad - \Pr\{n[0, t_1) \text{ 偶}\} \Pr\{n[t_1, t_2) \text{ 奇}\} \\
 &\quad - \Pr\{n[0, t_1) \text{ 奇}\} \Pr\{n[t_1, t_2) \text{ 奇}\} \\
 &= [\Pr\{n[0, t_1) \text{ 偶}\} + \Pr\{n[0, t_1) \text{ 奇}\}] \\
 &\quad \cdot [\Pr\{n[t_1, t_2) \text{ 偶}\} - \Pr\{n[t_1, t_2) \text{ 奇}\}] \\
 &= \Pr\{n[t_1, t_2) \text{ 偶}\} - \Pr\{n[t_1, t_2) \text{ 奇}\}. \tag{1.130}
 \end{aligned}$$

第一组括号为 1, 因为 $n[0, t_1)$ 只能是偶数或奇数。第二组括号就是长度为 $t_2 - t_1$ 的 Poisson 区间上“偶数概率减奇数概率”, 与均值计算完全同型, 因此

$$E[u(t_1)u^*(t_2)] = e^{-2\lambda(t_2-t_1)}, \quad t_1 \leq t_2. \tag{1.131}$$

同理, 当 $t_1 > t_2$ 时,

$$E[u(t_1)u^*(t_2)] = e^{-2\lambda(t_1-t_2)}. \tag{1.132}$$

半随机与全随机电报信号 合并两种时间顺序, 半随机电报信号的自相关函数为

$$R_{uu}(t_1, t_2) = E[u(t_1)u^*(t_2)] = e^{-2\lambda|t_1-t_2|}. \tag{1.133}$$

它只依赖时间差 $|t_1 - t_2|$, 且随时间间隔指数衰减到 0。这和上一讲的 Poisson 计数过程形成对照: 计数过程是累积量, 未来值包含过去累计的点; 电报信号被映射到 ± 1 , 有界且每次到达只翻转符号, 所以远距离时间点的关联会逐渐消失。

半随机的含义在于起点 $u(0) = 1$ 被固定。若希望起点也随机, 可引入独立于 $u(t)$ 的随机变量 a , 并令

$$v(t) = a u(t), \quad \Pr\{a = 1\} = \Pr\{a = -1\} = \frac{1}{2}. \tag{1.134}$$

这样的 $v(t)$ 称为全随机电报信号 (random telegraph signal)。因为 a 对称取 ± 1 , 所以

$$E[v(t)] = E[a]E[u(t)] = 0. \quad (1.135)$$

同时 $a^2 = 1$, 且 a 与 u 独立, 因此

$$R_{vv}(t_1, t_2) = E[a^2 u(t_1) u^*(t_2)] = R_{uu}(t_1, t_2). \quad (1.136)$$

两者的一阶分布也能看出起点影响。半随机信号满足

$$\begin{aligned} \Pr\{u(t) = 1\} &= e^{-\lambda t} \cosh(\lambda t) = \frac{1}{2} + \frac{1}{2}e^{-2\lambda t}, \\ \Pr\{u(t) = -1\} &= e^{-\lambda t} \sinh(\lambda t) = \frac{1}{2} - \frac{1}{2}e^{-2\lambda t}. \end{aligned} \quad (1.137)$$

当 $t \rightarrow \infty$ 时, 这两个概率都趋近于 $1/2$ 。全随机信号从一开始就有

$$\Pr\{v(t) = 1\} = \Pr\{v(t) = -1\} = \frac{1}{2}. \quad (1.138)$$

因此, 若观测结果在所有时间上都完全对称, 可能表示起始状态本身也是随机的; 若只在远离起点后趋近对称, 则说明模型中存在一个被固定的初始状态。

1.1.22 Poisson 过程的运算性质

Poisson 过程有一个重要封闭性: 独立 Poisson 过程相加仍为 Poisson 过程。

命题 1.1.33 (独立 Poisson 过程的叠加). 设

$$x_1(t) \sim \text{Poisson}(\lambda_1 t), \quad x_2(t) \sim \text{Poisson}(\lambda_2 t), \quad (1.139)$$

且二者独立。令

$$z(t) = x_1(t) + x_2(t), \quad (1.140)$$

则

$$z(t) \sim \text{Poisson}((\lambda_1 + \lambda_2)t). \quad (1.141)$$

在网络交换机或路由器中，多个独立 Poisson 流量汇合后仍可用 Poisson 模型描述，这正是该性质的工程意义。完整证明仍要检查两个定义性性质：每个区间内的计数为 Poisson 随机变量，以及非重叠区间计数相互独立。

例 1.1.34 (Poisson 过程的差). 差过程

$$y(t) = x_1(t) - x_2(t) \quad (1.142)$$

具有不同性质。Poisson 随机变量只能取 $0, 1, 2, \dots$ ，而两个计数相减可能为负数，因此差过程的边缘分布不会是 Poisson 分布。它的分布可直接由独立性计算。对整数 $n = 0, \pm 1, \pm 2, \dots$,

$$\begin{aligned} \Pr\{y(t) = n\} &= \sum_{k=\max\{0, -n\}}^{\infty} \Pr\{x_1(t) = n + k\} \Pr\{x_2(t) = k\} \\ &= \sum_{k=\max\{0, -n\}}^{\infty} e^{-\lambda_1 t} \frac{(\lambda_1 t)^{n+k}}{(n+k)!} e^{-\lambda_2 t} \frac{(\lambda_2 t)^k}{k!}. \end{aligned} \quad (1.143)$$

求和下限来自两个计数都必须非负： $k \geq 0$ 且 $n + k \geq 0$ 。

将 $\tilde{k} = k - \max\{0, -n\}$ 换成从 0 开始的指标，并整理与 $\tilde{k}$ 无关的项，可得到

$$\Pr\{y(t) = n\} = e^{-(\lambda_1 + \lambda_2)t} \left(\frac{\lambda_1}{\lambda_2}\right)^{n/2} I_{|n|} \left(2t\sqrt{\lambda_1 \lambda_2}\right), \quad (1.144)$$

其中

$$I_n(x) \triangleq \sum_{k=0}^{\infty} \frac{(x/2)^{n+2k}}{k!(n+k)!} \quad (1.145)$$

是 n 阶修正 Bessel 函数。这里出现 $|n|$ ，说明分母整理后与差值的绝对大小相关；若 $\lambda_1 = \lambda_2$ ，分布关于 0 对称。这个结果在比较两个 Poisson 流量的差异时会出现，例如两个封包流或两类话务量之间的净差。

1.1.23 Poisson 点的随机筛选

Poisson 点的另一条重要性质是随机筛选 (random selection, thinning) 后仍为 Poisson。设 $x(t) \sim \text{Poisson}(\lambda t)$, 其点为 $\{t_1, t_2, t_3, \dots\}$ 。假设每个到达点独立地以概率 p 被标记 (tagged), 令 $y(t)$ 表示 $[0, t)$ 内被标记事件总数, $z(t)$ 表示 $[0, t)$ 内未标记事件总数。

定义 1.1.35 (Poisson 随机筛选). 若每个 Poisson 到达点独立地以概率 p 被保留或标记, 则被标记点形成的计数过程满足

$$y(t) \sim \text{Poisson}(p\lambda t), \quad (1.146)$$

未被标记点形成的计数过程满足

$$z(t) \sim \text{Poisson}((1-p)\lambda t). \quad (1.147)$$

银行顾客可作为直观例子: 总顾客到达为 Poisson 过程, 若每位顾客独立地以概率 p 属于某一类, 例如男性顾客、某种业务类型或某类封包, 则该类顾客的到达过程仍为 Poisson 过程, 速率缩小为原来的 p 倍。

随机筛选的边缘分布证明

证明. 先证明 $y(t)$ 的边缘分布。若总到达数 $x(t) = n$, 其中恰有 k 个被标记, 则条件分布是二项分布:

$$\Pr\{k \text{ out of } n \text{ are tagged} \mid x(t) = n\} = \binom{n}{k} p^k (1-p)^{n-k}. \quad (1.148)$$

因此

$$\begin{aligned} \Pr\{y(t) = k\} &= \sum_{n=k}^{\infty} \Pr\{x(t) = n\} \Pr\{k \text{ out of } n \text{ are tagged} \mid x(t) = n\} \\ &= \sum_{n=k}^{\infty} \left[e^{-\lambda t} \frac{(\lambda t)^n}{n!} \right] \left[\binom{n}{k} p^k (1-p)^{n-k} \right] \\ &= e^{-\lambda t} \frac{(p\lambda t)^k}{k!} \sum_{n=k}^{\infty} \frac{[(1-p)\lambda t]^{n-k}}{(n-k)!}. \end{aligned} \quad (1.149)$$

令 $r = n - k$, 则

$$\begin{aligned}\Pr\{y(t) = k\} &= e^{-\lambda t} \frac{(p\lambda t)^k}{k!} \sum_{r=0}^{\infty} \frac{[(1-p)\lambda t]^r}{r!} \\ &= e^{-\lambda t} \frac{(p\lambda t)^k}{k!} e^{(1-p)\lambda t} = e^{-p\lambda t} \frac{(p\lambda t)^k}{k!}.\end{aligned}\quad (1.150)$$

这正是参数为 $p\lambda t$ 的 Poisson 分布。 $z(t)$ 的证明同理。

需要特别注意, 式 (1.150) 只证明了 Poisson 过程定义中的第一条性质, 也就是任一区间内计数服从 Poisson 分布。若要证明 $y(t)$ 本身是 Poisson 过程, 还必须证明互不重叠区间内的被标记计数相互独立。这个第二性质常被漏掉, 但它和边缘分布同等重要。□

1.1.24 Poisson 点的条件分布

命题 1.1.36 (给定总数时的二项分布). 设 $x(t)$ 是齐次 Poisson 过程, 且 $t_1 < t_2$ 。在已知 $x(t_2) = n$ 的条件下, $x(t_1) = k$ 的条件分布为

$$x(t_1) \mid x(t_2) = n \sim \text{Binomial}\left(n, \frac{t_1}{t_2}\right). \quad (1.151)$$

证明. 证明从条件概率定义开始:

$$\begin{aligned}\Pr\{x(t_1) = k \mid x(t_2) = n\} &= \frac{\Pr\{x(t_1) = k, x(t_2) = n\}}{\Pr\{x(t_2) = n\}} \\ &= \frac{\Pr\{n[0, t_1] = k, n[t_1, t_2] = n - k\}}{\Pr\{n[0, t_2] = n\}}.\end{aligned}\quad (1.152)$$

再次使用非重叠区间独立性, 分子可拆成两个 Poisson 概率的乘积:

$$\begin{aligned}\Pr\{x(t_1) = k \mid x(t_2) = n\} &= \frac{\Pr\{n[0, t_1] = k\} \Pr\{n[t_1, t_2] = n - k\}}{\Pr\{n[0, t_2] = n\}} \\ &= \frac{e^{-\lambda t_1} \frac{(\lambda t_1)^k}{k!} e^{-\lambda(t_2-t_1)} \frac{[\lambda(t_2-t_1)]^{n-k}}{(n-k)!}}{e^{-\lambda t_2} \frac{(\lambda t_2)^n}{n!}} \\ &= \binom{n}{k} \left(\frac{t_1}{t_2}\right)^k \left(1 - \frac{t_1}{t_2}\right)^{n-k}, \quad k = 0, 1, \dots, n.\end{aligned}\quad (1.153)$$

这个推导再次体现 Poisson 过程计算的固定路线：先把区间拆成非重叠部分以使用独立增量，再把各区间的 Poisson 概率代入。□

条件均匀性与顺序统计量 式 (1.153) 的参数是 t_1/t_2 ，它只等于时间长度比例。若在区间 $[0, T)$ 内已知恰好发生一次 Poisson 到达，则该到达落在 $[0, t_1)$ 内的概率为

$$\Pr\{x(t_1) = 1 \mid x(T) = 1\} = \binom{1}{1} \left(\frac{t_1}{T}\right) \left(1 - \frac{t_1}{T}\right)^0 = \frac{t_1}{T}. \quad (1.154)$$

这说明，在已知 $[0, T)$ 内恰有一个 Poisson 点的条件下，该点在整个长度为 T 的区间内均匀出现。若把 $[0, T)$ 想成银行一天营业时间，已知一天只有一个顾客到达，则该顾客落在前半天的概率就是 $1/2$ ，落在第一个小时的概率就是该小时长度占全天长度的比例。

更一般地，若已知 $x(T) = n$ ，则 n 个 Poisson 到达时刻 $t_1, \dots, t_n$ 的联合密度等于 n 个独立均匀随机变量排序后的顺序统计量 (order statistics)。设 $s_1, \dots, s_n$ 相互独立且都在 $[0, T)$ 上均匀分布，将它们从小到大排序后得到

$$t_1 \leq t_2 \leq \dots \leq t_n, \quad \{t_1, \dots, t_n\} = \{s_1, \dots, s_n\}. \quad (1.155)$$

这组有序点的分布就是给定 $x(T) = n$ 时 Poisson 到达点的分布。

因此，Poisson 过程除了“区间计数为 Poisson 分布”和“非重叠区间独立”两条定义性性质外，还有一个重要直观：在任意有限区间 $[0, T)$ 中，给定到达总数以后，到达点可看成独立均匀点排序后的结果。这个观点也给出一种模拟方法：先在 $[0, T)$ 上独立产生若干 uniform 点，再按时间排序，即得到给定总数条件下的 Poisson 到达时刻。

1.1.25 平稳性族

随机过程里最常见、也最有应用价值的假设之一是平稳性。通信系统设计时，输入信息、噪声、信道扰动常常都被建模为随机过程；如果设计阶段采用的统计特性与实际使用阶段的统计特性随时间基准改变而发生变更

化，设计出的系统便很难长期适用。因此，平稳性的核心思想是把时间原点平移以后，所观察到的统计规律保持不变。

定义 1.1.37 (严格平稳、联合平稳与宽平稳). 随机过程 $x(t)$ 称为严格平稳 (strict-sense stationary, SSS)，如果它的统计特性对时间原点平移保持不变。两个随机过程称为联合平稳 (jointly stationary)，如果它们的联合统计特性对时间原点平移保持不变。

复随机过程 $z(t) = x(t) + jy(t)$ 称为平稳，当且仅当其实部过程 $x(t)$ 与虚部过程 $y(t)$ 联合平稳。

随机过程 $x(t)$ 称为宽平稳 (wide-sense stationary, WSS)，如果它的均值函数和自相关函数对时间原点平移保持不变。由此

$$\eta_x(t) = \eta_x(0) = c, \quad R_{xx}(t_1, t_2) = R_{xx}(t_1 - t_2, 0) = R_{xx}(t_1 - t_2). \quad (1.156)$$

两个随机过程 $x(t)$ 与 $y(t)$ 称为联合宽平稳，如果它们各自的均值函数、自相关函数以及二者的互相关函数都对时间原点平移保持不变。

严格平稳中的“统计特性”范围很大。若以有限维分布描述随机过程，则任意多个时间采样点的联合分布在整体平移后都应相同；若回到更完整的概率空间观点，则路径层面的统计性质也包含在内。因此严格平稳很强，理论上清楚，实际验证往往困难。宽平稳把要求降到一阶与二阶统计量，常用于只关心平均功率、相关性和能量交换的系统分析。许多教材直接把“均值为常数、自相关只与时间差有关”当作 WSS 定义；从时间原点平移不变出发，它们正好是式 (1.156) 的等价表达。

1.1.26 其他形式的平稳性

定义 1.1.38 (平稳性的若干变体). 随机过程 $x(t)$ 称为协方差平稳 (covariance-stationary)，如果自协方差函数对时间原点平移保持不变。

随机过程 $x(t)$ 称为 n 阶平稳 (n th order stationary)，如果任意 n 维统计量对时间原点平移保持不变。

随机过程 $x(t)$ 称为在某区间内平稳 (stationary in an interval), 如果在该区间内的统计特性对时间原点平移保持不变。也就是说, 只要 t_i 与 $t_i + c$ 都属于该区间, 随机向量 $\{x(t_i)\}_{i=1}^n$ 与 $\{x(t_i + c)\}_{i=1}^n$ 具有相同统计特性。

随机过程 $x(t)$ 称为渐近平稳 (asymptotic stationary), 如果在极限存在时, $y(t) = \lim_{c \rightarrow \infty} x(t + c)$ 是平稳过程。

这些名称对应不同的使用范围。协方差平稳只追踪去均值后的二阶关系, 适合均值漂移可以另外处理的场景。 n 阶平稳只要求任取 n 个时间采样点的联合统计量平移不变, 并不保证 $n + 1$ 阶统计量也平移不变。区间平稳强调模型只在有限时段内适用, 例如通信设备在某个工作时段内可以采用同一统计模型, 或河川流量在春季、夏季分别具有不同统计规律。渐近平稳则描述暂态逐渐消失以后, 长时间极限进入平稳状态。无论名称如何变化, 共同精神都是时间基准平移后, 所关心的统计对象保持不变。

1.1.27 随机同相/正交载波的平稳性

考虑通信中常见的同相与正交载波形式

$$x(t) = a \cos(\omega t) + b \sin(\omega t), \quad (1.157)$$

其中 a 与 b 是随机变量, 可理解为送到余弦轴与正弦轴上的随机信息。这个模型随时间推进时, 本质上是在同相/正交平面中旋转随机向量 (a, b) ; 因此它的平稳性直接取决于二维统计分布在旋转下是否保持不变。

定理 1.1.39 (随机同相/正交载波的严格平稳条件). 过程 $x(t) = a \cos(\omega t) + b \sin(\omega t)$ 严格平稳, 当且仅当 (a, b) 的联合密度 $f(a, b)$ 具有圆对称性, 即

$$f(a, b) = g(r), \quad r = \sqrt{a^2 + b^2}, \quad (1.158)$$

其中 g 为某个只依赖半径的函数。

直观上, 若二维密度绕原点旋转后完全看不出变化, 时间平移便不会改变过程的统计特性; 若 (a, b) 的分布在某个方向上更集中, 载波旋转会把这种方向偏好转化为随时间变化的统计特性。

证明. 先证必要性。若 $x(t)$ 严格平稳, 则两个时间采样形成的随机向量

$$\mathbf{x} = \begin{bmatrix} x(0) \\ x(\pi/(2\omega)) \end{bmatrix} = \begin{bmatrix} a \\ b \end{bmatrix} \quad (1.159)$$

与平移后得到的

$$\mathbf{y} = \begin{bmatrix} x(t) \\ x(t + \pi/(2\omega)) \end{bmatrix} = \begin{bmatrix} \cos(\omega t) & \sin(\omega t) \\ -\sin(\omega t) & \cos(\omega t) \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \quad (1.160)$$

必须具有同一联合密度。式 (1.160) 是二维旋转, 行列式绝对值为 1, 于是密度变换给出

$$f_{\mathbf{y}}(y_1, y_2) = f_{\mathbf{x}}(y_1 \cos(\omega t) - y_2 \sin(\omega t), y_1 \sin(\omega t) + y_2 \cos(\omega t)). \quad (1.161)$$

由于严格平稳要求 $f_{\mathbf{x}} = f_{\mathbf{y}} = f$, 对所有角度 ωt 都有

$$f(y_1, y_2) = f(y_1 \cos(\omega t) - y_2 \sin(\omega t), y_1 \sin(\omega t) + y_2 \cos(\omega t)). \quad (1.162)$$

这正是旋转不变性, 也就是圆对称性。 $\square$

密度在映射下的变换 上面的证明用到多变量密度变换公式。

引理 1.1.40 (密度变换公式). 设 $\mathbf{x} \in \mathbb{R}^k$ 具有密度 f , 支撑集 V 是 $\mathbb{R}^k$ 中的开集; g 是从 V 到 U 的一一、连续可微映射, 其中 U 是 $\mathbb{R}^k$ 中的开集; T 是 g 的反函数, 且在 U 上连续可微, 写作

$$T(\mathbf{y}) = (T_1(\mathbf{y}), T_2(\mathbf{y}), \dots, T_k(\mathbf{y})). \quad (1.163)$$

若 $\mathbf{y} = g(\mathbf{x})$, 则 $\mathbf{y}$ 的密度为

$$f_{\mathbf{y}}(\mathbf{y}) = \begin{cases} f(T(\mathbf{y})) |J(\mathbf{y}; T)|, & \mathbf{y} \in U, \\ 0, & \mathbf{y} \notin U, \end{cases} \quad (1.164)$$

其中

$$J(\mathbf{y}; T) = \det \left[\frac{\partial T_i}{\partial y_j}(\mathbf{y}) \right]_{i,j=1}^k \neq 0, \quad \mathbf{y} \in U. \quad (1.165)$$

开集、连续可微、一一映射、反函数连续可微以及 Jacobian 非零，都是使用该公式时需要检查的条件。在线性旋转的证明中这些条件自然满足；在更一般的变量变换里，遗漏 Jacobian 或在 Jacobian 为零的地方直接套用公式，都会造成错误。

例 1.1.41 (极坐标变换). 二维标准正态密度

$$f(x_1, x_2) = \frac{1}{2\pi} \exp \left[-\frac{x_1^2 + x_2^2}{2} \right] \quad (1.166)$$

本身具有圆对称性。为了把直角坐标变成极坐标，令

$$g(x_1, x_2) = \left(\sqrt{x_1^2 + x_2^2}, \tan^{-1}(x_2/x_1) \bmod 2\pi \right), \quad (1.167)$$

并取

$$T(y_1, y_2) = (y_1 \cos y_2, y_1 \sin y_2), \quad U = \{(y_1, y_2) : y_1 > 0, 0 < y_2 < 2\pi\}. \quad (1.168)$$

为了满足开集和一一性要求，可把坐标轴等概率为零的集合从支撑集中去掉。对连续密度而言，少掉有限条直线不改变积分概率；这样处理以后，半径为正、角度避开端点，映射便落在开集 U 中。

反函数的 Jacobian 为

$$J(\mathbf{y}; T) = \det \begin{bmatrix} \cos y_2 & -y_1 \sin y_2 \\ \sin y_2 & y_1 \cos y_2 \end{bmatrix} = y_1, \quad (1.169)$$

在 U 上恒为正。因此极坐标变量 (y_1, y_2) 的密度为

$$f_{\mathbf{y}}(y_1, y_2) = \begin{cases} \frac{1}{2\pi} y_1 e^{-y_1^2/2}, & (y_1, y_2) \in U, \\ 0, & (y_1, y_2) \notin U. \end{cases} \quad (1.170)$$

这个例子说明 Jacobian 中的 y_1 是面积元素从直角坐标转换为极坐标时出现的尺度因子；去掉原点或坐标轴是为满足定理条件，对连续分布的概率值没有实质影响。

充分性

证明. 现在证明定理的充分性。固定任意时间平移量 τ ，定义

$$x_1(t) = a_1 \cos(\omega t) + b_1 \sin(\omega t), \quad (1.171)$$

其中

$$a_1 = a \cos(\omega \tau) + b \sin(\omega \tau), \quad b_1 = b \cos(\omega \tau) - a \sin(\omega \tau). \quad (1.172)$$

由三角恒等式可知 $x_1(t) = x(t + \tau)$ 。 $x(t)$ 的全部统计特性由 (a, b) 的统计特性决定， $x_1(t)$ 的全部统计特性由 (a_1, b_1) 的统计特性决定。若 $f(a, b)$ 圆对称，则式 (1.172) 只是把 (a, b) 在平面中旋转一个角度，旋转前后的联合密度完全相同，因而 (a, b) 与 (a_1, b_1) 具有相同分布。于是对任意 τ ， $x(t)$ 与 $x(t + \tau)$ 的统计特性相同，过程严格平稳。

这个结果给出通信信号生成的一个清晰准则：若希望式 (1.157) 表示的带通信号严格平稳，同相轴与正交轴上的二维统计分布必须对所有旋转角度保持不变。任何可观测的方向偏好都会随载波旋转转化为时间基准的可观测变化。 $\square$

1.1.28 弱平稳的两个常用充分条件

严格平稳要求完整密度圆对称。若只要求弱平稳，条件可以降到一阶与二阶统计量。设 a, b 零均值、互不相关并且方差相等，即

$$E[a] = E[b] = 0, \quad E[ab] = 0, \quad E[a^2] = E[b^2] = \sigma^2. \quad (1.173)$$

则 $x(t) = a \cos(\omega t) + b \sin(\omega t)$ 为 WSS。

证明. 均值为

$$E[x(t)] = E[a] \cos(\omega t) + E[b] \sin(\omega t) = 0, \quad (1.174)$$

自相关为

$$\begin{aligned}
 E[x(t_1)x(t_2)] &= E[a^2] \cos(\omega t_1) \cos(\omega t_2) + E[b^2] \sin(\omega t_1) \sin(\omega t_2) \\
 &\quad + E[ab] \{ \cos(\omega t_1) \sin(\omega t_2) + \sin(\omega t_1) \cos(\omega t_2) \} \\
 &= \sigma^2 \cos(\omega(t_1 - t_2)).
 \end{aligned} \tag{1.175}$$

均值为常数，自相关只依赖 $t_1 - t_2$ ，所以该过程宽平稳。与严格平稳相比，这里只要求两个轴在均值、方差与相关性上平衡。 $\square$

命题 1.1.42 (均匀随机相位给出宽平稳过程). 另一种常见形式是随机相位正弦信号

$$x(t) = a \cos(\omega t + \phi). \tag{1.176}$$

若相位 ϕ 在 $[-\pi, \pi)$ 上均匀分布，则 $x(t)$ 为 WSS。对固定的 ω ，均匀相位扫过一个完整周期，所以

证明.

$$E[x(t)] = 0. \tag{1.177}$$

再利用 $\cos A \cos B = \{\cos(A - B) + \cos(A + B)\}/2$,

$$\begin{aligned}
 E[x(t_1)x(t_2)] &= E \left[a^2 \frac{\cos(\omega(t_1 - t_2)) + \cos(\omega(t_1 + t_2) + 2\phi)}{2} \right] \\
 &= \frac{a^2}{2} E[\cos(\omega(t_1 - t_2))].
 \end{aligned} \tag{1.178}$$

含 2ϕ 的项在完整周期上平均为零，剩下的项只与时间差有关。这个条件是常用充分条件；若讨论必要性，需要另外给出论证或反例。复数形式

$$z(t) = ae^{j(\omega t + \phi)} \tag{1.179}$$

在 ϕ 均匀分布于 $[-\pi, \pi)$ 时同样为 WSS。 $\square$

1.1.29 圆对称与独立性推出高斯

进一步考虑式 (1.157)。

定理 1.1.43 (圆对称与独立性推出高斯). 若过程 $x(t) = a \cos(\omega t) + b \sin(\omega t)$ 严格平稳, 并且 a 与 b 相互独立, 则 (a, b) 必为二维正态随机向量, 且 $x(t)$ 是正态过程。

证明. 由前面的定理, 严格平稳推出 $f(a, b)$ 圆对称, 因此可写成 $g(r)$; 由独立性,

$$g(r) = f_a(a)f_b(b), \quad r = \sqrt{a^2 + b^2}. \quad (1.180)$$

把这两个条件合在一起, 得到

$$\begin{aligned} \frac{1}{r} \frac{g'(r)}{g(r)} &= \frac{1}{r} \frac{\partial g(r)/\partial r}{g(r)} \frac{\partial r/\partial a}{\partial r/\partial a} \\ &= \frac{1}{r} \frac{\partial g(r)/\partial a}{g(r)} \frac{1}{a/r} \\ &= \frac{1}{a} \frac{\partial f_a(a)/\partial a}{f_a(a)}. \end{aligned} \quad (1.181)$$

这里用到了 $\partial r/\partial a = a/r$, 以及 $f_b(b)$ 与 a 无关而可约去。

式 (1.181) 左边只通过半径 r 依赖 (a, b) 。若取 $(a, b) = (\alpha, \beta)$ 与 $(a, b) = (\beta, \alpha)$, 两点半径相同; 圆对称要求左边数值相同。于是右边

$$\frac{1}{a} \frac{f'_a(a)}{f_a(a)} \quad (1.182)$$

不能随 a 的具体取值改变, 只能是常数。该常数必须为负, 记为 $-1/\sigma^2$, 于是

$$\frac{1}{r} \frac{g'(r)}{g(r)} = -\frac{1}{\sigma^2}. \quad (1.183)$$

这个微分方程已经带出高斯形式: 函数的导数除以自身, 再除以半径后为负常数, 积分后必然得到指数二次型。

正态过程的完成论证

定义 1.1.44 (正态随机过程). 随机过程 $x(t)$ 称为正态过程 (normal process), 如果对任意有限个时间采样点, 随机向量

$$[x(t_1), x(t_2), \dots, x(t_k)] \quad (1.184)$$

都是联合正态随机向量。

由式 (1.183) 积分可得

$$\int \frac{g'(r)}{g(r)} dr = \int \left(-\frac{r}{\sigma^2}\right) dr + \log C, \quad g(r) = Ce^{-r^2/(2\sigma^2)}. \quad (1.185)$$

归一化常数由二维密度总积分为 1 决定:

$$C = \frac{1}{\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(x^2+y^2)/(2\sigma^2)} dx dy} = \frac{1}{2\pi\sigma^2}. \quad (1.186)$$

若常数为零, $g(r)$ 成为不可归一化的常数; 若常数为正, 指数随 r^2 增长, 同样无法让总积分有限。因此可积的概率密度只能对应负常数。最终

$$f_a(a)f_b(b) = g\left(\sqrt{a^2+b^2}\right) = \frac{1}{2\pi\sigma^2} \exp\left[-\frac{a^2+b^2}{2\sigma^2}\right], \quad (1.187)$$

说明 (a, b) 是二维高斯随机向量。这个结论可概括为: 圆对称与独立性同时成立时, 分布只能是高斯。□

还需把 (a, b) 的联合高斯性提升为 $x(t)$ 的正态过程性。任取 k 个时间点 $t_1, \dots, t_k$,

$$\begin{bmatrix} x(t_1) & x(t_2) & \cdots & x(t_k) \end{bmatrix} = \begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} \cos(\omega t_1) & \cos(\omega t_2) & \cdots & \cos(\omega t_k) \\ \sin(\omega t_1) & \sin(\omega t_2) & \cdots & \sin(\omega t_k) \end{bmatrix}. \quad (1.188)$$

右侧是高斯随机向量 (a, b) 的线性组合, 而高斯随机向量在线性变换下仍为高斯。因此任意有限维采样向量均联合正态, $x(t)$ 是正态过程。

1.1.30 相关时间

定义 1.1.45 (相关时间). 设 $x(t)$ 是 WSS 过程, 自协方差函数为 $C_{xx}(\tau)$ 。相关时间 (correlation time) 定义为

$$\tau_c = \frac{1}{C_{xx}(0)} \int_0^\infty C_{xx}(\tau) d\tau. \quad (1.189)$$

相关时间把整条自协方差曲线压缩成一个标量, 用来比较不同随机过程的相关性延续尺度。若 $x(t)$ 是 a -dependent WSS 过程, 即

$$C_{xx}(\tau) = 0, \quad |\tau| > a, \quad (1.190)$$

则

$$\begin{aligned} |\tau_c| &= \left| \frac{1}{C_{xx}(0)} \int_0^\infty C_{xx}(\tau) d\tau \right| \\ &\leq \frac{1}{C_{xx}(0)} \int_0^\infty |C_{xx}(\tau)| d\tau \\ &= \frac{1}{C_{xx}(0)} \int_0^a |C_{xx}(\tau)| d\tau \leq \int_0^a d\tau = a. \end{aligned} \quad (1.191)$$

其中最后一步使用 $|C_{xx}(\tau)| \leq C_{xx}(0)$ 。因此, 当超过时间差 a 后自协方差已经为零时, 相关时间的绝对值不会超过 a 。它给出一个单一尺度: 相关时间越大, 过程在较长时间间隔上仍保留较强相关; 相关时间越小, 相关性衰减得越快。

1.2 随机输入系统

1.2.1 随机输入系统的基本模型

随机过程进入系统以后, 输入、系统和输出都要放在同一个概率结构中理解。设输入过程为 $\{x(t), t \in I\}$, 并定义在概率空间 $(S, \mathcal{F}, P)$ 上。系统的作用可以写成算子 T : 它读取输入过程在指标集 I 上的一整段取值, 并在时刻 t 给出输出。于是输出过程由

$$y(t, \zeta) = T(\{x(s, \zeta), s \in I\}, t, \zeta), \quad t \in I, \zeta \in S \quad (1.192)$$

定义。式中 ζ 保留了系统本身可能含随机性的情形；若系统不含随机性， T 对 ζ 没有依赖。输出 $y(t)$ 由同一个样本点 ζ 产生，因此输入、系统随机性与输出之间的联合统计关系都回到同一个 $(S, \mathcal{F}, P)$ 上计算。这个共同概率空间是系统分析能够谈论联合事件、条件概率和相关函数的基础。

通常记号会压缩为 $y(t) = T(\{x(s), s \in I\}, t) = T_t(\{x(s), s \in I\})$ 。这里第二个参数或下标 t 表示系统可能随时间改变；第一个参数保留整段输入过程，表示输出可能依赖过去、当前甚至形式上的未来输入。若 T_t 随 t 改变，就是时变系统；若输出还需要过去的输入值，系统就有记忆。

例 1.2.1 (三时刻输入下的因果性与记忆). 设 $I = \{1, 2, 3\}$ ，输入过程为 $\{x(1), x(2), x(3)\}$ 。最一般的系统允许 $y(1), y(2), y(3)$ 都依赖整段输入 $\{x(1), x(2), x(3)\}$ 。在这种写法中， $y(1)$ 可以依赖 $x(2)$ 和 $x(3)$ ，因此它是非因果的。

若指标 t 是严格意义上的时间，较自然的因果系统满足： $y(1)$ 只依赖 $x(1)$ ， $y(2)$ 只依赖 $\{x(1), x(2)\}$ ， $y(3)$ 只依赖 $\{x(1), x(2), x(3)\}$ 。这体现了因果性中的“先有输入，再有输出”。若某个处理单位被人为当成时间指标，例如磁盘位置、存储地址或已经缓冲好的数据序列，形式上的非因果依赖可能只是系统边界划分造成的；把缓冲器纳入系统以后，对真实时间而言仍可解释为因果处理。

系统有记忆时，当前输出依赖过去输入。若进一步要求无记忆，则每个时刻只读取当前输入，即 $y(1) = T(\{x(1)\}, 1)$ 、 $y(2) = T(\{x(2)\}, 2)$ 、 $y(3) = T(\{x(3)\}, 3)$ 。若同一个映射在各时刻都相同，还可把时间参数去掉，写成 $y(t) = T(x(t))$ 。

1.2.2 确定性系统与随机系统

定义 1.2.2 (确定性系统与随机系统). 系统称为确定性系统 (deterministic system)，如果 $T_t(x_I, \zeta) = T_t(x_I)$ ，即系统算子只依赖输入轨迹 x_I 与时刻 t ，与样本点 ζ 无关。系统称为随机系统 (stochastic system)，如果存在 $\zeta_1 \neq \zeta_2$ ，使得 $T_t(x_I, \zeta_1) \neq T_t(x_I, \zeta_2)$ 。

确定性系统中的“确定性”可以用退化随机变量来理解。若随机变量 $z: S \rightarrow \mathbb{R}$ 对所有 $\zeta \in S$ 都取同一个常数 z_0 , 即 $z(\zeta) = z_0$, 则 $\Pr[z = z_0] = 1$ 。这时虽然 z 形式上仍定义在概率空间上, 但观察端只会看到一个数值。多数经典随机输入系统先研究确定性系统, 因为系统算子本身不再引入额外随机性; 衰落信道等问题则需要把系统状态也视为随机对象, 因此必须允许 T 依赖 ζ 。

这里的等号和不等号是在实数端比较。样本空间中的元素可以是抽象符号, 尚未赋予加减、排序或距离; 只有经过随机变量或系统映射到实数以后, 才能谈论相等、大小和数值运算。

1.2.3 无记忆系统

定义 1.2.3 (无记忆系统). 系统称为无记忆系统 (memoryless system), 如果当前输出的统计行为只由当前输入决定。记号上可写为 $T_t(x_I, \zeta) = T(x, \zeta)$, 即不需要过去或未来的输入值, 也不需要保留时间下标来指定不同的统计映射。常用写法为 $y(t) = T(x(t))$ 。

无记忆的关键在“当前输出只依赖当前输入的统计描述”。若还需要知道当前是第几个时刻, 才能确定从 $x(t)$ 到 $y(t)$ 的条件分布, 那么系统仍带有时间依赖。因而严格意义上的无记忆系统通常对应一个与时间无关的转移概率

$$P_{y|x}(y|x) = \Pr[T(x) = y]. \quad (1.193)$$

这也是通信中离散无记忆信道的基本记号。

例 1.2.4 (离散样本空间上的无记忆映射). 令样本空间为 $S = \{\oplus, \ominus, \otimes, \oslash\}$, 事件域为 $\mathcal{F} = 2^S$ 。四个样本点的概率依次为 0.1, 0.2, 0.3, 0.4。在某一固定时刻 t , 输入随机变量定义为 $x(t, \oplus) = x(t, \ominus) = 1$, $x(t, \otimes) = x(t, \oslash) = -1$ 。无记忆系统 T 在这些样本点上的取值为 $T(1, \oplus) = 1$, $T(1, \ominus) = -1$, $T(-1, \otimes) = 1$, $T(-1, \oslash) = -1$ 。于是输出由 $y(t, \zeta) = T(x(t, \zeta), \zeta)$ 自动给出: $y(t, \oplus) = 1$, $y(t, \ominus) = -1$, $y(t, \otimes) = 1$, $y(t, \oslash) = -1$ 。

这说明随机过程和系统都只是映射；一旦输入映射、系统映射和样本点概率给定，输出过程的统计性质随之确定。例如在已知输入为 1 的条件下，输出为 1 的概率为

$$\Pr[T(1) = 1] = \Pr[y(t) = 1 \mid x(t) = 1] = \frac{P(\{\oplus\})}{P(\{\oplus, \ominus\})} = \frac{0.1}{0.1 + 0.2} = \frac{1}{3}. \quad (1.194)$$

同理， $\Pr[T(1) = -1] = 2/3$ ， $\Pr[T(-1) = 1] = 3/7$ ， $\Pr[T(-1) = -1] = 4/7$ 。所有条件概率都回到同一个概率空间中取事件并计算概率。若考试或建模中要求构造例子，只要把样本空间、概率、输入映射和系统映射定义清楚，输出就已经定义完成。

无记忆系统还可以检验输入与系统映射之间的独立性。沿用上例， $\Pr[x(t) = 1, T(1) = 1] = P(\{\oplus, \ominus\} \cap \{\oplus\}) = 0.1$ ，而 $\Pr[x(t) = 1] \Pr[T(1) = 1] = P(\{\oplus, \ominus\}) \cdot (1/3) = 0.1$ 。其他三种组合也有相同的乘积分解： $\Pr[x(t) = 1, T(1) = -1] = 0.2$ ， $\Pr[x(t) = -1, T(-1) = 1] = 0.3$ ， $\Pr[x(t) = -1, T(-1) = -1] = 0.4$ 。这里的独立性需要通过共同概率空间中的事件相交与概率乘积来确认。

加性噪声系统 离散时间加性系统 $y(n) = x(n) + z(n)$ 只有在噪声序列 $\{z(n)\}$ 的统计分布不随 n 改变，并且各时刻噪声相互独立时，才能作为严格意义上的无记忆系统。仅有 $z(i)$ 与 $z(j)$ 独立还不够；若 $z(i)$ 和 $z(j)$ 的分布不同，判断 $x(n)$ 到 $y(n)$ 的统计映射仍需要知道时间 n ，因此保留了时间索引。对严格无记忆的加性系统，有 $\Pr[T(x) = y] = P_{y|x}(y|x) = P_z(y - x)$ 。这也是批注中强调“输出只跟当前输入有关、还需要忘记时间”的原因。

1.2.4 无记忆系统与平稳性

命题 1.2.5 (无记忆系统保持严格平稳性). 若无记忆系统的输入过程 $x(t)$ 是严格平稳的，则输出过程 $y(t)$ 也是严格平稳的。

证明. 严格平稳性要比较时间平移前后的事件概率。对任意时间平移 c 和任意 Borel 集 $A \subset \mathbb{R}$ ，考虑事件概率 $P\{\zeta \in S : y(t + c, \zeta) \in A\}$ 。由

$y(t, \zeta) = T(x(t, \zeta), \zeta)$, 它可以改写为

$$\begin{aligned} P\{\zeta \in S : y(t+c, \zeta) \in A\} &= P\{\zeta \in S : T(x(t+c, \zeta), \zeta) \in A\} \\ &= P\{\zeta \in S : x(t+c, \zeta) \in B\}, \end{aligned} \quad (1.195)$$

其中 $B \triangleq \{x \in \mathbb{R} : T(x, \zeta) \in A\}$ 。由于 $x(t)$ 严格平稳,

$$\begin{aligned} P\{\zeta \in S : x(t+c, \zeta) \in B\} &= P\{\zeta \in S : x(t, \zeta) \in B\} \\ &= P\{\zeta \in S : T(x(t, \zeta), \zeta) \in A\} \\ &= P\{\zeta \in S : y(t, \zeta) \in A\}. \end{aligned} \quad (1.196)$$

对任意 c 与任意 A 都成立, 因此输出过程严格平稳。 $\square$

这个证明的核心是: 平稳性比较的是映射后事件的概率, 不要求 $x(t+c, \zeta)$ 与 $x(t, \zeta)$ 对每个样本点逐点相等。只要所有 Borel 集上的概率不随时间平移改变, 严格平稳性就成立。无记忆条件保证了时间平移前后使用同一个当前输入映射, 因而可以把输出事件等价转成输入事件。

若系统有记忆或时变, 上述证明的关键步骤会失效。此时可能出现 $B_t = \{x \in \mathbb{R} : T_t(x, \zeta) \in A\}$ 与 $B_{t+c} = \{x \in \mathbb{R} : T_{t+c}(x, \zeta) \in A\}$ 不相等。输入平稳性只能保证同一个集合 B 上的概率平移不变, 无法保证两个不同集合 B_t 与 B_{t+c} 上的概率相同。因此若输入严格平稳而输出不平稳, 系统中一定有某种时间依赖、记忆或额外非平稳随机机制。

命题 1.2.6 (无记忆系统下的若干平稳性结论). 对无记忆系统, 有以下结论:

1. 若输入 $x(t)$ 为 n 阶平稳, 则输出 $y(t)$ 也是 n 阶平稳;
2. 若输入 $x(t)$ 在某个区间内平稳, 则输出 $y(t)$ 在同一区间内平稳;
3. 若输入 $x(t)$ 只是宽平稳, 则输出 $y(t)$ 未必宽平稳。

前两条是严格平稳性证明在有限维分布或限定区间上的直接变形。第三条指出宽平稳只控制均值和自相关, 而一般无记忆系统可以是非线性的;

非线性会把二阶统计量推到四阶甚至更高阶统计量上，宽平稳输入因此不足以保证宽平稳输出。

例 1.2.7 (平方律检波器给出的反例). 令 $y(t) = x^2(t)$, 其中 $x(t) = a \cos(\omega t) + b \sin(\omega t)$, a, b 独立、零均值且具有相同统计特性。映射 $x \mapsto x^2$ 是无记忆系统。若 $x(t)$ 满足宽平稳条件, 仍有

$$\begin{aligned} E[y(t_1)y(t_2)] &= E\left[\left(a \cos(\omega t_1) + b \sin(\omega t_1)\right)^2 \left(a \cos(\omega t_2) + b \sin(\omega t_2)\right)^2\right] \\ &= \frac{E[a^4] + E^2[a^2]}{2} + \frac{E[a^4] - E^2[a^2]}{2} \cos(2\omega t_1) \cos(2\omega t_2) \\ &\quad + E^2[a^2] \sin(2\omega t_1) \sin(2\omega t_2). \end{aligned} \quad (1.197)$$

式 (1.197) 一般依赖 t_1 和 t_2 的绝对位置, 因而输出不一定宽平稳。只有当 $E[a^4] = 3E^2[a^2]$ 时, 上式才化为只依赖时间差的形式。这个例子说明, 宽平稳输入经过无记忆非线性系统后, 输出宽平稳性需要额外分布条件; 线性系统受到重视, 一个重要原因正是它能更稳定地保持二阶结构。

1.2.5 硬限幅器与反正弦律

例 1.2.8 (反正弦律: 硬限幅器). 定义硬限幅器 (hard limiter) 输出为

$$y(t) = \begin{cases} +1, & x(t) > 0, \\ -1, & x(t) < 0, \end{cases} \quad (1.198)$$

其中 $x(t)$ 是零均值高斯平稳过程。通信接收端常把带噪观测信号送入比较器, 大于零判为 +1, 小于零判为 -1; 硬限幅器正是这种判决模型的理想化形式。

由于 $x(t)$ 零均值且高斯分布关于零对称, $y(t)$ 取 +1 与 -1 的概率相同, 因此 $E[y(t)] = 0$ 。自相关函数只需判断两个时刻的符号是否相同: 若 $x(t_1)x(t_2) > 0$, 则 $y(t_1)y(t_2) = +1$; 若 $x(t_1)x(t_2) < 0$, 则 $y(t_1)y(t_2) = -1$ 。

因为 $x(t)$ 是高斯过程, 二维样本 $(x(t_1), x(t_2))$ 联合正态。其协方差矩阵为

$$\Sigma = \begin{bmatrix} R_{xx}(0) & R_{xx}(t_1 - t_2) \\ R_{xx}(t_2 - t_1) & R_{xx}(0) \end{bmatrix} = R_{xx}(0) \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}, \quad \rho = \frac{R_{xx}(t_1 - t_2)}{R_{xx}(0)}. \quad (1.199)$$

符号相同的概率等于第一、第三象限概率之和。由二维高斯积分可得

$$\Pr[x(t_1)x(t_2) > 0] = \frac{1}{2} + \frac{1}{\pi} \arcsin(\rho). \quad (1.200)$$

于是

$$\begin{aligned} R_{yy}(t_1, t_2) &= E[y(t_1)y(t_2)] \\ &= \Pr[x(t_1)x(t_2) > 0] - \Pr[x(t_1)x(t_2) < 0] \\ &= \frac{2}{\pi} \arcsin(\rho) = \frac{2}{\pi} \arcsin\left(\frac{R_{xx}(t_1 - t_2)}{R_{xx}(0)}\right). \end{aligned} \quad (1.201)$$

这就是硬限幅器的反正弦律 (arcsine law)。输入相关系数 ρ 经过非线性函数 $\frac{2}{\pi} \arcsin(\rho)$ 变成输出相关函数; 当 ρ 很小时, $\arcsin(\rho)$ 近似为 ρ , 硬限幅器在相关性上近似线性; 当 ρ 较大时, 反正弦函数的弯曲使输出相关明显偏离线性关系。

式 (1.200) 的积分推导可通过变量代换得到。将二维高斯密度写出并只积分第一象限, 再乘以 2:

$$\begin{aligned} \Pr[x(t_1)x(t_2) > 0] &= 2 \int_0^\infty \int_0^\infty \frac{1}{2\pi(1-\rho^2)^{1/2}R_{xx}(0)} \\ &\quad \times \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)R_{xx}(0)}\right) dx dy. \end{aligned} \quad (1.202)$$

令 $x = r \cos \theta \sqrt{1-\rho^2}$ 、 $y = r \sin \theta \sqrt{1-\rho^2}$, 再用 $u = \tan \theta$, 积分最终化为反正弦函数。推导细节主要服务于验证式 (1.200); 在系统分析中, 更重要的是记住硬限幅把高斯输入的相关系数通过反正弦律映射为输出相关。

1.2.6 Bussgang 定理

上一部分的硬限幅器说明，零均值高斯输入经过无记忆非线性系统后，输出自相关函数通常是输入自相关函数的非线性函数。例如反正弦律给出 $R_{yy}(\tau) = \frac{2}{\pi} \arcsin(R_{xx}(\tau)/R_{xx}(0))$ 。Bussgang 定理考察另一个统计量：输入 $x(t)$ 与输出 $y(t)$ 之间的互相关。此时可以得到一个对任意无记忆映射都成立的线性比例关系。

定理 1.2.9 (Bussgang 定理). 设 $x(t)$ 是平稳、零均值高斯过程，经过无记忆系统 T 后得到 $y(t) = T(x(t))$ 。记系统在给定输入值时的平均输出为 $g(x) = E[T(x)]$ ，则输入与输出的互相关函数满足

$$R_{xy}(\tau) = R_{xx}(\tau) \frac{E[x(t)g(x(t))]}{R_{xx}(0)}. \quad (1.203)$$

因此， $R_{xy}(\tau)$ 与 $R_{xx}(\tau)$ 成正比，比例常数由输入的边缘分布和系统映射共同决定，与时差 τ 无关。

这里允许 T 本身带有随机性。对确定性系统有 $g(x) = T(x)$ ；对随机系统，先对系统随机性取条件平均，得到确定的平均映射 $g(x) = E[y(t) | x(t) = x]$ 。定理要求输入为高斯过程，并利用无记忆条件将 $y(t_2)$ 的条件分布归结为当前输入 $x(t_2)$ 。

证明. 令 $x_1 = x(t_1)$ 、 $x_2 = x(t_2)$ ，并设 $R_0 = R_{xx}(0)$ 、 $\rho = R_{xx}(t_1 - t_2)/R_0$ 。向量 $(x_1, x_2)^T$ 为零均值联合高斯向量，其协方差矩阵为 $R_0 \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$ ，所以条件均值为 $E[x_1 | x_2] = \rho x_2$ 。利用迭代期望，

$$\begin{aligned} R_{xy}(t_1, t_2) &= E[x_1 T(x_2)] = E[x_1 g(x_2)] \\ &= E[g(x_2) E[x_1 | x_2]] = \rho E[x_2 g(x_2)] \\ &= R_{xx}(t_1 - t_2) \frac{E[x(t)g(x(t))]}{R_{xx}(0)}. \end{aligned} \quad (1.204)$$

平稳性使右端只依赖 $t_1 - t_2$ ，于是得到式 (1.203)。□

证明中真正使用的高斯性质是条件均值 $E[x_1 | x_2] = \rho x_2$ 。这一步把原本可能很复杂的非线性映射 $g(x_2)$ 与 x_1 的关系压缩成常数 ρ ，剩余期望 $E[x_2 g(x_2)]$ 只决定比例系数。由此立刻得到：若 $R_{xx}(\tau) = 0$ ，则 $R_{xy}(\tau) = 0$ ；若两个时刻的高斯输入相互独立，它们也互不相关，因而相应的输入-输出互相关为零。输入自相关较小时，互相关也按同一比例减小。

上一部分离散样本空间的无记忆系统可用来说明平均映射 g 的计算。由 $P(y = 1 | x = 1) = 1/3$ 、 $P(y = -1 | x = 1) = 2/3$ ，有 $g(1) = 1 \cdot \frac{1}{3} + (-1) \cdot \frac{2}{3} = -\frac{1}{3}$ ；同理，由 $P(y = 1 | x = -1) = 3/7$ 、 $P(y = -1 | x = -1) = 4/7$ ，有 $g(-1) = -\frac{1}{7}$ 。因此，即使系统映射带随机性， $g(x)$ 仍可由条件分布直接求得。

例 1.2.10 (硬限幅器的输入-输出互相关). 对于确定性硬限幅器，取 $g(x) = 1$ ($x \geq 0$) 以及 $g(x) = -1$ ($x < 0$)。于是 $xg(x) = |x|$ 。若 $x(t) \sim \mathcal{N}(0, R_{xx}(0))$ ，则 $E|x(t)| = \sqrt{2R_{xx}(0)/\pi}$ ，代入 Bussgang 定理得到

$$R_{xy}(\tau) = R_{xx}(\tau) \sqrt{\frac{2}{\pi R_{xx}(0)}}. \quad (1.205)$$

硬限幅器的输出自相关遵循反正弦律，输入-输出互相关却保持严格的正比关系。这两个结论对应不同的统计量。

例 1.2.11 (限幅器的 Bussgang 系数). 通信系统常用限幅器 (limiter 或 clipper) 约束信号幅度。给定门限 $c > 0$ ，其映射为

$$g(x) = x \mathbf{1}_{\{|x| \leq c\}} + c \mathbf{1}_{\{x > c\}} - c \mathbf{1}_{\{x < -c\}}. \quad (1.206)$$

区间 $[-c, c]$ 内保留原输入，超过门限的部分分别截为 c 与 $-c$ 。这类处理可限制通信信号的峰值，避免过大幅度进入后续系统。

对零均值高斯输入直接积分可得 $E[x(t)g(x(t))] = R_{xx}(0) \operatorname{erf}(c/\sqrt{2R_{xx}(0)})$ ，所以

$$R_{xy}(\tau) = R_{xx}(\tau) \operatorname{erf}\left(\frac{c}{\sqrt{2R_{xx}(0)}}\right) = R_{xx}(\tau) \left[2\Phi\left(\frac{c}{\sqrt{R_{xx}(0)}}\right) - 1 \right], \quad (1.207)$$

其中 Φ 为标准正态分布函数。门限 c 改变的是比例系数，也就是 $R_{xy}(\tau)$ 关于 $R_{xx}(\tau)$ 的斜率。门限趋于无穷大时，限幅器趋近恒等映射，比例系数趋于 1；门限减小时，截幅更强，比例系数随之减小。

Bussgang 系数的导数形式 将式 (1.203) 中的比例系数记为 $K = E[xg(x)]/R_{xx}(0)$ 。若 $g'(x)$ 存在，并且 $g(x) \exp[-x^2/(2R_{xx}(0))]$ 在 $x \rightarrow \pm\infty$ 时具有有限极限，分部积分给出

$$K = \frac{E[x(t)g(x(t))]}{R_{xx}(0)} = E[g'(x(t))]. \quad (1.208)$$

导数形式计算较快，同时附带可微性与边界条件。原始期望形式对不可微映射更直接，也更一般。

在工程广义函数记号下，硬限幅器可写成 $g'(x) = 2\delta(x)$ ，从而 $E[g'(x(t))] = \sqrt{2/[\pi R_{xx}(0)]}$ ，与例中的结果一致。对门限为 c 的限幅器，斜率在 $(-c, c)$ 内为 1，区间外为 0，故 $g'(x) = \mathbf{1}_{\{-c < x < c\}}$ ，并有 $E[g'(x(t))] = 2\Phi(c/\sqrt{R_{xx}(0)}) - 1$ 。课本在此特例给出的常数未采用这一导数，计算时应以上式为准。

1.2.7 线性系统与卷积表示

定义 1.2.12 (线性系统) 若任意输入过程 $x_1, \dots, x_m$ 及权重 $a_1, \dots, a_m$ 满足

$$T\left(\sum_{i=1}^m a_i x_i\right) = \sum_{i=1}^m a_i T(x_i), \quad (1.209)$$

则称 T 为线性系统。权重 a_i 可以是随机变量。该条件同时包含可加性与齐次性，也称叠加原理。

例如，输入 A 、 C 分别产生输出 B 、 D 时，输入 $0.8A + 0.2C$ 必须产生输出 $0.8B + 0.2D$ 。令所有输入为零还可得到 $T(0) = 0$ ，所以线性映射通过原点。线性系统的重要性还体现在二阶统计量上：对宽平稳输入，线性时不变系统在有关积分存在的条件下产生宽平稳输出。

引理 1.2.13 (可微可加映射的形式). 设一阶可微函数 f 对任意向量 $\mathbf{x}$ 与 $\mathbf{u}$ 满足 $f(\mathbf{x}) + f(\mathbf{u}) = f(\mathbf{x} + \mathbf{u})$, 则

$$f(\mathbf{x}) = \sum_i \left. \frac{\partial f(\mathbf{x})}{\partial x_i} \right|_{\mathbf{x}=\mathbf{0}} x_i. \quad (1.210)$$

证明. 固定第 i 个坐标, 由偏导数定义及可加性,

$$\begin{aligned} \frac{\partial f(\mathbf{x})}{\partial x_i} &= \lim_{\delta \rightarrow 0} \frac{f(\mathbf{x} + \delta \mathbf{e}_i) - f(\mathbf{x})}{\delta} \\ &= \lim_{\delta \rightarrow 0} \frac{f(\delta \mathbf{e}_i)}{\delta}. \end{aligned} \quad (1.211)$$

右端与 $\mathbf{x}$ 无关, 因此 f 对每个坐标的偏导数均为常数, f 具有仿射形式 $f(\mathbf{x}) = \sum_i c_i x_i + C$. 再由 $f(\mathbf{0}) + f(\mathbf{0}) = f(\mathbf{0})$ 得 $C = 0$, 且 c_i 正是原点处的第 i 个偏导数。□

这个引理把卷积系数解释成输入-输出映射对各输入分量的偏导数。可微性在这里是关键前提; 映射缺少相应导数时, 线性仍可能成立, 卷积形式则需要另行讨论。

离散时间系统 先看只依赖当前输入与前一时刻输入的确定性、时变线性系统 $y(t) = T_t(x(t), x(t-1))$ 。由引理, 输出可写为 $y(t) = h(0;t)x(t) + h(1;t)x(t-1)$, 其中 $h(0;t)$ 与 $h(1;t)$ 分别是 T_t 在零输入处对两个分量的偏导数。一般离散时间线性系统写成

$$y(t) = \sum_{n=-\infty}^{\infty} h(n;t)x(t-n). \quad (1.212)$$

这里 n 标记输入相对当前时刻的位移, 分号后的 t 表示系数可随观察时刻改变。若 $n < 0$ 的项存在, 输出会用到未来输入, 系统不具因果性; 若只保留 $n \geq 0$, 则为因果系统。系统映射带随机性时, 偏导数 $h(n;t)$ 也可以是随机变量。

连续时间系统与冲激响应 连续时间情形由求和推广为积分:

$$y(t) = \int_{-\infty}^{\infty} h(\tau; t) x(t - \tau) d\tau. \quad (1.213)$$

通常假定 $h(\tau; t)$ 与输入过程 $x(t)$ 独立。若二者相关, 输入的统计分布会影响系统映射的条件统计量, 分析时必须保留这种联合关系。

系数 h 可以通过冲激输入测量。若输入 $x(t) = \delta(t - s)$, 利用抽取性质可得输出 $y(t) = h(t - s; t)$, 因此 $h(t - s; t)$ 称为系统对位于 s 的单位冲激所产生的冲激响应 (impulse response)。从映射观点看, 冲激响应就是线性映射对相应输入时刻的偏导系数。

卷积名称可从 $x(t - \tau)$ 的形状理解。固定 $t = 0$ 时出现 $x(-\tau)$, 它相当于把 $x(\tau)$ 关于纵轴翻转; 随后改变 t , 再让翻转后的函数平移并与 $h(\tau; t)$ 相乘积分。

1.2.8 时不变系统

定义 1.2.14 (时不变系统). 若系统映射不随绝对时间改变, 即 $T_t(x_I, \zeta) = T(x_I, \zeta)$, 则称系统为时不变系统 (time-invariant system)。等价地, 输入平移 s 后, 输出也平移相同的 s 。

对线性时不变系统, $h(\tau; t)$ 简化为只依赖时差的 $h(\tau)$ 。若输入 $x(t)$ 产生输出 $y(t)$, 则输入 $x(t - s)$ 产生 $y(t - s)$, 并有标准卷积关系

$$y(t) = \int_{-\infty}^{\infty} h(\tau) x(t - \tau) d\tau. \quad (1.214)$$

令输入为原点处的单位冲激 $x(t) = \delta(t)$, 输出即为 $h(t)$ 。因此, 向系统送入冲激并观测响应, 可以直接取得描述该线性时不变系统的卷积核。

引理 1.2.15 (线性时不变系统保持严格平稳性). 若输入 $x(t)$ 严格平稳, 且线性时不变系统的卷积积分存在, 则输出 $y(t)$ 也严格平稳。

其理由是任意共同时间平移只会把卷积中的输入样本整体平移, 所用核函数 $h(\tau)$ 保持不变; 严格平稳性保证平移前后的任意有限维输入分布相同, 经同一线性映射后, 输出的有限维分布也相同。

1.2.9 卷积表示的限制

前面的卷积化过程要求输入-输出映射具备相应的一阶导数。线性性质本身只规定叠加关系，因此仍存在线性、时不变却无法在当前普通函数框架中取得合法冲激响应的系统。

例 1.2.16 (微分器). 考虑微分系统

$$y(t) = \frac{dx(t)}{dt} = x'(t). \quad (1.215)$$

因为 $ax_1'(t) + bx_2'(t) = [ax_1(t) + bx_2(t)]'$ ，该系统满足线性叠加；输入发生时间平移时，导数也发生相同平移，所以系统同时具有时不变性。

若要按普通卷积形式确定冲激响应，需要向系统输入 $x(t) = \delta(t)$ 并计算 $d\delta(t)/dt$ 。在本课程当前采用的 Dirac delta 初等定义下，这个导数没有定义，因而无法得到合法的普通函数冲激响应。这个例子说明卷积形式足以产生线性系统，线性系统要获得上述普通卷积表示还需额外的正则性条件。

1.2.10 Dirac delta 函数

定义 1.2.17 (Dirac delta 函数及抽取性质). Dirac delta 函数 $\delta(t)$ 是一种理想化工具，形式上满足 $\delta(t) = \delta(-t)$ 、 $t \neq 0$ 时 $\delta(t) = 0$ ，并规定其全轴积分为 1。它的核心运算由抽取性质 (replication property) 定义：若 g 在 t 处连续，则

$$g(t) = \int_{-\infty}^{\infty} g(\tau)\delta(t - \tau) d\tau = \int_{-\infty}^{\infty} g(\tau)\delta(\tau - t) d\tau. \quad (1.216)$$

把 $\delta(0)$ 口头描述为“无穷大”只能帮助形成冲激的图像直觉，不能把无穷大当作普通实数参加等式消元。例如，从逐点图像看， $\delta(t)$ 与 $2\delta(t)$ 在 $t \neq 0$ 处都为零，在 $t = 0$ 处都被描述为无穷大；然而二者全轴积分分别为 1 与 2。因此，乘在 $\delta(t)$ 前的常数不可省略，“无穷大等于无穷大”也不能作为严谨的推导步骤。类似地， $x + a = y + a$ 在有限 a 下可推出 $x = y$ ，当 a 被写成无穷大时，这种消元已经失去依据。

抽取性质还要求被抽取的函数在冲激位置连续。若 g 在 t 处不连续, 本课程采用的定义不为该积分指定数值; 直接代入某一侧的函数值会引入歧义。这一限制在用 delta 函数表示硬限幅器导数时尤其重要。

例 1.2.18 (由 delta 积分表示硬限幅器). 定义

$$f(x) = \int_{-\infty}^x 2\delta(\tau) d\tau = \int_{-\infty}^{\infty} 2\mathbf{1}_{\{\tau < x\}} \delta(\tau) d\tau. \quad (1.217)$$

当 $x > 0$ 时, 指示函数在 $\tau = 0$ 附近取 1, 所以 $f(x) = 2$; 当 $x < 0$ 时取 0, 所以 $f(x) = 0$ 。在 $x = 0$ 处, $2\mathbf{1}_{\{\tau < x\}}$ 恰好于冲激位置不连续, 抽取性质不给出数值。于是对 $x \neq 0$ 有 $f(x) = g_{\text{HL}}(x) + 1$, 其中 g_{HL} 是取值 ± 1 的硬限幅器; 在 $x = 0$ 处仍需保留未定义状态。

Dirac delta 的工程意义集中在积分抽取。处理不连续点、普通微分或广义导数时, 需核对连续性条件; 含广义导数时, 微积分基本定理未必在每个点成立。

1.2.11 时变线性系统与模拟调制器

时变系统的映射会随观察时刻改变。在通信系统中, 调制与多普勒频移都具有这种时间变化: 信号乘上随时间旋转的复指数后, 频谱整体发生平移。考虑冲激响应 $h(\tau; t) = \delta(\tau)e^{j\omega_0 t}$ 。若输入在冲激位置连续, 利用 Dirac delta 的抽取性质可得

$$y(t) = \int_{-\infty}^{\infty} \delta(\tau)e^{j\omega_0 t} x(t - \tau) d\tau = x(t)e^{j\omega_0 t}. \quad (1.218)$$

该系统满足叠加原理, 因而具有线性。它同时随时间变化: 延迟输入 $x(t - s)$ 产生 $x(t - s)e^{j\omega_0 t}$, 原输出延迟 s 后则为 $y(t - s) = x(t - s)e^{j\omega_0(t-s)}$, 二者相差因子 $e^{j\omega_0 s}$ 。输入到达系统的时刻改变时, 载波相位也随之改变。

为了强调时变卷积中两个变量的不同角色, 采用记号

$$h(\tau; t) * x(t) \triangleq \int_{-\infty}^{\infty} h(\tau; t)x(t - \tau) d\tau. \quad (1.219)$$

其中 τ 是积分变量, t 是输出的观察时刻; 分号用于区分这两种角色。 $h(\tau; t)$ 是系统施加在各个延迟输入上的权重, $x(t - \tau)$ 是被加权并累加的输入。对时不变系统, h 与 t 无关, 常写成 $h(\tau) * x(t) = h(t) * x(t)$ 。此时卷积具有交换性; 推广到时变系统后, h 与 x 的系统角色需要保持清楚, 式 (1.219) 中的写法也更便于追踪时间参数。

1.2.12 线性系统中矩函数的传播

线性系统受到重视, 一个直接原因是输出的低阶矩可以由输入的低阶矩封闭地计算。无记忆映射能够保持严格平稳性; 宽平稳输入经过一般非线性无记忆映射后, 输出仍可能失去宽平稳性。线性条件使均值和二阶矩只需通过同一个系统核逐次传播。对确定性线性时不变系统, 这一结构进一步保证宽平稳输入产生宽平稳输出; 对随机或时变系统, 还需由核函数的统计特性判断输出是否只依赖时间差。

记输入、输出的均值函数为 $\eta_x(t) = E[x(t)]$ 、 $\eta_y(t) = E[y(t)]$, 并采用复随机过程的相关函数约定 $R_{xy}(t_1, t_2) = E[x(t_1)y^*(t_2)]$ 。以下结论把均值传播称为基本定理, 把相关函数传播称为定理 9-2。

定理 1.2.19 (线性系统的均值与相关函数传播). 设线性系统具有卷积表示 $y(t) = \int h(\tau; t)x(t - \tau) d\tau$, 系统核 h 与输入 x 独立, 并且期望与积分可以交换。则输出均值为

$$\eta_y(t) = \int_{-\infty}^{\infty} E[h(\tau; t)]\eta_x(t - \tau) d\tau. \quad (1.220)$$

输入-输出互相关与输出自相关分别为

$$R_{xy}(t_1, t_2) = \int_{-\infty}^{\infty} E[h^*(s; t_2)]R_{xx}(t_1, t_2 - s) ds, \quad (1.221)$$

$$R_{yy}(t_1, t_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} E[h(\tau; t_1)h^*(s; t_2)]R_{xx}(t_1 - \tau, t_2 - s) d\tau ds. \quad (1.222)$$

式 (1.220) 表明均值函数通过系统一次。式 (1.221) 只在第二个时间变量上通过一次共轭系统核, 因为相关函数定义中的输出 $y(t_2)$ 带复共轭。

式 (1.222) 分别在 t_2 与 t_1 上各通过一次系统, 因此二阶矩需要两次滤波。系统核带随机性时, 均值传播使用 $E[h]$, 输出自相关则使用核的二阶矩 $E[h(\tau; t_1)h^*(s; t_2)]$; 这正是衰落信道随机性进入输出二阶统计量的位置。

证明. 对均值直接交换期望与积分, 并利用 h 与 x 的独立性, 即得到式 (1.220)。对互相关,

$$\begin{aligned} R_{xy}(t_1, t_2) &= E \left[x(t_1) \int_{-\infty}^{\infty} h^*(s; t_2) x^*(t_2 - s) ds \right] \\ &= \int_{-\infty}^{\infty} E[h^*(s; t_2)] E[x(t_1) x^*(t_2 - s)] ds, \end{aligned} \quad (1.223)$$

于是得到式 (1.221)。将 $y(t_1)$ 与 $y^*(t_2)$ 的两个卷积同时代入, 交换两重积分与期望, 并再次分离系统核和输入的统计量, 即得到式 (1.222)。□

框图表明: η_x 经 h 一次得到 η_y ; R_{xx} 在 t_2 经 h^* 得到 R_{xy} , 再在 t_1 经 h 得到 R_{yy} 。

[协方差函数的传播] 在上述条件下, 将相关函数换成协方差函数后结论保持相同:

$$C_{xy}(t_1, t_2) = \int_{-\infty}^{\infty} E[h^*(s; t_2)] C_{xx}(t_1, t_2 - s) ds, \quad (1.224)$$

$$C_{yy}(t_1, t_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} E[h(\tau; t_1) h^*(s; t_2)] C_{xx}(t_1 - \tau, t_2 - s) d\tau ds. \quad (1.225)$$

相关函数在时域中表现为卷积, 形状往往不易直接判断。进入频域后, 卷积转化为乘法, 输入频谱与系统频率响应的重叠、抑制和频移会更加直观。后续功率谱分析将把上述时域传播关系改写成频域形式。

缺少普通卷积形式的线性系统 上述证明使用卷积表示, 但均值、相关函数和协方差函数的传播规律还可以延伸到缺少普通函数冲激响应的线性系统。以微分器为例, 可先用

$$h_\varepsilon(\tau) = \frac{\delta(\tau + \varepsilon) - \delta(\tau)}{\varepsilon}, \quad \varepsilon \downarrow 0, \quad (1.226)$$

构造一族可放入卷积积分的核，再对相应的均值和相关函数公式取极限。这样可以避免直接给 $\delta'(t)$ 指定普通函数意义，同时保留微分系统对统计量的作用。

1.2.13 微分器

定义 1.2.20 (微分器). 微分器 (differentiator) 是输出等于输入导数的确定性线性时不变系统，即 $y(t) = x'(t)$ 。

微分算子作用在输出对应的时间变量上。由均值与相关函数传播定理，

$$\eta_y(t) = \frac{d\eta_x(t)}{dt}, \quad (1.227)$$

$$R_{xy}(t_1, t_2) = \frac{\partial R_{xx}(t_1, t_2)}{\partial t_2}, \quad R_{yy}(t_1, t_2) = \frac{\partial^2 R_{xx}(t_1, t_2)}{\partial t_1 \partial t_2}. \quad (1.228)$$

第一式只通过一次微分器。互相关中的输出位于第二个位置，所以对 t_2 求导；输出自相关的两个位置都经过微分器，所以分别对 t_1 、 t_2 求导。协方差满足同样的关系： $C_{xy} = \partial C_{xx} / \partial t_2$ ， $C_{yy} = \partial^2 C_{xx} / (\partial t_1 \partial t_2)$ 。

例 1.2.21 (泊松计数过程经过微分器). 设输入 $x(t) = N(t)$ 是速率为 λ 的 Poisson 计数过程。每次到达使样本路径增加 1，因此广义微分后的输出是 Poisson 脉冲列

$$y(t) = \sum_i \delta(t - t_i), \quad (1.229)$$

其中 t_i 为各次到达时刻。已知 $\eta_x(t) = \lambda t$ ，故 $\eta_y(t) = \lambda$ 。又因为 $R_{xx}(t_1, t_2) = \lambda \min(t_1, t_2) + \lambda^2 t_1 t_2$ ，对两个时间变量分别求导得到

$$R_{yy}(t_1, t_2) = \lambda \delta(t_1 - t_2) + \lambda^2, \quad C_{yy}(t_1, t_2) = \lambda \delta(t_1 - t_2). \quad (1.230)$$

λ^2 来自不同到达事件的平均乘积， $\lambda \delta(t_1 - t_2)$ 则表示同一次到达在两个相同观察时刻产生的脉冲贡献。

1.2.14 随机激励下的微分方程

定义 1.2.22 (随机激励下的确定性微分方程). 设随机输入为 $x(t)$, 由

$$a_n y^{(n)}(t) + a_{n-1} y^{(n-1)}(t) + \cdots + a_0 y(t) = x(t) \quad (1.231)$$

确定输出 $y(t)$ 。在零初始条件下, 解唯一, 并可视为确定性线性时不变系统对输入 $x(t)$ 的响应。

线性微分算子首先作用于输出均值, 因此

$$a_n \eta_y^{(n)}(t) + a_{n-1} \eta_y^{(n-1)}(t) + \cdots + a_0 \eta_y(t) = \eta_x(t). \quad (1.232)$$

其初始条件为 $\eta_y(0) = \eta_y'(0) = \cdots = \eta_y^{(n-1)}(0) = 0$ 。求输出统计量由此转化为求解一个以 $\eta_x(t)$ 为激励的普通微分方程。

对互相关, 输出出现在第二个位置, 故同一微分算子作用于 t_2 :

$$a_n \frac{\partial^n R_{xy}(t_1, t_2)}{\partial t_2^n} + \cdots + a_0 R_{xy}(t_1, t_2) = R_{xx}(t_1, t_2). \quad (1.233)$$

相应零初始条件为 $R_{xy}(t_1, 0) = 0$, 以及它关于 t_2 的前 $n-1$ 阶导数在 $t_2 = 0$ 时均为零。得到 R_{xy} 后, 再让系统作用于第一个时间变量:

$$a_n \frac{\partial^n R_{yy}(t_1, t_2)}{\partial t_1^n} + \cdots + a_0 R_{yy}(t_1, t_2) = R_{xy}(t_1, t_2). \quad (1.234)$$

此时 $R_{yy}(0, t_2) = 0$, 并且它关于 t_1 的前 $n-1$ 阶导数在 $t_1 = 0$ 时均为零。均值求解一次方程, 输出自相关依次在 t_2 与 t_1 上求解两次同类方程。

1.2.15 高阶矩的推广

二阶矩传播可以按输出变量的数目推广到更高阶矩。对实值系统, 定义

$$\begin{aligned} R_{xxx}(t_1, t_2, t_3) &= E[x(t_1)x(t_2)x(t_3)], & R_{xxy}(t_1, t_2, t_3) &= E[x(t_1)x(t_2)y(t_3)], \\ R_{xyy}(t_1, t_2, t_3) &= E[x(t_1)y(t_2)y(t_3)], & R_{yyy}(t_1, t_2, t_3) &= E[y(t_1)y(t_2)y(t_3)]. \end{aligned} \quad (1.235)$$

若用 $\mathcal{H}_k$ 表示系统核在第 k 个时间变量上的滤波作用, 则

$$R_{xxy} = \mathcal{H}_3 R_{xxx}, \quad R_{xyy} = \mathcal{H}_2 \mathcal{H}_3 R_{xxx}, \quad R_{yyy} = \mathcal{H}_1 \mathcal{H}_2 \mathcal{H}_3 R_{xxx}. \quad (1.236)$$

例如, 第一次把第三个输入 $x(t_3)$ 换成输出 $y(t_3)$, 就在 t_3 上通过一次系统; 再把 $x(t_2)$ 换成 $y(t_2)$, 就在 t_2 上再通过一次系统。三个变量全部对应输出时, 共需三次滤波。四阶及更高阶矩遵循同一规律: 每增加一个输出变量, 就在该变量对应的时间参数上增加一次系统作用。复值系统还需按照相关函数中各变量是否带共轭, 选用 h 或 h^* 。

1.3 功率谱

1.3.1 功率谱与互功率谱

相关函数在时差域中的卷积通常不便于直接判断形状。经过傅里叶变换后，卷积成为同一频率处的乘法，滤波器保留哪些频率、抑制哪些频率也就一目了然。这里采用角频率 $\omega = 2\pi f$ ；因此逆变换带有系数 $1/(2\pi)$ 。功率谱在完整名称中称为功率谱密度，它描述平均功率如何分布在各个角频率附近，对频率积分后给出过程的平均功率。

定义 1.3.1 (功率谱密度). 设复随机过程 $x(t)$ 为宽平稳过程，其自相关函数为 $R_{xx}(\tau) = E[x(t+\tau)x^*(t)]$ 。 $R_{xx}(\tau)$ 的傅里叶变换称为 $x(t)$ 的功率谱密度 (power spectral density)，记为

$$S_{xx}(\omega) = \int_{-\infty}^{\infty} R_{xx}(\tau) e^{-j\omega\tau} d\tau. \quad (1.237)$$

相应的逆变换为

$$R_{xx}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{xx}(\omega) e^{j\omega\tau} d\omega. \quad (1.238)$$

令 $\tau = 0$ 可得

$$E[|x(t)|^2] = R_{xx}(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{xx}(\omega) d\omega. \quad (1.239)$$

所以 $S_{xx}(\omega)$ 是关于角频率的功率密度，而 $S_{xx}(\omega)d\omega/(2\pi)$ 表示窄频带 $[\omega, \omega+d\omega]$ 所贡献的平均功率。

宽平稳过程的自相关函数具有 Hermitian 对称性 $R_{xx}(-\tau) = R_{xx}^*(\tau)$ ，故其傅里叶变换 $S_{xx}(\omega)$ 为实函数。功率谱还处处非负，这一点将在 Wiener-Khinchin 定理中证明。若 $x(t)$ 为实过程，则 $R_{xx}(\tau)$ 为实偶函数， $S_{xx}(\omega)$ 也为实偶函数。此时正弦项在对称积分中抵消，只需使用余弦变换：

$$S_{xx}(\omega) = 2 \int_0^{\infty} R_{xx}(\tau) \cos(\omega\tau) d\tau, \quad (1.240)$$

$$R_{xx}(\tau) = \frac{1}{\pi} \int_0^{\infty} S_{xx}(\omega) \cos(\omega\tau) d\omega. \quad (1.241)$$

功率谱关于 $\omega = 0$ 左右对称，画图和积分时只需处理半轴，再由偶对称性补全另一半。

定义 1.3.2 (互功率谱). 设 $x(t)$ 与 $y(t)$ 联合宽平稳，互相关函数为 $R_{xy}(\tau) = E[x(t+\tau)y^*(t)]$ 。其傅里叶变换

$$S_{xy}(\omega) = \int_{-\infty}^{\infty} R_{xy}(\tau) e^{-j\omega\tau} d\tau \quad (1.242)$$

称为 $x(t)$ 与 $y(t)$ 的互功率谱。

这里只出现一个时差变量 τ ，隐含了联合宽平稳条件。一般的 $R_{xy}(t_1, t_2)$ 同时依赖两个绝对时刻，无法直接用单变量傅里叶变换定义上述频谱。

例 1.3.3 (半随机电报信号的功率谱). 设 $N(t)$ 是速率为 λ 的 Poisson 计数过程，并按区间 $[0, t)$ 内到达次数的奇偶性定义

$$x(t) = \begin{cases} 1, & N(t) \text{ 为偶数,} \\ -1, & N(t) \text{ 为奇数.} \end{cases} \quad (1.243)$$

此前已经得到 $R_{xx}(\tau) = e^{-2\lambda|\tau|}$ 。该函数为实偶函数，因此预期其功率谱也应为实偶函数。分开正、负半轴积分，

$$\begin{aligned} S_{xx}(\omega) &= \int_0^{\infty} e^{-(2\lambda+j\omega)\tau} d\tau + \int_0^{\infty} e^{-(2\lambda-j\omega)\tau} d\tau \\ &= \frac{1}{2\lambda+j\omega} + \frac{1}{2\lambda-j\omega} = \frac{4\lambda}{4\lambda^2 + \omega^2}. \end{aligned} \quad (1.244)$$

结果满足预期的实性、偶性与非负性。

傅里叶变换还把一个域中的局部光滑性映射为另一域中的远端衰减。这里 $R_{xx}(\tau) = e^{-2\lambda|\tau|}$ 在 $\tau = 0$ 处不可微，因而 $S_{xx}(\omega)$ 的尾部只能按 $1/\omega^2$ 衰减；确有 $\omega S_{xx}(\omega) \rightarrow 0$ ，而 $\omega^2 S_{xx}(\omega) \rightarrow 4\lambda$ 。一般来说，希望谱尾具有更高阶的代数衰减，就需要相关函数在原点具有相应阶数的光滑性。时差域某一点的性质会影响整个高频尾部，频域某一点附近的光滑性也会反映到相关函数的长时差尾部。

1.3.2 协方差谱

定义 1.3.4 (协方差谱). 设宽平稳过程 $x(t)$ 的均值为常数 η , 自协方差函数为 $C_{xx}(\tau) = E[(x(t+\tau) - \eta)(x(t) - \eta)^*]$. $C_{xx}(\tau)$ 的傅里叶变换

$$S_{xx}^c(\omega) = \int_{-\infty}^{\infty} C_{xx}(\tau) e^{-j\omega\tau} d\tau \quad (1.245)$$

称为协方差谱。

由于 $R_{xx}(\tau) = C_{xx}(\tau) + |\eta|^2$, 并且常数 1 的扩展傅里叶变换为 $2\pi\delta(\omega)$, 所以

$$S_{xx}(\omega) = S_{xx}^c(\omega) + 2\pi|\eta|^2\delta(\omega). \quad (1.246)$$

两种频谱只相差位于直流频率的冲激。协方差谱去除了均值所占的确定性直流功率, 因而更集中地描述随机波动。多数场合中的“功率谱”仍指自相关函数的傅里叶变换; 使用协方差函数时宜明确写成协方差谱。

例如, 速率为 λ 的 Poisson 脉冲过程 $y(t) = \sum_i \delta(t - t_i)$ 满足 $E[y(t)] = \lambda$, 且 $C_{yy}(\tau) = \lambda\delta(\tau)$, 所以其协方差谱为常数 $S_{yy}^c(\omega) = \lambda$ 。计数到达所形成的随机波动在各频率上具有相同的功率密度; 若计算完整功率谱, 还需加上 $2\pi\lambda^2\delta(\omega)$ 。

1.3.3 具有指定功率谱的过程

功率谱除了用于分析已有过程, 也可以直接用来构造过程。核心思路是把频谱归一化成随机角频率的概率密度: 频率出现得越频繁, 相应位置的平均功率越大。手写批注中的“ ω 的随机时序变化对应功率谱的变化”正是这一对应关系。

引理 1.3.5 (复宽平稳过程的频谱构造). 给定任意非负、可积函数 $S(\omega)$, 存在功率谱等于 $S(\omega)$ 的复宽平稳过程。

证明. 令

$$x(t) = ae^{j(\Omega t - \Phi)}, \quad |a|^2 = \frac{1}{2\pi} \int_{-\infty}^{\infty} S(\omega) d\omega, \quad (1.247)$$

其中 Φ 在 $[-\pi, \pi)$ 上均匀分布, 并与随机角频率 Ω 独立。当 $|a| > 0$ 时, 取 $f_\Omega(\omega) = S(\omega)/(2\pi|a|^2)$; 该函数由 a 的归一化条件保证积分为 1。均匀随机相位给出 $E[x(t)] = 0$, 而

$$\begin{aligned} R_{xx}(\tau) &= E[x(t+\tau)x^*(t)] = |a|^2 E[e^{j\Omega\tau}] \\ &= |a|^2 \int_{-\infty}^{\infty} e^{j\omega\tau} f_\Omega(\omega) d\omega = \frac{1}{2\pi} \int_{-\infty}^{\infty} S(\omega) e^{j\omega\tau} d\omega. \end{aligned} \quad (1.248)$$

故 $x(t)$ 为宽平稳过程, 功率谱正是 $S(\omega)$ 。若 $|a| = 0$, 则 $S(\omega)$ 几乎处处为零, 直接取 $x(t) = 0$ 即可。□

引理 1.3.6 (实宽平稳过程的频谱构造). 给定任意非负、可积的偶函数 $S(\omega)$, 存在功率谱等于 $S(\omega)$ 的实宽平稳过程。

证明. 令

$$x(t) = a \cos(\Omega t + \Phi), \quad a^2 = \frac{1}{\pi} \int_{-\infty}^{\infty} S(\omega) d\omega, \quad f_\Omega(\omega) = \frac{S(\omega)}{\pi a^2}, \quad (1.249)$$

其中 $\Phi \sim \text{Unif}[-\pi, \pi)$, 并与 Ω 独立。对相位取平均后, 含 $2\Omega t$ 的项消失, 得到 $R_{xx}(\tau) = \frac{a^2}{2} E[\cos(\Omega\tau)]$ 。利用 S 的偶性和余弦逆变换, 可验证其功率谱为 $S(\omega)$ 。 $a = 0$ 的情形仍取零过程。□

均匀随机相位的作用是使均值成为常数, 并消去自相关中对绝对时间 t 的依赖, 从而满足宽平稳条件。功率谱的形状由随机角频率 Ω 的密度决定; 只关心频率分布与谱形对应时, 相位不参与这一对应。通信中的 FSK、FM 和随机载波模型常可直接套用这个观察。

1.3.4 多普勒效应

例 1.3.7 (运动发射机的多普勒功率谱). 发射机以随机速率 v 运动, 速度方向与发射机指向固定接收机的方向夹角为 $\theta \in (-\pi/2, \pi/2)$ 。沿传播方向的投影速度为 $v_x = v \cos \theta$ 。若发射信号为角频率 ω_0 的单频信号, 传播距

离写成 $r = r_0 + v_x t$, 则接收信号为

$$x(t) = ae^{j\omega_0(t-r/c)} = ae^{j(\Omega t - \Phi)}, \quad \Omega = \omega_0 \left(1 - \frac{v \cos \theta}{c}\right), \quad \Phi = \frac{r_0 \omega_0}{c}, \quad (1.250)$$

其中 c 为传播速度。于是接收角频率是速率 v 的线性变换。

从累积分布函数出发可以稳妥地处理变换方向。由于 $\cos \theta > 0$,

$$\begin{aligned} F_\Omega(\omega) &= \Pr \left\{ \omega_0 \left(1 - \frac{v \cos \theta}{c}\right) \leq \omega \right\} \\ &= 1 - F_v \left[\frac{c}{\cos \theta} \left(1 - \frac{\omega}{\omega_0}\right) \right]. \end{aligned} \quad (1.251)$$

对 ω 求导, 得到

$$f_\Omega(\omega) = \frac{c}{\omega_0 \cos \theta} f_v \left[\frac{c}{\cos \theta} \left(1 - \frac{\omega}{\omega_0}\right) \right]. \quad (1.252)$$

因此, 按前述复过程构造的归一化关系,

$$S_{xx}(\omega) = 2\pi |a|^2 \frac{c}{\omega_0 \cos \theta} f_v \left[\frac{c}{\cos \theta} \left(1 - \frac{\omega}{\omega_0}\right) \right]. \quad (1.253)$$

这里若把 Φ 看成固定常数, 严格来说 $x(t)$ 的均值会随时间改变, 过程不满足完整的宽平稳条件; 令初相位在 $[-\pi, \pi)$ 上均匀分布即可补足宽平稳性。初相位是否均匀不改变式 (1.253) 中由随机频率决定的谱形。

若 $v \sim \text{Unif}[v_1, v_2]$, 则接收角频率也均匀分布, 并有

$$S_{xx}(\omega) = \frac{2\pi |a|^2 c}{\omega_0 (v_2 - v_1) \cos \theta}, \quad \omega_0 \left(1 - \frac{v_2}{c} \cos \theta\right) \leq \omega \leq \omega_0 \left(1 - \frac{v_1}{c} \cos \theta\right), \quad (1.254)$$

区间外为零。随机运动把原来的单一谱线展宽成一段平坦频带, 速度分布的形状直接成为频谱展宽的形状。若频谱测量显示载频附近存在约 10 kHz 的随机偏移, 便可据此判断瞬时接收频率也在相同范围内波动, 并由谱形读取这种波动的概率分布。

若速度恒为 v , 则 Ω 也为常数, 频谱退化为 $S_{xx}(\omega) = 2\pi |a|^2 \delta[\omega - \omega_0(1 - v \cos \theta/c)]$ 。确定性运动只使谱线平移, 不产生展宽。若运动方向与传播方向垂直, 即 $\cos \theta = 0$, 投影速度为零, $\Omega = \omega_0$; 无论速度本身随机或确定, 均无频移和谱展宽。

1.3.5 宽平稳输入通过线性系统

回到可分离的时变线性系统 $h(\tau; t) = h_1(\tau)h_2(t)$ 。宽平稳输入满足 $R_{xx}(t_1, t_2) = R_{xx}(t_1 - t_2)$ 。令 $t_1 = t + \tau$ 、 $t_2 = t$ ，上一节的相关函数传播公式化为

$$R_{xy}(t + \tau, t) = E\{h_2^*(t)[h_1^*(-\tau) * R_{xx}(\tau)]\}, \quad (1.255)$$

$$R_{yy}(t + \tau, t) = E\{h_2(t + \tau)h_2^*(t)[h_1^*(-\tau) * h_1(\tau) * R_{xx}(\tau)]\}. \quad (1.256)$$

互相关中的 $h_1^*(-\tau)$ 来自变量替换：原式出现 $R_{xx}(\tau + u)$ ，令新变量为 $-u$ 后，便得到以 $R_{xx}(\tau - u)$ 为被卷积信号的标准形式。书写卷积时把 h 视作权重，把 R_{xx} 视作被平移的信号；实际积分时可再选取最简洁的变量形式。

定理 1.3.8 (调制型时变系统的功率谱关系). 设宽平稳输入 $x(t)$ 通过与输入独立的线性系统 $h(\tau; t) = h_1(\tau)e^{j\omega_0 t}$ ，并令 $H_1(\omega) = \int h_1(\tau)e^{-j\omega\tau} d\tau$ 。则输入-输出互功率谱和输出功率谱分别为

$$S_{xy}(\omega; t) = e^{-j\omega_0 t} E[H_1^*(\omega)S_{xx}(\omega)], \quad (1.257)$$

$$S_{yy}(\omega) = E[|H_1(\omega - \omega_0)|^2 S_{xx}(\omega - \omega_0)]. \quad (1.258)$$

分号后的 t 表明互功率谱还随系统的绝对观察时刻变化；输出自相关中的相位因子只依赖时差，故 S_{yy} 不再含绝对时间。

证明. 由式 (1.255)，取 $h_2(t) = e^{j\omega_0 t}$ 后有 $R_{xy}(t + \tau, t) = e^{-j\omega_0 t} E[h_1^*(-\tau) * R_{xx}(\tau)]$ 。对 τ 作傅里叶变换，卷积转化为乘法，且 $h_1^*(-\tau)$ 的傅里叶变换为 $H_1^*(\omega)$ ，从而得到式 (1.257)。

对输出自相关， $h_2(t + \tau)h_2^*(t) = e^{j\omega_0 \tau}$ ，因此

$$R_{yy}(\tau) = e^{j\omega_0 \tau} E[h_1^*(-\tau) * h_1(\tau) * R_{xx}(\tau)]. \quad (1.259)$$

括号内三重卷积的傅里叶变换为 $E[|H_1(\omega)|^2 S_{xx}(\omega)]$ ；时差域乘以 $e^{j\omega_0 \tau}$ 会把频谱向右平移 ω_0 ，于是得到式 (1.258)。□

这一定理给出两条常用直觉。时差域中的卷积对应频域中的逐点相乘，因而滤波后的谱形由输入谱和 $|H_1|^2$ 的重叠区域决定；时差域乘以旋转相位 $e^{j\omega_0\tau}$ 对应频域平移，写成自变量 $\omega - \omega_0$ 时表示向右移动 ω_0 。多普勒频移可以看作自然传播环境产生的这种调制。

1.3.6 传递函数与扩展傅里叶变换

定义 1.3.9 (线性时不变系统的传递函数). 线性时不变系统在频域中可写为

$$Y(\omega) = X(\omega)H(\omega), \quad (1.260)$$

其中 $X(\omega)$ 、 $Y(\omega)$ 分别是输入和输出的傅里叶变换， $H(\omega)$ 称为系统的传递函数或频率响应。

式 (1.260) 立即保持线性：输入 $aX_1 + bX_2$ 产生输出 $[aX_1(\omega) + bX_2(\omega)]H(\omega) = aY_1(\omega) + bY_2(\omega)$ 。若 $H(\omega)$ 存在逆傅里叶变换 $h(t)$ ，则频域乘法与时域卷积完全等价，即 $y(t) = h(t) * x(t)$ 。 $h(t)$ 称为冲激响应， $H(\omega)$ 称为传递函数； $|H(\omega)|$ 也常称为幅频响应。

传递函数形式还能描述当前普通冲激响应框架难以处理的线性系统。例如微分器满足 $Y(\omega) = j\omega X(\omega)$ ，所以 $H(\omega) = j\omega$ 。这个函数缺少通常意义下的可积逆傅里叶变换，却能在频域中准确表示微分运算。

普通傅里叶变换存在的一组充分条件是： $\int_{-\infty}^{\infty} |g(t)|dt < \infty$ ，并且 g 在每个有限区间内仅有有限个局部极大值、局部极小值和不连续点。绝对可积本身还不够。例如定义 $g(x) = 1$ 当 $|x| < 1$ 且 x 为无理数，其他情形取 0；虽然 $\int_{-1}^1 |g(x)|dx \leq 2$ ，任意区间内稠密的有理点和无理点却使它处处不连续，通常的傅里叶积分没有定义。

定义 1.3.10 (扩展傅里叶变换). 若 $g(t)$ 缺少普通傅里叶变换，可选取一列具有普通傅里叶变换的函数 $g_n(t)$ ，使 $g_n(t) \rightarrow g(t)$ 。记 $G_n(\omega) = \mathcal{F}\{g_n(t)\}$ ；若 $G_n(\omega)$ 在所采用的广义意义下收敛，则把

$$G(\omega) = \lim_{n \rightarrow \infty} G_n(\omega) \quad (1.261)$$

称为 $g(t)$ 的扩展傅里叶变换。

工程中常用指数窗压低函数的远端，例如以 $g_n(t) = e^{-|t|/n}$ 逼近常数 1。计算得

$$\mathcal{F}\{e^{-|t|/n}\} = \frac{2n}{1 + n^2\omega^2} \xrightarrow{n \rightarrow \infty} 2\pi\delta(\omega), \quad (1.262)$$

故写作 $\mathcal{F}\{1\} = 2\pi\delta(\omega)$ 。系数 2π 保证近似函数的谱面积始终为 $\int 2n/(1 + n^2\omega^2)d\omega = 2\pi$ ，也与当前逆变换的 $1/(2\pi)$ 归一化一致。

扩展变换依赖逼近方式，若从不同函数列得到不同极限，定义便缺少唯一性。工程计算通常约定采用同类指数窗，从而使各处使用保持一致。这里的极限需要按广义函数理解： $2n/(1 + n^2\omega^2)$ 在 $\omega \neq 0$ 处逐点趋于零，却把固定的总面积集中到 $\omega = 0$ ，最终形成 delta 冲激。

1.3.7 Hilbert 变换与解析信号

定义 1.3.11 (Hilbert 变换). 传递函数为

$$H(\omega) = -j \operatorname{sgn}(\omega) = \begin{cases} -j, & \omega > 0, \\ j, & \omega < 0 \end{cases} \quad (1.263)$$

的正交滤波器称为 Hilbert 变换器。实信号 $x(t)$ 通过该系统所得的输出记为 $\hat{x}(t)$ ，称为 $x(t)$ 的 Hilbert 变换。

$|H(\omega)| = 1$ ，所以所有频率的幅度均保持不变；正频率相移 -90° ，负频率相移 $+90^\circ$ ，故又称正交滤波器或全通滤波器。 $\omega = 0$ 的单点取值对普通积分没有影响，常约定 $\operatorname{sgn}(0) = 0$ 。正、负频率的旋转方向相反，因此该系统无法化成一个对全部频率相同的相位旋转。

$H(\omega)$ 的普通逆傅里叶变换不存在。采用指数窗 $H_n(\omega) = -j \operatorname{sgn}(\omega)e^{-|\omega|/n}$,

把正、负半轴分开积分, 可得

$$h_n(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} H_n(\omega) e^{j\omega\tau} d\omega \quad (1.264)$$

$$= \frac{n^2\tau}{\pi(n^2\tau^2 + 1)} \xrightarrow{n \rightarrow \infty} \begin{cases} \frac{1}{\pi\tau}, & \tau \neq 0, \\ 0, & \tau = 0. \end{cases} \quad (1.265)$$

所以 Hilbert 变换常写为与 $1/(\pi t)$ 的卷积; 由于该核在原点奇异且不可绝对积分, 实际含义是扩展变换或 Cauchy 主值积分。

定义 1.3.12 (解析信号). 对实过程 $x(t)$, 定义

$$z(t) = x(t) + j\hat{x}(t), \quad (1.266)$$

称 $z(t)$ 为 $x(t)$ 的解析信号。

由 $\hat{X}(\omega) = X(\omega)H(\omega)$, 解析信号的频谱为

$$\begin{aligned} Z(\omega) &= X(\omega) + j\hat{X}(\omega) = [1 + \text{sgn}(\omega)]X(\omega) \\ &= 2X(\omega)\mathbf{1}_{\{\omega>0\}} + X(\omega)\mathbf{1}_{\{\omega=0\}}. \end{aligned} \quad (1.267)$$

负频率部分被完全消去, 正频率部分加倍, 直流分量保持原值。手写批注“只想看一半频谱”概括了它的用途: 实信号的正、负频率彼此共轭, 解析信号保留一侧频谱, 许多通信分析因而可以只在正频率上进行。

定理 1.3.13 (Wiener-Khinchin 定理). 任意宽平稳过程的功率谱处处非负, 即 $S_{xx}(\omega) \geq 0$ 。

证明. 先考虑由普通傅里叶变换定义的功率谱。它关于 ω 连续; 更强地说, 在通常的可积条件下它一致连续。假设某个频率处 $S_{xx}(\omega) < 0$, 连续性保证存在一个非零区间 (ω_1, ω_2) , 使该区间内的功率谱均为负。

构造理想带通滤波器 $H(\omega) = 1$ ($\omega \in (\omega_1, \omega_2)$), 区间外取 0。由线性系统的谱关系, 输出功率谱为 $S_{yy}(\omega) = S_{xx}(\omega)|H(\omega)|^2$ 。于是输出在任意时刻的均方值为

$$E[|y(t)|^2] = R_{yy}(0) = \frac{1}{2\pi} \int_{\omega_1}^{\omega_2} S_{xx}(\omega) d\omega < 0. \quad (1.268)$$

然而 $|y(t)|^2 \geq 0$ ，其期望不可能为负，产生矛盾。因此功率谱处处非负。

□

该证明也说明非负性为何具有直接的物理意义：若某一频带的谱密度为负，选取只通过该频带的滤波器就会得到负的输出平均功率，这与平方模的定义冲突。结合前面的 Hermitian 对称性，宽平稳过程的功率谱由此确认为实且非负。

1.3.8 累积谱与累积协方差谱

功率谱密度 $S_{xx}(\omega)$ 与累积谱的关系，类似于概率密度函数与累积分布函数的关系。概率论中，累积分布函数足以刻画随机变量，即使普通概率密度不存在；频谱分析也可以通过先对功率谱累积，避开 Dirac delta 等奇异函数在逐点运算中的困难。

定义 1.3.14 (累积谱). 过程 $x(t)$ 的累积谱 (integrated spectrum) 定义为

$$F_{xx}(\omega) \triangleq \int_{-\infty}^{\omega} S_{xx}(s) ds. \quad (1.269)$$

当功率谱是普通函数时， $S_{xx}(\omega) = dF_{xx}(\omega)/d\omega$ 。若频谱含有位于 ω_0 的冲激， F_{xx} 会在 ω_0 处产生相应大小的跳跃，仍可作为普通的累积函数处理。因此，累积谱比谱密度具有更广的适用范围。自相关函数可由 Riemann–Stieltjes 积分恢复：

$$R_{xx}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{j\omega\tau} dF_{xx}(\omega). \quad (1.270)$$

若 F_{xx} 可微，则 $dF_{xx}(\omega) = S_{xx}(\omega)d\omega$ ，式 (1.270) 就退化为通常的逆傅里叶变换。

Riemann 积分用许多窄矩形逼近面积，每个矩形的底宽为 $\Delta\omega_i$ ，高度由被积函数决定。Riemann–Stieltjes 积分保留同样的矩形逼近思想，但第 i 个矩形的底宽改成 $F_{xx}(\omega_i) - F_{xx}(\omega_{i-1})$ 。一般地， $\int f(x) dg(x)$ 的矩形高度由 f 决定，底宽由 $g(x_i) - g(x_{i-1})$ 决定。这样即使 g 没有普通导数，只要增量有意义，积分仍能吸收跳跃所携带的质量。

定义 1.3.15 (累积协方差谱). 过程 $x(t)$ 的累积协方差谱定义为

$$F_{xx}^c(\omega) \triangleq \int_{-\infty}^{\omega} S_{xx}^c(s) ds, \quad (1.271)$$

其中 S_{xx}^c 为协方差谱。

累积功率谱包含均值造成的直流跳跃, 累积协方差谱去除了这一确定性分量。若 $E[x(t)] = \eta$, 由 $S_{xx} = S_{xx}^c + 2\pi|\eta|^2\delta(\omega)$ 可知, 两种累积谱只相差在零点处大小为 $2\pi|\eta|^2$ 的阶跃。

1.3.9 非负频谱与非负定性

判断一个给定函数能否作为相关函数, 可以在时域检查非负定性, 也可以在频域检查傅里叶变换是否非负。两条路线在宽平稳情形下完全等价。

定义 1.3.16 (非负定核). 若对任意有限个时刻 $t_1, \dots, t_n$ 和任意复数 $a_1, \dots, a_n$, 函数 $R(t_1, t_2)$ 满足

$$\sum_{i=1}^n \sum_{j=1}^n a_i a_j^* R(t_i, t_j) \geq 0, \quad (1.272)$$

则称 R 为非负定核。本课程沿用 p.d. 作为该性质的简称。

式 (1.272) 对相关函数自然成立, 因为左端可写成 $E[|\sum_i a_i x(t_i)|^2]$ 。因此, 存在以 $R(t_1, t_2)$ 为相关函数的过程, 当且仅当 $R(t_1, t_2)$ 非负定。对宽平稳核 $R(t_i, t_j) = R(t_i - t_j)$, Wiener-Khinchin 定理和指定功率谱的构造引理进一步给出

$$R(\tau) \text{ 非负定} \iff S(\omega) = \mathcal{F}\{R(\tau)\} \geq 0. \quad (1.273)$$

正向结论来自功率谱的非负性; 反向结论可把非负的 $S(\omega)$ 归一化为随机角频率的概率密度, 并构造 $x(t) = ae^{j(\Omega t - \Phi)}$ 。由此得到的过程具有相关函数 $R(\tau)$ 。

频域判定往往更直接：只需计算傅里叶变换并检查其符号。时域判定则能利用相关函数的必要性质快速排除候选波形。例如自相关函数满足 $|R_{xx}(\tau)| \leq R_{xx}(0)$ ，所以原点处未取得最大模的函数立即失去成为自相关函数的资格。这类推理使用命题 $P \Rightarrow Q$ 的逆否形式 $\neg Q \Rightarrow \neg P$ ，称为必要排除 (necessary exclusion)。

1.3.10 Pólya 充分判据与必要排除

引理 1.3.17 (Pólya 充分判据). 若函数 $R(\tau)$ 在 $\tau > 0$ 上为凹函数，并且当 $|\tau| \rightarrow \infty$ 时趋于有限极限，则 $R(\tau)$ 非负定。

这是一个充分条件：满足条件即可确认非负定，未满足条件仍可能是合法的相关函数。该判据给出一条直接的波形检查方法；必要排除则从所有相关函数必须满足的性质出发，发现违背性质的局部结构后立即淘汰候选函数。

定理 1.3.18 (相关函数取到原点值时的周期性). 设宽平稳过程 $x(t)$ 的自相关函数为 $R_{xx}(\tau)$ 。若存在 $\tau_1 \neq 0$ 使 $R_{xx}(\tau_1) = R_{xx}(0)$ ，则 $R_{xx}(\tau)$ 以 τ_1 为周期。

这个结论比原点最大模性质更强。只要相关函数在某个非零时差再次取到原点值，此后整个波形必须按该时差重复。若画出的候选函数在 τ_1 处与原点等高，后续却没有周期性重复，它就无法成为宽平稳过程的自相关函数。

证明. 令 $u = x(t + \tau + \tau_1) - x(t + \tau)$ 、 $v = x(t)$ 。Cauchy-Schwarz 不等式给出

$$\begin{aligned} |R_{xx}(\tau + \tau_1) - R_{xx}(\tau)|^2 &\leq E[|u|^2]E[|v|^2] \\ &= [2R_{xx}(0) - R_{xx}(\tau_1) - R_{xx}(-\tau_1)]R_{xx}(0). \end{aligned} \quad (1.274)$$

因为 $R_{xx}(0)$ 为实数，且 $R_{xx}(-\tau_1) = R_{xx}^*(\tau_1)$ ，条件 $R_{xx}(\tau_1) = R_{xx}(0)$ 使右端等于零。左端为非负量，只能有 $R_{xx}(\tau + \tau_1) = R_{xx}(\tau)$ 对每个 τ 成立。

□

同一个 Cauchy-Schwarz 估计还能把原点处的连续性推广到全轴。

[原点连续蕴含处处连续] 若宽平稳过程的自相关函数 $R_{xx}(\tau)$ 在原点连续, 则它在每个 τ 处都连续。

证明. 对任意增量 τ_1 , 前面的估计仍给出

$$|R_{xx}(\tau + \tau_1) - R_{xx}(\tau)|^2 \leq [2R_{xx}(0) - R_{xx}(\tau_1) - R_{xx}(-\tau_1)]R_{xx}(0). \quad (1.275)$$

当 $|\tau_1| \downarrow 0$ 时, 原点连续性使右端趋于零, 所以 $R_{xx}(\tau + \tau_1) \rightarrow R_{xx}(\tau)$ 对任意 τ 成立。□

因此, 一个候选相关函数若在原点连续, 却在其他位置出现跳跃, 就可以直接排除。这个性质还可与合法线性系统结合: 若某函数真是输入相关函数, 则输入经过线性系统所得的输出相关函数也必须满足上述必要条件。

例 1.3.19 (用微分器排除截断抛物线). 考虑

$$w(\tau) = \begin{cases} a^2 - \tau^2, & |\tau| < a, \\ 0, & |\tau| > a. \end{cases} \quad (1.276)$$

该函数本身在原点取最大值且处处连续, 前面的两个简单条件无法直接排除它。假设 $w(\tau)$ 是某宽平稳输入 $x(t)$ 的自相关函数, 并令输入通过微分器得到 $y(t) = x'(t)$ 。由于对宽平稳相关函数有 $\partial^2 R_{xx}(t_1, t_2)/(\partial t_1 \partial t_2) = -d^2 R_{xx}(\tau)/d\tau^2$, 输出相关函数应为

$$R_{yy}(\tau) = -\frac{d^2 w(\tau)}{d\tau^2} = \begin{cases} 2, & |\tau| < a, \\ 0, & |\tau| > a. \end{cases} \quad (1.277)$$

R_{yy} 在原点连续, 却在 $|\tau| = a$ 处跳跃, 违反“原点连续蕴含处处连续”的必要条件。故 $w(\tau)$ 无法成为任何过程的自相关函数。

1.3.11 互功率谱的频带上界

互功率谱描述两个过程在各个频率上的二阶联系。对任意频带 $[a, b]$ ，这种联系的总量受到两个过程各自在该频带内功率的限制。

引理 1.3.20 (互功率谱的频带界). 对任意实数 $a < b$ ，有

$$\left| \int_a^b S_{xy}(\omega) d\omega \right|^2 \leq \left(\int_a^b S_{xx}(\omega) d\omega \right) \left(\int_a^b S_{yy}(\omega) d\omega \right). \quad (1.278)$$

该不等式可以只检查一段指定带宽。例如只关心中心频率附近 200 kHz 的频带时，互功率谱在该段的积分不可能超过两个自功率谱带内积分的几何平均。等号对应滤波后的两个过程在均方意义下线性相关。

证明. 取理想带通滤波器 $H(\omega) = \mathbf{1}_{\{a < \omega < b\}}$ ，令 $z(t)$ 、 $w(t)$ 分别为 $x(t)$ 、 $y(t)$ 通过该滤波器后的输出。由 Cauchy-Schwarz 不等式，

$$|E[z(t)w^*(t)]|^2 \leq E[|z(t)|^2]E[|w(t)|^2] = R_{zz}(0)R_{ww}(0). \quad (1.279)$$

输出功率谱分别为 $S_{zz} = S_{xx}|H|^2$ 、 $S_{ww} = S_{yy}|H|^2$ ，所以

$$R_{zz}(0)R_{ww}(0) = \frac{1}{4\pi^2} \left(\int_a^b S_{xx}(\omega) d\omega \right) \left(\int_a^b S_{yy}(\omega) d\omega \right). \quad (1.280)$$

另一方面，把两个滤波器卷积代入交叉均值，

$$\begin{aligned} E[z(t)w^*(t)] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(\tau)h^*(s)R_{xy}(s-\tau) d\tau ds \\ &= \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{xy}(\omega)|H(\omega)|^2 d\omega = \frac{1}{2\pi} \int_a^b S_{xy}(\omega) d\omega. \end{aligned} \quad (1.281)$$

将后两式代入式 (1.279)，约去共同的 $1/(4\pi^2)$ ，即得结论。 $\square$

1.3.12 均方意义下的相等与周期性

随机过程在固定时刻的取值仍是随机变量，因此过程之间的“相等”需要说明采用何种意义。这里沿用二阶矩的能量观点，以差过程的平均能量是否为零作为判据。

定义 1.3.21 (均方意义下相等). 定义在同一指标集 I 上的两个过程 $\{x(t), t \in I\}$ 与 $\{y(t), t \in I\}$ 在均方意义 (mean-square sense, MS) 下相等, 当且仅当对每个固定的 $t \in I$ 都有

$$E[|x(t) - y(t)|^2] = 0. \quad (1.282)$$

非负随机变量的期望为零意味着它以概率 1 等于零, 所以式 (1.282) 等价于对每个固定 t 都有 $P\{x(t) = y(t)\} = 1$ 。这一定义逐个时刻成立, 尚未要求存在一个概率为 1 的共同事件, 使两条样本路径在所有时刻同时相等。

为看清两者的差别, 设样本空间为 S , 并定义

$$A_t = \{\zeta \in S : x(t, \zeta) = y(t, \zeta)\}, \quad A_\infty = \bigcap_{t \in I} A_t. \quad (1.283)$$

均方相等要求每个 $P(A_t) = 1$, 没有附加 $P(A_\infty) = 1$ 。有限个或可数个概率为 1 的事件取交集后, 概率仍为 1; 当指标集不可数时, 概率空间的 σ -代数只保证对可数交并封闭, A_∞ 甚至可能缺少可测性。

例如取 $S = I = \mathbb{R}$, 令 $A_t = S \setminus \{t\}$, 并在 S 上使用连续高斯概率测度。每个单点的概率为零, 所以对所有固定 t 都有 $P(A_t) = 1$; 然而 $\bigcap_{t \in \mathbb{R}} A_t = \emptyset$, 从而 $P(A_\infty) = 0$ 。这说明逐点几乎必然相等与整条样本路径在同一事件上相等是两个强度不同的命题。

定义 1.3.22 (均方周期过程). 若存在 $T > 0$, 使过程 $x(t)$ 对每个 t 都满足

$$E[|x(t+T) - x(t)|^2] = 0, \quad (1.284)$$

则称 $x(t)$ 为均方周期过程, T 为其均方周期。

与均方相等相同, 式 (1.284) 要求对每个固定 t , 事件 $A_t = \{\zeta : x(t+T, \zeta) = x(t, \zeta)\}$ 的概率为 1, 并未要求不可数交集 $\bigcap_{t \in I} A_t$ 的概率为 1。过程在均方意义下的周期性完全由二阶矩刻画。

定理 1.3.23 (均方周期性与相关函数的双周期性). 过程 $x(t)$ 为均方周期过程, 当且仅当其自相关函数关于两个时间变量分别以 T 为周期, 即对任意整数 m, n ,

$$R_{xx}(t_1 + mT, t_2 + nT) = R_{xx}(t_1, t_2). \quad (1.285)$$

证明. 先设 $x(t)$ 均方周期。由 Cauchy-Schwarz 不等式,

$$\begin{aligned} & |E\{x(t_1)[x(t_2 + T) - x(t_2)]^*\}| \\ & \leq E^{1/2}[|x(t_1)|^2]E^{1/2}[|x(t_2 + T) - x(t_2)|^2] = 0. \end{aligned} \quad (1.286)$$

故 $R_{xx}(t_1, t_2 + T) = R_{xx}(t_1, t_2)$ 。对第一个变量重复同样的估计, 再按整数次数迭代, 即得式 (1.285)。

反之, 若相关函数满足双周期性, 则

$$\begin{aligned} E[|x(t + T) - x(t)|^2] &= R_{xx}(t + T, t + T) + R_{xx}(t, t) \\ &\quad - R_{xx}(t + T, t) - R_{xx}(t, t + T) = 0, \end{aligned} \quad (1.287)$$

其中四项由双周期性均化为 $R_{xx}(t, t)$ 。因此 $x(t)$ 满足均方周期性的定义。□

1.3.13 均方连续性

均方 (mean square, MS) 的次序是先对差值取平方, 再计算期望。随机过程的相等、周期、连续、可微和可积都可以采用这种意义来定义。虽然定义直接写在过程 $x(t)$ 上, 平方展开后只会出现二阶矩, 所以这些性质最终都由自相关函数刻画。

定义 1.3.24 (均方连续). 若过程 $x(t)$ 对每个 t 都满足

$$\lim_{\varepsilon \rightarrow 0} E[|x(t + \varepsilon) - x(t)|^2] = 0, \quad (1.288)$$

则称 $x(t)$ 在均方意义下连续, 简称均方连续 (MS continuous)。

展开式 (1.288) 中的平方模, 得到

$$\begin{aligned} E[|x(t+\varepsilon) - x(t)|^2] &= R_{xx}(t+\varepsilon, t+\varepsilon) - R_{xx}(t+\varepsilon, t) \\ &\quad - R_{xx}(t, t+\varepsilon) + R_{xx}(t, t). \end{aligned} \quad (1.289)$$

中间两项彼此共轭, 它们的和只保留实部。由此, 过程均方连续当且仅当其自相关函数满足相应的连续性条件。均方连续是二阶统计意义下的性质, 对单条样本函数的逐点连续性没有直接保证。

例 1.3.25 (Poisson 计数过程的均方连续性). 设 $N(t)$ 是速率为 λ 的 Poisson 计数过程。其样本路径在每个到达时刻 $t_i(\zeta)$ 跳增 1, 因而具有不连续的阶跃。对长度为 $\varepsilon > 0$ 的短区间, 增量 $N(t+\varepsilon) - N(t) = N[t, t+\varepsilon)$ 服从参数为 $\lambda\varepsilon$ 的 Poisson 分布。因此

$$E[|N(t+\varepsilon) - N(t)|^2] = \lambda\varepsilon(1 + \lambda\varepsilon) \xrightarrow{\varepsilon \downarrow 0} 0. \quad (1.290)$$

所以 Poisson 计数过程均方连续, 同时它的每条典型样本路径仍含有跳跃。该例区分了统计上的连续性与样本路径连续性。

若 $x(t)$ 还是宽平稳过程, 则自相关函数只依赖时间差, 并有

$$E[|x(t+T) - x(t)|^2] = 2 \operatorname{Re}\{R_{xx}(0) - R_{xx}(T)\}. \quad (1.291)$$

因此, 宽平稳过程是否以 T 为均方周期, 只需比较 $R_{xx}(0)$ 与 $R_{xx}(T)$ 的实部; 虚部在两个共轭交叉项相加时消失。条件 $\operatorname{Re} R_{xx}(T) = R_{xx}(0)$ 成立时, 均方误差为零, 过程具有均方周期 T , 相应的相关函数也按 T 重复。宽平稳性把一般二维相关函数的检查简化成对一维函数两个时差点的比较。

1.3.14 均方可微性

确定性函数的导数由差商极限定义。对随机过程, 每个差商仍是随机变量, 因此需要说明差商在何种意义下收敛。均方可微采用上一节的均方相等概念: 差商与候选导过程之间的均方误差趋于零。

定义 1.3.26 (均方可微). 若存在随机过程 $x'(t)$, 使对每个 t 都有

$$\lim_{\varepsilon \rightarrow 0} E \left[\left| \frac{x(t+\varepsilon) - x(t)}{\varepsilon} - x'(t) \right|^2 \right] = 0, \quad (1.292)$$

则称 $x(t)$ 均方可微, $x'(t)$ 称为它的均方导过程。

也可以不用预先指定 $x'(t)$, 要求差商族在均方范数下满足 Cauchy 条件: 当 $\varepsilon, \gamma \rightarrow 0$ 时, $E[|D_\varepsilon x(t) - D_\gamma x(t)|^2] \rightarrow 0$, 其中 $D_\varepsilon x(t) = [x(t+\varepsilon) - x(t)]/\varepsilon$ 。这与式 (1.292) 表达同一收敛思想。

为把定义转换成相关函数条件, 将平方展开为

$$\begin{aligned} & E \left[\left| \frac{x(t+\varepsilon) - x(t)}{\varepsilon} - x'(t) \right|^2 \right] \\ &= \frac{R_{xx}(t+\varepsilon, t+\varepsilon) - R_{xx}(t+\varepsilon, t) - R_{xx}(t, t+\varepsilon) + R_{xx}(t, t)}{\varepsilon^2} \\ &\quad - \frac{R_{xx'}(t+\varepsilon, t) - R_{xx'}(t, t)}{\varepsilon} - \frac{R_{x'x}(t, t+\varepsilon) - R_{x'x}(t, t)}{\varepsilon} + R_{x'x'}(t, t). \end{aligned} \quad (1.293)$$

这里 $R_{xx'}(t_1, t_2) = E[x(t_1)x'^*(t_2)]$, $R_{x'x}(t_1, t_2) = E[x'(t_1)x^*(t_2)]$ 。微分器是线性系统, 故均值与相关函数传播定理给出

$$R_{xx'}(t_1, t_2) = \frac{\partial R_{xx}(t_1, t_2)}{\partial t_2}, \quad R_{x'x'}(t_1, t_2) = \frac{\partial^2 R_{xx}(t_1, t_2)}{\partial t_1 \partial t_2}. \quad (1.294)$$

因此, 均方可微性等价于自相关函数在对角线 $t_1 = t_2$ 附近具有所需的混合二阶偏导数; 均方导过程的相关函数就是该混合偏导数。检验随机过程能否微分时, 核心对象仍是 $R_{xx}(t_1, t_2)$, 并且微分器需要分别作用在相关函数的两个时间变量上。

1.3.15 均方可积性

均方积分沿用 Riemann 积分的矩形和逼近。每个 Riemann 和都是有限个随机变量的线性组合, 所以仍是随机变量; 积分存在表示这些随机变量在均方意义下收敛。

定义 1.3.27 (均方 Riemann 可积). 给定任意有限区间 $[a, b]$, 令 $N_\Delta = \lfloor (b-a)/\Delta \rfloor$. 若存在随机变量 $\int_a^b x(t) dt$, 使

$$\lim_{\Delta \downarrow 0} E \left[\left| \int_a^b x(t) dt - \Delta \sum_{i=0}^{N_\Delta} x(a + i\Delta) \right|^2 \right] = 0, \quad (1.295)$$

则称过程 $x(t)$ 在均方意义下 Riemann 可积。

有限区间积分可以看作一个线性时不变系统。令

$$y(t) = \int_{t-(b-a)}^t x(s) ds = \int_{-\infty}^{\infty} h(\tau) x(t - \tau) d\tau, \quad h(\tau) = \mathbf{1}_{\{0 \leq \tau < b-a\}}, \quad (1.296)$$

则 $y(b) = \int_a^b x(s) ds$ 。记 Riemann 和为 $Q_\Delta = \Delta \sum_{i=0}^{N_\Delta} x(a + i\Delta)$, 均方误差展开为

$$\begin{aligned} E[|y(b) - Q_\Delta|^2] &= R_{yy}(b, b) + \Delta^2 \sum_{i=0}^{N_\Delta} \sum_{k=0}^{N_\Delta} R_{xx}(a + i\Delta, a + k\Delta) \\ &\quad - \Delta \sum_{i=0}^{N_\Delta} R_{xy}(a + i\Delta, b) - \Delta \sum_{i=0}^{N_\Delta} R_{yx}(b, a + i\Delta). \end{aligned} \quad (1.297)$$

积分器是线性滤波器, 故 R_{xy} 与 R_{yy} 可由输入相关函数依次通过系统得到。随着 $\Delta \downarrow 0$, 式 (1.297) 中的和趋向相应的单重与二重 Riemann 积分。由此得到判据:

定理 1.3.28 (均方可积判据). 过程 $x(t)$ 在任意有限区间 $[a, b]$ 上均方 Riemann 可积, 当且仅当

$$\int_a^b \int_a^b R_{xx}(t_1, t_2) dt_1 dt_2 \quad (1.298)$$

作为二重 Riemann 积分存在。

均方连续、均方可微和均方可积由此具有统一结构: 先用均方误差定义过程的性质, 再展开为相关函数; 涉及微分器或积分器时, 利用线性系统的均值与相关函数传播定理, 把输出二阶矩写回输入的 R_{xx} 。这套方法依赖系统的线性, 无法直接套用于一般非线性变换。

1.4 离散时间过程

1.4.1 离散时间过程与离散功率谱

连续时间过程在等间隔时刻取样后得到离散时间过程。把取样周期归一化为 1, 可写成 $x[m] = x(m)$, 其中 m 只能取整数。这里用方括号标记离散时间变量, 用圆括号标记连续时间变量; 一般取样周期为 T_s 时, 只需把定义改写成 $x[m] = x(mT_s)$ 。连续时间随机过程的大部分二阶统计概念都能直接移到整数时间轴上。

定义 1.4.1 (离散时间过程的相关函数与宽平稳性). 离散时间随机过程 $x[m]$ 的自相关函数定义为

$$R_{xx}[m_1, m_2] = E\{x[m_1]x^*[m_2]\}. \quad (1.299)$$

若其均值与时间无关, 且相关函数只依赖整数时差 n , 则称 $x[m]$ 为宽平稳过程, 并记 $R_{xx}[n] = E\{x[m+n]x^*[m]\}$ 。若 $x[m]$ 来自连续时间宽平稳过程的整数取样, 则 $R_{xx}[n] = R_{xx}(n)$ 。

相关函数仍然描述两个随机变量在二阶矩意义下的相似程度。方括号同时提醒我们: m_1, m_2, n 都是整数, 非整数时刻没有对应的序列值。宽平稳性把二元函数 $R_{xx}[m_1, m_2]$ 化成一元序列 $R_{xx}[n]$, 因此可以对它作离散时间 Fourier 变换。

定义 1.4.2 (离散时间功率谱密度). 宽平稳离散时间过程的功率谱密度定义为相关序列的离散时间 Fourier 变换

$$S_{xx}[\omega] = \sum_{n=-\infty}^{\infty} R_{xx}[n]e^{-j\omega n} = \sum_{n=-\infty}^{\infty} R_{xx}[n]z^{-n}, \quad z = e^{j\omega}. \quad (1.300)$$

其逆变换为

$$R_{xx}[n] = \frac{1}{2\pi} \int_{-\pi}^{\pi} S_{xx}[\omega]e^{j\omega n} d\omega, \quad n \in \mathbb{Z}. \quad (1.301)$$

由于 $e^{-j(\omega+2\pi)n} = e^{-j\omega n}$, $S_{xx}[\omega]$ 以 2π 为周期, 只需考察任意一个长度为 2π 的区间, 常取 $[-\pi, \pi]$ 。文献中还常写成 $S_{xx}[e^{j\omega}]$ 或 $S_{xx}[z]$; $z = e^{j\omega}$ 在单位圆上只是频率变量的另一种写法, 处理差分方程和数字滤波器时尤其方便。使用角频率 ω 后, 逆变换前的系数 $1/(2\pi)$ 需要保留。

1.4.2 取样后的谱周期延拓与混叠

设连续时间宽平稳过程的功率谱为 $S_{xx}(\omega)$, 以单位周期取样所得序列的相关函数满足 $R_{xx}[n] = R_{xx}(n)$ 。把连续时间 Fourier 逆变换的积分轴分成区间 $[(2k-1)\pi, (2k+1)\pi]$, 再在每段中令原频率等于 $\omega + 2k\pi$ 。因为 n 为整数, 因子 $e^{j2\pi kn} = 1$, 于是

$$\begin{aligned} R_{xx}[n] &= \frac{1}{2\pi} \sum_{k=-\infty}^{\infty} \int_{-\pi}^{\pi} S_{xx}(\omega + 2k\pi) e^{j\omega n} d\omega \\ &= \frac{1}{2\pi} \int_{-\pi}^{\pi} \left[\sum_{k=-\infty}^{\infty} S_{xx}(\omega + 2k\pi) \right] e^{j\omega n} d\omega. \end{aligned} \quad (1.302)$$

与式 (1.301) 比较, 并利用 Fourier 表示的唯一性, 得到

$$\boxed{S_{xx}[\omega] = \sum_{k=-\infty}^{\infty} S_{xx}(\omega + 2k\pi)}. \quad (1.303)$$

因此, 取样把连续谱以 2π 为间隔平移并叠加, 离散谱自然成为周期函数。若相邻副本在基本区间内重叠, 叠加后的谱形已经无法唯一分解回原连续谱, 这一现象称为频谱混叠。数字系统只观察离散样点, 频率相差 $2\pi k$ 的复指数在这些样点上完全相同; 混叠正是这种不可区分性在功率谱上的表现。取样周期为 T_s 时, 谱副本间隔相应变为 $2\pi/T_s$, 并带有尺度因子 $1/T_s$ 。

1.4.3 离散时间卷积与二阶矩传播

离散时间线性时不变系统的冲激响应为 $h[n]$ 时, 输入 $x[n]$ 与输出 $y[n]$ 的关系为 $y[n] = \sum_{k=-\infty}^{\infty} h[k]x[n-k] = (h * x)[n]$ 。积分卷积在这里换成求

和卷积；线性系统对均值作用一次，对互相关作用一次，对输出自相关分别沿两个时间变量作用一次。

定理 1.4.3 (离散时间系统的均值与相关函数传播). 设系统与输入相互独立，冲激响应可以是随机序列，则

$$\begin{aligned} m_y[n] &= \sum_k E\{h[k]\} m_x[n-k], \\ R_{xy}[n_1, n_2] &= \sum_k E\{h^*[k]\} R_{xx}[n_1, n_2-k], \\ R_{yy}[n_1, n_2] &= \sum_k \sum_\ell E\{h[k]h^*[\ell]\} R_{xx}[n_1-k, n_2-\ell]. \end{aligned} \quad (1.304)$$

确定性系统中可直接去掉关于 h 的期望。上述各式成立还要求相应的求和与期望可以交换。

这些式子与连续时间系统的传播公式具有相同结构。若系统确定且输入宽平稳，输出相关函数可写成 $R_{yy}[n] = h[n] * h^*[-n] * R_{xx}[n]$ ；转到频域后，卷积化为乘积，这将在本节末得到更直接的谱传播公式。

1.4.4 Schur 引理与 Toeplitz 非负定性

连续时间相关函数的正定性可由非负 Fourier 变换刻画。离散时间中，有限个样点上的二次型自然排列成 Hermitian Toeplitz 矩阵。为了让 Fourier 级数逐点有意义并允许交换求和与积分，以下结论明确要求 $\sum_{n=-\infty}^{\infty} |R[n]| < \infty$ 。由 Hermitian 对称性 $R^*[-n] = R[n]$ ，其变换还可写成 $S[\omega] = R[0] + 2 \sum_{n=1}^{\infty} \operatorname{Re}\{R[n]e^{-jn\omega}\}$ ，所以 $S[\omega]$ 为实函数。

引理 1.4.4 (Schur 引理). 设 $R[n]$ 绝对可和且满足 $R^*[-n] = R[n]$ ，并令 $S[\omega] = \sum_{n=-\infty}^{\infty} R[n]e^{-jn\omega}$ 。则 $S[\omega] \geq 0$ 对所有 ω 成立，当且仅当对每个

$N \geq 0$, *Toeplitz* 矩阵

$$T_N = \begin{bmatrix} R[0] & R[1] & \cdots & R[N] \\ R^*[1] & R[0] & \cdots & R[N-1] \\ \vdots & \vdots & \ddots & \vdots \\ R^*[N] & R^*[N-1] & \cdots & R[0] \end{bmatrix} \quad (1.305)$$

均为非负定矩阵。

证明. 先设 $S[\omega] \geq 0$ 。对任意 $\mathbf{a} = [a_0, \dots, a_N]^\top$, 由式 (1.301) 可得

$$\mathbf{a}^\dagger T_N \mathbf{a} = \frac{1}{2\pi} \int_{-\pi}^{\pi} S[\omega] \left| \sum_{m=0}^N a_m e^{jm\omega} \right|^2 d\omega \geq 0. \quad (1.306)$$

这里 $\dagger$ 表示共轭转置。被积函数由非负谱和模平方组成, 故每个有限阶二次型都非负。

反向证明需要从所有有限阶二次型中恢复谱在单个频率处的符号。固定 $0 < \rho < 1$ 和 ω_0 , 在 T_N 的二次型中选取 $a_m = \sqrt{1-\rho^2} \rho^m e^{-jm\omega_0}$ 。有限几何级数给出 $\sum_{m=0}^N a_m e^{jm\omega} = \sqrt{1-\rho^2} [1 - \rho^{N+1} e^{j(N+1)(\omega-\omega_0)}] / [1 - \rho e^{j(\omega-\omega_0)}]$ 。对固定的 ρ , 其模平方乘 $|S[\omega]|$ 可由常数 $(1-\rho)^{-2} \sum_n |R[n]|$ 控制。Lebesgue 控制收敛定理因而允许把 $N \rightarrow \infty$ 移入积分, 得到

$$\frac{1}{2\pi} \int_{-\pi}^{\pi} \frac{1-\rho^2}{1-2\rho \cos(\omega-\omega_0) + \rho^2} S[\omega] d\omega \geq 0. \quad (1.307)$$

积分核是单位圆上的 Poisson 核。Poisson 积分公式表明, 式 (1.307) 等于谱的圆内调和延拓 $\sum_{n=-\infty}^{\infty} R[n] \rho^{|n|} e^{-jn\omega_0}$ 。绝对可和性保证该延拓在 $\rho \uparrow 1$ 时收敛到 $S[\omega_0]$, 于是 $S[\omega_0] \geq 0$ 。 ω_0 任意, 结论成立。 $\square$

Schur 引理中的“非负定”允许某个非零向量使二次型等于零。若要保证每个 T_N 都正定, 还需排除功率谱在具有正测度的频率集合上消失; 下面的可积对数条件恰好完成这一点。

1.4.5 Paley–Wiener 判据

定理 1.4.5 (Paley–Wiener 判据). 在 *Schur* 引理的条件下, 若

$$\frac{1}{2\pi} \int_{-\pi}^{\pi} \log S[\omega], d\omega > -\infty, \quad (1.308)$$

则每个 *Toeplitz* 矩阵 T_N 都是正定矩阵。

证明. 假设存在非零向量 $\mathbf{a}$ 使 $\mathbf{a}^\dagger T_N \mathbf{a} = 0$ 。记 $p(e^{j\omega}) = \sum_{m=0}^N a_m e^{jm\omega}$ 和 $f(\omega) = |p(e^{j\omega})|^2$ 。由式 (1.306) 及 $S[\omega] \geq 0$, 有 $S[\omega]f(\omega) = 0$ 几乎处处成立。

整数频率复指数在 $[-\pi, \pi]$ 上正交, 即 $(2\pi)^{-1} \int_{-\pi}^{\pi} e^{j(n-m)\omega} d\omega = \delta_{nm}$ 。Parseval 等式随即给出

$$\frac{1}{2\pi} \int_{-\pi}^{\pi} f(\omega), d\omega = \sum_{m=0}^N |a_m|^2 > 0. \quad (1.309)$$

令 $\mu = \int_{-\pi}^{\pi} f(\omega) d\omega$, 并取 $\varepsilon = \mu/(4\pi)$ 。集合 $A_\varepsilon = \{\omega : f(\omega) > \varepsilon\}$ 必有正 Lebesgue 测度; 否则 $\int f \leq 2\pi\varepsilon = \mu/2$, 与 μ 的定义矛盾。由于 $Sf = 0$ 几乎处处, $S[\omega] = 0$ 在 A_ε 上几乎处处成立, 于是 $\log S[\omega] = -\infty$ 出现在正测度集合上。这将使式 (1.308) 的积分等于 $-\infty$, 产生矛盾。因此二次型只可能在 $\mathbf{a} = 0$ 时取零, T_N 正定。□

该判据说明, 正定相关序列对应的谱不能在一段具有正测度的频带上完全为零。条件允许谱在孤立频率点取零, 因为有限个点的 Lebesgue 测度为零; 真正破坏正定性的是具有正测度的零谱集合。

1.4.6 有限谐波和的宽平稳性

考虑由有限个离散频率组成的随机过程 $x[m] = \sum_{i=1}^K c_i e^{j\omega_i m}$, 其中各 ω_i 在模 2π 意义下两两不同且均不等于零。随机性全部包含在复系数 c_i 中。

定理 1.4.6 (有限谐波和的宽平稳条件). 上述过程宽平稳, 当且仅当各系数满足 $E\{c_i\} = 0$, 并且两两不相关, 即 $E\{c_i c_k^*\} = 0$ 对 $i \neq k$ 成立。此时

$$R_{xx}[n] = \sum_{i=1}^K E\{|c_i|^2\} e^{j\omega_i n}. \quad (1.310)$$

证明. 若系数零均值且两两不相关, 均值立即为零; 展开 $E\{x[m+n]x^*[m]\}$ 后, 所有交叉项消失, 只留下式 (1.310), 它与 m 无关, 所以过程宽平稳。

下面说明条件的必要性。宽平稳要求 $\sum_i E\{c_i\} e^{j\omega_i m}$ 对 m 为常数。把常数看作频率 $\omega_0 = 0$ 的分量, 在连续的 $K+1$ 个整数时刻列方程, 会得到以 $e^{j\omega_i}$ 为节点的 Vandermonde 方程组。其行列式含有乘积 $\prod_{i < k} (e^{j\omega_k} - e^{j\omega_i})$, 由频率互异可知行列式非零, 因此 $E\{c_i\} = 0$ 。若频率集合含有零频分量, 则该分量可以保留非零均值, 这正是排除 $\omega_i = 0$ 的原因。

再展开相关函数:

$$R_{xx}[m+n, m] = \sum_{i=1}^K \sum_{k=1}^K E\{c_i c_k^*\} e^{j\omega_i n} e^{jm(\omega_i - \omega_k)}. \quad (1.311)$$

宽平稳性要求所有非零差频对应的系数为零。若各差频互异, 可直接由关于 m 的 Vandermonde 方程组得到 $E\{c_i c_k^*\} = 0$ 。若若干对 (i, k) 具有相同差频, 先得到同一差频下交叉项之和为零, 再改变时差 n ; 其中的 $e^{j\omega_i n}$ 具有互异频率, 第二个 Vandermonde 方程组便逐项分离这些交叉矩, 从而仍有 $E\{c_i c_k^*\} = 0$ 。□

1.4.7 离散时间系统中的功率谱传播

离散时间系统的频率响应可以等价地写成 $H[\omega]$ 、 $H[e^{j\omega}]$ 或 $H[z]$ 。对宽平稳输入, 功率谱由一元相关序列的 Fourier 变换得到, 因此只需要一维频率变量。

定理 1.4.7 (离散时间系统的功率谱传播). 设宽平稳输入 $x[n]$ 通过与输入独立的线性时不变系统 H , 则

$$S_{xy}[\omega] = E\{H^*[\omega]\} S_{xx}[\omega], \quad S_{yy}[\omega] = E\{|H[\omega]|^2\} S_{xx}[\omega]. \quad (1.312)$$

系统确定时，期望符号可以去掉。

这一结果在频域中具有直接的增益解释：某个频率处的输入功率乘以 $|H[\omega]|^2$ ，得到该频率处的输出功率。随机系统还要对随机频率响应取平均，因此式中保留期望。若系统冲激响应为实序列，则在单位圆上 $H^*[z] = H[1/z]$ ，从而 $S_{xy}[z] = E\{H[1/z]\}S_{xx}[z]$ ，且 $S_{yy}[z] = E\{H[1/z]H[z]\}S_{xx}[z]$ 。

例 1.4.8 (随机一阶差分系统). 考虑实系统 $y[n] - ay[n-1] = x[n]$ ，其中 a 是概率密度为 $f(a)$ 的实随机变量，并假设系统取值满足所需的稳定性条件。 z^{-1} 表示一个单位延迟，对差分方程作 z 变换可得 $Y[z](1 - az^{-1}) = X[z]$ ，所以 $H[z] = 1/(1 - az^{-1})$ 。利用实系统关系 $H^*[z] = H[1/z]$ ，输出谱为

$$S_{yy}[z] = S_{xx}[z] \int_{-\infty}^{\infty} \frac{f(a)}{(1 - az^{-1})(1 - az)} da. \quad (1.313)$$

差分方程中的延迟在 z 域化为乘法因子，传递函数可以直接由代数运算得到；随机参数的影响则集中在最后关于 a 的平均中。

第2章 随机游走及其他应用

2.3 调制

2.4 循环平稳过程

2.5 带限过程与采样理论

2.6 噪声中的确定性信号

附录 10A: 泊松求和公式

第3章 谱表示

3.1 因子分解与新息

3.2 有限阶系统与状态变量

3.3 傅里叶级数与 Karhunen–Loève 展开

3.4 随机过程的谱表示

第4章 谱估计

4.1 遍历性

4.2 谱估计

第5章 均方估计

5.1 引言

5.2 预测（部分）

5.3 格型滤波器与 Levinson 算法

课程说明

本项目按“章一小节一课时”组织。每个课时均位于独立的课时目录中，可由总文件统一编译，也可单独编译。